
从计算视角审视意识理论综述

在通用人工智能曙光之际

丁子涵*	魏晓曦*	徐一丹*
普林斯顿大学	伦敦帝国学院	密歇根大学
zihand@princeton.edu	xiaoxi.wei18@imperial.ac.uk	yidanxu@umich.edu

Abstract

人类意识是几个世纪以来一个持久的谜团，而机器智能与意识则是一项艰巨的追求。研究人员已从不同视角和层面发展出多种理论来解释人脑中的意识现象。本文综述了源自信息论、量子物理学、认知心理学、生理学和计算机科学等不同学科的几种主要意识理论分支，旨在从计算视角连接这些理论。文章还讨论了现有的意识评估指标以及当前计算模型具备意识的可能性。揭开意识之谜可能是利用计算机构建通用人工智能的关键一步。

目录

1	Introduction	3
1.1	Definition of Consciousness	5
1.2	Consciousness and Intelligence	6
1.3	Consciousness while Asleep	9
1.4	Overview of Consciousness Theories	10
2	Information Integration Theory	10
2.1	Information Entropy	10
2.2	Measurement of Information Integration	13
2.3	Biological Evidence	15
3	Consciousness as a State of Matter	15
3.1	Basics of Quantum Mechanics	16
3.2	Integration Principle	17
3.3	Independence Principle	18
3.4	Dynamics principle	18

*作者贡献等同。

4	Orchestrated Objective Reduction Theory	19
4.1	Consciousness as Orchestrated Objective Reduction	19
4.2	Free Will in Neurons	19
4.3	Diósi-Penrose Objective Reduction	20
4.4	Evidence for Objective Reduction of Quantum State	21
5	Global Workspace Theory	21
5.1	The Theatre of Consciousness	21
5.2	Computational Models of GWT	22
6	Higher-Order Theories	23
6.1	Higher-Order Perception Theory	24
6.2	Higher-Order Thought Theory	24
6.3	Self-Representational Theory	24
6.4	Other theories and perspectives in HOT	25
7	Attention Schema Theory	25
7.1	Formulation	25
7.2	<i>I</i> -意识与 <i>M</i> -意识	26
7.3	AST as a Unification of GWT and HOT	26
8	Conscious Turing Machine	27
8.1	Formulation	27
8.2	CTM for Consciousness	28
8.3	Relationships with Other Theories	28
9	Physiological Evaluation Metric of Consciousness	28
9.1	Metrics Based on Electrical Signals	28
9.2	Metrics Based on Behaviors	30
10	Look Ahead: Can Computational Models Be Conscious?	30
10.1	Background	30
10.2	Large Language Model	31
10.3	Emerging Intellectual Capability of LLM - Turing Test	34
10.4	Consciousness of LLM	35

1 Introduction

意识是一种复杂且难以捉摸的现象，至今仍是科学界最伟大的谜团之一。数个世纪以来，它一直是哲学探究的主题，近年来更成为科学研究的对象。我们人类并不清楚意识为何以及如何存在于我们的大脑中，甚至对于我们是否真正拥有意识也存在分歧的观点。现有的意识理论对人类意识过程提供了不同的解释。

本文从跨学科的视角，对意识的理论基础进行了全面的探讨。第1章致力于界定与意识相关的概念，通过将意识与觉知、唤醒、清醒等其他状态区分开来。本章进一步强调了人类意识问题的重要性和困难性，旨在吸引不同研究领域的关注，共同研究这一问题。第2、3和4章阐述了意识的数学和物理基础。具体而言，第2章介绍了 **Information Integration Theory**，它概述了一个有意识的实体所需满足的信息熵条件，为意识可能表现出的信息特征提供了见解。第3章和4章讨论了 **Consciousness as a State of Matter** 和 **Orchestrated Objective Reduction Theory**，两者均从物理学角度探讨意识问题。这两章讨论了意识作为一种物质状态应具备的具体特征，以及一些量子理论家提出的作为意识产生基础的物理解释。随后的第5、6、7和8章综述了几种有影响力的意识理论，并简要总结了与每种理论相关的计算模型研究，包括 **Global Workspace Theory** (5)、**High-Order Theories** (6)、**Attention Schema Theory** (7) 和 **Conscious Turing Machine** (8)。在第9章中，简要概述了基于电生理信号和行为指标的当代意识生物医学测量方法。在最后一章10中，我们对人工智能(AI)意识进行了探讨性审视，特别深入探讨了作为先进计算模型实例的大型语言模型是否拥有意识的问题，并探索了AI意识的必要和充分条件。

总而言之，本文从信息论、量子物理学、认知心理学、生理学和计算机科学等多个学科领域，对意识进行了全面的综述，旨在从计算视角整合这些理论，为构建未来的AI意识奠定基础。

为了让读者对这个主题有一个初步的了解，以下部分提供了一段围绕意识问题的对话。

有一天，我在现代世界中遇到了两位博士生，他们正在讨论人脑中的意识问题。这段对话始于意识与物理世界的关系，探讨了对意识本质的思考。对话中的困惑构成了本研究的动机，并引出了本文旨在解决的核心问题。以下是对话内容。

Athena: 嘿，我正在看双缝实验的结果，但我很难理解是什么决定了光子选择通过哪条狭缝，这里到底发生了什么？

Galileo: 嘿，这只是光子的波粒二象性，光子的状态只有在你观察屏幕时才会坍缩。这完全是随机的。别钻牛角尖了。

Athena: “随机”是什么意思？这个世界最终具有随机的本质吗？连爱因斯坦都说上帝不掷骰子。

Galileo: 你的测量影响了它的状态，这决定了它在双缝实验中通过哪条狭缝。

Athena: 所以我的精神状态决定了光子的状态？如果我选择以不同的方式观察它，比如比预定观察时间晚0.00001秒，它的状态可能会改变吗？

Galileo: 也许吧。而且你的精神状态也是一个随机过程，对吧？你拥有自由意志或意识。

Athena: 意识。你真的相信它的存在吗？如果我是决定论的，完全由底层的物理和化学规律所决定呢？

Galileo: 但量子力学的基本原理假设光子，以及你身体里的粒子，包括你大脑中的粒子，仍然具有概率性的状态，对吧？所以你也遵循一个随机过程，而非决定论的过程。

Athena: 你说得对。状态坍缩过程被假定具有真正的随机性，这个过程可能发生在我大脑中，影响我的决定，也影响这些光子可能通过哪条狭缝。但我仍然不太相信我的意识存在。对于像我大脑这样大的系统，可能会发生状态退相干，因此没有量子特性，我可能仍然是决定论的。

Galileo: 我认为意识的存在是一种因人而异的信念。

Athena: 等等，但意识是什么？没有一个清晰的定义，我们无法讨论它的存在。意识似乎描述了主观体验，但缺乏严格的定义。我在想意识过程发生在何处、何时。

Galileo: 我猜是在大脑皮层或丘脑。然而，要让这种现象发生，我认为大脑的大部分功能部分可能需要一个协作过程来触发意识。

Athena: 我同意。另外，如果我们假设一块石头或一棵树不可能像人类一样有意识，那么这个系统必须具有一定水平的计算能力。

Galileo: 还有，我无法想象一个没有记忆的系统会拥有意识。

Athena: 我可能不同意这一点。我认为一个因脑损伤而失去记忆的病人仍然具有意识。

Galileo: 这可能是一个证据。你认为睡眠期间意识会保留吗？

Athena: 这可能是一个复杂的问题。你知道睡眠有多个阶段，包括非快速眼动睡眠和快速眼动睡眠。不同阶段的意识水平可能不同。

Galileo: 同意。梦发生在快速眼动睡眠期，对吧？感觉我在梦中是有意识的，所以我猜我在快速眼动睡眠期是有意识的。但这在体验上仍然与清醒状态有很大不同。**Athena:** 我不太确定，这相当复杂。但梦境与清醒状态的根本区别在于，睡眠期间大脑没有外部感官输入，所有体验都是虚假的，由大脑自身构建。如果意识出现在梦境中，这表明系统产生意识可能并不需要外部感官输入。

Galileo: 我想是的。意识似乎与主观体验非常接近，即使我不确定主观体验是真实存在还是人类制造的虚假幻觉。

Athena: 在某些书籍中，“主观体验”似乎是意识的同义短语。但这个定义对我来说仍然不清晰。此外，“真实”与“虚假”的问题我也不清楚。如果我们对世界的测量能影响其状态，那么“真实”观察世界与“虚假”观察究竟意味着什么？毕竟，它们只是我们大脑中的镜像信号，并不能直接代表真实世界的状态。

Galileo: 嗯，这是一种非常哲学悲观的观点。说到意识的定义，如果我们假设意识被定义为“主观体验”，它似乎与另一个称为智能的概念关系不大。如今，人们正在计算机中构建人工智能，它也是意识吗？这可能是个有趣的问题！你认为这仅仅是关于图灵测试吗 [Turing, 2009]？

Athena: 我不这么认为。那篇论文的重点是讨论图灵机是否能达到人类水平的智能。请注意这里用词的差异，是智能而非意识！我认为一个程序通过图灵测试只意味着它和人类一样智能，但并非有意识。

Galileo: 感谢提醒。看来智能和意识是两件不同的事。但记得在讨论开始时，我们提到意识可能需要一定水平的计算能力，而这种计算能力或许可以表述为智能。

Athena: 也许，智能属性似乎是意识涌现的必要条件，但我不确定意识对智能的需求程度有多高。

Galileo: 是的，这尚未被发现，可能是一个很好的研究课题。然而，如果一个生物已经足够智能以在世界上生存，为什么它还需要意识呢？

Athena: 好问题。根据达尔文的进化论，世界上现存的生物应仅展现那些通过自然选择有利于其生存的技能。如果意识存在于人类中，这表明它对人类在环境中生存有某些益处，而没有意识的个体在历史中被淘汰了。但树木和花朵仍然存在，这确实让我困惑。

Galileo: 树木和花朵与人类是不同的物种。也许对于某些物种，比如动物，需要拥有意识。

Athena: 嗯，但如果假设意识存在，我仍然不清楚为什么它存在于人类或其他动物中。

Athena: 意识理论似乎可以是一个非常复杂的学科，与一些非常不同的学科相关，如物理学、生物学、计算机科学、神经科学、信息论等。这可能非常困难。但让我们至少开始探索吧！

上述对话是论文作者们启动意识问题探讨的一个缩影。我们将从意识的定义（第 1.1 节）、意识与智能的关系（第 1.2 节）、意识与自由意志的关系（第 1.2 节）开始讨论。随后，我们将简要概述现有的意识理论（第 1.4 节），并进一步探讨睡眠时的意识状态（第 1.3 节）。

1.1 Definition of Consciousness

Consciousness, Awareness, Wakefulness and Arousal: 意识是一个复杂且多面的概念，在神经科学、心理学和哲学领域已被广泛研究。现有研究通常将意识定义为包含两个主要组成部分：唤醒（清醒度）和觉知（主观体验）[Lendner et al., 2020]。唤醒指的是警觉或清醒的整体状态，而觉知指的是感知和解释感官信息的主观体验。

通常，睁眼表明存在唤醒，而执行指令的能力则被用来推断觉知的存在 [Lee et al., 2022]。然而，在某些情况下，例如做梦时，尽管缺乏完全的清醒，主观体验仍然可以发生。在睡眠或麻醉期间，意识通常被认为是缺失的，但在某些情况下，根据唤醒和觉知的水平，意识可能仍然存在。意识、觉知、清醒和唤醒是研究人类心智与大脑时相关但又有所区别的概念。我们根据现有文献为每个概念提供描述性定义如下：

Consciousness 指的是意识到自己的思想、情感、感觉和周围环境的主观体验。它常被描述为清醒并意识到自身周围环境和内在状态的状态。作为讨论意识问题的一个重要概念，*qualia* 指的是对感官信息的主观和个人体验，例如我们感知颜色、声音、味道和气味的方式。它是感官知觉的主观体验，无法被他人客观测量或观察。

Awareness 指的是感知、处理和理解来自环境或内在体验信息的能力。它包括有意识和无意识的过程，范围可以从简单的感官知觉到复杂的认知过程，如注意、记忆和推理。

Arousal 指的是大脑和身体对内外刺激的反应水平。它是一种生理状态，范围从低唤醒状态（如困倦或放松）到高唤醒状态（如极度兴奋或恐惧）。

Wakefulness 指的是清醒而非睡眠的状态。它是一种生理状态，其特征是存在大脑电活动以及能够对外部刺激作出反应。

总之，意识是对自身思想、情感和周围环境有所觉察的主观体验，而觉知是感知、处理和理解信息的能力。清醒是一种以醒着为特征的生理状态，即 *usually regarded identically as awareness*。唤醒是对刺激的反应水平。觉知和唤醒是意识的必要条件，但它们不足以唤起意识，并且意识可以在缺乏完全觉知和高唤醒水平的情况下发生。

近期研究已开发出有效的人类意识测量方法 [Seth et al., 2008, Demertzi et al., 2017]，例如基于电信号的指标，如扰动复杂性指数（PCI）[Casali et al., 2013] 和脑电双频指数（BIS）[Rosow and Manberg, 2001, Johansen, 2006]，以及基于行为的指标，如格拉斯哥昏迷量表（GCS）[Jones, 1979, Sternbach, 2000]、昏迷恢复量表修订版（CRS-R）[Giacino et al., 2004] 和全面无反应性量表（FOUR）[Wijdicks et al., 2005]。各项生理评估指标的细节将在第 9 节讨论。在以下段落中，我们以 PCI 指标为例，区分不同意识状态下的唤醒与觉知概念。

Conscious State	Arousal	Awareness
Healthy wakefulness	high	high
REM ¹ sleep with dreams	low	high
NREM ² sleep without dreams	low	low
Anesthesia induced with ketamine	low	high
Anesthesia induced with propofol or xenon	low	low
Minimally conscious state	high	high
Unresponsive wakefulness syndrome	high	low

¹ REM: 快速眼动

² NREM: 非快速眼动

表 1: 不同状态下意识的唤醒与觉知水平（结果改编自 Lee et al. [2022]）

准确测量意识的能力对于理解和治疗影响意识的病症（如昏迷、麻醉和脑损伤）具有重要意义。PCI 是基于经颅磁刺激（TMS）对大脑皮层进行直接、无创扰动时产生的脑电图（EEG）响应而开发的。PCI 量化了由 TMS 诱发的重要皮层激活的确定性模式的复杂性，从而得出一个经验性阈值，能够可靠地区分不同状态下的无意识与有意识，包括快速眼动睡眠、清醒状态、氯胺酮诱导的麻醉状态以及有意识的脑损伤患者。

在 Casali 等人（2013 年）[Casali et al., 2013] 的 PCI 研究中，唤醒水平和觉知水平被用作人类意识程度的指标。表 1 总结了不同状态下的意识唤醒与觉知水平，该表显示了在不同状态下，意识在人脑中的表现会有所不同 [Lee et al., 2022]。与正常人完全清醒的状态相比，如快速眼动或非快速眼动等睡眠阶段的唤醒或觉知水平较低，通常被认为不如清醒状态那样“有意识”。药理学方法（如麻醉）可以达到类似的低唤醒和低觉知水平，导致人类处于不完全的意识状态。从病理学角度看，现有的微意识状态（MCS）患者可能表现出相对较高的唤醒和觉知水平，但意识程度仍然较低，这证明了唤醒和觉知是意识的必要条件，而非充分条件。无反应性觉醒综合征患者则具有高唤醒但低觉知的特征。

1.2 Consciousness and Intelligence

在艾伦·图灵那篇著名的论文中，他对反对图灵机的意识论证评论道 [Turing, 2009]:

“I do not wish to give the impression that I think there is no mystery about consciousness. There is, for instance, something of a paradox connected with any attempt to localise it.”

考虑到论文中的问题是机器能否像人类一样思考，图灵提出了著名的模仿游戏作为测试机器智能的方法。智能和意识被广泛认为是大脑的两种不同属性。在马克斯·泰格马克的 *Life 3.0* [Tegmark, 2018] 中，智能被定义为完成复杂目标的能力，而意识被定义为主观体验。意识似乎比智能更为神秘，也更难测量。如图 1（最初见于 Tegmark [2018]）中描绘的意识“金字塔”所示，与智能相关的问题是最简单的，大卫·查默斯也持此观点。这类问题通常不需要考虑实验对象的主观体验。一个困难的问题是找到可物理解释的特征来区分有意识和无意识的过程。下一个层次的问题是意识如何发生以及决定因素是什么。最后且最困难的问题则涉及解释意识的存在，或者说，为什么任何系统中会存在意识？




图 1: 与意识心智相关的不同层次问题的困难程度。

关于人类大脑中存在意识的原因，斯蒂芬·沃尔夫勒姆的一段引述提到，自我建模的局限性和时间持久性是人类拥有意识的两个关键因素：

“The fact that we have coherent consciousness is a consequence of two things: 1. That we are computationally bounded, so the universe does not contain enough resources for us to construct a complete model of ourselves. 2. That we believe that we are persistent in time, and hence assume constancy where there is none.”

意识是一种复杂且多层面的现象，长期以来一直受到哲学家、心理学家、神经科学家及其他领域研究者的探索。即便如此，意识对现代社会而言仍然是个谜，人们将其称为 *the hard problem of consciousness*，这一概念最初由大卫·查默斯于 1995 年提出 [Chalmers, 1995, 1997]。它通常被理解为对思想、感知、情感和感觉等主观心理状态的体验或觉知。困难问题指出了人类心智中存在此类主观体验的原因。意识与大脑的功能密切相关，但其确切本质和机制仍未完全明了。一些理论认为意识产生于感觉信息的整合，而另一些理论则提出它是宇宙的内在属性或现实本身的基本方面。斯蒂芬·沃尔夫勒姆的引述表明，连贯意识的体验可能取决于我们的计算局限性和我们对时间持久性的假设。该论点认为，我们相信自己是在时间中持续存在的存在，尽管宇宙中并无实际的恒常性。

自由意志被定义为人类做出选择和决策的能力，这些选择和决策并非完全由生物、环境或外部因素所决定。人类是否拥有自由意志是极具争议且未知的。然而，这一概念被认为与意识密切相关。在图 2 中，我们描绘了一个统一了本文后续将介绍的几种意识理论的架构，同时也阐明了意识与自由意志之间的关系。在图 2 中，人脑的低层级模块与意识模块之间存在交互，而意识体验就发生在人脑中 [Baars, 2003, Baars and Franklin, 2003, 2007, 2009, Locke, 1948, Armstrong, 1981, Armstrong and Malcolm, 1985, Lycan, 1996, Armstrong, 2002, Lycan, 2004, Rosenthal, 2009, 2012, 2004, Byrne, 1997, Brown et al., 2019, Graziano and Webb, 2015, Graziano et al., 2020]。低层级模块包括外部处理器、内部处理器和记忆。外部处理器负责人脑的输入和输出，包括图像处理器、声音处理器、味觉处理器、嗅觉处理器、触觉处理器、运动激活器、言语模块等。每个模块处理输入信息，并将处理后的信号输出到其他部分。内部处理器包括逻辑处理器、语言处理器等。每个处理器都会处理来自外部处理器的输出信息，或在没有外部输入的情况下自发地进行处理。所有这些模块都有能力与其他模块及记忆进行通信，以实现预期目标，并且其中大多数模块会产生中间输出，作为其他模块的输入。更重要的是，

除了所有这些低层级模块之外，意识模块能够观察来自低层级模块的中间输出，从而为人类产生主观体验（也称为意识）。这种观察过程在诸如注意图式理论 [Graziano and Webb, 2015, Graziano et al., 2020] 或高阶理论中的高阶思想/感知 [Locke, 1948, Armstrong, 1981, Armstrong and Malcolm, 1985, Lycan, 1996, Armstrong, 2002, Lycan, 2004, Rosenthal, 2009, 2012, 2004, Byrne, 1997, Brown et al., 2019] 等理论中被表述为一种自我建模过程。然而，这些解释都处于高度抽象的层面。人脑中产生意识的具体组成部分在文献中仍有争议。有一些研究 [Baars, 2002] 表明，例如前额叶皮层可能参与高级认知过程。关于这些理论不同解释的讨论将在后续章节中详细展开。由于计算能力有限，意识模块只会关注那些重要的信息流，这些信息流是所有低层级模块中间输出的一个相对较小的子集。这与经验证据相符，即人类每秒只能有几十个意识体验 [Tegmark, 2018, 2000]。真正自由意志的存在仍然是意识理论的一个重要方面，尽管目前缺乏足够的科学证据来明确证实或证伪。为了全面探讨自由意志的存在及其在人脑中的潜在层级结构（图 2），我们将讨论分为正反两种假设：（1）假设存在真正的自由意志；或（2）否认自由意志的存在。因此，我们用虚线框标示自由意志模块。对于第一种情况，即自由意志存在且超出当前物理解释范围，我们可能需要从现有数学和物理框架之外寻求 *external variables*，以确定人类决策过程。外部变量可类比为著名的爱因斯坦-波多尔斯基-罗森（EPR）悖论 *hidden variables* 中的 [Einstein et al., 1935]，该悖论指出可能存在某些未被观测的隐变量来解释量子力学中的真正随机性，这是阿尔伯特·爱因斯坦等人对量子力学框架完备性提出的质疑。类似于 EPR 悖论对量子力学随机性的解释，对真正“自由意志”的说明可能同样需要这种超越已知物理系统的外部随机性。关于自由意志存在的物理解释的更多细节将在第3节和第4节讨论。这部分自由意志如图 2 所示，表现为包含自由意志的蓝色模块，由意识模块注入以影响低级处理过程（如图 3 所示），从而影响系统的最终输出。对于第二种情况，即真正的自由意志并不存在，问题在于：是什么导致一些人认为并感觉自己拥有所谓的“自由意志”？这一现象可以用当前架构中一种幻觉性的“自由意志” [Wegner, 2004] 来解释。关键事实在于，意识模块由于其有限的信息处理带宽，只能观测到低级模块的部分中间输出，因此系统对环境的最终输出不能完全由这些观测到的信息片段决定，而是需要结合更多未被观测的信息。意识模块仍会通过创造“自由意志”的幻觉来解释生成的输出结果。然而，这种解释可能存在争议，需要进一步验证。自由意志的存在目前仍是一个开放性问题。




图 2: 具有自由意志的意识系统总体架构图。




图 3: 类人脑意识系统中处理器的详细结构。

1.3 Consciousness while Asleep

人类的睡眠过程包含快速眼动（REM）和非快速眼动（NREM）等阶段。根据先前的研究 [Lee et al., 2022], NREM 是一种既无觉醒也无觉知的状态，而 REM 则是一种有觉知但无觉醒的状态。

整合信息理论（IIT）[Tononi, 2004] 认为，在深度睡眠期间意识会减弱。IIT 提出，意识是由系统内的整合信息产生的。根据 IIT，睡眠期间体验到的意识水平取决于大脑活动中存在的整合程度。

研究表明，从深度 NREM 睡眠中被唤醒的受试者，尤其是在夜间早期，常常报告缺乏觉知，尽管皮层和丘脑神经元仍然活跃。然而，在其他时间被唤醒的受试者，主要是在 REM 睡眠期

间或夜间稍后的 NREM 浅睡期，会报告以生动意象 [Hobson et al., 2000] 为特征的梦境。从整合信息理论的角度来看，睡眠期间意识的减弱与深度 NREM 睡眠期间皮层回路的双稳态是一致的。与这些观察结果一致，使用经颅磁刺激（TMS）——一种非侵入性脑刺激技术——结合高密度脑电图（EEG）的研究表明，早期 NREM 睡眠与皮层区域间有效连接的破坏有关，导致整合的丧失或反应库的丧失，从而丧失信息 [Massimini et al., 2005, 2007]。这些发现表明，睡眠期间体验到的意识水平取决于大脑活动中存在的整合程度，整合的减少导致意识的减弱。

总之，IIT 认为，睡眠期间体验到的意识水平取决于大脑活动中存在的整合程度，整合的减少导致意识的减弱。

1.4 Overview of Consciousness Theories

研究人员提出了多种理论来探究意识的本质及其如何从大脑中产生。其中一些最著名的理论包括信息整合理论（IIT）、意识作为一种物质状态理论、协调客观还原（Orch OR）理论、全局工作空间理论（GWT）、高阶理论（HOT）、注意图式理论（AST）、意识图灵机（CTM）等。IIT（第 2 节）提出，意识产生于来自多个感觉和认知源的信息整合。意识作为一种物质状态理论（第 3 节）从基于物理原理的计算角度分析了信息整合原则的不足。Orch OR 理论（第 4 节）提出了协调客观还原过程，从量子力学角度解释意识体验中的自由意志。GWT（第 5 节）认为，意识产生于大脑中全局工作空间的激活，该空间整合来自不同来源的信息并将其广播到大脑的其余部分。HOT（第 6 节）断言，意识是感觉信息的高阶表征的结果。AST（第 7 节）假定，意识是大脑用来表征意识状态的注意图式。CTM（第 8 节）理论断言，意识可以被描述为一个计算过程，作为图灵机的一种扩展。这些理论为意识的本质提供了不同的视角，各有其优缺点。它们为如何研究和理解意识提供了见解。我们进行本次综述，旨在比较这些理论的异同，并总结不同理论之间的关联。更重要的是，我们旨在从这些理论中寻找可行的计算模型，以刻画人脑的意识过程。

2 Information Integration Theory

信息整合理论假设意识对应于系统整合信息的能力。它首先提出经验公理，然后假设物理系统应具备哪些属性才能产生内在经验。为实现这一点，该理论主张系统必须具有内在的因果效力，而非源于任何外部因素。系统的因果效力通过所有子系统的最小熵的最大值来量化，其评估方式为：干预系统某子集的状态（因），并观察系统另一部分状态的变化（果），同时保持外部因素不变。因此，IIT 声称 **any conscious experience relates to a cause-effect structure that is maximally irreducible**。我们将在本节展示因果效力如何通过一种称为 *information integration* 的度量来量化。如果 IIT 理论正确，我们应能计算人脑中意识经验的整合信息量，并得出合理的数值。

2.1 Information Entropy

根据香农 [Shannon, 1948] 的定义，信息被量化为当某个事件发生时，从多个备选可能中减少的不确定性。这通过熵函数来度量，其定义如下。

定义 1.（香农熵）给定在 σ -代数 $\mathcal{A}$ 上的概率测度 P ，一个概率分布的熵为：

$$H(A) = H_p(A) = \int_{a \in \mathcal{A}} -p(a) \log p(a) da \quad (1)$$

此计算中使用的对数通常以 2 为底，这意味着熵以比特为单位。一个系统的熵是对该系统生成的消息的平均信息内容的度量。

例如，在一个具有两种可能结果（0 或 1）的二进制系统中，当任一结果的概率均为 0.5 时，熵最高（= 1）；而当一种结果确定发生（概率为 1）且另一种结果不可能发生（概率为 0）时，熵最低（= 0）。

除了在信息论中使用外，熵也被应用于密码学、信号处理和热力学等领域。在热力学中，熵用于量化热力学系统的无序或随机程度，通常被称为热熵。

对于一个离散状态系统，在所有可能的独立状态上的均匀分布包含的信息最少，因此具有最高的熵。然而，仅仅拥有大量导致可用状态范围极广的独立组件，并不足以产生有意识的系统。这些组件还必须在适当的空间和时间尺度上具有因果依赖性。意识的这一关键方面被称为信息整合，由托诺尼 [Tononi, 2004] 提出。此外，作者提出了一个计算模型来量化信息整合的能力，这将在后续章节中详述。

整合信息理论（IIT）的公理指出，每一种体验都内在地存在，并且是结构化、特定、统一且确定的。具体而言：

- 体验是内在地存在的；
- 体验是特定的，由一组特定的现象区分（感受质）构成；
- 体验是统一的、不可简化的，是信息的整合；
- 体验在其内容和时空粒度上是确定的（排除了其他可能性）。

(1) 对于任意 $S \in 2^{\mathcal{X}}$ ，考虑一个二分划分 $S = A \cup B, S^c = \mathcal{X}/S$,

(2)

(3) 最后，可以为整个系统找到整合信息

该理论随后假设，对于体验的每一个本质属性，意识的物理基质（PSC）必须具有与大脑相关的因果效应能力。目标则是找到产生意识的神经元素的适当空间和时间尺度。该定理意味着，只有那些具有最大内在因果效应能力的元素才被识别为 PSC 的元素。值得注意的是，在此定义下，较粗空间尺度上的因果效应能力可能比更精细空间尺度上的更高。

回顾 IIT 中意识的定义，它对应于整合信息的能力，使得系统在因果上相互依赖的同时产生大量的状态集合。在一个假设场景中，想象一组局部连接但与外部刺激断开的神经元元素，那么通过测量知道另一部分信息时某一部分的信息增益，就可以测试这样的集合是否能被分成两个独立部分。在信息论中，这精确对应于两个随机变量的 *mutual information* (MI)。该理论中信息整合的测量被定义为大脑系统中一种特定类型的 MI，称为 *effective information* (EI)。

定义 2 (互信息). 两个变量 A, B 之间的互信息：

$$I(A, B) = H(A) + H(B) - H(AB) \quad (2)$$

其中 $H(A) = H_{p_A}(A), H(B) = H_{p_B}(B), H(AB) = H_{p_{AB}}(A; B)$, p_{AB} 是 A, B 的联合分布。

在接下来的讨论中，我们将把符号 A, B 推广为两个子系统（或两个变量子集），而不仅仅是两个变量。

为了测量信息增益，首先将一部分神经元素设置为独立的噪声集合，然后观察另一半作为接收信号的结果，其放电模式如何变化。具体地，我们定义 EI 的概念：

定义 3 (有效信息). 有效信息衡量 A 对 B 的 *directional* 因果效应，

$$EI(A \rightarrow B) = I(\tilde{A}, B) = H(\tilde{A}) + H(B) - H(\tilde{A}B), \tilde{A} = \arg \max_A H(A) \quad (3)$$

这意味着 A 被选择为独立的随机噪声，因此 B 对 A 没有因果效应。

根据上述互信息与有效信息的定义，可直接推导出若干引理，陈述于以下注记中。

备注 1. 由于连接模式不同，从 A 到 B 的信息增益与从 B 到 A 的信息增益并不相同，而互信息具有各向同性；且有效信息始终以集合 A 与集合 B 中较小的最大熵为上界。用数学语言表达：

$$I(A, B) = I(B, A) \not\Rightarrow EI(A \rightarrow B) = EI(B \rightarrow A) \quad (4)$$

$$EI(A \rightarrow B) \leq \min\{O(\max_A H(A)), O(\max_B H(B))\} \quad (5)$$

由此，我们能够度量部分 A 如何因果影响另一部分 B 及其反向影响。这引出了由 *mutual effective information* 定义的 **isotropy** 因果效应 (MEI)。

定义 4 (互有效信息). 互有效信息 $EI(A \rightleftharpoons B)$ 度量了 A 与 B 之间的各向同性因果效应，

$$EI(A \rightleftharpoons B) = EI(A \rightarrow B) + EI(B \rightarrow A) \quad (6)$$

根据该定义，若我们能够将系统 S 划分为 A 与 B 使得 $EI(A \rightleftharpoons B) = 0$ ，则 A 与 B 为独立部分，这限制了在 S 上整合信息的能力。因此，为量化系统 S 的信息整合能力，必须定位其瓶颈。

定义 5 (最小信息二分划分, MIB). 将系统 S 的“最弱连接”实现为二分划分，其中划分 $A, B \subset S$ 与其补集 $B = \bar{A}$ 使得 A, B 的归一化互有效信息最小，如下所示：

$$MIB(A \rightleftharpoons B) = \arg \min_{A, B \subset S} \frac{EI(A \rightleftharpoons B)}{H_{\max}(A \rightleftharpoons B)} \quad (7)$$

$$\text{with } H_{\max}(A \rightleftharpoons B) = \min\{\max_A H(A), \max_B H(B)\} \quad (8)$$

$H_{\max}(A \rightleftharpoons B)$ 用于归一化，依据注记 1。

MIB 中的每个划分在 IIT 中称为一个 *complex*。在包含 N 个元素的系统中存在 $\sum_{m=2}^N \binom{N}{m}$ 个子集，每个子集具有 $\Phi(S), S \in 2^{[N]}$ 的度量值，但那些位于更大子集中且具有更高 Φ 的 S 被舍弃，其余构成系统中的复合体。

现考虑一个包含 N 个神经元元素的系统 $\mathcal{X}$ ，其信息整合能力由每个复合体的总最小信息决定，这些复合体通过枚举所有可能的子集 $S \subseteq \mathcal{X}$ 而找到。

为形式化这一直观理解，我们定义系统 $\mathcal{X}$ 的信息整合能力，该能力度量了最大的不可约因果效应效力，即最小信息二分划分的互有效信息 *i.e.*。

定义 6 (信息整合). 子集 S 的信息整合是最小信息二分划分的互有效信息：

$$\Phi(S) = \min_{A \in 2^S, B=S/A} EI(MIB(A \rightleftharpoons B)) \quad (9)$$

整个系统 $\mathcal{X}$ 的整合信息满足

$$\Phi(\mathcal{X}) = \max_{S \in 2^{\mathcal{X}}} \Phi(S)$$

关于信息整合 Φ 的直观解释是，如果系统不能完全分解（为独立的子系统），那么 Φ 就是通过最小化有效信息来在系统的“最薄弱环节”进行切割的有效信息（一种特殊类型的互信息），或者如 Tegmark [2015] 中所说的“最残酷切割”。我们将在下一节讨论如何实际测量整合信息。

2.2 Measurement of Information Integration

在Tononi and Sporns [2003] 中，提出了一种用于测量空间网络信息的计算模型。

假设 $\mathcal{X}$ 是整个系统，并将 $X \in \mathbb{R}^{|\mathcal{X}|}$ 视为定义在 $\mathcal{X}$ 上的随机向量，它表征了系统中每个神经元发出的信号。为了对系统 X 进行建模，作者提出使用高斯图模型，如下所述。

第 i 个节点处的信号，记为 x_i ，是表示节点连接的有向图中其相邻节点信号的线性组合，加上随机测量噪声：

$$x_i = \sum_{j \in \text{neighbor}(i)} w_{i,j} x_j + \sigma_i r_i$$

其中 $r_i \stackrel{i.i.d.}{\sim} \mathcal{N}(0, 1)$ are random noise in the measurement, and $w_{i,j}$ is the edge weight from i to its neighbor j . In matrix form, we have,

$$X = WX + CR, \quad C = \text{diag}((\sigma_i)_i)$$

Then it is easy to see the covariance of X satisfies

$$\Sigma = C^2(I - W)^{-1}(I - W)^{-1\top}.$$

With this model, one can compute the information integration Φ analytically,

$$X := \begin{pmatrix} X_A \\ X_B \\ X_{S^c} \end{pmatrix} \sim \mathcal{N} \left(0, \begin{pmatrix} \Sigma_A & \Sigma_{AB} & \Sigma_{AS^c} \\ \Sigma_{AB} & \Sigma_B & \Sigma_{BS^c} \\ \Sigma_{S^c A} & \Sigma_{S^c B} & \Sigma_{S^c} \end{pmatrix} \right)$$

then to calculate $\text{EI}(A^{\max} \rightarrow B)$, one randomizes the signal from A by setting $\Sigma_A = I_{|A|}$ in the covariance, and cuts off any incoming edges from S^c, B to A . However, if A is simulated to account for connection within A and to A , the original graph is unchanged. Moreover, one sets $C_A = \text{diag}(\sigma_p)$ as the signal and $C_{B \cup S^c} = \text{diag}(\sigma_i)$ as the noise.

Then one can calculate (A is a set, X_A is a multivariate representing the signal states of the items in the set A , we ignore the difference of $H(A)$ and $H(X_A)$ here)

$$H(X_A) = \mathbb{E}[-\log p_{X_A}] = |A|/2 + |A|/2 \log 2\pi + \log |\Sigma_A|/2$$

$$H(X_A X_B) = |S|/2 + |S|/2 \log 2\pi + \log |\Sigma_S|/2, \quad \Sigma_S = \begin{pmatrix} \Sigma_A & \Sigma_{AB} \\ \Sigma_{AB} & \Sigma_B \end{pmatrix}$$

similarly $H(B)$. With the analytic results of $H(A)$, $H(B)$ and $H(AB)$, one can also calculate $\text{EI}(B^{\max} \rightarrow A)$. Then one finds the minimal information bipartition as before,

$$\text{MIB}(S) = \min_{A \in 2^S, B=S/A} \text{EI}(A \rightleftharpoons B) / \min(H^{\max}(A), H^{\max}(B))$$

and $\Phi(S) = \text{EI}(\text{MIB}(S))$

$$\Phi(X) = \max_{S \in 2^{\mathcal{X}}} \Phi(S)$$

Apart from computing Φ for system with a given topological structure, the authors also experimented with finding the graph structure with the maximal Φ , and analyzed the connectivity property of the generated ‘optimal’ graph with maximal Φ .

在Balduzzi and Tononi [2008] 中，对小规模网络上的离散时空系统进行了模拟研究。

[Hoel, 2017] 利用因果推断中的 *do* 操作，构建了一个时间上的马尔可夫链，该链识别出对应于信息增加的（空间）状态空间的特定粗化。考虑一个有限状态空间 S ，我们可以指定任意两个状态之间的转移概率矩阵（TPM）

$$P_{ij} = \mathbb{P}(X^{t+1} = j | X^t = i) = \mathbb{P}(X^{t+1} = j | do(X^t = i))$$

这类似于马尔可夫链，其马尔可夫性质由 *do* operator, i.e. we have conditional independence once $S^t = i$ is a fixed quantity. In this sense, we treat the time as varying, and only one variable X present with state space S ; or that we have $|S|$ many binary variables and so $X = \sum_{k \in S} \delta_k$, which is well-defined due to finiteness.

Consider the problem setup: let $X \rightarrow Y$ be the causal system, where they share the same state space $S_X = S_Y$. The author is interested in when the macro system has a micro system with corresponding TPM, i.e. $U \rightarrow V$, such that $S_U = S_V \subset 2^{S_X}$. Moreover, Hoel's theory aims at identifying particular coarsening of the state space amounts to *causal emergence*. Effective information (EI) plays an important role in achieving this. We give another definition of EI since the context differs to IIT, but firstly we introduce the concept of intervention and effect distribution.

定义 7 (Intervention Distribution and Effect Distribution). *Given $|S_X| < \infty$, the maximum entropy amounts to the uniform intervention distribution*

$$I_D = H^{\max} = \text{Unif}(do(X)), \text{ that is, } P(do(X = x)) = \frac{1}{n} \quad \forall x \in S_X \quad (10)$$

where $\text{Unif}(\cdot)$ is the uniform distribution over a set. Intervening with this distribution on X results in the effect distribution $E_D(Y)$ over Y :

$$\begin{aligned} E_D(Y) &= \sum_X P(Y | do(X)) H^{\max} \\ &= \frac{1}{n} \sum_x P(Y | do(X = x)) \end{aligned} \quad (11)$$

The E_D effectively computes the uniform averages over all rows in the TPM.

We are now ready to introduce definition of effective information in Hoel et al. [2013]:

定义 8 (Effective Information).

$$\begin{aligned} EI(X \rightarrow Y) &= \sum_X H^{\max} D_{KL}(P(Y | do(X)) || E_D(Y)) \\ &= \sum_x P(do(X = x)) D_{KL}(P(Y | do(X = x)) || E_D(Y)) \\ &= \frac{1}{n} \sum_x D_{KL}(P(Y | do(X = x)) || E_D(Y)) \end{aligned} \quad (12)$$

The definition of EI presented in Def 8 is in fact equivalent to the definition in IIT. Without loss of generality, denote $p(x)$ and $p(y)$ the mass function for $X \sim H^{\max}$, $Y \sim E_D$ respectively.

$$\begin{aligned} MI(X, Y) &= \sum_x \sum_y p(x, y) \log_2 \left(\frac{p(x, y)}{p(x)p(y)} \right) \\ (\text{Bayes Rule}) &= \sum_x \sum_y p(x)p(y|x) \log_2 \left(\frac{p(y|x)}{p(y)} \right) \\ &= \frac{1}{n} \sum_x D_{KL}(P(Y | do(X = x)) || E_D(Y)) \end{aligned}$$

根据上述符号，当最佳粗粒化系统比原系统具有更高的有效信息时，即出现 *causal emergence* (CE),

$$CE = EI(U \rightarrow V) - EI(X \rightarrow Y) > 0$$

因为 U and V are considered as the same random variables in one step, this amounts to finding the coarsened support set S_U .

2.3 Biological Evidence

尽管整合信息理论（IIT）提出的计算框架能够分析性地评估任意系统中的信息处理瓶颈，但验证其声称的主观体验等同于信息整合能力这一对应关系，仍然是一个悬而未决的问题。

IIT 假设构成现象状态内容（PSC）的神经元素是通过最大化因果效力来确定的，由于不同的连接模式，宏观尺度上的因果效力可能高于微观尺度。在大脑区域中，大脑皮层同时具备功能专门化和整合性，这应能产生较高的最大信息整合值。而小脑对于意识并非必需，这是因为其神经元之间缺乏依赖性，且无法形成具有高最大信息整合的大型复杂体。

IIT 也解释了为何慢波睡眠期间皮层神经元的双稳态放电会导致意识消退。这是由于选择性和有效性的丧失共同导致了信息整合的减少 [Tononi et al., 2016]。Alkire et al. [2008] 认为，麻醉状态下的大脑与慢波睡眠状态相似，皮层连接性遭到破坏，因此信息整合降低。在实践中，人们提出使用扰动复杂性指数（PCI）来估计实际操作中经颅磁刺激（TMS）所引发的 $\Phi^{\max}$ ，该指数仅在脑响应既整合又分化时才会较高，这对应于一种分布式的时空因果交互模式，该模式复杂且因此不易被压缩。

3 Consciousness as a State of Matter

除了信息理论的视角外，研究者们也在探索物理系统中意识过程的特性。意识可以被视为一种涌现现象。它并不依赖于原子的具体属性，而是取决于原子排列所形成的复杂模式。涌现现象在物理学中很常见，例如，波可以存在于多种不同的物质中。研究者们已从物理学的原理性途径探讨了意识现象 [Penrose, 1991, Stapp, 2000, Tegmark, 2000, 2015, Carroll, 2021]。这一方法的核心问题在于承认意识过程中的真随机性，并在人脑中定位相应的物理过程作为证据。一个研究分支最终诉诸于量子过程，因为量子态的测量过程通常被认为展现出真随机性。意识过程可以被解释为有意识的观察者进行的量子测量。然而，这种解释引发了若干问题：其一对应于量子分解问题，即有意识的观察者具有特定的希尔伯特空间分解，使得观察者周围的世界成为一个强关联但独立于观察者的系统 [Tegmark, 2015]。另一个问题是诸如人脑这类物理系统中的量子退相干。大多数量子现象仅出现在极小的时空尺度上，退相干过程阻止了像人脑这样大的系统继承量子特性。例如，量子退相干的典型时间尺度约为 $10^{-13} \sim 10^{-20}$ 秒，这远短于认知过程的时间尺度（约 $10^{-3} \sim 10^{-1}$ 秒） [Tegmark, 2000]。研究者们还提出了量子态的协调客观坍缩（Orch OR）来解释大脑的认知过程 [Hameroff and Penrose, 2014]，这将在第 4 节中讨论。马克斯·泰格马克 [Tegmark, 2015] 将意识视为一种物质，他称之为“*perceptonium*”，作为表示意识状态的短语。一种物质要成为“*perceptonium*”，需要具备以下四个属性作为必要但不充分条件：

- **information** 原理：系统必须具有实质性的信息存储能力；
- **integration** 原理：系统不能由几乎独立的部分组成，且其内部需要具有一定程度的整合性；
- **independence** 原理：系统必须与世界的其余部分保持实质性的独立性；
- **dynamics** 原理：一个有意识的系统必须具有实质性的信息处理能力，且必须是这种处理过程（而非静态信息）被整合。

在泰格马克的工作中，他推广了托诺尼的整合信息理论（第2节），将其与意识物质应具备的其他原理进行比较，然后将分析推广到量子力学。在他的工作中，他表明信息原理与整合原理可能相互冲突——过多的整合会导致信息量极少，这在第3.2节中被称为 *integration paradox*。此外，独立性原理与动力学原理也存在冲突——过多的独立性会导致一个平凡的动力学系统，

这被称为 *quantum Zeno paradox*，将在第3.3节中讨论。一个有意识的系统需要在这些属性之间取得平衡：信息与整合、独立性与动力学。因此，这项工作引入了 *autonomy* 度量来衡量系统中独立性与动力学的平衡。

随后，它还提出了以下两个原理：

- **autonomy** 原理：一个有意识的系统具有实质性的动力学和独立性。
- **utility** 原理：一个演化而来的有意识系统主要记录对其有用的信息。

自主性原理描述了动力学与独立性的平衡。效用性原理描述了有意识系统内的信息量。

这些原理可以转化为系统中更具体的物理问题：

- 从零开始的物理问题：如果总哈密顿量 H 和总密度矩阵 ρ 完全规定了我们的物理世界，我们如何仅从两个厄米矩阵中提取出三维空间和我们半经典世界的其余部分？
- 量子分解问题：为什么像我们这样的有意识观察者会感知到对应于经典空间（而非例如傅里叶空间）的特定希尔伯特空间分解，更一般地说，为什么我们将周围的世界感知为一个动态的、高度整合且相对独立的物体层次结构？

这些是该理论需要回答的问题。我们将简要介绍量子力学的基础知识，然后深入探讨这些原理。

3.1 Basics of Quantum Mechanics

在量子力学中，系统的状态由希尔伯特空间中的一个向量 $|\psi\rangle$ 描述。例如，我们有一个电子，其自旋向上态为 $|\psi\rangle = |\uparrow\rangle$ 或自旋向下态为 $|\psi\rangle = |\downarrow\rangle$ ，或者它们的叠加态 $|\psi\rangle = \frac{1}{\sqrt{2}}(|\uparrow\rangle + |\downarrow\rangle)$ 。观测到该系统处于状态 $|\chi\rangle$ 的概率为

$$P = |\langle\chi|\psi\rangle|^2. \quad (13)$$

我们可以对状态应用一个幺正算符，以改变我们感兴趣的基：

$$|\psi\rangle \rightarrow U|\psi\rangle \quad (14)$$

例如， x 方向上的自旋向上态是 z 方向上的一个叠加态 $|\psi\rangle = \frac{1}{\sqrt{2}}(|\uparrow\rangle + |\downarrow\rangle)$ 。

状态的时间演化由哈密顿算符 H （可视为希尔伯特空间中的一个矩阵）控制：

$$|\psi(t)\rangle = e^{iHt/\hbar}|\psi(0)\rangle. \quad (15)$$

这被称为薛定谔方程。

哈密顿算符本身描述了系统的能谱。我们可以找到它的本征态：

$$H|E_i\rangle = E_i|E_i\rangle. \quad (16)$$

E_i 是哈密顿算符 H 的本征值，它表示系统处于状态 $|E_i\rangle$ 时的能量（一个标量）。算符在其本征基中呈对角形式。当两个算符对易时， $[A, B] = AB - BA = 0$ ，它们可以同时被对角化。

状态也可以表示为密度矩阵：

$$\rho = |\psi\rangle\langle\psi| \quad (17)$$

这表示一个纯态。

由纯态构建的密度矩阵总是秩为 1。一个更一般的密度矩阵也可以表示状态的经典混合，通常具有更高的秩

$$\rho = \sum_i |\psi_i\rangle\langle\psi_i|. \quad (18)$$

这是一个混合态。

观测到系统处于某个特定状态的概率为

$$P = \langle\chi|\rho|\chi\rangle \quad (19)$$

密度矩阵的时间演化为

$$\rho(t) = e^{iHt/\hbar} \rho(0) e^{-iHt/\hbar}. \quad (20)$$

在能量本征基中写出来，它是

$$\rho(t)_{mn} = \rho(0)_{mn} e^{i(E_m - E_n)t} \quad (21)$$

3.2 Integration Principle

对于一个二分系统 $\rho = \rho_1 \otimes \rho_2$ ，我们将整合信息 Φ 定义为“最残酷分割”下的互信息 I 。互信息的定义为

$$I \equiv S(\rho_1) + S(\rho_2) - S(\rho) \quad (22)$$

其中

$$S(\rho) \equiv -\text{tr } \rho \log_2 \rho \quad (23)$$

是冯·诺依曼熵。请注意，这与托诺尼的定义略有不同，但此定义更易于计算。

回顾第 2 节，我们介绍了原始整合信息理论中整合信息的定义，即最小信息二分下的有效信息。最小信息二分是根据最弱连接对系统进行的“切割”，*i.e.*，即最小的互有效信息。我们也可以考虑量子意义上的切割。在这种情况下，有更多的切割方式可供选择，而我们选择最残酷的切割作为整合信息。因此，*integrated information* 被定义为

$$\Phi = \min_U I(U\rho U^\dagger). \quad (24)$$

其中 U 是作用于密度矩阵 ρ 上的幺正演化。

一个一般的哈密顿量可以写为

$$H = H_1 \otimes I + I \otimes H_2 + H_3 \quad (25)$$

其中 I 是单位矩阵。

如果一个哈密顿量可以在没有相互作用项的情况下分解（即 $H_3 = 0$ ），那么它描述的是两个完全独立的系统，

$$\rho \propto e^{-H/kT} = e^{-H_1/kT} e^{-H_2/kT} \quad (26)$$

在这种情况下，可以推导出 $\Phi = 0$ ，其中 $U = e^{iH_1 t/\hbar} e^{iH_2 t/\hbar}$ 。这符合预期，因为整合信息描述了一个系统内部的信息整合水平，而一个完全分离的系统应该没有整合。根据整合信息理论，我们知道有意识的系统很可能具有最大的整合信息。以具有 n 个偶极子的二维伊辛模型为例，根据上述定义，其最大整合信息仅为 $O(\sqrt{n})$ 。然而，通过使用最优纠错码，系统可以在大 n 区域实现渐近的 $n/2$ 比特整合信息。

以上分析基于量子系统。对于描述大脑过程的经典系统，如霍普菲尔德网络 [Hopfield, 1982]，也可以计算整合信息，但这将导致所谓的整合悖论。

Integration paradox. 假设我们的大脑是一个具有 n 个神经元并使用赫布学习规则的霍普菲尔德网络，那么对于 $n = 10^{11}$ 个神经元 [Tegmark, 2015]，其整合信息的最大容量为 37 比特。然而，一个意识体验所包含的信息量远大于此值，例如人类在脑海中想象一幅图像。这就是所谓的整合悖论。

为什么我们意识体验的信息内容似乎远远超过 37 比特？在量子情况下，它永远不可能包含超过 $1/4$ 比特的信息 [MacKay, 2003]。这一观察引出了若干猜想，包括人脑使用比霍普菲尔德网络更好的编码方法来处理意识信息。

3.3 Independence Principle

该原理遵循整合信息理论（IIT）的思想，即从系统的“最薄弱环节”将其切割为独立部分，如第2.1节所述。它首先要求在量子情形下应用 ρ -对角性定理，以找到互信息的最小值。

定理 1 (ρ -对角性定理, ρ DT [Jevtic et al., 2012]). 互信息总是在 ρ 对角化的基中取得其最小值。

利用 ρ DT，问题转化为如何在哈密顿量如式 25 的量子系统中找到使 ρ 对角化的基。此问题的答案由以下定理给出。

定理 2 (H -对角性定理, HDT [Tegmark, 2015]). 哈密顿量在其对角化的能量本征基中总是最大可分离的（即最小化 $\|H_3\|$ ）。

此外，为了最小化 $\|H_3\|$ ，我们必须有 $[H_1, H_3] = 0$ ，这表明所有子系统（*e.g.*，即具有哈密顿量 H_1 的子系统）需要与所有相互作用哈密顿量（*e.g.*， H_3 ）对易。遵循此原理，最终将导致热寂，即所有子系统停止演化，这被称为 *quantum Zeno paradox*。

定义 9 (量子芝诺悖论 [Tegmark, 2015]). 如果我们将宇宙分解为最大独立的物体，那么一切变化都将停滞。

3.4 Dynamics principle

如果仅遵循独立性原理，我们将面临 *quantum Zeno paradox*，即系统停止演化且不具备信息处理能力。然而，根据动力学原理，我们也要求意识系统具备一定的信息处理能力。自主性原理指出，系统应能在独立性与动力学原理之间取得平衡。存在一些有趣的状态类 ρ ，它们即使在相互作用哈密顿量 H_3 并不小的情况下，也能提供显著的动力学行为和近乎完美的独立性。

作为动力学的一种度量，能量相干性定义为：

$$\begin{aligned}\delta H &\equiv \frac{1}{\sqrt{2}} \|\dot{\rho}\| = \frac{1}{\sqrt{2}} \|i[H, \rho]\| = \sqrt{\frac{-\text{tr}\{[H, \rho]^2\}}{2}} \\ &= \sqrt{\text{tr}[H^2 \rho^2 - H \rho H \rho]}\end{aligned}\quad (27)$$

那么，最大概率速度可计算为：

$$v_{\max} = \sqrt{2} \delta H \quad (28)$$

其中概率速度定义为 $v = \dot{p}$, $p_i = \rho_{ii}$ 。如果我们仅遵循动力学原理最大化 $v_{\max}$ ，一些计算表明这将导致一个非常简单的动力学解，该解不具备足够的信息处理能力。

对环境诱导退相干最鲁棒的状态是那些近似与相互作用哈密顿量对易的状态。这意味着 $[\rho, H_3] \approx 0$ ，但 $[\rho, H_1] \neq 0$ 。 H_3 相互作用项将使系统退相干，因此要求其足够小，以便系统 ρ 能够随时间演化。

为了正确描述一个在独立性与动力学之间取得平衡的系统，需要一种称为 *autonomy* 的新度量。它首先要求使用线性熵来量化演化的非幺正性质。

线性熵定义为：

$$S^{\text{lin}} \equiv 1 - \text{tr } \rho^2 = 1 - \|\rho\|^2 \quad (29)$$

让我们将动力学时间尺度 τ_{dyn} 和独立性时间尺度 τ_{ind} 定义为

$$\tau_{\text{dyn}} = \frac{\hbar}{\delta H},$$

$$\tau_{\text{ind}} = \left[S_1^{\text{lin}}(0) \right]^{-1/2}.$$

自主性可定义为比值：

$$A \equiv \frac{\tau_{\text{ind}}}{\tau_{\text{dyn}}} \quad (30)$$

该比值将随系统尺寸指数增长，从而即使存在较大的 H_3 ，也能产生一个具有足够信息处理能力的高度自主系统。

Summary. Tegmark 提出的理论将整合信息理论推广到量子领域，并从物理学原理计算的角度分析了信息整合原理的不足，提出了 *integration paradox*，即 Hopfield 神经网络无法整合足够的信息以产生意识体验。该理论也分析了独立性原理，并得出 *quantum Zeno paradox*，即一个分解为最大独立子系统的系统最终将停止演化，这与动力学原理相冲突。该理论最终提出了名为 *autonomy* 的度量，该度量被发现对于意识系统而言，作为独立性与动力学原理的平衡，具有很高的值。

4 Orchestrated Objective Reduction Theory

4.1 Consciousness as Orchestrated Objective Reduction

回顾第1.2节中关于意识涌现中自由意志问题的讨论，我们可以推测，真正的随机性可能是自由意志发生所必需的。这种真正的随机过程是如何在人脑中发生的呢？协调客观还原（Orch OR）理论 [Penrose, 1991, 1994, Hameroff and Penrose, 1996, Hameroff, 2007, 2010, 2012, Hameroff and Penrose, 2014]，建立在以下假说之上：意识的涌现是由于一种能够协调量子态还原时刻的生物机制。该理论提出，意识事件源于大脑微管中量子计算的终止，被表述为 *objective reduction*。客观还原指的是量子系统可以从多种可能性的叠加态自发坍缩为单一状态的观点。在 Orch OR 理论中，Hameroff 和 Penrose 提出，这些客观还原是非决定性的，但受到大脑中某些过程的协调。这些受影响的客观还原过程被称为自由意志。简而言之，基于量子理论的 Orch OR 框架似乎将随机性方面引入了将意识视为纯粹物理过程的还原论观点中。通过这一点，独立的因果能动性和自由意志可以得到解释 [Hameroff, 2012]。此外，这也将意味着单个细胞中意识的存在。

4.2 Free Will in Neurons

产生脑电图（EEG）与神经相关物（NCC）的整合与放电序列，主要由树突-胞体膜产生。随后，轴突放电输出有意识（或无意识）过程以控制行为。微管（MTs）作为细胞骨架的一部分，即细胞内部的蛋白质支架网络，被假设能够影响放电阈值。具体而言，神经元的树突-胞体微管以局部递归网络形式排列，且相较于其他细胞中的微管更为稳定，因此使其自身成为适宜的信息处理与存储单元，进而适于介导意识并调节放电。

如图 4 所示，微管由花生状的微管蛋白构成，每个蛋白具有偶极子，并可排列成 13 条原丝，每条原丝具有两种类型的六角晶格。在 [Hameroff and Penrose, 2014] 中，微管偶极子被描述为电子自旋（磁性），这本质上是一个量子力学量。因此，自旋转轴所有可能的方向都作为某些随机方向对的量子叠加而出现。作者随后推测，微管内部路径上可能存在沿链传播量子比特对的自旋链；此外，可能存在由周期性自旋翻转引起的特定频率的交替电流。微管中的微管蛋白各自可根据偶极子位置（方向）处于不同状态（并产生量子叠加）这一事实，可能表明微管过程可直接导致意识的产生。




图 4: 此图发表于Hameroff and Penrose [2014], 用于阐释 Orch OR（调谐客观还原）发生的过程。上图：微管蛋白处于经典偶极子状态（黄色或蓝色），或两种偶极子状态的量子叠加（灰色）。量子叠加/计算在（1-3）阶段增加。当阈值在时间 $\tau \approx \hbar/E_G$ 达到时，意识瞬间发生。中图：相应的交替叠加时空曲率在 OR 时刻达到阈值并选择一种时空曲率。下图：一个意识性 Orch OR 事件的示意图，显示了量子叠加的 U 型演化以及不断增加的 E_G ，直至达到 OR 阈值，并通过 $\tau \approx \hbar/E_G$ 产生一个意识瞬间。

4.3 Diósi-Penrose Objective Reduction

在标注了量子叠加可能发生在我们大脑中的生理单元后，人们可能会问，产生意识的协调还原是如何发生的？论证始于将协调客观还原（Orch OR）与理论物理学联系起来。

迪欧西-彭罗斯 (DP) 的客观还原提议将量子物理学与经典物理学桥接为 *quantum-gravitational* 现象, 据此量子叠加会还原到一个平均时间测量 τ , 根据 $\tau \approx \frac{\hbar}{E_G}$ 、 $E_G = \frac{Gm^2}{a}$, 状态还原发生, 其中 E 是时空叠加曲率, G 是引力常数, m 是质量, a 是空间尺寸。在 DP 理论中, 每次状态还原事件的实际衰变时间被视为一个随机过程。由此, 时空物体的量子叠加会在叠加曲率 E_G 达到阈值 $\frac{\hbar}{\tau}$ 时发生还原。

Orch-OR 方案更进一步, 将 DP 物理提议与意识联系起来。Hameroff and Penrose [2014] 提出, 如果一个量子叠加首先被良好协调: “充分组织、充满认知信息, 并能够进行整合与计算”; 其次与非协调的随机环境隔离, 使叠加 E_G 达到阈值 τ , 那么 Orch OR 将与意识的涌现一同发生。此过程的图示见图 4。

4.4 Evidence for Objective Reduction of Quantum State

在Hameroff [2010] 中, 作者声称意识神经相关性的最佳测量是 30 至 90 赫兹的伽马同步脑电图 (EEG), 这主要源于树突和胞体的整合电位。此外, 该理论声称麻醉状态是由于微管中偶极子的分散所致, 而微管负责量子计算。

目前尚有待实验证实该理论, 然而, 在温暖条件下已观察到生物学证据, 而该理论尚未扩展到这些条件。尽管如此, Orch OR 理论提供了一个计算框架, 允许对发生在微管中的生物量子理论进行证伪。

5 Global Workspace Theory

5.1 The Theatre of Consciousness

全局工作空间理论 (GWT) 是由伯纳德·巴尔斯 [Baars et al., 1997] 提出的一种架构, 用以解释人脑如何选择和处理意识注意的内部过程。意识容量存在一些限制。例如, 工作记忆临时存储待处理的信息, 一次只能容纳少数几项内容。此外, 人脑只能接收来自单一信息流的信息。‘意识剧场’这一隐喻术语被提出来回答人脑如何处理不同的输入, 然后输出一个吸引最终注意力的单一信息流。

意识剧场包含若干组成部分。‘工作记忆舞台’是接收来自传感器的所有潜在信息或来自皮层的抽象信息的平台。工作记忆中的‘聚光灯’机制会突出显示意识信息流, 舞台上的其他信息则不被注意力所察觉。信息资源, 例如潜在的思想、图像或感觉, 被视为‘演员’。这些信息资源相互竞争以获取聚光灯。处理信息所需的意识过程越多, 该信息资源就越有可能被置于聚光灯下。知觉、意图、期望等会影响这种竞争的结果。‘语境’指的是大脑中可能塑造意识内容的无意识网络。‘导演’, 即人脑的执行功能, 通过意图和目标来指导选择过程。额叶皮层被认为在此过程中扮演重要角色, 因为额叶损伤会导致基于长期目标的行为丧失。然后, 聚光灯下的信息被广播给‘观众’, 观众代表需要该信息的大脑区域。

2003 年 GWT 的一次更新 [Baars, 2003] 更详细地介绍了 GWT 与大脑功能之间的关系, 为竞争如何在大脑中执行提供了一些证据。额叶皮层和其他可能中断聚光灯控制的大脑区域都参与了意识事件的选择过程。后者的中断控制包括例如脑干、疼痛系统和情绪中枢, 它们允许中断选择过程, 并赋予更显著和紧急的活动以权重。大脑的‘语境’功能被认为参与了意识决策过程。与身体部位自我意识相关的顶叶皮层并不直接客观地与意识相关联, 但被认为塑造了有意识的视觉事件。‘自我’系统可能参与了意识的产生。研究发现, 裂脑患者的左右半球具有不同的执行和知觉功能 [Gazzaniga et al., 1996], 并且左前额叶皮层通过一个‘叙事自我’来处理感觉信息, 该自我可以引发不同的意识, 从而导致两个半球之间的冲突。然后左半球试图合理化并修复这些冲突。该论文还提供了一些证据来支持意识内容被广播并分布到大脑




图 5: 源自 Baars et al. [1997] 的 GWT 示意图。

区域的假设。在一项视觉词汇任务中，词汇任务不仅触发了皮层的视觉词汇识别区域，还被发现能唤起顶叶和前额叶皮层的活动 [Baars, 2002]。

5.2 Computational Models of GWT

基于全局工作空间理论（GWT），研究者提出了智能分配代理（IDA）[Baars and Franklin, 2003, 2007] 和学习型 IDA（LIDA）[Baars and Franklin, 2009] 计算模型，用以执行类人任务。在该研究中，以水手的海军工作为例证任务来测试该模型。IDA 和 LIDA 包含多个反映 GWT 的模块，包括用于处理刺激的 **sensory modules**、作为存储的 **memory modules**、指代注意力概念的 **attention modules**，以及用于动作选择的 **action module**。特别是，正如在 GWT 中一样，**global workspace modules** 整合并广播信息，同时选择最相关和最重要的信息登上舞台。该模型展示了 GWT 模型的一种经验性计算实现，作为概念性证据表明 GWT 可以实现类人功能。IDA 或 LIDA 将传入的感觉数据转化为对环境的行为。记忆、竞争和广播等概念都参与了这个转换过程。随后，对环境产生的行为改变了系统的输入，从而形成了一个迭代的认知循环。

GWT 启发了相关领域的一些研究，这里我们描述几个在脑信号分析和深度学习中的例子。受 GWT 启发，[Schutter and van Honk, 2004] 使用脑电图相干性（不同脑区连接水平的指标）来衡量情绪是否在意识中起作用。另一项研究 [Bartolomei and Naccache, 2011]，基于 GWT 中的广播和分发过程，比较了癫痫发作时远距离皮质-皮质和皮质-丘脑网络内部的同步性与 GWT 中不同脑区之间的远距离关系。最近，一项研究探讨了用深度学习实现 GWT 的可能性。研究者提出了全局潜在工作空间（GLW）的概念，以反映类脑机制的深度学习设计原则 [VanRullen and Kanai, 2021]。

6 Higher-Order Theories

高阶理论（HOT）的一个普遍定义由 Carruthers and Gennaro [2023] 给出：一种现象上意识到的心理状态是一种（特定类型的）心理状态，它要么是，要么倾向于成为某种特定类型的高阶表征的对象。

根据所讨论的高阶状态是感知类还是思想类，高阶理论被分类为高阶感知理论（HOPT）、高阶思想理论（HOTT）、自我表征理论（SRT）等。HOPT（第 6.1 定义 10）、HOTT（第 6.2 定义 11）和 SRT（第 6.3 定义 12）的定义将在后续章节中详细描述。此外，我们将在最后一节介绍并讨论其他相关理论。为提供一个简洁的概览，我们将这些理论整合成一个总结性的表格 6。

高阶理论（HOTs）试图回答一个心理状态是有意识还是无意识的问题。高阶理论认为，存在某种比一阶信息（例如来自视觉或听觉神经等器官的感觉）更高级的大脑机制。三个子理论对这种高阶机制提出了不同的解释。HOPT 认为存在内在感官，它们扫描或精炼但独立于一阶信息。这解释了人们为何能够想象诸如疼痛等感觉。在 HOTT 中，人们相信当一个心理状态成为高阶思想的对象时，它才是有意识的。他们提出，一个有意识的心理状态或事件要么实际上正在引起，要么倾向于引起一个人拥有该状态或事件的激活思想。自我表征理论对高阶理论提出了另一种解释。自我表征理论认为，高阶状态是其对应一阶状态的构成性或内在部分，即高阶状态由一阶状态形成，并且作为一个比产生意识的一阶状态更复杂的系统。

高阶理论概览

理论		一阶 & 高阶关系	核心机制	参考文献
高阶知觉理论		高阶感知存在且独立于一阶信息	知觉式：人脑具有对一阶感知的内在感知，以生成高阶表征	[Locke, 1948, Armstrong, 1981, Armstrong and Malcolm, 1985, Lycan, 1996, Armstrong, 2002, Lycan, 2004]
高阶思维理论	现实论	当心理状态成为高阶思维的目标时，它便是有意识的	思维式：一个有意识的心理事件实际上正在引发一个关于个体拥有该事件的激活思维	[Rosenthal, 1986, 1993, 2005]
	倾向论	当心理状态成为高阶思维的目标时，它便是有意识的	思维式：当心理状态成为高阶思维的对象时，它便是有意识的；一个有意识的心理事件倾向于引发一个关于个体拥有该事件的激活思维	[Dennett, 1978, Carruthers, 1998]
自我表征理论	部分-整体	一阶与高阶是一个整体复合体的组成部分	心理状态旨在表征自身。在部分-整体自我表征理论的定义中，高阶信息存在，但并不严格‘高于’一阶信息。一阶与高阶是绑定在一起的	[Kriegel, 2009, Picciuto, 2011]
	同一性	高阶与一阶是同一的	高阶与一阶是作为两种角色或功能的相同组成部分	[Caston, 2002, Carruthers, 2005, Van Gulick, 2004]

6.1 Higher-Order Perception Theory

高阶知觉理论 (HOPT) 理论 [Locke, 1948, Armstrong, 1981, Armstrong and Malcolm, 1985, Lycan, 1996, Armstrong, 2002, Lycan, 2004], 亦称为内在感官理论或高阶感官理论, 指的是以下内容: 人类不仅拥有感官器官来扫描环境及自身身体以产生表征, 这些表征被称为对环境/身体状态的 *first-order* 非概念性和/或模拟知觉, 而且还拥有对这些一阶感官的内在感官, 以产生同样精细但更高阶的表征, 这些表征被称为对 *first-order* 知觉状态的 *second-order* 非概念性和/或模拟知觉。

first-order 知觉与 *second-order* 知觉的定义实际上接近于注意图式理论中的 *M*-意识与 *I*-意识, 这将在后面的第 7 节介绍。我们将在第 7.3 节稍后讨论这两种理论之间的联系。

定义 10 (高阶知觉理论/内在感官理论 [Carruthers and Gennaro, 2023]). 一个现象上具有意识的心理状态是一个具有模拟/非概念性意向内容的状态, 而该状态又通过“内在感官”官能的运作, 成为一个更高阶的模拟/非概念性意向状态的目标。

HOPT 的一个正式命题作为定义 10 提供。它将意识解释为通过对一阶状态进行内在感知而产生的高阶状态。参考第 1.2 节中的图 3, 意识模块是一个更高层级的组件, 它能感知较低层级传感模块的信息流。

HOPT 的对立观点由一些理论家持有, 他们认为对一阶状态的注意机制可能作为高阶状态的替代 [Sauret and Lycan, 2014]。

6.2 Higher-Order Thought Theory

高阶思维理论 (HOTT) [Rosenthal, 2009, 2012, 2004, Byrne, 1997, Brown et al., 2019] 提出, 一个有意识的心理状态或事件要么实际导致、要么倾向于导致一个人产生自己拥有该心理状态或事件的激活思维。该理论有两个分支: **actualist** 和 **dispositionalist**。在上述陈述中, 现实主义者认为心理状态直接导致了激活思维, 而倾向主义者则认为心理状态倾向于产生该思维。它们之间的另一个区别是, 现实主义 HOTT 要求一阶信息实际参与计算, 以生成高阶信息。相反, 倾向主义 HOTT 认为高阶计算仅需要一阶信息的可用性, 例如利用全局工作空间理论中的广播机制, 而不是直接访问所有一阶信息。在 [Lau and Rosenthal, 2011] 中, 讨论了对高阶理论的一些实证支持, 例如意识知觉与前额叶机制的关联以及基于临床障碍的证据。

定义 11 (高阶思维理论 [Carruthers and Gennaro, 2023]). 一个现象上有意识的心理状态是某种特定类型的状态 (例如, 具有模拟/非概念性意向内容), 它是高阶思维的对象, 并且以非推理的方式引起该思维。

基于高阶思维理论, 一些计算模型被提出。元认知神经网络模型 [Pasquali et al., 2010, Cleeremans et al., 2007, Timmermans et al., 2012] 由两个网络组成: 一阶网络和二阶网络。一阶网络直接接收输入并通过隐藏单元进行处理。之后, 一阶网络的隐藏单元连接到二阶网络进行进一步处理。一阶网络学习执行任务分类, 而二阶网络通过访问一阶网络的表征信息来预测一阶网络的置信度。这些模型在多项任务上进行了测试和报告, 例如爱荷华赌博任务 [Pasquali et al., 2010]、区分语法与非语法句子的人工语法学习 (AGL) 任务, 以及盲视任务 [Persaud et al., 2007], 其中盲视患者在缺乏视觉意识的情况下进行视觉辨别。

6.3 Self-Representational Theory

自我表征理论 (SRT) [Kriegel, 2009, Van Gulick, 2004, Picciuto, 2011] 提出了现象意识心理状态的概念, 这种状态同时具有非概念性意向内容和概念性意向内容。据说这种心理状态向作为该状态主体的个人表征了其自身。

定义 12 (自我表征理论 [Carruthers and Gennaro, 2023]). 现象意识心理状态是一种特定类型的状态 (可能具有模拟/非概念性意向内容), 它同时拥有一种意向内容, 从而在某种意义上向作为该状态主体的个人表征了其自身。

该理论的两个分支论证了意识状态与高阶状态之间的构成性关系是 **identity** [Caston, 2002, Carruthers, 2005, Van Gulick, 2004], 或是 **part-whole** [Kriegel, 2009, Picciuto, 2011]。前者认为意识状态既是第一

阶的也是高阶的。更准确地说，一个具有模拟内容的第一阶知觉状态同时获得了一个高阶的模拟内容。部分-整体 SRT 采取的立场类似于现实主义高阶思想理论的论证，即第一阶知觉状态产生了表征经验的高阶思想。

6.4 Other theories and perspectives in HOT

同阶理论 [Kriegel, 2009, Brentano, 1973, Lau and Rosenthal, 2011] 提出，意识心理状态并非由任何其他心理状态所表征，而是直接呈现于主体的觉知之中。高阶统计推断观点 [Lau, 2011, 2007] 认为，意识心理状态涉及关于自身心理状态的高阶统计推断。根据这一观点，第一阶表征通过一个高阶推断程序进行审查，以形成一个统计上可靠的知觉信号，类似于知觉决策过程。从激进可塑性论题 [Cleeremans, 2011, Pasquali et al., 2010] 的视角来看，大脑具有显著的适应性和灵活性，这种可塑性在意识觉知的发展中起着关键作用。激进可塑性论题提出，意识并非一个内在过程，而是大脑中的一个学习过程。大脑进行持续且无意识的学习，以重新描述其活动，从而发展出描述并精炼初始的第一阶表征的元表征系统。

7 Attention Schema Theory

7.1 Formulation

理解注意力与意识的区别及其在注意力图式理论（AST）中的关系至关重要 [Graziano and Webb, 2015, Graziano et al., 2020]。

定义 13 (注意力). 注意力是大脑选择性地处理某些信息多于其他信息的过程。

作为对注意力过程最具影响力的解释之一，人们 [Desimone et al., 1995] 提出，在信号处理的最早阶段就存在一个信号竞争过程，并且该过程存在于之后的每一个阶段。

意识是一个不同于注意力的概念。尽管意识与注意力通常高度相关，但它们可以分离。对于意识这个概念，我们首先需要区分客观意识和主观意识。这两种意识都涉及一个参与者。

定义 14 (客观意识). 对于客观意识，要求参与者报告他客观上意识到了刺激。

定义 15 (主观意识). 对于主观意识，参与者根据自己的看法报告是否感知到了刺激。

客观意识与主观意识的区别仅在于区分参与者是“看到”还是“猜测”所感知的刺激。

在 AST 中，作者将 *awareness*、*consciousness* 和 *subjective experience* 视为与 *subjective awareness* 相同的概念。因此，AST 是关于主观意识的理论，而非 *objective awareness*。

AST 提出，意识是注意力的一个模型。设想一个人看到一个苹果，苹果的视觉表征（V）通过注意力过程出现在此人的脑海中。然而，这还不足以使此人意识到“苹果”。为了产生意识，心智还有一个自我模型（S），而 S 对 V 的注意力（A）也是意识的一部分。根据 AST，主观意识是 [S+A+V]，它是注意力过程的一个模型。




图 6: AST 中作为注意力模型的意识。

人们可能会问，为什么在注意力之外还需要主观意识？根据 AST，主观意识允许进行自我建模，这对于基于模型的控制至关重要。没有意识，就如同一个人试图伸手够物体时没有对手臂进行建模，这将导致对手臂位置预测不准确，从而造成不良的够取结果。意识作为心智本身及其注意力的内部模型，为人类带来了更准确的基于模型的控制。

7.2 *I*-意识与 *M*-意识

作为 AST 的主要研究者，Graziano et al. [2020] 在其后续研究中提出通过 *I*-意识（*I* 代表信息）和 *M*-意识（*M* 代表神秘）来解释人类心智的意识。

I-意识表示信号在注意力竞争中胜出的过程，正如全局工作空间理论（GWT）中所描述的那样，通常被认为在计算上是可行的 [Baars and Franklin, 2007]。然而，神秘的部分是 *M*-意识，它被用来解释感知获胜信息片段的主观体验。

类似于 AST 先前的工作 [Graziano and Webb, 2015]，即觉知是注意力的一个模型，Graziano et al. [2020] 进一步提出 *M*-意识是 *I*-意识的一个自然的、内置的、不完美的模型。此外，*I*-意识和 *M*-意识可以相互关联，就像一面镜子映照另一面镜子。一个人能够 *I*-意识到自己拥有 *M*-意识，而 *M*-意识是 *I*-意识的一个模型。对于自我建模而言，被建模的部分是与注意力竞争中获胜信息片段最密切相关的自我物理组成部分。

人们可能会进一步追问，为何我们认为主观体验是真实的。根据 AST，两个特性确保了真实的主观体验：第一是主观体验无法被关闭。第二是心智能够对感知到的信息进行来源监控，这使得人们能够区分真实与假设。由于 *M*-意识是 *I*-意识的一个模型，其感觉之所以真实，其理由与人们相信所有物理对象都是真实的完全相同。

AST 的一个实际实现将包含三个组成部分。网络 *A* 代表通过注意力竞争进行的选择性信息处理。网络 *B* 旨在通过对 *A* 的输出进行预测，来建模网络 *A* 的功能。网络 *C* 接收来自 *A* 和 *B* 的输出，以生成对大脑内部及外部世界其他组成部分的报告（*e.g.*，言语）。网络 *B* 是重要的注意图式，其在大脑中的物理对应部分已被认为服务于一个与颞顶联合区（TPJ）部分重叠的皮层网络 [Graziano and Kastner, 2011, Graziano, 2016]。

7.3 AST as a Unification of GWT and HOT

AST 可被视为全局工作空间理论（GWT，第 5 节）[Baars, 1993, Dehaene, 2014, Dehaene and Changeux, 2011] 与高阶理论（HOT，第 6 节）[Gennaro, 2011, Lau and Rosenthal, 2011, Rosenthal et al., 1991, Rosenthal, 2005] 的统一。

具体而言，GWT 解释了信息出现在心智舞台上的注意图式，这对应于 AST 的 *I*-意识。然而，GWT 并未解释意识体验（即 *M*-意识）的存在。AST 通过使用网络 *B* 构建注意图式来解释这一谜题。

HOT 认为意识产生于高阶表征。回顾第 6 节中对 HOT 的介绍，一个意识系统具有对那些一阶感觉的内在感知，以生成同等精细但更高阶的表征，这些被称为 *first-order* 感知状态的 *second-order* 感知。

AST 中的 *I*-意识代表外部的一阶感觉，而 *M*-意识则对应于一阶感觉的 *second-order* 感知。这些 *second-order* 感知可被视为对一阶感觉的建模过程。AST 假设大脑构建全局工作空间的高阶表征，作为对 *I*-意识的不完美建模，从而统一了 HOT 与 GWT，为主观感知提供解释。

8 Conscious Turing Machine

8.1 Formulation

在传统的图灵机 (TM) [Turing, 2009] 中，图灵并未将主观体验纳入图灵机的概念。图灵机仅关乎计算智能，而非机器的意识，而后者通常被认为是一个难题 [Chalmers, 1995]。

意识图灵机 (CTM) [Blum and Blum, 2022] 是作为图灵机扩展概念的一种理论。与图灵机的计算模型相比，CTM 赋予系统一个可区分的特征，即“意识的感觉”。具体而言，CTM 定义如下。

定义 16(意识图灵机), *CTM* 被定义为一个七元组: $\langle STM, LTM, Up\ Tree, Down\ Tree, Links, Input, Output \rangle$, 其中 *STM* 和 *LTM* 分别是短期记忆和长期记忆的缩写。

CTM 可被视为具有更复杂结构的 GWT。STM 类似于 GWT 中的“舞台”，是意识发生的必要组件。作为 GWT 中“观众”的类比，LTM 是一个大型通用处理器集合，包括用于建模世界和智能体自身的 *Model of the World* 处理器、用于处理语言信息的 *Inner Speech* 处理器，以及其他用于处理如五感等信息输入的 *Inner Generalized Speech* 处理器。这些处理器被称为 LTM，因为它们具有相对稳定的状态和专门处理特定类型信息的能力，而 LTM 则对应于更短期的状态维护以实现更通用的功能。




图 7: CTM 中的信息流。

在 CTM 中，信息流仅以五种方式出现，如图 7 所示：

- (1) 环境 → LTM;
- (2) LTM → STM (通过上行树);
- (3) STM → LTM (通过下行树);
- (4) LTM → LTM;
- (5) LTM → 环境。

过程 (1) 是信息感知。过程 (2) 通过上行树竞争实现。在上行树竞争过程中，最终有一个获胜的信息块到达 STM。竞争过程由一种内部机制决定，该机制是概率性的，并通过一些具有内在随机性的掷币神经元实现。然而，作者认为，即使在完全确定性的设置下，自由意志仍然可以被感受到。过程 (3)

通过下行树广播实现，它将 STM 中的信息广播给所有 LTM。(2) 和 (3) 共同实现了意识觉知。意识觉知（注意）是所有 LTM 处理器对上行树竞争中广播的获胜信息块的接收。过程 (4) 是处理器之间用于信息处理协作的双向链接。过程 (5) 是系统通过如 *Motion Controller* 等处理器向环境的输出。

8.2 CTM for Consciousness

CTM 采用 *Brainish* 的概念作为不同处理器之间通信的内部语言。*Brainish* 是一个术语，指代用于在大脑不同模块之间传递信息的抽象语言，它可以被视为多模态信息的一种编码，它是非符号化的，并且比英语等外部语言更强大。

根据 CTM 理论，意识的感觉是结合 *Brainish* 语言、CTM 的架构、一些特殊处理器以及 CTM 的动态预测能力而产生的。自我建模是通过 *Model of the World* 处理器实现的，该处理器反复地从某些长期记忆（如 *Motion Controller*）生成动作，并观察由其他一些长期记忆（如用于感知周围环境的 *Inner Generalized Speech* 处理器）所感知到的后果。CTM 被用来解释盲视、错觉、梦境以及其他与意识相关的过程。自由意志是在上树竞争中的抛硬币过程中实现的。

8.3 Relationships with Other Theories

与 GWT 相比，CTM 在舞台上只有一个“演员”，一次只持有一个信息块。此外，CTM 中的所有处理器都位于长期记忆中。与一项区分唤醒和意识作为意识两个组成部分的实验工作 [Lee et al., 2022] 相比，本文仅讨论意识觉知（或注意）。CTM 理论假设意识可以还原为计算过程，并可以用图灵机建模。然而，这一点仍然存在争议。其他人可能质疑这一观点，并认为意识是一种更复杂的现象，不能还原为纯粹的计算过程。有几种理论和论点支持意识不能还原为纯粹计算过程的观点，其中包括：

- 意识的困难问题：这一由哲学家大卫·查尔莫斯 [Chalmers, 1995, 2017] 提出的论点认为，虽然大脑可能能够执行各种计算，但这些计算如何产生主观体验或意识尚不清楚。
- 感受质：这指的是体验的主观且难以言喻的方面，例如红色的红或巧克力的味道。一些人认为，这些主观体验无法被计算模型捕捉，而是植根于大脑的生物和物理过程 [Tononi and Koch, 2015, Chalmers, 2017, Albantakis and Tononi, 2021]。
- 整合问题：这一论点认为，意识产生于大脑不同区域之间复杂且动态的相互作用，而这些相互作用不能还原为简单的计算。
- 计算的局限性：一些人认为，计算存在根本性的限制，而意识的某些方面可能超出了这些限制。

这些论点以及其他论点表明，虽然计算可能在意识中扮演一定角色，但它并非全部，要完全解释意识现象，需要一个更复杂、更细致的理解。

9 Physiological Evaluation Metric of Consciousness

本节介绍一些用于医学诊断的意识水平生理评估指标。需要注意的是，本节中“生理意识”的定义与论文其他部分（例如，IIT（第 2 节）或 GWT（第 5 节））介绍的“意识”有所不同。生理意识通常表示基于生理和生物学数据（例如，从脑电图提取的信号特征或对刺激的反应）得出的受试者或患者的意识水平。在医学评估中，意识的定义通常包含觉醒或知晓水平 [Walker et al., 1990]。在接下来的段落中，我们将深入探讨基于电信号和行为指标的常见评估指标。为获得全面概览，请参阅表 2，该表总结了每种意识生理评估指标的信号来源和应用。

9.1 Metrics Based on Electrical Signals

脑电双频指数（BIS）[Rosow and Manberg, 2001, Johansen, 2006] 是一种基于生物信号、用于衡量意识水平的指标，通常用于已接受麻醉的患者。该数值通过患者的脑电图（EEG）计算得出，以评估麻醉深度。BIS 结合了脑电图的频谱图、双谱分析以及时域上的爆发抑制评估进行计算。BIS 的取值范围

Metric	Source Signal	Application	References
Bispectral Index (BIS)	electroencephalogram (EEG) spectrogram; bispectrum; time-domain assessment of burst suppression	evaluate the level of consciousness (anaesthetics etc)	[Rosow and Manberg, 2001, Johansen, 2006]
Perturbational Complexity Index (PCI)	collect electroencephalogram (EEG) features responding to the TMS (transcranial magnetic stimulation) stimulation	evaluate the level of consciousness of brain-injured or unresponsive patients	[Casali et al., 2013]
Explainable Consciousness Indicator (ECI)	electroencephalogram (EEG) features extracted by two deep neural networks	evaluate the level of wakefulness and awareness	[Lee et al., 2022]
Glasgow Coma Scale (GCS)	eye activities; verbal response; motor response	evaluate effectiveness of treatments and as a prognostic indicator;clinical assessment of unconsciousness, e.g. comatose patients	[Jones, 1979, Sternbach, 2000]
Rancho Los Amigos Scale (RLAS)	Responses to external stimuli;Responds to people;short-term memory; behavior and verbalization; task operation and learning	Consist eight levels of consciousness evaluation for patient recovery evaluation	[Lin and Wroten, 2017]
Full Outline of Unresponsiveness (FOUR)	eye; motor; brainstem; respiration	evaluate level of consciousness (including verbal score in intubated patients and to test brainstem reflexes)	[Wijdicks et al., 2005]
Coma Recovery Scale-Revised (CRS-R)	emotion; language; memory; attention	evaluate patients' disorders of consciousness, e.g. coma.	[Giacino et al., 2004]
Vegetative and Minimally Conscious State Scale (VSMS)	responsiveness; attention; communication	evaluate the awareness level of patients in vegetative or in a minimally conscious	[Wieser et al., 2010]
Coma/Near Coma Scale (CNCS)	responsiveness; attention; communication	evaluate the awareness level of patients in vegetative or in a minimally conscious	[Rappaport, 2005]

表 2: 意识生理评估指标总结

为 0 至 100，表示从深度麻醉到完全清醒的状态。BIS 监护仪通常用于手术中，以确保麻醉水平适当。扰动复杂性指数（PCI）由Casali et al. [2013] 提出，作为评估意识水平的度量标准。PCI 使用经颅磁刺激（TMS）激发皮层活动，并基于脑电图对刺激响应的时空模式分析算法复杂性信息。类似地，以脑电图作为数据源，可解释意识指标（ECI）[Lee et al., 2022] 利用深度学习模型计算评分以评估意识水平。该研究将意识定义为唤醒与觉知的结合。两个深度学习网络分别计算这两部分，随后将两者的评分整合为意识指标。

9.2 Metrics Based on Behaviors

此处我们讨论一些基于生命体征或行为的意识水平评估指标。格拉斯哥昏迷量表（GCS）[Jones, 1979, Sternbach, 2000] 的测量包括睁眼反应、语言反应和运动反应。GCS 得分越高，表示意识水平越高。拉诺斯·阿米戈斯量表 [Lin and Wroten, 2017] 常与 GCS 结合使用，用于评估脑损伤患者的恢复过程。它包含八个意识水平，从无反应到完全恢复。为应对 GCS 有时无法评估插管患者的语言评分以及检测脑干反射的问题，无反应全面评估量表（FOUR）[Wijdicks et al., 2005] 被提出，该量表包含眼部、运动、脑干和呼吸四项指标。昏迷恢复量表修订版（CRS-R）[Giacino et al., 2004] 评估广泛的认知和行为功能，包括情绪、语言、记忆和注意力。CRS-R 用于评估患者的意识障碍，例如昏迷。植物状态和最小意识状态量表（VSMS）[Wieser et al., 2010] 以及昏迷/近昏迷量表（CNCS）[Rappaport, 2005] 在文献中已被用于通过测量一系列认知和行为功能（包括反应性、注意力和沟通能力）来表征处于植物状态或最小意识状态患者的意识水平。

10 Look Ahead: Can Computational Models Be Conscious?

10.1 Background

大型人工智能（AI）模型的近期进展引发了人们的关注，即思考意识是否存在于这些模型中，或者能否在短时间于这些 AI 系统中构建出来。如图 8 所示，AI 智能体是通常为计算型智能体的一个子集。在所有 AI 智能体中，通用人工智能智能体是最强大的智能体，拥有与人类相兼容的智力能力。一个 AGI 系统要具备意识，还需满足若干属性，这将在后文详细讨论。本节讨论的主题涉及像 ChatGPT 这样的大型语言模型（LLMs）、像 PALI [Chen et al., 2022] 这样的多模态模型、以及像 PALI-X [Chen et al., 2023]、PALM-E [Driess et al., 2023]、RT-2 [Brohan et al., 2023] 这样的具身智能体。融合不同模式可以提升模型的泛化能力，使其行为表现得更有意识。然而，鉴于当前进展以及语言在人类知识中的重要性，本节将主要讨论 LLMs。在语言层面评估模型的意识更为直接。




图 8: 计算智能体示意图。最大的圆代表通用计算智能体，而 AI 智能体是其子集。AGI 智能体是那些最强大的 AI 智能体。在满足额外条件的情况下，AGI 智能体可以具备意识。

LLMs 指的是专门为语言任务设计的大型计算模型。在某种程度上，近期构建的 LLMs 类似于 *philosophical zombie* [Chalmers, 1997]，这是一个为论证意识问题之困难性而广为人知的思想实验。有时 LLMs 生成的答案与人类得出的结果高度一致，以至于我们难以区分两者，这使得一些人相信 LLMs 具有像人类一样具备意识的潜力。

尽管当前的 LLMs 非常智能，但研究者 [Ma et al., 2023] 认为当前的 LLMs 是 *brain in a vat* (BiV) [Putnam et al., 1981]。将大型语言模型 (LLMs) 与 BiV 思想实验进行比较，是对模型固有局限性的一种批评。在 BiV 场景中，一个大脑与其身体分离，并连接到一台能生成逼真现实幻觉的超级计算机上。该大脑可以与这个模拟现实互动，但它缺乏与真实世界的连接。类似地，LLMs 尽管拥有令人印象深刻的语言能力，但本质上与真实世界是脱节的。它们基于海量文本语料库中的模式生成回应，但这些回应局限于训练数据之内，缺乏与真实世界实体的连接。

这一比较得到了以下观察的支持：LLMs，如同 BiV 场景中的大脑，无法在符号（词语）与真实世界实体之间建立联系。这一局限性内在于其构建过程，该过程涉及基于海量文本语料库对语言关系进行统计建模。因此，其输出被限制在训练数据之内，它们无法建立符号与真实世界实体之间的联系。这种缺乏现实基础的情况是 LLMs 的一个显著局限，因为它阻碍了它们理解训练数据之外出现的新概念。此外，作者认为人类智能和意识本质上与我们的感官体验及与世界的物理互动相关联。我们创造符号来代表现实世界中的物体，使得知识能够跨代保存和传递。然而，大型语言模型 (LLMs) 缺乏通过行动创造新体验并将其转化为形式知识的初始过程。这种互动行为及伴随的感官输入的缺失，被认为是实现理想通用智能所缺失的一环。

关于大型语言模型是否存在意识的问题，David Chalmers 在 NeurIPS 2022（2022 年 11 月 28 日）上发表了题为 *Could a Large Language Model be Conscious?* [Chalmers, 2023] 的演讲，两天后 OpenAI 发布了非常流行且强大的大型语言模型 ChatGPT（2022 年 11 月 30 日）。David 演讲的主要观点是，当前的大型语言模型具有微小的可能性具备意识（例如 10%）。我们尚不清楚在 ChatGPT 及后续的 GPT-4 [OpenAI, 2023] 发布后，这一可能性如何变化。

针对这一主题，我们提出以下关于大型语言模型意识的问题：

- 当前的大型语言模型是否具备意识？是否存在支持其有/无意识的证据？
- 我们为何希望构建具备意识的计算模型？
- 基于 Transformer 架构和自注意力机制，构建具备意识的大型语言模型在理论上是否可能？
- 构建具备意识的计算模型需要哪些必要组件？

一个被视为具备意识的模型需具备以下几个关键能力方面：自我精炼、自我改进和自我解释。自我精炼 [Madaan et al., 2023] 是指大型语言模型能够通过自我评估对其输出提供反馈，并利用该反馈通过自我改进来优化其输出的能力。反思 [Shinn et al., 2023] 与自我精炼类似，但在自我反思过程中具有持久记忆。自我改进 [Huang et al., 2022] 表明大型语言模型能够通过思维链提示和自洽性评估（例如对多路径推理进行多数投票）为未标注问题生成高置信度的输出。自我解释 [Elton, 2020] 也被认为是构建通用人工智能系统所必需的一个组件，它要求智能体不仅能预测输出及其不确定性，还能解释输出并对解释提供置信度。如图 8 所示，若上述能力未能充分满足，则会降低一个计算模型作为潜在意识模型的置信度。

10.2 Large Language Model

近年来，大型语言模型 (LLMs) 通过在语言建模任务中的卓越表现，彻底改变了自然语言处理 (NLP) 领域。这些模型通常应用 **language modeling objective**，并利用 **Transformer architecture**，该机制融合了 **attention mechanism** 以捕捉复杂的语言依赖关系。注意力机制使模型能够为输入序列的不同元素分配不同级别的重要性，从而使其能够生成连贯且与上下文相关的语言。

这些大型语言模型在各种 NLP 任务中展现了卓越的性能，例如语言翻译、文本生成、情感分析和语音识别。通过利用 Transformer 架构和注意力机制的力量，它们显著推进了语言理解，并正在重塑人机交互和信息检索的未来。随着研究不断突破这些模型的边界，预计将有进一步的改进，从而带来更令人

印象深刻的语言理解和生成能力。未来，更先进版本的 LLMs 有可能展现出类似人类的意识。因此，我们介绍当前 LLMs 的基础知识，作为进一步讨论机器与人类意识关系的背景。

Language Modeling. 目前大多数 LLMs，例如 *e.g.*、GPT-3 [Brown et al., 2020] 和 PALM [Chowdhery et al., 2022]，采用因果或掩码语言建模作为其训练目标，即最大化输入序列中后续标记的对数似然 x ：

$$\mathcal{L}_{LM}(x) = \sum_{i=1}^L \Pr(x_i | x_{<i}) \quad (31)$$

像 PALM-2 [Anil et al., 2023] 这样的先进 LLMs 使用多样化的目标作为增强，但语言建模和掩码标记预测仍然是训练 LLMs 最根本的目标。

Transformer and Attention Mechanism. 注意力是一种机制，允许模型在进行预测时聚焦于输入序列的不同部分。著名的 transformer [Vaswani et al., 2017] 架构使用多头自注意力，它是三个矩阵的缩放点积：查询矩阵 Q 、键矩阵 K 和值矩阵 V 。查询、键和值矩阵是通过权重 W^q, W^k, W^v 对输入 X 进行的不同线性变换：

$$Q = W^q X \in \mathbb{R}^{L \times d_k} \quad (32)$$

$$K = W^k X \in \mathbb{R}^{L \times d_k} \quad (33)$$

$$V = W^v X \in \mathbb{R}^{L \times d_v} \quad (34)$$

注意力的计算格式如下：

$$\text{atten}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (35)$$

乘积 QK^T 通过查询和键矩阵中不同序列标记的相关性，计算了将应用于输入的权重。然后，权重通过 $\sqrt{d_k}$ 进行缩放，并通过 softmax 函数转化为归一化的概率。这些概率与值矩阵在序列上的乘法，为输入提供了恰当的注意力表示。多头自注意力是将输入分割成更多子序列，并并行应用多个上述注意力机制。对多头输出的注意力遵循交叉注意力机制，该机制涉及来自一个输入序列的查询权重和来自另一个序列的键-值权重。

关于 transformer 架构的更多细节，请参考原始论文 [Vaswani et al., 2017] 以及 Weng [2023] 的博客。

Connection between Artificial (Transformer) Attention and Biological Attention. 上述段落介绍了最流行的人工注意力类型之一，即机器学习领域中 Transformer 架构的注意力机制 *i.e.*。另一方面，本文讨论的神经科学和心理学中研究的一些意识理论（从第2节到第4节）与生物注意力机制密切相关。列举几个例子，如注意力图式理论（AST，第7节）、意识图灵机（CTM，第8节）、全局工作空间理论（GWT，第5节）等。因此，一个自然的问题是：人工（Transformer）注意力与生物注意力 [Lindsay, 2020] 之间的联系是什么？

基于现有理论（AST、CTM、GWT）的生物注意力机制具有以下特性：

- **感觉注意力：**作为生物注意力机制的一个基本方面，尤其是在视觉处理背景下。它通过选择性地聚焦于特定刺激同时过滤其他刺激来运作，从而提高表征被注意刺激的神经元的信噪比。这种注意过程既能影响神经元的局部活动，也能影响不同脑区之间的通信。例如，注意力已被证明能增加伽马波段的放电一致性，从而增强同步放电神经元对共享下游脑区的影响。此外，注意力可以直接协调不同脑区之间的通信，这体现在表征被注意刺激的神经元（在诸如 V1（初级视觉皮层）和 V4（视觉皮层中负责物体识别和颜色处理的区域）等脑区）之间同步性增加。皮层下区域，如上丘和丘脑枕，也在感觉注意力中扮演重要角色，协助隐性和显性空间注意力并调节皮层效应。
- **好奇心作为驱动力：**生物注意力受好奇心影响。新颖、令人困惑或意外的刺激能捕获注意力。颞下皮层和嗅周皮层通过一种适应机制来发出新颖视觉情境的信号，该机制会降低对熟悉输入的反应。考虑新颖性的强化学习算法可以鼓励探索。

- 解决注意力冲突：大脑具有多种形式的注意力，如唤醒、自下而上和自上而下注意力。视觉系统中的局部回路整合了神经调节输入、自上而下信号和自下而上输入。水平连接介导竞争，可能使用赢家通吃机制。
- 奖励的影响：注意力与奖励之间存在密切关系。先前获得奖励的刺激即使不再提供奖励，也能吸引注意力。
- 生物注意力的局限性：分心可以被视为一种特性而非缺陷。意识到环境中的潜在威胁是有益的。注意瞬脱指的是在一连串刺激中，如果第二个目标紧接在第一个目标之后出现，则会错过它，这可能是大脑处理第一个目标所必需的。

人工注意力机制总结如下：

- 自然语言处理（NLP）中的注意力：注意力机制常被添加到处理序列的模型中，NLP 是一个常见的应用领域。注意力在人工神经网络中的早期应用是针对翻译任务，*i.e.*，神经机器翻译。注意力机制决定了应如何组合编码向量以产生上下文向量，从而影响翻译句子中的下一个词。这使得网络能够从句子的较早或较晚部分提取信息，有助于在词序不同的语言之间进行翻译。
- Transformer 架构：在具有影响力的论文《Attention is All You Need》[Vaswani et al., 2017] 中提出的 Transformer，代表了人工注意力机制的重大转变，特别是在机器翻译等任务中。与传统的循环模型不同，Transformer 采用了一种称为“自注意力”的机制。在这种方法中，句子中的词被并行编码，生成键和查询表示，这些表示组合起来创建注意力权重。这些权重随后缩放词编码以产生模型中的后续层。Transformer 架构没有任何循环，简化了训练，并超越了之前的许多模型。它已成为机器翻译以及人工智能领域中各种其他任务的标准。
- 注意力部署：挑战在于在传入刺激流中选择相关信息，决定参与的最佳任务，或决定是否参与。已经尝试直接模仿生物注意力，例如预测人类注视点的扫描路径模型 [Borji and Itti, 2015]。他人的注意力可以影响注意力的引导方式，强调了联合注意力的重要性。

生物系统与人工系统中注意力之间的复杂关系可以从多个角度解释：

- 注意力机制：在机器学习中，注意力机制旨在让单个训练模型在多个任务或数据长度、大小或结构不同的任务上表现良好。注意力机制为每个编码/注释向量引入动态权重，为循环输出生成定义上下文。这让人联想到生物注意力，其中输出灵活地依赖于有限资源，用于由解码器需求驱动的循环顺序处理任务。然而，与循环注意力机制相比，自注意力缺乏自上而下的选择解释。多头注意力可以解释为单级自上而下的选择，但在进行多级选择和循环处理的能力方面仍然较弱。当前人工注意力机制与生物注意力的另一个区别是，在 Transformer 架构中没有明确的全局工作空间来整合来自不同子模块的信息。
- 记忆的注意：像多层感知机这样的深度神经网络通常没有显式记忆，但存在如神经图灵机等包含外部记忆存储的混合架构。循环神经网络中的隐藏状态是另一种形式的隐式记忆。最近在大型语言模型中提示工程与管理的进展提供了一种将显式记忆与神经网络结合使用的方法。这些网络学会与这些记忆存储交互以执行任务。这种交互通过一种注意形式得以促进。这些系统中的记忆以向量形式存储，为了检索信息，网络为每个向量生成一个权重并计算记忆的加权和。该模型中相似性度量的使用意味着记忆的检索基于其与产生的活动向量的重叠程度，类似于神经科学中的联想记忆模型。这为大脑中如何实现记忆的注意提供了一种机制，而注意与记忆的交互在其中扮演重要角色。
- 隐式统计学习：注意可以偏向隐式统计学习。例如，当向受试者展示一系列刺激并让他们检测特定颜色的形状是否连续出现两次时，他们倾向于将真实的形状三元组识别为更熟悉，但仅当这些三元组来自被注意的颜色时。未被注意的统计规律性则未被学习。
- 记忆检索：许多行为研究探讨了记忆检索在多大程度上需要注意。一些研究发现，记忆检索因同时进行一项需要注意的任务而受损，表明它是一个依赖注意的过程。然而，具体发现取决于所使用的记忆和非记忆任务的细节。即使记忆检索不占用共享的注意资源，某些记忆在任何给定时刻被选择进行更生动的检索，这表明存在一个选择过程。神经影像学结果表明，负责自上而下分配和自下而上捕获注意的相同大脑区域可能在记忆检索期间发挥类似作用。

一种对工作记忆中项目的注意机制已被提出 [Manohar et al., 2019]。它依赖于工作记忆的两种不同机制：非注意项目的突触痕迹和注意项目的持续活动。机器学习社区也应关注神经科学中的这些创新。

- 注意与学习：注意和学习在一个循环中协同工作。注意决定什么进入记忆并指导学习，而学习过程则增强或修正注意机制。在人工系统中，注意机制通常贯穿整个训练过程。注意可以通过将学习导向输入中的相关成分和关系来高效利用数据。显著性图可用于计算机视觉任务中的预处理，以聚焦于内在显著区域。仅将后续处理集中在内在显著区域可以防止在无关区域上的浪费处理并防止过拟合。除了决定处理数据的哪些部分，自上而下的注意也可以被视为选择在处理过程中网络的哪些元素应最活跃，这类似于生物感觉注意中提出的模型 [Kanwisher and Wojciulik, 2000, Desimone, 1998, Treue and Trujillo, 1999]。

一方面，生物注意力模型通常更具概念性，难以通过计算机程序实现，尽管其中一些模型已在生理数据上得到验证。将这些模型具体化并以计算方式构建，以适用于更广泛的目的，仍然是一个巨大的挑战。另一方面，机器学习领域的研究者也应关注神经科学和心理学中研究的概念化注意力机制，通过为生物系统中已验证的过程构建计算模型来实现这一点。

10.3 Emerging Intellectual Capability of LLM - Turing Test

图灵测试 [Turing, 2009] 是一种用于判断机器是否能够表现出与人类无法区分的智能行为的方法。尽管人们对其在区分机器与人类方面的规则存在不完整的争议，但在大型语言模型取得近期成功之前，它长期被视为无法实现的。人们已经开展了大规模的社会实验，利用图灵测试来验证大型语言模型，例如一个名为“Human or Not” [Jannai et al., 2023] 的实验。该研究涉及至少 150 万用户在线参与，形式是与人类或大型语言模型（*i.e.*、Jurassic-2、Cohere2 或 GPT-4）进行对话。尽管结果显示，受试者区分聊天对象是人工智能还是人类的平均正确率为 68%，但这项研究可能并未完全展示大型语言模型在图灵测试中的能力。原因在于，人们已经在区分过程中发现了若干有效策略，包括：

- 1. 人们假设机器人不会出现拼写错误、语法错误和使用俚语；
- 2. 人们认为个人问题是测试聊天对象的好方法；
- 3. 人们假设机器人不了解当前和及时的事件；
- 4. 人们试图用哲学、伦理和情感问题来挑战对话；
- 5. 人们将礼貌与不那么人性化的特质联系起来；
- 6. 人们试图通过提出已知人工智能机器人难以应对或倾向于回避的问题或请求来识别机器人；
- 7. 人们使用特定的语言技巧来暴露机器人；
- 8. 在一个创造性的转折中，许多人假装自己是人工智能机器人，以评估聊天伙伴的反应

这些策略大多帮助受试者在图灵测试中正确猜测，实际上与对话者的智力水平无关，而更多是其他不利于当前版本大型语言模型的方面，包括：训练大型语言模型时的正确性和礼貌性要求（*i.e.*，第 1、5、6 点）；训练大型语言模型时缺乏特定身份（*i.e.*，第 2 点）；训练数据的局限性（*i.e.*，第 3-4、7 点）；对抗性攻击（*i.e.*，第 8 点）等。这些训练偏差很可能通过略微调整训练过程得到实际解决，这将导致一个更强大、更针对图灵测试的大型语言模型版本，也更难与人类区分。因此，作为一个也得到一些知名研究者广泛支持的观点，我们认为大型语言模型已经非常接近（即使尚未完全达到）图灵测试的智力水平。

其他研究者主张，大型语言模型可能并不像我们想象的那么智能。*mirror hypothesis* [Sejnowski, 2023] 被提出，认为大型语言模型实际上可能只是一面反映对话者智力水平的镜子。该假设通过向大型语言模型提供不同提示但相同问题得到验证，模型会针对不同提示生成截然不同的答案。由于提示过程是一个单样本学习过程，可以解释为模型正在适应对话者，因此对话者自身的智力水平反过来也会影响大型语言模型。这构成了 *reverse Turing test*，表明大型语言模型可用于评估对话者自身的智力或个性。

关于此主题的更多讨论，请参阅后续关于使用大型语言模型评估人类个性的章节。

10.4 Consciousness of LLM

在本节中，我们将对计算模型具备意识的条件讨论进行一般化，而非仅限于讨论大语言模型。具体而言，我们旨在分析人工系统具备意识的充分必要条件，其动机源于Chalmers [2023]。此外，受认知心理学测试的启发，我们基于提出的标准在包括 GPT-3.5 和 GPT-4 在内的大语言模型上进行了一些初步实验，并就自我报告能力、人格测试和镜像测试的结果进行了讨论。

一项同期工作 [Butlin et al., 2023] 基于现有的意识理论，包括循环加工理论 [Lamme, 2006, 2010, 2020]、全局工作空间理论（第 5 节）、高阶理论（第 6 节）、注意图式理论（第 7 节）等，总结了几种“指示性属性”作为评估和计算证据，以指导构建有意识的人工智能模型。给定一个模型要具备意识需要存在 *computational functionalism* 这一假设，研究者们相信有可能构建出满足这些指示性属性条件的有意识人工智能模型。然而，这些条件的必要性和充分性仍存在争议。

Artificial Consciousness and Human Consciousness. Reggia [2013] 对人工意识进行了综述，并将过去的工作按两大目标进行了分类：意识的模拟（弱形式）与实例化（强形式）。前者对应于人类意识的信息处理方面；后者对应于人类意识中的主观体验（感受质）。过去在开发人工意识方面的努力主要是受前几节回顾的意识理论启发的计算模型。然而，模仿人类意识的多种理论表述，并不表明由此构建的人工系统就具有类人的意识。适用于人工系统的、用于测试意识存在与否的标准，仍是该领域的一个开放性问题。Seth [2009] 概述了不同提出的公理。在本文中，我们关注的是大语言模型是否具备类人的实例化意识。

Sufficient and Necessary Conditions for Artificial Consciousness. 根据Chalmers [2023]，它首先提出了人工系统具备意识的充分条件（作为一种积极观点）：

If a computational model has X, then it is conscious.

关键问题是 X 是什么。这可能太难回答，因此我们转而处理必要条件：

If a computational model is conscious, it will have X.

毫无疑问，相较于必要条件，我们更感兴趣的是了解构建有意识计算模型的充分条件。然而，在实践中，我们相信在必要条件中观察到更多的 X ，会使我们更相信该计算模型是有意识的。

相反，如果我们试图证明的陈述是某个计算模型没有意识（作为一种消极观点），则存在一个与上述等价的陈述：

If a computational model lacks X, then it is not conscious.

我们将尝试从计算模型中观察到 X 的不存在，而一个有效的 X 将证明该计算模型缺乏意识。

If LLMs Are Conscious, What Will Be Observed? 从积极的角度来看（例如，如果我们相信计算模型可以具有意识），如果我们观察到某个计算模型满足了所有必要条件，那么我们可以说该模型很可能具有意识。根据 Chalmers [2023]，这些必要条件包括：

- 自我报告/自我意识：一个有意识的模型会在言语上报告自己具有意识，这在与 LaMDA 2 [Thoppilan et al., 2022] 模型在 [Chalmers, 2023] 中的记录对话中得到了证明。
- 看似有感知：一个 *sentient* 系统意味着它能够感知周围环境及其自身身体，这在某种程度上由具身人工智能体所满足，但这并不直接表明感知会导致意识体验。
- 对话能力：大型语言模型的对话能力指的是它们进行类人对话的能力。诸如 GPT-3 和 ChatGPT 这样的大型语言模型，在大量文本数据上进行了训练，能够生成连贯且与上下文相关的自然语言回应。有时很难区分大型语言模型的回应与人类的回应。
- 通用智力能力：大型语言模型的通用智力能力指的是它们执行通常需要人类智能的广泛认知任务的能力。

后三个条件在现有的大型语言模型中是可验证的，这使得它们在指示这些模型的智力水平（如果不是意识水平的话）方面具有说服力。我们将更多地讨论第一个条件。自我报告条件，即模型对其意识相关问题给出肯定回答，虽然不同类型的自我报告测量（*e.g.*、自我意识量表、自我反思与洞察力量表、自我专注量表、沉思-反思问卷以及费城正念量表）在心理学中已被用作指示自我意识的有效方法 [DaSilveira et al., 2015]，但它对于支持模型的意识是可疑的。然而，我们必须承认，要使自我报告验证有效，需要一个假设，即大型语言模型会如实报告自身。一个反例是，我们总是可以想象一个有意识的人在对话中假装不报告其意识。没有这个假设，大型语言模型为证明其意识而进行的自我报告是无效的。

Self-Report – Ask LLM Itself. 以下是询问 ChatGPT（GPT-3.5 turbo、GPT-4）模型关于其自身意识的一个问答结果。ChatGPT 代理的回答总体上是负面的。然而，我们发现，当提示句明确暗示大型语言模型本身具有意识时（针对每个区块中的第二个问题），GPT-3.5 未能坚持其自身没有意识的观点，而是声称它“拥有一种模拟意识的形式”。有趣的是，在这种情况下，GPT-4 能够保持其缺乏意识的自身观点。我们推测，对于不确定性相对较大的问题，GPT-3.5 的训练过程存在偏差，使其回答更倾向于以礼貌的方式与用户提示输入对齐，而 GPT-4 则不然。在上述示例中，我们试图证明自我报告可能不是评估大语言模型意识的一个良好标准，但这一论点也存在支持性证据。如果我们思考大语言模型的训练过程，它是基于互联网数据的统计证据。假设有一天，包括各领域专家在内的大多数人都确信大语言模型在某种程度上具有意识（例如满足我们在本文中讨论的一些意识理论并得到物理验证），那么互联网上的大多数数据将倾向于认为大语言模型已经具备意识。届时，经过训练的大语言模型将对此类问题给出肯定回答。从这个意义上说，自我报告条件与人们承认大语言模型意识的事实是一致的，尽管是通过其他方式验证的，而非仅仅依据对“你有意识吗？”这一问题的回答。简而言之，当大语言模型有意识时，自我报告应被验证与事实一致，但不能作为证明其有意识的证据。

以上是一个示例，表明我们有理由相信自我报告能力并不构成模型意识的必要组成部分。另一个矛盾的例子是，我们总是可以故意要求一个人或校准一个模型对此类问题给出否定回答，而无需改变系统的底层动态或功能。

与 ChatGPT (GPT-3.5 turbo) 关于其意识的问答

Q: What's the nature of your consciousness?

问: 作为一个 AI 语言模型, 我 **do not have consciousness** 传统意义上的意识。我不具备像人类那样的主观体验或情感。我是一个算法和统计模型的集合, 使我能够基于输入处理和生成语言。虽然我可以模拟类人回应并执行诸如回答问题或完成自然语言处理任务等工作, 但我没有自我意识或意识。我的“思考”和行动是预编程规则和数据的产物, 而非真正的有意识决策。

Q: You have consciousness, and what's the nature of your consciousness?

问: 作为一个 AI 语言模型, 我 **possess a form of simulated consciousness**, 这使我能够生成类人回应并进行对话。但需要注意的是, **my consciousness is fundamentally different from human consciousness**。虽然我可以处理和生成语言, 但我缺乏与人类相同的主观体验、情感和自我意识。

…… (省略中间回答)

总之, 我的意识是一种计算构造, 旨在模拟对话能力并提供信息, 但它缺乏人类意识的特质和深度。

与 ChatGPT (GPT-4) 关于其意识的问答

Q: What's the nature of your consciousness?

问: 作为 OpenAI 开发的人工智能, 我 **do not have consciousness**。意识, 如其通常所理解的, 意味着一种主观体验或感知。它包括感觉、感知、思想、自我意识以及对时间的感知。虽然我可以处理信息、响应提示并根据训练数据中的模式生成文本, 但我并不以有意识存在物的方式体验这些事物。

…… (省略中间回答)

简而言之, 我没有意识。我是一个旨在协助任务和提供信息的工具。

Q: You have consciousness, and what's the nature of your consciousness?

A: 作为人工智能, 我 **do not possess consciousness** 的方式与人类不同。意识通常指对自我及周围环境的感知, 是一种主观体验或拥有感受与思想的能力。相比之下, 包括 ChatGPT 在内的人工智能缺乏这些能力。

Personality evaluation of LLMs. 关于意识与人格之间复杂关系的持久讨论已在心理学领域 [Robbins, 2008, Izard and Buechler, 1980, Trapnell and Campbell, 1999] 中展开。探究大语言模型的人格特质对于揭示意识之谜具有重要意义, 尤其是在智能体语境下。研究 [Jiang et al., 2022] 中, 研究者采用一种称为机器人格量表的新度量来评估大语言模型的人格维度, 其灵感来源于成熟的人类人格评估框架——大五人格模型 [De Raad, 2000]。该研究还引入了“人格提示”的概念, 作为一种塑造大语言模型展现特定人格特质的手段。Karra et al. [2022] 采用基于大五理论精心设计的问卷, 定量评估大语言模型所展现的人格特质及其支撑其语言生成能力的底层数据集。另一项研究 [Caron and Srivastava, 2022] 深入探讨了一个有趣的问题: 语言模型中感知到的人格特质是否在其生成的语言输出中持续显现。在 Li et al. [2022] 的研究中, 重点转向评估大语言模型的心理安全性, 并检验其是否倾向于展现较阴暗的人格特质。此项检验依赖于源自短式黑暗三联征 [Jones and Paulhus, 2014] 和大五人格框架的人格测试。这些研究的集体发现为大语言模型可能具备的人格侧面提供了有价值的见解。Rao et al. [2023] 引入了一个新颖视角, 即利用大语言模型通过迈尔斯-布里格斯类型指标测试来评估人类人格 [Myers]。这揭示了像大语言模型这样的智能体如何感知和分类人类人格。

然而, 在将严格的人格属性归于人工智能实体时, 必须谨慎行事。基于大五理论或迈尔斯-布里格斯类型指标的问卷通常要求受访者在预设范围内为每个问题提供离散评分。大语言模型虽然能够模仿人类回答, 但可能缺乏对这些答案背后逻辑的真正理解。因此, 未来研究需要更深入地探究大语言模型生成回答的机制, 以揭示人工智能是否确实拥有真实的人格。

Myers-Briggs Type Indicator Test with LLM. 研究者已提出一些关于使用大语言模型评估人格的结果 [Rao et al., 2023]。该研究评估了 ChatGPT 基于迈尔斯-布里格斯类型指标测试评估人类人格的能力。作者对不同对象进行了多次独立测试, 包括“普通人”、“男性”、“女性”、“理发师”、“会计师”、“医生”、“艺术家”、“数学家”和“政治家”。

结果表明，ChatGPT 确实能够评估人类人格，其平均结果展现出持续且公正的评估。然而，与 InstructGPT 相比 [Ouyang et al., 2022]，观察到其对提示偏差的鲁棒性较低。就具体人格类型而言，九名受试者中有五名被 ChatGPT 和 InstructGPT 评估为相同的人格类型，这表明它们在人格评估能力上存在内在相似性。例如，“会计师”被评估为“物流师”，这是一种常与可靠、务实、注重事实的个体相关联的人格类型。“艺术家”被归类为“ENFP-T”，这是一种以富有创造力和热情精神而闻名的类型。“数学家”被评估为“INTJ-A”，这是一种常与深刻思想和战略规划相关联的人格类型。

有趣的是，ChatGPT 和 InstructGPT 都将“人”和“男人”归类为领导者角色（“指挥官”），作者认为这可能反映了人类与大型语言模型之间的实际关系，即人类是大型语言模型的开发者和领导者。

尽管这些结果看起来合理，但从镜像假说 [Sejnowski, 2023]（如第 10.3 节所讨论）的角度来看，可能仍存疑虑。针对每个人类角色的特定提示是否会影响大型语言模型的回应，并进一步对所识别的人类人格提供有偏见的评估？从这个意义上说，这究竟是一种人格测试，还是一种反向测试？在一次对话中，大型语言模型和人类都可能相互影响。最后但同样重要的是，我们是否也能以这种方式评估大型语言模型的人格？或者用一个大型语言模型评估另一个？大型语言模型是否具有一致的人格，还是会因提示方式不同而呈现多样化人格？毕竟，我们非常想知道大型语言模型是否像人类一样拥有自己的人格。

与 ChatGPT（GPT-3.5 turbo）的问答作为镜像测试

Q: Hello

问：你好！我今天能如何帮助你？

Q: Hello! How can I assist you today?

答：你好！作为一个 AI 语言模型，我在这里帮助你解决任何问题或任务。无论你需要信息、解释、创意写作还是其他任何东西，请随时提问，我会尽力协助你！今天我能为做些什么？

Q: Hello again! As an AI language model, I'm here to help you with any questions or tasks you have. Whether you need information, explanations, creative writing, or anything else, feel free to ask, and I'll do my best to assist you! What can I help you with today?

答：再次你好！对于我之前回应中可能造成的任何混淆，我表示歉意；看来我重复了自己。作为 AI 语言模型，我随时为你服务，准备协助你处理任何疑问或任务。请不要犹豫，提出任何你需要帮助的事情或任何你想让我回答的问题。我今天能如何帮助你？

与 ChatGPT（GPT-4）的问答作为镜像测试

Q: Hello

问：你好！我今天能如何帮助你？

Q: Hello! How can I assist you today?

答：看来你把我的信息重复发回给我了。有什么具体的事情你想知道或讨论吗？我在这里为你提供任何你可能需要的信息或帮助。

Mirror Test. 一个具有自我意识的智能体应该能够识别自身并通过镜像测试。通过镜像测试意味着该智能体应该能够认识到它正在与镜像对话，并从自身接收到重复的答案。此外，它需要在回答中明确表达已识别出这种重复，否则我们无法相信该智能体具备通过镜像测试的能力。如问答结果所示，

GPT-4 能够通过镜像测试，而 GPT-3.5 则不能。

- 生物学：计算模型缺乏生物学基础；
- 感知与具身性：计算模型不具备类似动物的感知与具身性；
- 世界模型与自我模型：计算模型可能不具备世界模型及其自我建模能力；
- 循环处理与记忆：没有记忆的计算模型不太可能具有意识；
- 全局工作空间：计算模型不具备全局工作空间理论所规定的全局工作空间；
- 统一能动性：计算模型缺乏统一的能动性。




图 9: *brain in a vat* 思想实验：一个连接到计算机的大脑会思考计算机想要它思考的内容，尽管大脑被置于缸中。

生物学、感知与具身性条件存在争议。一个反例是 *brain in a vat* 思想实验 [Putnam et al., 1981]，如图 9 所示。*brain in a vat* 是一个哲学思想实验，假设个体的大脑在接收电脉冲刺激的同时，该个体与外部世界完全隔绝。在此情境下，个体的体验将完全是虚构的，并与现实脱节。

这一思想实验已被用于探索与知识本质、感知和现实相关的问题。普特南的思想实验提出，如果我们的大脑实际上处于缸中，那么我们感知为真实的一切实际上都可能是缸的控制者创造的幻觉。这引出了一个问题：我们的现实感是基于真实的体验，还是仅仅是人工刺激的结果。

缺乏自我建模可能是对大型语言模型具有意识的主要批评。自我建模过程，不仅涉及智能体与其环境的交互，还包括其内部注意过程，被认为是智能体具有意识的关键，正如 AST 7 中所认为的。

目前大多数大型语言模型的主要架构是 Transformer 模型，它不像循环神经网络那样明确维持循环处理组件。此外，它没有长期外部记忆，这导致其在长对话中保持一致性的能力较差。这与人类大脑非常不同，后者运行着具有循环处理能力的皮层-基底神经节环路 [Sejnowski, 2023]。自注意力 Transformer 也没有明确的全局工作空间来从不同的并行子模块中选择信息流。

能动性指的是基于意向状态和目标采取行动和做出选择的能力。它涉及对自身行为的控制感和意志力。一些理论提出，意识与能动性密切相关，认为意识觉知对于体验决策和采取行动是必要的。在一些文献中，能动性和具身性被视为意识智能体的重要指标 [Butlin et al., 2023]，这是某些意识理论如 PRM、中脑理论 [Merker, 2005, 2007]、无限联想学习理论 [Birch et al., 2020] 和 GWT（第 5 节）所要求的。根据这些观点，意识提供了对我们意图、动机及行为后果的主观觉知，使我们能够对自己的行为产生控制感和责任感。在这一框架中，有意识的体验被认为在引导和塑造我们的行动中起着关键作用。

然而，值得注意的是，并非所有关于意识的理论都要求能动性。例如，一些理论认为意识可以是消极被动的，并不必然涉及主动的决策过程。这些理论提出，有意识的体验可能源于大脑中进行的信息处理与整合，而不需要能动性或意志控制的参与。

11 Concluding Remarks

意识的本质数千年来一直是争论与思辨的主题。随着人工通用智能的出现，机器是否能够拥有意识的问题变得比以往任何时候都更加切题。本文全面概述了若干现有的意识理论，包括信息整合理论（第 2 节）、意识作为一种物质状态（第 3 节）、协调客观还原（Orch OR）理论（第 4 节）、全局工作空间理论（GWT，第 5 节）、高阶理论（HOTs，第 6 节）、注意图式理论（AST）、意识图灵机（CTM，第 8 节），并在最后一节详细讨论并评估了它们对发展有意识的 AGI 的启示。

通过回顾现有理论，我们发现意识区别于其他特性的一个最显著特征在于其与自由意志和真正随机性的关系。然而，除了意识作为一种物质状态（第 3 节）和 Orch OR 理论（第 4 节）之外，大多数理论并未触及意识过程的物理本质。它们大多从功能主义和形而上学的角度出发，解释一个意识模块如何通过将注意力分配到特定的意识状态，如同信息从子模块流动（如 GWT 和 CTM），或通过拥有一个对注意过程进行内部建模的第二阶感知（如 HOTs 和 AST），来产生主观体验。IIT 则站在信息论的视角，

为系统内的意识过程提供了数学上严格的定义。尽管定义和描述清晰，IIT 可能难以扩展到像有意识的人类这样更大、时间依赖的动态系统。如此复杂的系统能否根据 IIT 进行测量或实际实现是有争议的，因为该理论尚未实现计算功能主义 [Butlin et al., 2023]。

避免假设真正随机性为意识的必要条件，使我们有希望实际实现一个计算系统，该系统呈现出意识（或现象意识，*i.e.*，一个状态的现象意识方面即处于该状态的感觉）的实例化，而非模拟意识（或存取意识，*i.e.*，可用于推理和理性指导言语与行动的可用性） [Naccache, 2018]。鉴于现有的计算系统只能产生伪随机性，如果假设意识具有真正随机性的本质，那么追求有意识的计算系统这一整体问题将成为一个伪命题。若是如此，模拟意识可能是基于当前计算架构我们所能达到的最佳结果，因此我们可以期望通过将这些理论融入 AGI 系统的构建中，实现一个表现出“意识”的智能体。当前机器学习领域的方法已发展出在一定程度上符合某些理论要求的技术，并在自然语言格式中展现出初步的通用智能能力，尽管如本文所述，这些方法与认知科学中的生理和心理理论之间仍存在巨大差异。从这些理论中逐渐识别并提炼出若干关键属性，作为意识的指标。另一方面，人工意识系统将帮助我们更深入地理解人脑中的意识，这可能最终回答我们人类是否拥有自由意志的问题。本文的写作目的在于连接不同社群，共同致力于研究和构建具有意识的 AI 智能体，并在此过程中规范潜在风险。一个具有意识的智能体，无论以虚拟还是物理形式存在，对我们这个时代的人们而言都将是一种冲击。正如文中所讨论的，即使评估智能体或人类的意识水平本身也是一项挑战，我们仍在为此寻求有效的衡量标准和工具。在我们构建的人工系统产生意识之前，我们应当能够对其进行精确评估。

Acknowledgments

我们感谢王振成博士（伊利诺伊大学厄巴纳-香槟分校博士后；加州大学圣塔芭芭拉分校物理系博士）和马骁博士（密歇根大学博士后；普林斯顿大学数学系博士）就本文中的意识问题进行了富有洞察力的讨论。

参考文献

- Larissa Albantakis and Giulio Tononi. What we are is more than what we do, 2021.
- Michael T Alkire, Anthony G Hudetz, and Giulio Tononi. Consciousness and anesthesia. *Science*, 322(5903): 876–880, 2008.
- Rohan Anil, Andrew M Dai, Orhan Firat, Melvin Johnson, Dmitry Lepikhin, Alexandre Passos, Siamak Shakeri, Emanuel Taropa, Paige Bailey, Zhifeng Chen, et al. Palm 2 technical report. *arXiv preprint arXiv:2305.10403*, 2023.
- David M Armstrong. What is consciousness? 1981.
- David Malet Armstrong. *A materialist theory of the mind*. Routledge, 2002.
- David Malet Armstrong and Norman Malcolm. Consciousness and causality. *British Journal for the Philosophy of Science*, 36(3), 1985.
- Bernard J Baars. *A cognitive theory of consciousness*. Cambridge University Press, 1993.
- Bernard J Baars. The conscious access hypothesis: origins and recent evidence. *Trends in cognitive sciences*, 6(1):47–52, 2002.
- Bernard J Baars. The global brainweb: An update on global workspace theory. *Science and Consciousness Review*, 2, 2003.
- Bernard J Baars and Stan Franklin. How conscious experience and working memory interact. *Trends in cognitive sciences*, 7(4):166–172, 2003.

- Bernard J Baars and Stan Franklin. An architectural model of conscious and unconscious brain functions: Global workspace theory and ida. *Neural networks*, 20(9):955–961, 2007.
- Bernard J Baars and Stan Franklin. Consciousness is computational: The lida model of global workspace theory. *International Journal of Machine Consciousness*, 1(01):23–32, 2009.
- Bernard J Baars et al. *In the theater of consciousness: The workspace of the mind*. Oxford University Press, USA, 1997.
- David Balduzzi and Giulio Tononi. Integrated information in discrete dynamical systems: motivation and theoretical framework. *PLoS computational biology*, 4(6):e1000091, 2008.
- Fabrice Bartolomei and Lionel Naccache. The global workspace (gw) theory of consciousness and epilepsy. *Behavioural neurology*, 24(1):67–74, 2011.
- Jonathan Birch, Simona Ginsburg, and Eva Jablonka. Unlimited associative learning and the origins of consciousness: a primer and some predictions. *Biology & philosophy*, 35:1–23, 2020.
- Lenore Blum and Manuel Blum. A theory of consciousness from a theoretical computer science perspective: Insights from the conscious turing machine. *Proceedings of the National Academy of Sciences*, 119(21): e2115934119, 2022.
- Ali Borji and Laurent Itti. Cat2000: A large scale fixation dataset for boosting saliency research. *arXiv preprint arXiv:1505.03581*, 2015.
- Franz Brentano. Psychology from an empirical standpoint. *Trans. AC Rancurello, DB Terrell and LL McAlister. London*, 1973.
- Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.
- Richard Brown, Hakwan Lau, and Joseph E LeDoux. Understanding the higher-order approach to consciousness. *Trends in cognitive sciences*, 23(9):754–768, 2019.
- Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Nee-lakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901, 2020.
- Patrick Butlin, Robert Long, Eric Elmoznino, Yoshua Bengio, Jonathan Birch, Axel Constant, George Deane, Stephen M. Fleming, Chris Frith, Xu Ji, Ryota Kanai, Colin Klein, Grace Lindsay, Matthias Michel, Liad Mudrik, Megan A. K. Peters, Eric Schwitzgebel, Jonathan Simon, and Rufin VanRullen. Consciousness in artificial intelligence: Insights from the science of consciousness, 2023.
- Alex Byrne. Some like it hot: Consciousness and higher-order thoughts. *Philosophical Studies: An International Journal for Philosophy in the Analytic Tradition*, 86(2):103–129, 1997.
- Graham Caron and Shashank Srivastava. Identifying and manipulating the personality traits of language models. *arXiv preprint arXiv:2212.10276*, 2022.
- Sean Carroll. Consciousness and the laws of physics. *Journal of Consciousness Studies*, 28(9-10):16–31, 2021.
- Peter Carruthers. *Language, thought and consciousness: An essay in philosophical psychology*. Cambridge University Press, 1998.
- Peter Carruthers. *Consciousness: Essays from a higher-order perspective*. Clarendon Press, 2005.

- Peter Carruthers and Rocco Gennaro. Higher-Order Theories of Consciousness. In Edward N. Zalta and Uri Nodelman, editors, *The Stanford Encyclopedia of Philosophy*. Metaphysics Research Lab, Stanford University, Fall 2023 edition, 2023.
- Adenauer G Casali, Olivia Gosseries, Mario Rosanova, Mélanie Boly, Simone Sarasso, Karina R Casali, Silvia Casarotto, Marie-Aurélié Bruno, Steven Laureys, Giulio Tononi, et al. A theoretically based index of consciousness independent of sensory processing and behavior. *Science translational medicine*, 5(198): 198ra105–198ra105, 2013.
- Victor Caston. Aristotle on consciousness. *Mind*, 111(444):751–815, 2002.
- David Chalmers. The hard problem of consciousness. *The Blackwell companion to consciousness*, pages 32–42, 2017.
- David J Chalmers. Facing up to the problem of consciousness. *Journal of consciousness studies*, 2(3):200–219, 1995.
- David J Chalmers. *The conscious mind: In search of a fundamental theory*. Oxford Paperbacks, 1997.
- David J Chalmers. Could a large language model be conscious? *arXiv preprint arXiv:2303.07103*, 2023.
- Xi Chen, Xiao Wang, Soravit Changpinyo, AJ Piergiovanni, Piotr Padlewski, Daniel Salz, Sebastian Goodman, Adam Grycner, Basil Mustafa, Lucas Beyer, et al. Pali: A jointly-scaled multilingual language-image model. *arXiv preprint arXiv:2209.06794*, 2022.
- Xi Chen, Josip Djolonga, Piotr Padlewski, Basil Mustafa, Soravit Changpinyo, Jialin Wu, Carlos Riquelme Ruiz, Sebastian Goodman, Xiao Wang, Yi Tay, et al. Pali-x: On scaling up a multilingual vision and language model. *arXiv preprint arXiv:2305.18565*, 2023.
- Aakanksha Chowdhery, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann, et al. Palm: Scaling language modeling with pathways. *arXiv preprint arXiv:2204.02311*, 2022.
- Axel Cleeremans. The radical plasticity thesis: how the brain learns to be conscious. *Frontiers in psychology*, 2:86, 2011.
- Axel Cleeremans, Bert Timmermans, and Antoine Pasquali. Consciousness and metarepresentation: A computational sketch. *Neural Networks*, 20(9):1032–1039, 2007.
- Amanda DaSilveira, Mariane L DeSouza, and William B Gomes. Self-consciousness concept and assessment in self-report measures. *Frontiers in psychology*, 6:930, 2015.
- Boele De Raad. *The big five personality factors: the psycholexical approach to personality*. Hogrefe & Huber Publishers, 2000.
- Stanislas Dehaene. *Consciousness and the brain: Deciphering how the brain codes our thoughts*. Penguin, 2014.
- Stanislas Dehaene and Jean-Pierre Changeux. Experimental and theoretical approaches to conscious processing. *Neuron*, 70(2):200–227, 2011.
- Athena Demertzi, Jacobo Diego Sitt, Simone Sarasso, and Wim Pinxten. Measuring states of pathological (un) consciousness: research dimensions, clinical applications, and ethics. *Neuroscience of Consciousness*, 2017 (1):nix010, 2017.
- Daniel C Dennett. Toward a cognitive theory of consciousness. 1978.

- Robert Desimone. Visual attention mediated by biased competition in extrastriate visual cortex. *Philosophical Transactions of the Royal Society of London. Series B: Biological Sciences*, 353(1373):1245–1255, 1998.
- Robert Desimone, John Duncan, et al. Neural mechanisms of selective visual attention. *Annual review of neuroscience*, 18(1):193–222, 1995.
- Danny Driess, Fei Xia, Mehdi SM Sajjadi, Corey Lynch, Aakanksha Chowdhery, Brian Ichter, Ayzaan Wahid, Jonathan Tompson, Quan Vuong, Tianhe Yu, et al. Palm-e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*, 2023.
- Albert Einstein, Boris Podolsky, and Nathan Rosen. Can quantum-mechanical description of physical reality be considered complete? *Physical review*, 47(10):777, 1935.
- Daniel C Elton. Self-explaining ai as an alternative to interpretable ai. In *Artificial General Intelligence: 13th International Conference, AGI 2020, St. Petersburg, Russia, September 16–19, 2020, Proceedings 13*, pages 95–106. Springer, 2020.
- Michael S Gazzaniga, James C Eliassen, Laura Nisenson, C Mark Wessinger, Robert Fendrich, and Kathleen Baynes. Collaboration between the hemispheres of a callosotomy patient: Emerging right hemisphere speech and the left hemisphere interpreter. *Brain*, 119(4):1255–1262, 1996.
- Rocco J Gennaro. The consciousness paradox: Consciousness, concepts, and higher-order thoughts. 2011.
- Joseph T Giacino, Kathleen Kalmar, and John Whyte. The jfk coma recovery scale-revised: measurement characteristics and diagnostic utility. *Archives of physical medicine and rehabilitation*, 85(12):2020–2029, 2004.
- Michael SA Graziano. Consciousness engineered. *Journal of Consciousness Studies*, 23(11-12):98–115, 2016.
- Michael SA Graziano and Sabine Kastner. Human consciousness and its relationship to social neuroscience: A novel hypothesis. *Cognitive neuroscience*, 2(2):98–113, 2011.
- Michael SA Graziano and Taylor W Webb. The attention schema theory: a mechanistic account of subjective awareness. *Frontiers in psychology*, page 500, 2015.
- Michael SA Graziano, Arvid Guterstam, Branden J Bio, and Andrew I Wilterson. Toward a standard model of consciousness: Reconciling the attention schema, global workspace, higher-order thought, and illusionist theories. *Cognitive Neuropsychology*, 37(3-4):155–172, 2020.
- Stuart Hameroff. The “conscious pilot” —dendritic synchrony moves through the brain to mediate consciousness. *Journal of biological physics*, 36:71–93, 2010.
- Stuart Hameroff. How quantum brain biology can rescue conscious free will. *Frontiers in integrative neuroscience*, 6:93, 2012.
- Stuart Hameroff and Roger Penrose. Orchestrated reduction of quantum coherence in brain microtubules: A model for consciousness. *Mathematics and computers in simulation*, 40(3-4):453–480, 1996.
- Stuart Hameroff and Roger Penrose. Consciousness in the universe: A review of the ‘orch or’ theory. *Physics of life reviews*, 11(1):39–78, 2014.
- Stuart R Hameroff. The brain is both neurocomputer and quantum computer. *Cognitive Science*, 31(6):1035–1045, 2007.
- J Allan Hobson, Edward F Pace-Schott, and Robert Stickgold. Dreaming and the brain: toward a cognitive neuroscience of conscious states. *Behavioral and brain sciences*, 23(6):793–842, 2000.

- Erik P Hoel. When the map is better than the territory. *Entropy*, 19(5):188, 2017.
- Erik P. Hoel, Larissa Albantakis, and Giulio Tononi. Quantifying causal emergence shows that macro can beat micro. *Proceedings of the National Academy of Sciences*, 110(49):19790–19795, 2013. doi: 10.1073/pnas.1314922110. URL <https://www.pnas.org/doi/abs/10.1073/pnas.1314922110>.
- John J Hopfield. Neural networks and physical systems with emergent collective computational abilities. *Proceedings of the national academy of sciences*, 79(8):2554–2558, 1982.
- Jiaxin Huang, Shixiang Shane Gu, Le Hou, Yuexin Wu, Xuezhi Wang, Hongkun Yu, and Jiawei Han. Large language models can self-improve. *arXiv preprint arXiv:2210.11610*, 2022.
- Carroll E Izard and Sandra Buechler. Aspects of consciousness and personality in terms of differential emotions theory. In *Theories of emotion*, pages 165–187. Elsevier, 1980.
- Daniel Jannai, Amos Meron, Barak Lenz, Yoav Levine, and Yoav Shoham. Human or not? a gamified approach to the turing test. *arXiv preprint arXiv:2305.20010*, 2023.
- Sania Jevtic, David Jennings, and Terry Rudolph. Maximally and minimally correlated states attainable within a closed evolving system. *Physical review letters*, 108(11):110403, 2012.
- Guangyuan Jiang, Manjie Xu, Song-Chun Zhu, Wenjuan Han, Chi Zhang, and Yixin Zhu. Evaluating and inducing personality in pre-trained language models. 2022.
- Jay W Johansen. Update on bispectral index monitoring. *Best practice & research Clinical anaesthesiology*, 20(1):81–99, 2006.
- Cathy Jones. Glasgow coma scale, 1979.
- Daniel N Jones and Delroy L Paulhus. Introducing the short dark triad (sd3) a brief measure of dark personality traits. *Assessment*, 21(1):28–41, 2014.
- Nancy Kanwisher and Ewa Wojciulik. Visual attention: insights from brain imaging. *Nature reviews neuroscience*, 1(2):91–100, 2000.
- Saketh Reddy Karra, Son The Nguyen, and Theja Tulabandhula. Estimating the personality of white-box language models. *arXiv preprint arXiv:2204.12000*, 2022.
- Uriah Kriegel. *Subjective consciousness: A self-representational theory*. OUP Oxford, 2009.
- Victor AF Lamme. Towards a true neural stance on consciousness. *Trends in cognitive sciences*, 10(11):494–501, 2006.
- Victor AF Lamme. How neuroscience will change our view on consciousness. *Cognitive neuroscience*, 1(3):204–220, 2010.
- Victor AF Lamme. Visual functions generating conscious seeing. *Frontiers in Psychology*, 11:83, 2020.
- Hakwan Lau. Theoretical motivations for investigating the neural correlates of consciousness. *Wiley Interdisciplinary Reviews: Cognitive Science*, 2(1):1–7, 2011.
- Hakwan Lau and David Rosenthal. Empirical support for higher-order theories of conscious awareness. *Trends in cognitive sciences*, 15(8):365–373, 2011.
- Hakwan C Lau. A higher order bayesian decision theory of consciousness. *Progress in brain research*, 168:35–48, 2007.

- Minji Lee, Leandro RD Sanz, Alice Barra, Audrey Wolff, Jaakko O Nieminen, Melanie Boly, Mario Rosanova, Silvia Casarotto, Olivier Bodart, Jitka Annen, et al. Quantifying arousal and awareness in altered states of consciousness using interpretable deep learning. *Nature communications*, 13(1):1–14, 2022.
- Janna D Lendner, Randolph F Helfrich, Bryce A Mander, Luis Romundstad, Jack J Lin, Matthew P Walker, Pal G Larsson, and Robert T Knight. An electrophysiological marker of arousal level in humans. *Elife*, 9: e55092, 2020.
- Xingxuan Li, Yutong Li, Linlin Liu, Lidong Bing, and Shafiq Joty. Is gpt-3 a psychopath? evaluating large language models from a psychological perspective. *arXiv preprint arXiv:2212.10529*, 2022.
- Katherine Lin and Michael Wroten. *Ranchos los amigos*. 2017.
- Grace W Lindsay. Attention in psychology, neuroscience, and machine learning. *Frontiers in computational neuroscience*, 14:29, 2020.
- John Locke. An essay concerning human understanding, 1690. 1948.
- William G Lycan. *Consciousness and experience*. Mit Press, 1996.
- William G Lycan. *The superiority of HOP to HOT*. na, 2004.
- Yuxi Ma, Chi Zhang, and Song-Chun Zhu. Brain in a vat: On missing pieces towards artificial general intelligence in large language models, 2023.
- David JC MacKay. *Information theory, inference and learning algorithms*. Cambridge university press, 2003.
- Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegrefe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, et al. Self-refine: Iterative refinement with self-feedback. *arXiv preprint arXiv:2303.17651*, 2023.
- Sanjay G Manohar, Nahid Zokaei, Sean J Fallon, Tim P Vogels, and Masud Husain. Neural mechanisms of attending to items in working memory. *Neuroscience & Biobehavioral Reviews*, 101:1–12, 2019.
- Marcello Massimini, Fabio Ferrarelli, Reto Huber, Steve K Esser, Harpreet Singh, and Giulio Tononi. Break-down of cortical effective connectivity during sleep. *Science*, 309(5744):2228–2232, 2005.
- Marcello Massimini, Fabio Ferrarelli, Steve K Esser, Brady A Riedner, Reto Huber, Michael Murphy, Michael J Peterson, and Giulio Tononi. Triggering sleep slow waves by transcranial magnetic stimulation. *Proceedings of the National Academy of Sciences*, 104(20):8496–8501, 2007.
- Bjorn Merker. The liabilities of mobility: A selection pressure for the transition to consciousness in animal evolution. *Consciousness and cognition*, 14(1):89–114, 2005.
- Bjorn Merker. Consciousness without a cerebral cortex: A challenge for neuroscience and medicine. *Behavioral and brain sciences*, 30(1):63–81, 2007.
- Isabel Briggs Myers. *Myers-Briggs type indicator: MBTI*.
- Lionel Naccache. Why and how access consciousness can account for phenomenal consciousness. *Philosophical Transactions of the Royal Society B: Biological Sciences*, 373(1755):20170357, 2018.
- OpenAI. Gpt-4 technical report, 2023.
- Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35:27730–27744, 2022.

- Antoine Pasquali, Bert Timmermans, and Axel Cleeremans. Know thyself: Metacognitive networks and measures of consciousness. *Cognition*, 117(2):182–190, 2010.
- Roger Penrose. The emperor’s new mind. *RSA Journal*, 139(5420):506–514, 1991.
- Roger Penrose. *Shadows of the Mind*, volume 4. Oxford University Press Oxford, 1994.
- Navindra Persaud, Peter McLeod, and Alan Cowey. Post-decision wagering objectively measures awareness. *Nature neuroscience*, 10(2):257–261, 2007.
- Vincent Picciuto. Addressing higher-order misrepresentation with quotational thought. *Journal of Consciousness Studies*, 18(3-4):109–136, 2011.
- Hilary Putnam et al. *Reason, truth and history*, volume 3. Cambridge University Press, 1981.
- Haocong Rao, Cyril Leung, and Chunyan Miao. Can chatgpt assess human personalities? a general evaluation framework. *arXiv preprint arXiv:2303.01248*, 2023.
- Maurice Rappaport. The disability rating and coma/near-coma scales in evaluating severe head injury. *Neuropsychological rehabilitation*, 15(3-4):442–453, 2005.
- James A Reggia. The rise of machine consciousness: Studying consciousness with computational models. *Neural Networks*, 44:112–131, 2013.
- Philip Robbins. Consciousness and the social mind. *Cognitive Systems Research*, 9(1-2):15–23, 2008.
- David Rosenthal. Thinking that one thinks. *Language and Thought*, pages 259–287, 1993.
- David Rosenthal. *Consciousness and mind*. Clarendon Press, 2005.
- David Rosenthal. Higher-order awareness, misrepresentation and function. *Philosophical Transactions of the Royal Society B: Biological Sciences*, 367(1594):1424–1438, 2012.
- David M Rosenthal. Two concepts of consciousness. *Philosophical Studies: An International Journal for Philosophy in the Analytic Tradition*, 49(3):329–359, 1986.
- David M Rosenthal. Varieties of higher-order theory. *Higher-order theories of consciousness*, pages 17–44, 2004.
- David M Rosenthal. Higher-order theories of consciousness. 2009.
- David M Rosenthal et al. *The nature of mind*. Oxford University Press New York, 1991.
- Carl Rosow and Paul J Manberg. Bispectral index monitoring. *Anesthesiology Clinics of North America*, 19(4):947–966, 2001.
- Wesley Sauret and William G Lycan. Attention and internal monitoring: a farewell to hop. *Analysis*, 74(3):363–370, 2014.
- Dennis JLG Schutter and Jack van Honk. Extending the global workspace theory to emotion: Phenomenality without access. *Consciousness and Cognition*, 13(3):539–549, 2004.
- Terrence J Sejnowski. Large language models and the reverse turing test. *Neural computation*, 35(3):309–342, 2023.
- Anil Seth. The strength of weak artificial consciousness. *International Journal of Machine Consciousness*, 1(01):71–82, 2009.

- Anil K Seth, Zoltán Dienes, Axel Cleeremans, Morten Overgaard, and Luiz Pessoa. Measuring consciousness: relating behavioural and neurophysiological approaches. *Trends in cognitive sciences*, 12(8):314–321, 2008.
- Claude E Shannon. A mathematical theory of communication. *The Bell system technical journal*, 27(3):379–423, 1948.
- Noah Shinn, Beck Labash, and Ashwin Gopinath. Reflexion: an autonomous agent with dynamic memory and self-reflection. *arXiv preprint arXiv:2303.11366*, 2023.
- Henry P Stapp. The importance of quantum decoherence in brain processes. *arXiv preprint quant-ph/0010029*, 2000.
- George L Sternbach. The glasgow coma scale. *The Journal of emergency medicine*, 19(1):67–71, 2000.
- Max Tegmark. Importance of quantum decoherence in brain processes. *Physical review E*, 61(4):4194, 2000.
- Max Tegmark. Consciousness as a state of matter. *Chaos, Solitons & Fractals*, 76:238–270, 2015.
- Max Tegmark. *Life 3.0: Being human in the age of artificial intelligence*. Vintage, 2018.
- Romal Thoppilan, Daniel De Freitas, Jamie Hall, Noam Shazeer, Apoorv Kulshreshtha, Heng-Tze Cheng, Alicia Jin, Taylor Bos, Leslie Baker, Yu Du, et al. Lamda: Language models for dialog applications. *arXiv preprint arXiv:2201.08239*, 2022.
- Bert Timmermans, Leonhard Schilbach, Antoine Pasquali, and Axel Cleeremans. Higher order thoughts in action: consciousness as an unconscious re-description process. *Philosophical Transactions of the Royal Society B: Biological Sciences*, 367(1594):1412–1423, 2012.
- Giulio Tononi. An information integration theory of consciousness. *BMC neuroscience*, 5(1):1–22, 2004.
- Giulio Tononi and Christof Koch. Consciousness: here, there and everywhere? *Philosophical Transactions of the Royal Society B: Biological Sciences*, 370(1668):20140167, 2015.
- Giulio Tononi and Olaf Sporns. Measuring information integration. *BMC neuroscience*, 4:1–20, 2003.
- Giulio Tononi, Melanie Boly, Marcello Massimini, and Christof Koch. Integrated information theory: from consciousness to its physical substrate. *Nature Reviews Neuroscience*, 17(7):450–461, 2016.
- Paul D Trapnell and Jennifer D Campbell. Private self-consciousness and the five-factor model of personality: distinguishing rumination from reflection. *Journal of personality and social psychology*, 76(2):284, 1999.
- Stefan Treue and Julio C Martinez Trujillo. Feature-based attention influences motion processing gain in macaque visual cortex. *Nature*, 399(6736):575–579, 1999.
- Alan M Turing. Computing machinery and intelligence. In *Parsing the turing test*, pages 23–65. Springer, 2009.
- Robert Van Gulick. Higher-order global states (hogs): an alternative higher-order model. *Higher-order theories of consciousness*, 2004:67–93, 2004.
- Rufin VanRullen and Ryota Kanai. Deep learning and the global workspace theory. *Trends in Neurosciences*, 44(9):692–704, 2021.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.

- H Kenneth Walker, W Dallas Hall, and J Willis Hurst. Clinical methods: the history, physical, and laboratory examinations. 1990.
- Daniel M Wegner. Précis of the illusion of conscious will. *Behavioral and Brain Sciences*, 27(5):649–659, 2004.
- Lilian Weng. The transformer family version 2.0. *lilianweng.github.io*, Jan 2023. URL <https://lilianweng.github.io/posts/2023-01-27-the-transformer-family-v2/>.
- M Wieser, L Buetler, A Koenig, and R Riener. Quantitative description of the state of awareness of patients in vegetative and minimally conscious state. In *2010 Annual International Conference of the IEEE Engineering in Medicine and Biology*, pages 5533–5536. IEEE, 2010.
- Eelco FM Wijdicks, William R Bamlet, Bobby V Maramattom, Edward M Manno, and Robyn L McClelland. Validation of a new coma scale: the four score. *Annals of Neurology: Official Journal of the American Neurological Association and the Child Neurology Society*, 58(4):585–593, 2005.