

大语言模型与小语言模型协同机制综述

陈毅^{1,2}, 赵佳豪^{1,2}, 韩浩浩^{1,2}

¹ 中国科学院成都计算机应用研究所, 成都, 中国

² 中国科学院大学, 北京, 中国

{chenyi24,zhaojiahao241,hanhaohao24}@mailsucas.ac.cn

摘要

大语言模型 (LLMs) 提供了强大的人工智能能力, 但由于高昂的资源成本和延迟问题而面临部署挑战; 而小语言模型 (SLMs) 则提供了高效性和可部署性, 但性能有所降低。大语言模型与小语言模型之间的协同成为一个关键的范式, 旨在协同平衡这些权衡, 从而推动先进人工智能应用的发展, 尤其是在资源受限的边缘设备上。本综述全面概述了 LLM-SLM 协同, 详细阐述了各种交互机制 (流水线、路由、辅助、蒸馏、融合)、关键使能技术, 以及由低延迟、隐私、个性化和离线操作等设备端需求驱动的多样化应用场景。在强调创建更高效、更适应、更易访问的人工智能的巨大潜力的同时, 我们也讨论了持续存在的挑战, 包括系统开销、模型间一致性、鲁棒的任务分配、评估复杂性以及安全/隐私问题。未来的方向指向更智能的自适应框架、更深度的模型融合, 以及向多模态和具身人工智能的扩展, 这使 LLM-SLM 协同成为下一代实用且无处不在的人工智能的关键驱动力。

1 引言

1.1 研究背景与动机

近年来, 大语言模型在自然语言处理、代码生成、智能问答等领域取得了突破性进展 (brown2020language; openai2023gpt4)。然而, 随着模型参数规模的持续增长, 其计算资源消耗、能源成本以及部署开销也显著上升。特别是在需要低延迟和高隐私的边缘场景, 如智能手机、物联网设备和边缘服务器中, 传统基于云端的大语言模型推理模式面临着严重的可行性挑战 (zhou2024benchmark)。与此同时, 小语言模型因其轻量化的结构、快速的推理速度和易于部署的特点, 在资源受限的设备上得到了广泛应用 (gao2025strategic)。在此背景下, 大语言模型与小语言模型之间的协同机制逐渐成为工业界和学术界的重要研究方向。其旨在通过智能协作, 利用大语言模型的强大能力与小语言模型的高效性, 构建一个更智能、更高效、更可靠的推理系统。

1.2 大小模型协作的定义与范畴

广义而言，大小模型协作是指在一个系统中，大语言模型与小语言模型协同工作、优势互补的机制。这一范式可细分为多个子方向，例如流水线协作、并行协作、条件触发式推理以及知识蒸馏等 (wang2024comprehensive; gao2025strategic)。流水线协作是一种顺序执行模式，其中一个模型的输出作为另一个模型的输入 (wang2024comprehensive)。由于小语言模型通常具有更高的效率，它们常被用于初步处理或生成候选结果，然后传递给大语言模型进行更复杂的推理或知识整合 (gao2025strategic)。在级联推测解码框架中，小语言模型生成草稿响应，而大语言模型并行进行验证和修正，从而提升响应速度 (chen2023speculative)。在条件推理方面，研究提出了利用置信度分数来决定是否调用大语言模型，从而实现按需激活 (gupta2023adaptive)。此外，知识蒸馏使得大语言模型的知识能够通过训练被压缩并迁移到小语言模型中，在保留其计算优势的同时，增强后者对复杂任务的建模能力 (gu2024minillm)。这些研究构成了大小模型协作的核心范畴，并为构建高能效的人工智能系统提供了理论与实践基础。

1.3 端侧大模型的兴起及其对协作研究的推动

端侧大语言模型的出现，正将协作机制研究推向新阶段。近年来，随着芯片性能提升和模型压缩技术成熟，多家科技巨头已开始将终端部署自研大模型。2024 年，苹果将约 30 亿参数的端侧语言模型集成至“Apple Intelligence”系统，以本地处理部分自然语言任务，复杂请求则交由云端模型处理 (apple2024ai)。同样，华为也将轻量化盘古大模型引入鸿蒙智能助手，实现边云协同推理 (huawei2024pangu)。这种架构促使研究者更深入探讨：如何更有效划分 LLM 与 SLM 的任务边界？如何管理边云间的计算卸载与动态路由？协作机制如何提升整体能效与响应质量？相关挑战包括模型选择策略、边云通信开销、隐私保护机制及多模型融合精度等 (zhang2025efficient)。因此，研究大小模型协作机制不仅是理论探索的热点，更是智能终端迈向本地化、高性能、低功耗 AI 推理的关键技术路径。

1.4 本文结构与贡献

本文首先给出引言，阐述研究背景、动机以及大小模型协作的定义与范畴。接着详述相关概念与基础，包括大语言模型与小语言模型的特点、优势与局限，以及二者协作的基础与必要性。第三部分深入探讨大小模型协作的机制与架构，对流水线式、混合/路由式、辅助/增强式、知识蒸馏驱动式、集成/融合式等模式进行分类介绍，并分析实现协作的关键技术。随后，在端侧需求驱动下，讨论协作机制的应用场景，按实时低延迟推理、隐私敏感、任务特定定制、离线/弱网环境、能耗约束等类别展开。最后，提出当前挑战与开放问题，展望未来发展趋势，并总结全文研究意义、价值与思考。

2 相关概念与基础

在深入探讨大语言模型 (LLMs) 与小语言模型 (SLMs) 之间的协作机制之前，有必要系统回顾这两类模型的基本概念、结构特点、优势与局限。它们在模型能力、资源消耗、部署场

景及研究路径上均存在显著差异。正是这种异质性构成了模型协作研究的基本动因。

2.1 大语言模型

2.1.1 定义、架构与特性

大语言模型 (LLMs) 通常指参数量达到数十亿或以上的语言理解与生成模型。其架构大多基于 Transformer 框架, 采用自回归 (如 GPT 系列) 或掩码语言建模策略 (如 BERT、T5) 进行预训练 (brown2020language; raffel2020exploring; openai2023gpt4)。这些模型从海量无监督语料中学习语言结构、知识表示和推理模式, 能够对自然语言文本进行深度建模, 并支持泛化到多种下游任务。

从架构角度看, LLMs 通常由数十至数百个 Transformer 层堆叠而成, 每层包含多头注意力机制、前馈网络、残差连接和归一化操作。随着模型参数量的增加, 其能力并非线性增长, 而是呈现出一定的“涌现现象”。即当模型规模超过某个阈值后, 它们会自动展现出更复杂的语言理解、数学推理和多模态交互等能力 (wei2022emergent; gao2025strategic)。这种非线性的性能跃迁已成为当前探索通用人工智能的重要线索。

2.1.2 优势与局限

LLMs 在通用语言建模方面具有无可比拟的优势。它们展现出强大的泛化能力, 能够通过提示或上下文学习完成多种自然语言处理任务, 包括问答、翻译、摘要、代码生成和知识检索, 显示出零样本和少样本学习的潜力。LLMs 具备深度的语义理解和长文本建模能力, 能够保持上下文逻辑和结构完整性。通过微调或强化学习 (如 RLHF), 可以进一步优化其行为表现和与人类偏好的对齐。

然而, LLMs 的局限性也不容忽视。首先, 资源消耗极高。训练通常需要高性能计算集群 (如 GPU/TPU) 和数周至数月的时间成本, 而推理阶段也面临内存占用大、延迟高等问题。其庞大的体积使其难以部署在资源受限的终端或边缘设备上, 限制了实时应用场景。由于预训练阶段数据的不可控性, 模型可能出现事实性错误、偏见放大和幻觉风险, 增加了实际应用中的安全与伦理成本 (zhang2025efficient)。LLMs 的闭源部署以及依赖云平台进行大模型调用也引发了数据隐私与合规性的担忧 (zhou2024benchmark)。

2.2 小语言模型

2.2.1 定义与特征

小型语言模型 (SLMs) 指参数量级在数百万至数亿之间的模型。其设计目标是在语言建模能力与部署效率之间取得平衡, 在保证基本语言理解能力的同时, 显著降低计算开销与硬件需求。结构上, SLMs 通常是大型模型的压缩版本, 采用更少的 Transformer 层、更小的隐藏维度与更少的注意力头, 同时在推理路径上尽可能简化计算流程 (gu2024minillm; apple2024ai)。

与 LLMs 相比, SLMs 更适合在计算资源受限的平台部署, 例如边缘设备、移动终端与浏览器插件等。其具备推理速度快、能耗低、部署灵活等特点, 是实现本地化、低延迟人机交互

的关键组成部分。在语音助手、文本输入法、智能客服等应用场景中，小模型能够快速响应用户请求，保护用户隐私，并降低对网络与云端的依赖。

2.2.2 优势、局限性与典型构建方法

小模型的突出优势体现在其轻量化、高效率与部署友好性上。一方面，由于其结构紧凑，可在普通 CPU 或低功耗设备上推理，无需依赖高性能 GPU，显著降低了运营成本。另一方面，SLMs 通常具备较好的任务适应性，可通过微调或蒸馏等方式在特定场景下实现性能优化。此外，保持数据处理本地化有助于提升用户隐私保护能力，满足某些合规要求较高的行业需求。

然而不可否认，SLMs 在知识规模、语义表达与推理深度等方面与 LLMs 仍存在明显差距。由于模型容量有限，其难以覆盖广泛领域的知识，面对开放域任务时常常表现出理解不足、生成模糊或逻辑不连贯等问题。在处理长文本处理、复杂推理与多轮对话等任务时，小模型往往难以维持语义连贯性与信息一致性。此外，其泛化能力较弱，在跨领域迁移或零样本学习方面表现不如 LLMs (gupta2023adaptive)。

目前，SLMs 的主流构建方法可归纳为三类：第一，知识蒸馏，通过师生框架将大模型能力压缩至小模型，如 DistilGPT 与 TinyLLaMA；第二，通过在中规模语料上独立训练从头构建轻量模型，如 MiniBERT 与 ALBERT；第三，基于现有模型架构进行剪枝、量化或低秩分解，在压缩尺寸的同时保留部分原有性能 (wang2024comprehensive)。这些方法共同推动了小模型在工业部署中的广泛应用，并为后续协同机制的研究提供了技术储备。

2.3 大语言模型与小语言模型协同的基础与必要性

2.3.1 协同的技术基础：能力与特征的互补性

大语言模型（LLMs）与小语言模型（SLMs）在能力、架构与部署特征上存在显著差异，构成了协同的自然技术基础。

2.3.2 能力边界的互补性

大模型的优势包括强大的上下文理解能力、逻辑推理能力以及多任务泛化能力（例如，GPT-4 在数学推理、代码生成等复杂任务上准确率超过 90%），但其依赖海量训练数据（万亿级参数、千亿级语料）与高算力支持（单次推理成本约 0.1–1）。

反之，小模型的优势在于参数量较小（通常低于 10 亿参数，如 TinyBERT、DistilBERT）、部署灵活（可在手机、智能音箱等边缘设备运行）以及推理速度快（延迟低于 10ms，为大模型的 1/10）。但其在复杂逻辑与长上下文处理方面能力受限（例如，数学题准确率不足 50%）。

协作本质上是大型模型充当复杂决策的“大脑”，小模型作为轻量交互的“神经末梢”，形成“中央处理器 + 边缘节点”的分工体系。

2.3.3 架构与训练的可迁移性

这可通过知识蒸馏技术、参数高效微调等要点实现。知识蒸馏技术通过软标签、中间层特征迁移（如 FitNets）等方法，使大模型能够将隐式知识（如语义表示、推理逻辑）转化为小模型的训练信号，从而让小模型在保持轻量化的同时继承大模型的核心能力（例如，TinyBERT 在 GLUE 基准上以参数量减少 75% 达到 BERT 性能的 96%）。

参数高效微调通过 LoRA、QLoRA 等技术，让小模型能够基于大模型的预训练参数进行局部微调，快速适应特定任务（例如，在医疗问答场景中，小模型经微调后准确率提升 20%）。这形成了“大模型基础 + 小模型专精”的协同训练范式。

2.3.4 部署场景的适应性

在适应性方面，可利用云边协同。大模型依赖高算力云服务器（需数十 GB 显存），适合处理批量复杂任务（如文本生成、多轮对话）。小模型可部署于低算力设备（如树莓派、手机芯片），负责实时交互与本地数据预处理（如语音识别、初步用户意图分析）。二者通过 API 或轻量协议（如 gRPC）进行通信，实现数据流转。

2.3.5 协作的必要性：现实需求驱动的必然选择

在大模型与小模型的协作过程中，应对现实需求至关重要。需要考虑的问题包括计算成本约束、实时性要求、某些层级任务的处理以及多模态性等。

具体而言，在计算能力方面，大模型单次推理的能耗是小模型的数百倍（例如，GPT-4 生成 1000 字消耗的能量约为 TinyBERT 的 500 倍）。在高频交互场景中（例如客服、实时翻译），仅依赖大模型将导致成本飙升（企业级应用月度计算成本可能超过百万元）。此外，边缘设备（例如自动驾驶系统）要求响应延迟低于 50 毫秒。基于云端的大模型推理延迟通常超过 500 毫秒，无法满足需求。小模型的本地部署可实现亚毫秒级响应。与大模型协作可将端到端延迟压缩至 200 毫秒以内（例如智能汽车中的语音交互系统）。复杂任务（例如法律文件生成、科学论文润色）由大模型处理，而简单任务（例如关键词提取、情感分类）则由小模型处理，形成“金字塔式”任务分配体系。在电商客服中，小模型首先识别用户意图（准确率 90

小模型可对图像、语音等多模态数据进行预处理（例如语音转文本、图像特征提取）。大模型执行跨模态推理（例如根据用户语音和表情生成个性化回应），从而降低大模型的输入复杂度（例如多模态处理延迟降低 30）。医疗、金融等领域要求用户数据保留在本地。小模型可在设备上数据进行清洗和匿名化处理（例如从医疗记录中移除姓名和身份证号），仅将匿名化特征传输给大模型，从而避免隐私泄露风险（例如在联邦学习中，小模型在本地训练参数，而大模型聚合全局知识）。小模型结构简单（例如单层 Transformer 或 CNN），其决策逻辑可通过可视化工具进行解释（例如注意力热力图），弥补了大模型的“黑箱”特性（例如在医疗诊断场景中，小模型提供初步结论，大模型进行验证并生成解释性文本）。

除了上述问题，应用场景也需要考虑。大模型难以适应小众领域（例如方言识别、垂直行业知识库）。小模型可针对特定场景进行定制（例如税务领域的小模型仅需 10 亿参数，在政策解读中达到 95SLMs（小型语言模型）凭借其高效性和特异性，已成为人工智能系统中不可

或缺的“前端处理器”。通过与 LLMs 的分工协作，它们显著提升了整体性能和资源利用率。这种架构在工业界得到广泛应用，是实现“大模型 + 小模型”混合生态系统的重要实践。

3 大模型与小模型的协作机制与架构

3.1 协作模式分类

根据大语言模型（LLM）与小语言模型（SLM）之间的交互方式和信息流向，其协作模式可分为流水线式、混合/路由式、辅助/增强式、知识蒸馏驱动式以及集成/融合式协作。

3.1.1 流水线协作

流水线协作是一种顺序执行模式，其中一个模型的输出作为另一个模型的输入 (wang2024comprehensive)。由于 SLM 通常具有更高的效率，它们常被用于执行初步处理或生成候选结果，然后传递给 LLM 进行更复杂的推理或知识整合 (gao2025strategic)。

在推荐系统中，流水线协作被广泛使用。LLM 可以根据用户历史行为和偏好生成一系列候选推荐项目，这利用了 LLM 捕捉用户偏好的强大能力 (lv2025collaboration)。然后，部署在本地设备上的 SLM 可以根据用户的实时交互行为对这些候选项目进行重新排序，从而更准确地反映用户当前的兴趣。这种方法利用了 LLM 的全局理解能力，同时也兼顾了 SLM 对实时数据的快速响应能力 (lv2025collaboration)。

CoGenesis 框架是流水线协作的另一个典型示例，如图 1 所示。在该框架中，部署在用户本地设备上的 SLM 可以访问用户的私有数据和活动日志，并基于此信息处理指令。对于需要更深层次推理的任务，SLM 的输出可以作为输入传递给部署在云基础设施中的 LLM。这种设计保护了用户隐私，同时利用了大型模型的强大能力。此外，SLM 可用于从输入文本中提取关键信息或生成简洁的提示，然后发送给 LLM，以指导其生成更相关的输出 (zhang2024cogenesis; wang2024comprehensive)。

流水线协作的关键在于合理划分任务并设计有效的模型间接口，以确保信息能够在不同模型之间准确、高效地传递 (wang2024comprehensive; liu2025towards; chen2025knowledge; xu2024slmrec)。这种模式的有效性在很大程度上取决于第一个模型提取相关信息的能力以及传递给第二个模型的信息质量。如果 SLM 未能准确捕捉关键信息，或者以不适当的格式传递信息，LLM 的性能将受到不利影响。因此，必须仔细考虑通信协议和交换信息的类型，以确保无缝且有效的协作。流水线协作通常利用 SLM 的效率进行初步处理或上下文收集，将计算密集型和知识依赖型任务卸载给 LLM，从而在速度与准确性之间取得平衡。

3.1.2 混合/路由协作

混合或路由协作指的是使用一种机制（通常称为路由器）来决定哪个模型（LLM 或 SLM）应该处理特定的输入或子任务 (wang2025mixllm; zheng2025citer; lv2025collaboration)。路由决策通常基于任务复杂度、领域、成本、所需延迟或其他预定义的标准。

CITER 框架是路由协作的一个典型示例，如图 2 所示。该框架采用令牌级路由策略，将非关键令牌路由到 SLM 以提高效率，同时将关键令牌路由到 LLM 以确保生成质量。这种细




Figure 1: CoGenesis 框架结构图。1. 上下文感知的指令示例。2. 上下文感知的大语言模型（LLM）在上下文感知方面表现出色，但存在隐私风险。3. 设备端专用小语言模型（SLM）优先考虑隐私，但性能较低。4. 协作的 LLM 和 SLM 增强了隐私保护并提高了性能。

粒度的路由允许系统在效率和质量之间动态调整 (zheng2025citer)。

其他研究工作侧重于开发能够从候选模型池中选择最合适 LLM 的路由器 (varangot2025doing; wang2025mixllm)。这种方法可以扩展到包含 SLM，使路由器能够根据任务需求在不同规模和能力的模型中进行选择。HybridLLM 利用二元分类器来预测查询难度，并相应地路由到不同模型 (yao2025toward)。

级联是一种常见的路由策略，首先尝试使用较小的 LLM 处理输入，并在必要时将查询传递给较大的 LLM (chen2025harnessing; ong2024routellm)。这种方法可以在确保性能的同时降低计算成本。

智能路由需要一种能够准确评估输入特征和可用模型能力以做出最优决策的机制。路由器需要理解任务的复杂性、查询的领域以及系统中每个 LLM 和 SLM 的具体优势和劣势。这可能涉及训练一个单独的模型来预测性能，或使用基于查询特征的启发式方法。在设计路由机制时，平衡成本、延迟和质量是一个关键的考虑因素。更强大的模型通常伴随着更高的成本和延迟，因此路由策略必须根据应用需求权衡这些因素。对于实时应用，延迟可能是最关键的因素，可能会优先为某些查询类型选择更快（但可能准确性较低）的 SLM。对于需要高准确性的任务，系统可能会路由到更强大（也更昂贵）的 LLM。路由策略需要可配置，以满足不同的性能目标。




Figure 2: CITER 框架结构图。利用路由器在 SLM 和 LLM 之间进行协作推理。路由器使用通过三种场景收集的路由偏好进行训练。场景 1：SLM 生成正确的令牌，路由偏好分配给 SLM。场景 2：SLM 生成错误的令牌，而 LLM 生成正确的令牌，路由偏好分配给 LLM。场景 3：SLM 和 LLM 都未生成正确的令牌；执行协作推理以获得完整响应以分配路由偏好。

3.1.3 辅助/增强协作

在辅助或增强协作中，一个模型（可以是 LLM 或 SLM）辅助另一个模型，以提升其性能或能力 (wang2024comprehensive; shao2025division; hu2024auxiliary)。

LLM 可以将一个复杂查询分解为若干子问题，然后将这些子问题分配给 SLM 处理，反之亦然 (shao2025division; xu2025collab)。SLM 可以为 LLM 提供上下文信息或领域特定知识，以增强 LLM 的推理能力。LLM 也可用于为 SLM 生成训练数据或提供反馈信号，从而帮助 SLM 学习与改进 (deng2023mutual)。

Collab-RAG 框架展示了辅助协作的一个应用，如图 3 所示。在此框架中，一个 SLM 负责将用户查询分解为更简单的子问题，以便于从知识库中检索相关信息，从而增强 LLM 在回答复杂问题时的推理能力 (xu2025collab)。

辅助协作允许基于每种模型类型固有优势进行分工，与单独使用任一模型相比，可能提升整体性能。LLM 擅长理解复杂指令并拥有广泛知识，而 SLM 在某些特定任务上可能更专业、更高效。通过让它们相互辅助，系统可以利用 LLM 的理解能力来指导 SLM，或利用 SLM 的专业知识来为 LLM 的推理提供信息。设计有效的辅助机制需要仔细考虑模型如何能最好地互补，以及用于这种交互的通信方法。简单地让一个模型将其输出馈送给另一个模型可能不是最有效的方法。辅助可能涉及提供特定类型的信息、指导推理过程，或对另一个模型的性能提供反馈。通信需要根据所提供的具体辅助进行定制。

3.1.4 知识蒸馏驱动的协作

知识蒸馏 (KD) 是一种关键技术，用于将知识和能力从大型（通常是专有的）教师模型 (LLM) 转移到更小、更高效的学生模型 (SLM) (xu2024survey; xu2024slmrec)。




Figure 3: Collab-RAG 的迭代训练框架。SLM 根据 LLM 阅读器的生成质量更新其参数。此过程迭代多次，逐步提升 SLM 的分解能力。

KD 涉及多个方面，包括知识类型（输出概率、中间表示）、蒸馏算法（监督微调、散度最小化）以及应用领域（模型压缩、技能迁移、领域专业化）。数据增强在提升 LLM 知识蒸馏效果方面也扮演着重要角色。根据教师模型能否提供内部信息，KD 方法可分为白盒 KD 和黑盒 KD。KD 也用于迁移特定技能，例如推理、指令遵循和工具使用 (xu2024survey; hendriks2025honey; gu2023minillm)。

知识蒸馏是通过创建更小、更高效的模型，使 LLM 级别的智能能够在资源受限环境中部署的关键机制。虽然 LLM 提供了卓越的性能，但其规模和计算需求限制了许多实际场景中的应用。KD 允许我们将这些大型模型学到的知识转移到更小的模型中，这些模型可以部署在边缘设备上，或用于具有严格延迟要求的应用。知识蒸馏的成功取决于几个因素，包括教师和学生模型的选择、蒸馏数据的质量和数量，以及所采用的具体蒸馏技术。不同的 LLM 具有不同的优势，教师模型的选择将影响所迁移知识的类型。蒸馏数据应能代表学生模型将要执行的任务。选择合适的蒸馏算法并调整其参数对于实现最佳性能也至关重要。

3.1.5 集成/融合作

集成或融合作是指将 LLM 和 SLM 的架构或输出结合成一个统一的系统，以更紧密耦合的方式利用它们的互补优势 (naveed2023comprehensive; subramanian2025small; lv2025collaboration; dong2024hymba; wan2024knowledge)。

Hymba 是一种混合架构，如图 4所示，它在同一层内集成了 Transformer 的注意力机制




Figure 4: Hymba 模型的整体架构

和状态空间模型（SSM），从而实现了高召回率和高效的上下文摘要 (dong2024hymba)。模型融合技术是指结合多个模型的参数或预测结果。这可以包括权重平均、集成方法或更复杂的融合架构。多模态大语言模型（MLLM）是集成协作的另一个例子，通常使用 LLM 作为主干，并整合来自不同模态（如文本和图像）的信息。

集成协作通过在架构层面深度结合不同类型模型的优势，为创建更强大、更多功能的 AI 系统提供了潜力。模型融合提供了一种经济高效的方法，通过结合现有预训练模型的知识 and 能力来创建更强大的模型，而无需进行大量的重新训练。然而，有效融合具有不同架构的模型，并确保所得模型保留所需的特性，仍然具有挑战性。

3.2 实现协作的关键技术

为了有效实现 LLM 和 SLM 之间的协作，需要以下关键技术：

3.2.1 任务分配与智能路由

在异构的 LLM-SLM 系统中，任务分配面临诸多挑战，需要考虑任务复杂性、所需知识、计算资源、延迟约束和成本 (varangot2025doing)。主要目标是智能地将系统输入任务分配给最合适的模型进行处理。

通过动态的复杂度感知路由技术，系统可以根据任务特征（如任务类型、上下文长度、领域特异性）和输入复杂性来决定使用哪个模型。在 Hybrid LLM 等系统中，路由器根据查询难度和期望的质量水平做出决策 (ding2024hybrid)。

自我强化的路由优化利用强化学习逐步改进路由策略，以模型的实际性能作为反馈信号，持续优化和调整路由策略。MixLLM 使用上下文感知的上下文老虎机算法来学习最优的查询-模型分配，从而适应不断变化的需求和模型能力 (wang2025mixllm)。

智能路由机制可以根据预定义的标准或学习到的策略，动态地将任务分配给最合适的模型。这包括基于查询难度、性能预测和成本意识的路由 (wang2025mixllm; mohammadshahi2024routoo)。更小、更快的模型可用于初始意图检测，将请求路由到更专业化或更大的模型 (guha2024smoothie)。有效的任务分配和路由对于优化协作 LLM-SLM 系统的性能和效率至关重要，确保每项任务

都由最合适的模型处理。开发稳健且自适应的路由机制需要深入了解每个模型的能力以及所处理任务的特征。这可能涉及创建基准来评估模型在不同任务类型上的性能，并设计能够适应变化条件的路由策略。

3.2.2 模型间通信与接口设计

在协作环境中，大语言模型（LLM）与小语言模型（SLM）之间无缝且高效的通信至关重要。

自然语言接口在此过程中扮演着重要角色，特别是在智能体链（Chain-of-Agents）(zhang2024chain)中，工作智能体可以通过自然语言传递信息。这种方法利用了 LLM 的语言理解能力，简化了接口设计的复杂性，并提高了系统的可解释性 (zhang2024chain)。

结构化的中间表示可以提供更标准化的通信机制。CoGenesis (zhang2024cogenesis) 使用“草图”（sketch）格式在大模型与小模型之间进行通信。这种表示以结构化摘要的形式传达关键信息，使得下游模型更易于处理，并且比原始文本更紧凑且信息丰富 (zhang2024cogenesis)。

通过概率分布共享，模型可以在更深层次上传递不确定性。在 FS-GEN (zhang2024fast) 和 CoGenesis (zhang2024fast) 中，logits 共享允许大模型将词元概率分布传递给小模型。这不仅传递了最终预测，还传递了选择的相对可能性，使得小模型能够通过将此信息与本地上下文结合来做出更明智的决策 (zhang2024cogenesis; zhang2024fast)。

这涉及不同的通信方法，例如传递基于文本的提示和响应、共享中间表示（如嵌入、隐藏状态），或使用专门的 API 进行模型间通信 (king2024thoughtful; pozdniakov2024large; wozniak2024personalized)。设计标准化的接口，使得不同模型无论其底层架构如何都能有效交互，也是一个重要的考量。此外，还需要解决确保模型间数据一致性和格式兼容性相关的挑战。协作的效率和效果直接受到模型间通信和信息交换程度的影响。精心设计的接口和通信协议对于实现无缝交互至关重要。通信方法的选择和接口设计应根据具体的协作模式和信息交换类型进行定制。流水线协作可能只需要传递最终输出，而更紧密集成的模型则可能受益于共享中间表示。

3.2.3 模型融合与结果整合

模型融合是指合并 LLM 和 SLM 的架构或参数以创建更优的模型，包括权重平均、知识融合、集成学习、基于概率分布的融合、模型堆叠以及专家混合模型等技术 (tang2024small; wan2024knowledge; yang2024model; mavromatis2024pack; wang2025speculate; shi2024profuser)。

结果整合是指合并协作模型的输出。常见方法包括简单平均、加权平均、多数投票，或使用另一个模型来组合输出。此外，还需要处理不同模型输出之间潜在的不一致或冲突。模型融合与结果整合对于创建能够利用多个模型独特优势和知识的统一系统至关重要。技术的选择取决于协作的具体目标以及所涉及模型的特点。评估模型融合与结果整合的有效性需要仔细考虑适当的指标和基准，以评估组合系统的性能。

3.2.4 状态同步与上下文管理

在协作式大语言模型与小语言模型中，尤其是在多轮对话或序列任务中，保持状态一致性和管理上下文至关重要。这涉及同步协作模型间的内部状态（记忆、注意力权重）以及管理和共享它们之间的上下文信息 (subramanian2025small; wang2024comprehensive; naveed2023comprehensive; mojarradi2024improving)，例如使用共享记忆模块或在输入时传递上下文。此外，还需要解决与处理长上下文场景以及确保跨多次交互的上下文连贯性相关的挑战。

保持状态一致性和有效管理上下文对于确保协作式大语言模型-小语言模型系统进行连贯且有意义的交互至关重要，特别是对于涉及多个步骤或轮次的任务。状态同步和上下文管理的复杂性随着协作模型数量和交互长度的增加而增加。开发可扩展且高效的技术来处理这些方面是一个持续的研究挑战。

3.2.5 动态资源调度与优化

在协作式大语言模型-小语言模型系统中，尤其是在处理动态工作负载和变化的资源需求时，高效分配和管理计算资源（如 GPU 内存、处理时间）是一个重大挑战 (wang2024comprehensive)。

动态资源调度技术可以根据协作模型的当前需求和可用资源来调整资源分配。优化策略，如量化、剪枝和高效注意力机制，可用于降低协作推理的计算成本和内存占用 (huang2025dynamic; amayuelas2025self; sun2024illumix)。云计算与边缘计算的结合也为资源管理提供了潜力，例如，大语言模型可以在云端运行，而小语言模型在边缘设备上运行 (lv2025collaboration)。高效的资源调度和优化对于使协作式大语言模型-小语言模型系统变得实用且具有成本效益至关重要，尤其是在资源受限或高流量的现实应用中。大语言模型和小语言模型在资源需求和性能特征方面的异构性增加了资源调度和优化的复杂性。策略需要考虑这些差异以实现最优的资源利用。

4 由设备端需求驱动的应用场景

随着大语言模型的快速发展，其在多样化场景中的应用需求日益增长。然而，大语言模型的高计算资源需求与边缘设备有限的计算能力之间存在显著矛盾。小语言模型凭借其轻量级和高效的特点，为解决这一矛盾提供了潜在方案。本节分析由实际设备端需求驱动的大语言模型与小语言模型协作的典型应用场景。

4.1 实时低延迟推理场景

实时低延迟推理是边缘计算的核心需求，尤其是在需要即时响应的应用中，例如可穿戴设备/物联网语音助手和工业设备异常检测。LLM 与 SLM 的协作通过模型优化和边云协同框架，显著降低了推理延迟，提升了用户体验和系统效率。

可穿戴设备和物联网语音助手需要快速处理用户指令，以提供流畅的交互体验。LLM 强大的语言理解能力使其成为语音助手的理想选择，但其高计算需求需要通过 SLM 和边缘计算进行优化。Froiz-Miguez 等人的研究 (froiz2023design) 表明，依赖云端处理的传统语音助手




Figure 5: 边云协同 LLM-SLM 架构

在弱网络环境下用户体验会显著下降。为解决此问题，研究人员提出了边云协同的 LLM-SLM 架构，如图 5 所示。

Hao 等人提出的 Hybrid SLM-LLM 框架 (hao2024hybrid) 展示了一种动态令牌级边云协同推理方法，如图 6 所示。在该方法中，一个轻量级 SLM 部署在边缘设备上，用于处理基本语音指令并生成初步响应。复杂任务则基于不确定性量化机制，被路由到云端 LLM 进行进一步处理。该方法在延迟和准确性之间实现了最佳平衡，特别适用于资源受限的可穿戴设备场景。实验表明，与纯云端模式相比，该方法可将端到端延迟降低高达 40%，同时保持较高的响应质量。

在实际应用中，谷歌的 Gboard 和 SwiftKey 已采用类似方法，将本地 SLM 集成到移动键盘中用于语音识别和文本预测，仅在需要更复杂理解时才调用云服务 (kumar2025large)。这种协同方法显著提升了用户体验的流畅度和隐私保护水平。

工业场景中的设备监控与异常检测要求系统在毫秒级内响应，以防止潜在事故。研究表明，虽然 LLM 具备强大的分析能力，但单独部署难以满足工业环境的实时性要求 (zheng2025review)。

为应对这一挑战，研究人员提出了“推测解码”机制，利用边缘部署的 SLM 进行初步异常识别和风险评估，仅在检测到潜在风险时才激活更全面的 LLM 分析 (friha2024llm)。Zheng 等人的研究 (zheng2025review) 表明，这种协同模式可将工业异常检测的响应时间从秒级降低到毫秒级，同时保持与纯 LLM 方案相当的异常检测准确率。

WinCLIP 和 AnomalyGPT 等模型专门针对工业异常检测场景进行了优化。通过设备端 SLM 与云端 LLM 的协同，它们实现了准确性与实时性能的双重优化 (zheng2025review)。这一范式在化工生产、电力输送等高危工业场景中展现出显著价值。




Figure 6: Hybrid SLM-LLM 框架结构




Figure 7: LLM 边缘部署策略

4.2 隐私敏感与本地数据场景

在涉及敏感数据的场景中，例如移动端个人知识库检索和医学影像预筛查，本地数据处理是保护隐私的关键。LLM 与 SLM 的协作通过本地部署和高效推理，满足了隐私保护和数据安全的需求。

移动设备上的个人知识库检索与问答系统需要快速响应用户查询，同时确保数据不离开设备以保护隐私。个人知识库通常包含敏感信息，直接将其上传至云端供 LLM 处理存在隐私泄露风险。为解决此问题，研究者提出了隐私保护的本地知识库检索框架。Chen 等人 (chen2024llm) 指出，在移动设备上部署 SLM 可以有效处理包含敏感信息的本地数据，而无需将原始数据传输至云端。

一个典型的实现是“隐私敏感检索增强生成”（Privacy-Sensitive RAG）架构。在此架构中，本地 SLM 负责敏感数据处理和初步检索，仅将去标识化的查询发送至云端 LLM 进行深度分析 (wang2024comprehensive)。这种方法在保护用户隐私的同时，仍能充分利用 LLM 强大的语义理解能力。

FedCoLLM (fan2024fedcollm) 进一步提出了一个联邦学习框架，使移动设备上的 SLM

能够从云端 LLM 获取知识,同时保护用户隐私数据。该框架通过参数高效的联合调优机制增强了设备端 SLM 的能力,为移动端隐私保护知识库提供了新途径。

医疗数据具有高度敏感性。将数据发送至云端进行分析的传统做法不仅存在隐私风险,还可能违反相关法规。研究表明,在本地部署 SLM 可以有效解决此问题 (niu2025collaborative)。

Zheng 等人 (zheng2025review) 提出了一个“分层诊断”模型,将初步筛查和基本诊断任务分配给本地部署的 SLM,仅在遇到复杂病例或需要专家意见时才调用云端 LLM。实验表明,该方法在诊断常见疾病方面表现良好,同时显著减少了敏感医疗数据的传输。

诸如 BioMistral (lan2019albert) 和 PathChat (lu2024multimodal) 等医学领域专用模型采用了类似的架构。设备端 SLM 处理基础医疗数据并进行初步筛查,而云端 LLM 则提供更专业的诊断建议。这种协作模式在保护患者隐私的同时,也提高了医疗服务的可及性,特别是在偏远地区和资源有限的医疗机构中。

4.3 任务特定定制与个性化场景

通过微调与适配器技术,LLM 和 SLM 能够针对特定任务进行定制,满足个人与企业的个性化需求,例如个人写作助手和企业内部知识管理。

个性化写作助手需要深入理解用户的长期写作风格与偏好,并具备实时响应能力 (liu2024contemporary)。传统的基于云的 LLM 解决方案虽然强大,但缺乏对个人数据的长期记忆和快速适应能力。研究者提出了一种“混合记忆架构”,将用户的写作风格特征、词汇偏好和常用表达保存在本地部署的 SLM 中,形成个性化的写作档案 (deng2023mutual)。当用户需要更深层次的创意或复杂内容生成时,系统调用云端 LLM 进行支持,并将交互结果反馈给本地 SLM,以持续优化个性化服务。

Liu 等人的实验 (liu2024contemporary) 表明,与纯云端或纯本地解决方案相比,这种协作模式将写作建议的个性化程度提高了高达 35%,同时将响应时间减少了 70%。主流文档编辑工具如 Microsoft Word 和 Google Docs 已开始采用类似架构,通过本地模型提供即时写作建议,并将复杂任务委托给云端处理。

企业知识管理系统需要处理大量专业领域知识,同时确保信息安全与快速访问。Jin 等人提出的 CE-CoLLM 框架 (jin2024collm) 为企业场景设计了一种云边协同的 LLM 推理架构,支持低延迟的边缘独立推理和高精度的云边协同推理两种模式。

在此框架下,企业可以在内部服务器上部署 SLM 来处理常见查询和基本任务,同时通过“提前退出机制”和“云端上下文管理器”在必要时高效调用外部 LLM 资源 (jin2024collm)。这种方法在确保敏感信息安全的同时,满足了高性能需求。

软银与 Aizip 合作开发的企业级定制 SLM 解决方案进一步证明了该方法的实用价值 (Aizip2024Softbank)。利用领域特定数据微调的 SLM 部署在企业环境中,能够处理企业特有的任务,其准确性与体积大 100 倍的云端 LLM 相当,同时显著降低了延迟和成本 (Aizip2024Softbank)。

4.4 离线或弱网络环境场景

在网络不可用或网络连接不稳定的环境中，LLM 和 SLM 的本地运行为关键任务提供了重要支持，适用于远洋船舶、森林巡检无人机和灾害现场应急指挥等场景。

远洋船舶和森林巡检无人机通常在网络覆盖有限或没有网络的环境中运行，传统的依赖云端的 LLM 在此类场景下无法有效工作。为解决这一问题，研究人员提出了一种“离线优先”的 SLM-LLM 协同架构。实践表明，经过领域知识微调的 SLM 可以完全离线执行大多数基本交互任务。Kalita ([kalita2024large](#)) 的研究发现，通过对特定领域数据进行充分微调，拥有 40-50 亿参数的 SLM 在离线环境中可以处理 70-80% 的常见查询，其性能接近在线 LLM。这些系统在网络连接恢复时与云端 LLM 同步，更新本地模型的知识库和参数 ([kalita2024large](#))。

一个典型应用是用于森林巡检的无人机系统。通过为无人机配备经过林业知识微调的 SLM，它们可以在离线状态下识别和分析植被状况、火灾风险等关键信息，显著提升巡检效率和可靠性 ([lee2025multi](#))。

在灾害响应、边境救援等紧急情况下，网络基础设施可能遭到破坏，决策支持系统的实时性直接影响救援效果。Tong 等人 ([tong2024robots](#)) 的研究表明，传统的云端 LLM 在此类场景下缺乏可靠性，而纯本地模型则往往因能力有限而无法处理复杂情况。

为解决此问题，研究人员开发了一种“弹性协作”框架。在网络正常情况下，本地 SLM 与云端 LLM 协同工作，形成完整的决策支持链。当网络中断时，本地 SLM 可以利用预缓存的知识独立运行，确保基本的决策支持能力 ([boateng2025survey](#))。

一个成功的案例是应用于地震救援的多智能体协同系统。该系统集成了离线部署的小语言模型和远程大语言模型，使得救援人员即使在网络中断期间也能获得基本的决策支持，并在网络恢复后立即获得更全面的分析 ([Jayant2024StateEdgeAI_misc](#))。实验表明，与单一模型解决方案相比，这种弹性协作解决方案在极端环境下能提供显著更优的决策支持能力。

4.5 能量受限与绿色人工智能场景

在能量受限场景中，SLM 和优化后的 LLM 通过低功耗设计满足边缘设备的需求，例如超低功耗终端上的键盘预测和车载系统中的驾驶安全提示。

在具有严格功耗限制的终端设备上，如智能手表和功能受限的物联网设备，传统的云端 LLM 模式由于需要持续的网络连接，会显著缩短电池续航。研究表明，像键盘预测这样的功能，虽然不需要 LLM 级别的理解能力，但要求极低的延迟和能耗 ([qu2025mobile](#))。

Kumar 的研究 ([kumar2025large](#)) 介绍了一种专为键盘预测优化的超低功耗 SLM 设计。通过极端的模型压缩和针对硬件的优化，预测功能的功耗降低到了传统方法的十分之一。尽管这些模型仅有数百万参数，但在特定场景下表现良好。

与 GloVe 合作开发的移动键盘预测 SLM 进一步证明了 SLM 在此场景中的价值 ([kumar2025large](#))。该系统仅在复杂语境或用户明确请求时才唤醒更强大但能耗更高的模型，在预测准确性和能耗之间实现了最佳平衡，从而延长了设备使用时间。

车载系统面临着独特的能耗和实时性挑战。过高的功耗可能影响车辆整体电气系统，而与安全相关的提示则需要毫秒级的响应 ([lin2023tiny](#))。传统的 LLM 模式难以满足这些需求。

Qu 等人 ([qu2025mobile](#)) 提出了一种“分层安全提示”架构。通过在车载系统内部署

一个专门掌握安全驾驶知识的 SLM 进行实时环境监控和基本安全提示，同时保留连接云端 LLM 以进行复杂情况分析的能力，该架构在保持安全提示准确性的同时，降低了 65% 的能耗。

一些汽车制造商已开始采用类似的"绿色人工智能"解决方案，使用本地 SLM 处理导航提示、语音控制和基本安全警告，仅在需要深度驾驶辅助时才激活更强大的模型 (qu2025mobile)。这种方法不仅显著降低了能耗，还提高了系统可靠性，尤其是在网络连接不稳定的区域。

5 挑战与开放性问题

大型语言模型 (LLM) 与小型语言模型 (SLM) 的协作旨在结合两者的优势：LLM 强大的通用能力和知识广度，以及 SLM 在特定任务上的高效性、低延迟和低成本。然而，实现完美的协作并非易事，面临着诸多挑战和尚未解决的开放性问题。本节将深入探讨这些挑战，主要聚焦于协作效率与系统开销、模型间一致性与兼容性、任务分配策略的鲁棒性与最优性、协作系统的训练与维护、评估指标与基准测试，以及相关的安全、隐私和伦理问题。

5.1 协作效率与系统开销

5.1.1 任务路由决策的延迟

尽管大语言模型与小语言模型的协作旨在提升整体效率，但协作过程本身可能引入新的开销，从而对系统性能产生潜在的负面影响。关键挑战在于任务路由决策的延迟、模型间通信的成本以及整体系统的复杂性管理。

在大语言模型与小语言模型的协作系统中，任务路由机制负责决定应由哪个模型处理特定的查询或子任务，这是实现协作效率的核心。然而，路由决策过程本身会引入延迟，可能部分抵消使用小语言模型所带来的速度优势 (arcee2025slms)。挑战在于设计既准确又快速的路由机制。

小语言模型因其低推理延迟而备受青睐，尤其适用于边缘设备。相比之下，大语言模型由于其庞大的参数量和高计算需求，通常具有更高的推理延迟 (wang2024comprehensive)。协作系统需要一个路由机制，以便根据任务复杂性或其他标准动态选择模型 (arize2025survey)。这些路由决策，无论是基于不确定性估计、词元级分析、任务分解还是其他预测方法，都会产生其自身的计算开销和延迟。级联方法（先查询小语言模型，必要时再升级到大语言模型）会明确引入延迟和潜在的冗余。像 CITER 这样的框架试图通过词元级路由来最小化大语言模型的调用，但仍需要一个路由机制 (zheng2025citer)。预生成路由旨在通过预先推断大语言模型的能力来最小化延迟，但这种预测本身可能很复杂 (varangot2025doing)。

存在一个核心悖论：使用小语言模型的主要动机通常是减少延迟，然而，有效选择何时使用小语言模型（即路由器）的机制本身却引入了延迟。路由器的延迟成为一个关键因素；如果它太高，那么协作带来的净延迟减少（小语言模型延迟 + 路由器延迟对比大语言模型延迟）就会减弱。这提出了一个开放的研究挑战：开发近乎零延迟的路由机制，或者证明路由开销与大语言模型-小语言模型之间的延迟差异相比始终可以忽略不计。 ** 开放性问题： ** 开发超

低延迟路由机制；量化路由复杂性/准确性与延迟之间的权衡；设计能够通过并行处理掩盖路由延迟的系统。

5.1.2 模型间通信成本

在协作系统中，尤其是在边云协同场景中（SLM 本地运行，LLM 在云端运行），模型之间的数据传输（例如查询、中间结果、上下文、模型输出）会产生通信成本和延迟。这对于实时应用程序或处理大量数据时尤其具有挑战性。

云边协作是一种常见的模式，旨在平衡隐私/延迟（设备端 SLM）与能力（云端 LLM）。将用户数据实时传输到云端会引发对通信成本、延迟和带宽限制的担忧。像 LSC4Rec 这样的框架旨在通过让 LLM 仅向设备端小型推荐模型（SRM）发送候选列表进行重新排序，以最小化实时数据传输 (lv2025collaboration)。类似地，MinionS 在云端分解任务，将子任务发送到本地 SLM，并在云端聚合结果，旨在减少与云端交互的数据量和频率 (narayan2025minions)。然而，通信开销仍然是一个因素，尤其是在需要交换中间结果或大量上下文时。

虽然边云协作利用了本地 SLM 的效率和云端 LLM 的强大能力，但通信通道本身可能成为瓶颈，限制系统的整体响应能力和成本效益。协作协议的设计和任务分解的性质对于管理通信开销至关重要。优化通信内容和时序是一个开放的挑战。* 开放性问题：* 设计通信高效的协作协议；开发用于压缩模型间交换的中间表示的技术；量化网络条件对协作系统性能的影响。

5.2 模型间一致性与兼容性

5.2.1 确保不同模型间输出风格与知识范围的一致性

大型语言模型（LLM）与小型语言模型（SLM）通常在不同数据集上训练或为不同目的进行微调，这可能导致它们展现出不同的写作风格、语调或响应格式。当不同模型为同一输出或对话做出贡献时，确保一致的用户体验需要机制来对齐或管理这些风格差异。

一致性被认为是 LLM 可信赖性的一个基本方面。诸如“指导链”（CoG）等技术旨在通过引导式提示来改进 LLM 输出的语义一致性 (raj2025improving)。像 SAG 这样的框架，通过协同训练（S-SFT, C-DPO）和自我改进方法，明确解决了 LLM-SLM 协作中的风格对齐问题 (xusag)。模块化多元主义框架使用较小的“社区 LM”将不同的视角/风格整合到基础 LLM 中 (feng2024modular)。评估一致性本身具有挑战性，通常需要超越简单相似度的细致指标 (raj2025improving)。KnowsLM 框架使用 LLM 作为评判者来评估风格适应能力，发现微调在语调适应方面优于 RAG (harbola2025knowslm)。

协作本身存在风格冲突的风险。在 CoGenesis 框架中，如果 SLM 处理个人细节而 LLM 处理更广泛的叙述 (zhang2024cogenesis)，除非采用特定的对齐技术，否则组合输出可能会显得脱节。这需要在训练/微调过程中标准化风格，或开发复杂的输出融合技术。由于 LLM 和 SLM 通常具有不同的训练历史和目标，这导致了潜在不同的输出风格、语调和格式。在协作系统中，不同模型可能生成最终输出的各个部分。将风格迥异的模型输出组合起来，可能导致不一致且令人不适的用户体验。确保一致性需要明确的努力，要么通过联合训练/微调以实现风格对齐 (xusag)，要么通过后处理/融合技术 (pei2025mathfusion)。这增加了系统设计

和评估的复杂性。**** 开放性问题:** ** 开发用于评估不同模型间风格一致性的稳健指标; 创建用于协作生成中实时风格对齐或迁移的高效技术; 理解风格一致性与事实准确性或创造性等其他目标之间的权衡。

5.2.2 模型知识范围对齐与事实一致性

由于训练数据和模型能力的差异, 大语言模型 (LLM) 和小语言模型 (SLM) 拥有不同的知识库。大语言模型通常知识面更广, 但可能产生幻觉或包含过时信息; 小语言模型可能拥有更专业、可能更及时的领域知识, 但广度不足。确保模型协作时的事实一致性并解决知识冲突是一个重大障碍。

大语言模型存在幻觉和知识陈旧问题, 而小语言模型在缺乏足够领域特定知识的专业领域往往表现不佳。知识蒸馏(KD)等技术旨在将知识从大语言模型迁移到小语言模型 (**wang2024comprehensive**) 但对齐复杂分布是困难的 (**peng2024enhancing**)。检索增强生成(RAG)被用于注入外部、最新的知识, 但持续整合检索到的知识同样具有挑战性。使用 KnowsLM 框架的研究表明, RAG 擅长实时知识注入, 而微调在风格一致性方面表现更佳 (**harbola2025knowslm**)。CoVer 框架利用小语言模型验证来检查大语言模型推理的一致性 (**yan2025collaborative**)。CrossLM 框架利用小语言模型的反馈来改进大语言模型生成的合成数据, 以实现相互增强 (**deng2023mutual**)。

当大语言模型和小语言模型拥有相互冲突的信息时 (由于不同的训练截止时间或专业领域), 协作系统需要一种机制来解决这种冲突。简单的融合可能导致事实错误。这需要一个复杂的真相发现机制, 或者一种基于特定查询类型明确信任某个模型知识领域的策略。大语言模型和小语言模型拥有不同的知识库; 大语言模型可能产生幻觉或信息过时, 而小语言模型可能缺乏广泛的知识或领域细节。协作可能导致模型提供相互冲突的事实信息。系统需要一种策略来处理这些冲突: 根据上下文/任务优先考虑某个模型、使用外部验证 (如 RAG)、或采用权衡置信度/时效性的融合机制。未能解决冲突将导致输出不可靠且不可信。

这需要在 LLM-SLM 协作系统中研究鲁棒的知识融合和冲突解决机制。**** 开放性问题:** ** 为 LLM-SLM 输出开发有效的知识融合技术; 创建基于来源可靠性或上下文的动态冲突解决机制; 确保协作输出中信息来源的可追溯性; 对齐协作模型间的知识更新。

全面评估 LLM-SLM 协作系统的性能是复杂的, 不仅需要衡量最终结果的质量, 还需要考虑效率、成本等多个维度。目前, 该领域缺乏标准化的测试平台和数据集, 这使得比较不同协作策略和衡量进展变得困难。

评估 LLM-SLM 协作系统不能仅仅依赖传统的 NLP 指标; 还必须全面考虑协作带来的效率提升和成本节约。这需要一个能够捕捉协作系统多方面性能的评估框架。

LLMOps 的挑战超越了部署单一模型, 还包括数据处理、模型训练、部署、维护、应对模型漂移以及确保适应不断变化的数据和任务。对于协作系统而言, 这些挑战更为严峻。从业者认为模型部署和监控阶段既重要又困难。模型通常作为独立服务部署, MLOps 原则的采用有限。报告的问题包括为生产部署设计基础设施架构的困难, 以及与遗留应用程序的集成问题。生产中的许多模型并未受到监控; 关键的监控方面包括输入、输出和决策。挑战还包括缺乏监控实践、需要创建自定义监控工具以及选择合适的指标 (**zimelewicz2024ml**)。Acxiom 在使用 LLM 和 LangChain 创建受众细分系统时, 在调试复杂 workflows 方面遇到了挑

战。通过 LangSmith 实现的观测性优化了令牌使用，并有效扩展了他们的混合模型部署 (zenml2025llmops)。持续监控 LLM 并主动检测异常和对抗行为对于确保其完整性至关重要。将 LLM 集成到 CI/CD 管道中会引发与计算成本、不准确性、错误处理、偏见以及开发、部署、维护和伦理相关的问题相关的担忧 (pahune2025transitioning)。协作系统中组件数量的增加意味着监控复杂性的提升和更多潜在的故障点。每个模型 (LLM、SLM)、路由机制以及它们之间的通信链路都需要监控其性能、资源消耗、错误率和漂移情况。关联来自不同组件的日志和指标以诊断系统范围的问题可能极具挑战性。需要专门为这种分布式、异构模型环境设计的监控和调试工具。协作系统比单模型系统拥有更多组件 (LLM、SLM、路由器)。每个组件都是一个潜在的故障点，需要单独监控其健康状况、性能 (延迟、吞吐量)、资源使用情况和输出质量。此外，组件之间的交互也需要监控，例如数据流、API 调用成功率和通信延迟。当问题出现时 (例如，整体响应质量下降)，精确定位哪个组件或交互出现故障可能非常复杂，需要复杂的日志记录、追踪和根本原因分析能力。这显著增加了部署和运维的复杂性。* 开放性问题：* 为 LLM-SLM 协作系统开发标准化的部署模式和最佳实践；创建能够跨多个模型跟踪请求流和性能指标的全面监控框架；为协作系统设计自动化的异常检测和故障诊断工具；研究如何在分布式模型部署中有效管理和更新各个组件。

5.3 安全、隐私与伦理问题

尽管具有潜在优势，LLM-SLM 协作系统也可能引入或放大与安全、隐私和伦理相关的风险。不同模型之间的数据流动、协作决策过程以及模型自身固有的缺陷，都可能是这些问题的来源。

5.3.1 不同模型间数据流动的隐私风险

当数据，尤其是包含敏感用户信息的数据，在本地 SLM 与云端 LLM (甚至在不同 LLM 之间) 流动时，隐私泄露的风险会增加。

由于资源限制，使用云端 API 调用 LLM 很常见，这本身就引发了隐私担忧。SLM 通常部署在边缘设备上以保护隐私 (wang2024comprehensive)。LLM 可能会从训练数据或交互中泄露个人可识别信息 (PII)。像 CoGenesis 这样的框架旨在通过让 SLM 在本地处理私有数据，从逻辑上防止隐私泄露 (zhang2024cogenesis)。CrossLM 框架涉及在私有客户端数据上训练的 SLM 来增强云端 LLM，这引发了关于知识转移与数据泄露的问题 (deng2023mutual)。联邦协作被认为是一种平衡隐私的策略。

虽然云边协作分布了数据处理，但它也创建了更多的数据传输或处理节点，如果设计不当，可能会增加隐私泄露的攻击面。LLM-SLM 协作通常涉及模型之间的数据流动，可能跨越信任边界 (例如，设备到云端)。LLM 如果处理敏感用户数据，会带来隐私风险。设备上的 SLM 通常用于通过将敏感数据保留在本地来缓解这些风险。然而，协作本身可能需要共享一些信息 (中间结果、上下文摘要)，这些信息可能会无意中泄露隐私细节。确保共享的信息被充分匿名化或泛化，同时仍对协作有用，是一个重大挑战。这需要精心设计数据流协议，并可能在协作框架内采用隐私增强技术 (PETs)。* 开放性问题：* 为 LLM-SLM 协作开发隐私保护的数据共享协议；形式化混合系统中的隐私保证；研究隐私保护与协作性能之间的权衡；

审计数据流以识别潜在的泄露点。

5.3.2 协作系统中潜在的偏见放大或安全漏洞

单个大语言模型和小语言模型可能携带其训练数据中的偏见。当这些模型协作时，这些偏见可能会被放大，或者由于交互动态而产生新的、涌现的偏见。确保组合系统的公平性并减轻偏见比单个模型更为复杂。

大语言模型可能会延续并放大训练数据中存在的社会偏见。小语言模型如果在较小或多样性不足的数据集上训练，也可能表现出偏见。大语言模型之间的迭代学习可能会放大细微的偏见 ([ren2024bias](#))。ViLBias 框架指出，结合不同模态（文本和图像）可以揭示单一模态中不明显的偏见，这表明模型协作可能产生类似的效果 ([raza2024vilbias](#))。大语言模型路由器本身也可能存在漏洞；如果攻击者控制了路由，将查询导向有偏见的模型，就可能被利用来诱导产生有偏见的结果 ([lin2025life](#))。

偏见在协作系统中可能会叠加。如果一个小语言模型基于对用户人口统计数据的偏见理解来路由查询，而选中的大语言模型随后又生成带有其自身偏见的内容，那么最终输出可能会受到双重偏见的影响。交互本身也可能产生个体模型中不存在的新形式偏见。大语言模型和小语言模型都可能因其训练数据或架构而产生偏见。在协作系统中，多个模型共同参与最终输出或决策过程。如果不同模型具有不同的偏见，这些偏见可能会以不可预测的方式相互作用。一个模型的偏见输出可能成为另一个模型的偏见输入，从而可能放大初始偏见（例如，一个有偏见的小语言模型将查询路由到一个大语言模型，后者随后强化了该偏见）。减轻此类系统中的偏见不仅需要评估单个组件，还需要评估整个协作流程及其决策逻辑。*

开放性问
题：*

开发检测和衡量大语言模型-小语言模型协作系统中偏见放大的方法；设计公平的路由和任务分配策略；创建用于消除多模型系统输出偏见的技术；理解不同的协作架构如何影响偏见传播。

大语言模型-小语言模型系统的复杂性和分布式特性可能会引入新的安全漏洞。攻击者可能针对通信信道、路由机制，或利用一个模型的弱点来危害整个系统。大语言模型容易受到各种攻击，如提示注入、越狱、数据投毒和个人身份信息泄露。研究表明，大语言模型路由器本身存在生命周期漏洞，包括对抗性攻击和后门，其中基于深度神经网络的路由器尤其脆弱。如果路由器被攻破，它可能恶意地将查询路由到不适当的模型或泄露数据。大语言模型和小语言模型之间的交互点（例如，API 调用、数据交换）成为潜在的攻击面。如果边缘设备上的小语言模型被攻破，它可能向云端大语言模型发送恶意输入，反之亦然。协作系统中的每个额外模型和通信链路都可能扩大攻击面。协作系统中“最薄弱环节”（安全性较低的 SLM 或路由器）的漏洞可能危及更强大的 LLM 或整个系统的完整性/安全性。LLM-SLM 系统由多个组件（LLM、SLM、路由器、通信通道）组成。每个组件和接口都是潜在的攻击点。路由器可能遭受攻击导致误路由（将所有查询发送至昂贵的 LLM，或发送至已遭破坏/无效的 SLM）。通信通道若不安全，则允许模型间交换的数据被拦截或篡改。遭破坏的 SLM 可能向 LLM 输送恶意数据（反之亦然），可能导致有害输出或系统被接管。确保协作系统的安全性需要采用整体性方法，考虑每个组件及其交互的安全性，这比保护单一整体模型更为复杂。

开放性问
题：*

为 LLM-SLM 协作开发安全通信协议；设计鲁棒且抗攻击的路由机

制；研究针对混合模型架构的新型攻击向量；为多模型系统建立全面的安全审计框架。

6 未来趋势

6.1 更智能、更自适应的协作框架

大型语言模型（LLMs）与小型语言模型（SLMs）之间的协作，正从预设的、静态的交互模式，向能够动态学习、适应并优化其协作策略的智能框架演进。这一趋势的核心在于赋予协作系统更大的自主性，使其能够根据任务特性、数据变化和环境反馈灵活调整，而非仅仅依赖固定规则或人工配置。未来的协作框架将越来越多地利用先进的机器学习技术，例如强化学习和元学习，以实现动态策略调整和高效的自优化。

6.1.1 基于强化学习的动态协作策略

强化学习（RL）为训练智能体在复杂动态环境中做出最优决策提供了强大的范式。在 LLM-SLM 协作中，RL 可用于学习任务分配、资源管理和交互协议等策略，以最大化系统性能、运行效率或其他预定义目标。

一项重要进展是细粒度的动态资源分配。CITER 框架 (zheng2025citer) 利用 RL 训练一个路由器，在词元级别决定下一个词元应由 SLM 还是 LLM 生成。该路由器的优化目标同时考虑了预测质量和推理成本，学习预测词元级别的重要性并权衡其决策对未来生成序列的影响，从而在效率与准确性之间实现动态平衡。这种词元级别的路由策略比传统的查询级别路由精细得多，使得系统能够在生成任务的“较简单”部分利用 SLM 的效率，而在“关键”词元上依赖 LLM 的能力，从而可能带来显著的效率提升。

RL 也被应用于优化特定任务场景下的协作策略。在检索增强生成（RAG）任务中，Collab-RAG 框架 (xu2025collab) 使用 SLM 来分解复杂查询，并通过一个黑盒 LLM 提供的反馈信号来提升 SLM 的分解能力。这种类似于 RL 机制的迭代优化过程，增强了 SLM 在协作式 RAG 流程中的作用。此外，研究者提出了 ReMA 框架 (wan2025rema)，使用多智能体强化学习（MARL）引导模型进行元思考行为，其中一个高层元认知智能体和一个低层推理智能体通过 RL 进行协作。这表明 RL 不仅可以优化任务执行，还可以优化协作框架内的战略规划。另外，逆强化学习（UDRL）已被用于训练 SLM 进行可控提示生成，以优化输出属性（如长度和相关性）(lin2025efficient)。虽然主要关注 SLM 训练，但通过 RL 控制生成属性的原理可以扩展到协作场景，例如当 SLM 输出需要满足特定 LLM 输入要求时。另一项研究提出了一种协作模式，其中 LLM 生成简洁的思维链（CoT）指令，然后由一个在 RL 优化的高密度 CoT 数据上微调过的 SLM 将其扩展为完整回答 (she2025hawkeye)，这展示了 RL 在优化结构化协作推理 workflow 中 SLM 角色方面的潜力。

这些发展共同揭示了一个重要趋势：RL 正在推动协作模式从“预编程”向“基于学习”转变。早期的 LLM-SLM 协作通常依赖于简单、基于规则的路由逻辑。然而，如 CITER 等框架所示，RL 可以基于质量和成本等复杂因素优化词元级别的路由决策，这比静态规则要动态和精细得多。像 SmallPlan 和 Collab-RAG 这样的工作进一步表明，RL 可以使协作策略适应特定任务（例如路径规划、RAG），甚至基于 LLM 反馈改进协作组件（如 SLM 查询分解器）。

ReMA 框架将 RL 应用推向了更高层次，实现了分层的元认知与推理协作。这意味着 RL 不仅是在自动化决策过程，更是在教导系统如何有效地协作，这种学习由数据驱动，使系统能够适应任务的细微差别以及不同模型的优势与弱点。

6.1.2 基于元学习的动态协作策略

元学习，或称“学会学习”，旨在训练模型能够利用少量新数据快速适应新任务或新环境。在 LLM-SLM 协作中，元学习可用于开发自适应路由策略或协作机制，从而更好地泛化到不同的下游任务或变化的数据分布。

尽管在当前研究中，将元学习明确应用于 LLM-SLM 协作的案例仍在涌现，但已有若干方向显示出与元学习目标的强一致性。基于不确定性的 SLM 路由策略 ([chuang2025confident](#))，即当 SLM 对其预测不确定时将查询传递给能力更强的 LLM，探索了路由策略对新数据集的有效泛化。他们提出了一个数据构建流程来生成与数据无关的保留集，从而能够在不需要大量新数据的情况下做出有效的路由决策。这种高效适应和泛化的目标正是元学习的核心。

这些探索表明，元学习有望解决协作框架中快速适应的挑战。协作系统需要在多样化的任务和领域中有效工作。为每个新任务重新训练复杂的强化学习策略成本高昂且效率低下。元学习通过在元训练阶段让学习算法接触一系列任务分布，来明确训练快速适应能力。因此，未来的研究可能会更深入地探索利用元学习来训练 LLM-SLM 系统中的“路由器”或“协调器”，使其能够仅用少量样本就为未见的新任务快速配置有效的协作策略。这不仅将显著降低 LLM-SLM 系统在新应用中的部署成本和时间，使其更具通用性，也意味着系统具备“学会如何学习协作”的潜力。

6.2 模型能力的深度融合

目前，大型语言模型（LLM）与小型语言模型（SLM）的协作正超越简单的任务路由或流水线处理，朝着能力深度融合的方向发展。未来的趋势不仅关注任务分配的优化，更致力于探索模型间更细粒度的交互，甚至可能深入到模型内部的神经网络层级。其目标是构建共享的理解或表示空间，从而实现能力的真正融合。

传统的 LLM-SLM 协作通常涉及 SLM 处理简单任务或充当初步过滤器，而 LLM 则处理复杂任务。然而，未来的协作模式将远超这种简单的层级划分，朝着更复杂、双向甚至迭代的交互方式演进。在这种模式下，不同的模型可能会相互咨询、验证输出或共同构建解决方案，形成一个动态的“模型社会”。

未来的协作将类似于一个模型的“社会”，其中每个模型扮演不同的角色并遵循多样化的交互协议，而非简单的层级结构（例如，LLM 作为领导者，SLM 作为助手）。简单的路由虽然高效，但可能无法充分利用每种模型类型的独特优势，或解决高度复杂的问题。引入诸如 LLM 增强 SLM 输入数据（例如 SynCID）或 SLM 验证 LLM 输出（例如 CoVer）等机制，可以创造更有价值的协作。可以预见，将出现更多样、更灵活的交互模式，例如迭代精炼、相互查询和集成方法，其中 SLM 和 LLM 从不同角度或针对解决方案的不同组成部分做出贡献。这将带来更稳健和更具创造性的问题解决能力，但也对模型间的编排和通信机制提出了更高的要求。

更深度的融合探索了 LLM 和 SLM 在内部神经网络层级（而不仅仅是输入/输出层面）进行交互的可能性。这可能涉及共享激活值、相互影响注意力机制，或融合学习到的中间表示。这种方法旨在摆脱将每个模型视为独立黑盒的局限。

DeepMLF 模型 (georgiou2025deepmlf) 虽然是为多模态情感分析设计的，但其提供了一个富有启发性的“深度融合”概念。它引入了可学习的令牌，在预训练解码器的多个层级上整合多模态信息。这种跨层深度融合以及使用可学习令牌作为信息载体的概念，可以适用于 LLM-SLM 协作。SLM 可以处理特定类型的特征，然后将这些特征（例如激活值）注入到 LLM 的特定层中，反之亦然。这为模型间更紧密的耦合提供了路径，其中一个模型的内部处理可以直接影响另一个模型，从而可能产生更丰富的组合表示。另一项关于模型剪枝的研究 (ding2025sliding) 提出了一种“滑动层合并”方法，该方法基于预定义的相似度阈值动态选择和融合连续的层。虽然应用于单个 LLM 的剪枝，但基于相似度合并层的想法为融合来自 SLM 和 LLM 的对齐层（如果它们的表示空间能够对齐）提供了一种潜在的方法论。这些探索表明，大语言模型（LLM）与小语言模型（SLM）之间的界限可能会变得“更模糊”。黑盒式的输入/输出交互限制了模型间可交换信息的带宽和类型，因为内部表示（激活值、隐藏状态）通常包含丰富、细微的信息，而这些信息在最终输出中丢失了。DeepMLF 的成功突显了在单一模型内部进行深度、多层融合的优势，这一原则可以扩展到模型间的协作。如果一个 SLM 专门提取特定的句法特征，那么这些特征（作为激活值）可以直接输入到处理同一文本以完成语义任务的 LLM 的相关层中，从而在更深层次上丰富 LLM 的输入。未来的研究可能会侧重于探索在特定层“嫁接”或“连接”SLM 和 LLM 的方法，或许会使用适配器模块或学习到的门控机制来控制信息流。这可能会催生出高效且强大的混合模型，其中 SLM 的优势（例如，专业化的特征提取）被深度整合到 LLM 更广泛的推理过程中。然而，这也带来了重大的架构和训练挑战，需要仔细对齐内部表示。

大型语言模型（LLMs）与小型语言模型（SLMs）之间的协作正从纯文本领域扩展到更复杂、更丰富的多模态理解（整合视觉、语音等）和具身智能（例如，与环境交互的机器人、虚拟智能体）领域。在这些新兴领域中，LLM-SLM 协作将在应对多样化的计算需求和专门的处理任务方面发挥关键作用。

6.2.1 整合视觉与语音等多模态信息的大模型与小模型协作

随着人工智能系统越来越需要处理和理解来自多种模态的信息，LLM-SLM 协作对于有效管理文本、图像、音频及其他数据类型不同计算需求和专门处理流程变得至关重要。多模态数据在数据量、特征提取和融合方面提出了独特的挑战。LLM-SLM 协作可以高效地分配这些任务，由 SLMs 处理高吞吐量、较低层级的模态处理，而 LLMs 则专注于高层级的跨模态推理与生成。

现有研究设想 LLM 智能体具备“大-小模型协作”能力，并处理可能涉及多模态输入的多轮对话，例如在搜索和推荐场景中 (zhang2025survey)。一项研究描述了通过 LLM 蒸馏训练 SLMs，使其成为多模态上下文中的多任务学习者，特别是用于提示生成（例如，文本到图像、文本到模板）(lin2025efficient)，这表明 SLMs 可以在 LLM 的协助下专门处理多模态相关任务。VITA-1.5 模型 (fu2025vita) 是一个整合了视觉、语言和语音的多模态大语言模型

(MLLM)。虽然它是一个单一的 MLLM，但其多阶段训练方法（逐步整合视觉和语音数据）以及模态冲突（语音数据可能降低视觉任务性能）等挑战，突显了 LLM-SLM 协作方法的潜在优势。专门的 SLMs 可以在将特征馈送到中心 LLM 之前，处理特定模态（如 VITA-1.5 中提到的语音编码器）的初始处理或编码，或者管理语音输出。Long-VITA 模型 (shen2025longvita) 专注于长上下文视觉语言理解。训练此类模型的复杂性和成本表明，SLMs 可能在处理部分视觉信息（例如，预处理、从片段中提取特征）或在由 LLM 编排的更大任务中管理较短上下文交互方面发挥潜在作用。

这些趋势指向一种“专用处理器”模式：在多模态场景中，SLMs 很可能充当特定模态的高效编码器/解码器或早期融合模块。视觉 SLM 处理视觉输入，音频 SLM 处理听觉输入，这些专门的 SLMs 将紧凑、信息丰富的表示馈送给核心 LLM，由后者执行跨模态理解、推理并生成多模态响应（或许在 SLM 解码器的帮助下）。这种架构有望实现更具可扩展性和成本效益的 MLLMs，从而实现更丰富的人机交互。它还允许独立更新或改进特定于模态的 SLMs，而无需重新训练整个 MLLM。

6.2.2 大模型-小模型协作在机器人及具身智能体中的应用

具身智能体（如机器人）在动态的现实世界环境中运行，需要具备实时感知、决策和行动能力。LLM-SLM 协作非常适合满足这些需求：LLM 提供高层推理与规划，而 SLM 则负责在资源受限的机器人硬件上进行底层控制、传感器数据处理和快速反应。

SmallPlan 框架直接针对这一点：一个 LLM 作为教师模型，训练轻量级 SLM 以完成机器人学中的高层路径规划任务。这些 SLM 通过 LLM 指导和模拟环境中的强化学习进行训练，能够为导航提供动作序列。这明确地将 LLM-SLM 协作应用于具身任务，展示了一种将 LLM 推理能力提炼为机器人可部署 SLM 的实用方法。一项研究 (glocker2025llm) 提出了一个由 LLM 驱动的具身智能体系统，用于机器人在家庭环境中自主管理物品。该系统集成了多个由任务特定 LLM（可能包括 SLM 或为专业化/更小规模而微调的 LLM）驱动的专门智能体（路由、任务规划、知识库）。该系统使用 RAG 进行记忆增强，并结合 Grounded SAM 和 LLaMa3.2-Vision 实现鲁棒的目标检测，展示了不同模型（例如，Qwen2.5 用于专门智能体，LLaMA3.1 用于路由）如何在复杂的具身任务中协作。此外，关于具身多模态大模型 (EMLMs) 的背景研究 (chen2025exploring) 强调了感知、语言和行动的整合，指出了可扩展性和泛化性等挑战，而 LLM-SLM 协作可能为此提供解决方案（SLM 用于机载感知，LLM 用于基于云的复杂规划）。

这些进展表明，分层控制和推理架构正成为具身人工智能的主导范式。机器人既需要高层的理解和规划（“清洁厨房”），也需要底层的、实时的感觉运动控制（“抓住海绵”、“避开障碍物”）。LLM 擅长常识推理、任务分解和理解自然语言指令，但对于直接的实时机器人控制而言，它们通常太慢或计算成本过高。相比之下，SLM 更适合在设备上部署，处理诸如局部感知、反射性动作或执行由 LLM 提供的明确定义的子目标等任务。未来的系统很可能由 LLM 负责解释用户目标、将其分解为可执行的步骤并监控进度，而一组 SLM（或一个通用的机载 SLM）则通过与物理世界交互并向 LLM 发送反馈来执行这些步骤。这种架构有望使机器人更加智能、适应性强且能力出众，能够在人类环境中执行复杂、长周期的任务，同时利用

强大的基于云的 LLM 以及保持实时响应性和自主性的机载 SLM。

7 结论

大型语言模型（LLMs）的快速发展带来了人工智能能力的显著提升。然而，其高昂的计算资源需求、部署成本以及潜在的延迟问题限制了其在更广泛场景中的应用。与此同时，小型语言模型（SLMs）凭借其高效、低耗和易于部署的特点，在特定任务和资源受限环境中展现出独特优势，尽管其能力和泛化性相对有限。如何有效结合 LLMs 和 SLMs 的优势，弥补各自的不足，已成为推动 AI 技术向更高效、更经济、更普适方向发展的重要研究课题。

本文系统性地回顾和探讨了大小语言模型之间的协作机制与架构。首先阐述了 LLMs 和 SLMs 的基本概念、特点以及各自的优势与局限。在此基础上，重点分析了当前主流的协作模式，包括流水线式、混合/路由式、辅助/增强式、知识蒸馏驱动式以及集成/融合式协作。并深入探讨了实现这些模式的关键技术，如任务分配与智能路由、模型间通信与接口设计、模型融合与结果集成、状态同步与上下文管理以及动态资源调度与优化。此外，结合实际端侧需求，本文探讨了协作机制在多种应用场景中的实用价值，包括实时低延迟推理、隐私敏感与本地数据处理、任务特定定制与个性化服务、离线或弱网络环境以及能源受限与绿色 AI 场景。

尽管 LLM-SLM 协作研究已取得显著进展并展现出巨大潜力，但仍面临诸多挑战。这些挑战主要集中在：协作效率与系统开销方面，任务路由决策和模型间通信可能引入额外的延迟与成本；模型间一致性与兼容性方面，涉及如何确保不同模型在输出风格、知识范围及事实准确性上的统一；协作系统的评估指标与基准测试方面，目前缺乏能够全面衡量协作效果、效率与成本的标准化测试平台与指标；以及安全、隐私与伦理方面，需要应对模型间数据流动带来的隐私风险，以及协作系统中潜在的偏见放大与安全漏洞。这些挑战指明了未来研究的方向。

7.1 研究意义与价值

大语言模型与小语言模型之间的协作机制研究具有深远的理论意义和广泛的应用价值。协作的核心价值在于能够在不显著牺牲性能的前提下，显著降低对计算资源的需求、减少推理延迟并降低运营成本。这使得原本因高资源门槛而无法获取的先进 AI 能力，得以部署在更多的边缘设备和嵌入式系统上，从而促进 AI 技术的普及化和民主化，惠及更广泛的用户和行业。

正如本综述第 4 章所展示的，LLM-SLM 协作能够有效满足边缘设备对实时响应、隐私保护、个性化、离线运行和低功耗等方面的苛刻要求。无论是可穿戴设备上的即时语音助手、保护个人隐私的本地知识库问答系统，还是工业场景中的快速异常检测，协作机制都为在资源受限环境中实现复杂的智能任务提供了可行的解决方案。

通过合理的任务分解和模块化设计，协作系统能够将复杂任务分配给具有不同专长的模型。这种模块化不仅有助于提高特定任务的处理精度和效率，也使系统调试、更新和维护变得更加灵活。可以针对性地升级或替换特定的 SLM 模块，而无需重新训练或调整整个庞大的 LLM。

随着对 AI 能耗问题的日益关注，LLM-SLM 协作通过优化资源利用和减少不必要的计算

开销，有助于构建更节能环保的"绿色 AI"系统。这对于 AI 技术的可持续发展至关重要。

总而言之，大语言模型与小语言模型之间的协作，不仅是应对当前 AI 技术挑战的有效策略，也是激发 AI 应用创新、拓展 AI 能力边界的关键驱动力。

7.2 反思与展望

展望未来，关于大语言模型与小语言模型之间协作机制的研究将继续朝着更智能、更深度融合、更广泛适用的方向深化。

目前许多协作策略仍依赖于预设规则或相对固定的任务分配。未来，基于强化学习、元学习等先进技术的动态协作策略将成为主流。系统将能够根据实时任务复杂度、数据特征、可用资源乃至用户反馈，自主学习和优化协作方式，实现自配置与自适应。例如，CITER 框架中的令牌级动态路由，以及通过强化学习优化 SLM 在 RAG 任务中的角色。这将使协作系统更加灵活高效，更好地应对复杂多变的现实应用环境。

未来的协作将超越任务级分配或简单的输出组合，探索模型间更深层次的交互与能力融合。这可能涉及内部神经级别的信息交换与影响，例如共享激活值、注意力机制的相互引导，甚至构建统一或对齐的表征空间。受 DeepMLF 模型、滑动层合并等技术启发，打破模型黑箱，实现内部状态的深度耦合，有望催生出能力更强、协调更无缝的混合智能体。

随着 AI 技术向多模态理解和具身智能演进，LLM-SLM 协作将在处理和整合文本、视觉、语音乃至物理交互等多源信息流中扮演核心角色。在机器人应用中，LLM 可处理高层任务规划与理解，而机器人硬件上的一系列专用 SLM 则负责实时传感器数据、执行底层控制指令并提供快速环境响应，正如 SmallPlan 框架所展示的那样。这种分层协作将是构建能够在复杂物理世界中自主运行的智能体的关键。

随着协作系统能力的增强和广泛应用，其决策过程的透明度、潜在安全风险（如对抗性攻击、隐私泄露）以及可能存在的偏见等问题将愈发突出。未来的研究需要投入更多精力开发有效的可解释性方法、构建鲁棒的安全防御体系，并探索适用于协作智能系统的伦理准则与治理框架。

总之，大语言模型与小语言模型之间的协作机制正处于快速发展阶段。它不仅为现有 AI 技术的瓶颈提供了创新解决方案，也为人工智能的未来开辟了一片充满可能性的新大陆。我们有理由相信，随着理论研究的深入和应用场景的不断拓展，这种协作智能范式必将在未来的 AI 生态系统中扮演越来越重要的角色，推动 AI 技术朝着更高效、更通用、更智能、更负责任的方向发展。