

超越持续同调论的拓扑数据分析与拓扑深度学习——综述

Zhe Su¹, Xiang Liu², Layal Bou Hamdan³, Vasileios Maroulas³, Jie Wu⁴, Gunnar Carlsson⁵ and Guo-Wei Wei^{*2,6,7}

¹ 数学与统计系, 奥本大学, 阿拉巴马州 36849, 美国.

² 数学系, 密歇根州立大学, 密歇根州 48824, 美国.

³ 数学系, 田纳西大学诺克斯维尔分校, 田纳西州 37996-1320, 美国.

⁴ 北京数学与数学应用研究院, 北京 101408, 中国.

⁵ 数学系, 斯坦福大学, 加利福尼亚州 94305, 美国.

⁶ 生物化学与分子生物学系, 密歇根州立大学, 密歇根州 48824, 美国.

⁷ 电气与计算机工程系, 密歇根州立大学, 密歇根州 48824, 美国.

摘要

拓扑数据分析 (TDA) 是应用数学和数据科学中一个快速发展的领域, 它利用拓扑学的工具来揭示复杂数据集中稳健的、由形状驱动的洞见。其主要工具是持续同调, 这是一种植根于代数拓扑学的技术。结合拓扑深度学习 (TDL) 或拓扑机器学习, 持续同调在科学、工程、医学和工业的广泛应用中取得了巨大成功。然而, 由于其高度的抽象性、对非拓扑变化的不敏感性以及对点云数据的依赖, 持续同调存在许多局限性。本文对超越持续同调的 TDA 和 TDL 进行了全面综述。它分析了持续拓扑拉普拉斯算子和狄拉克算子如何提供谱表示, 以捕获拓扑不变量和同伦演化。其他表述则从层理论、迈耶拓扑和交互拓扑的角度进行介绍。对于可微流形上的数据, 综述了植根于微分拓扑的技术, 例如持续德拉姆上同调、持续霍奇拉普拉斯算子和霍奇分解。对于嵌入三维空间的一维 (1D) 曲线, 讨论了来自几何拓扑的方法, 包括多尺度高斯链环积分、持续琼斯多项式和持续霍诺夫同调。本文进一步讨论了针对不同输入数据 (如点云、序列数据、流形上的数据、嵌入三维空间的曲线以及具有额外非几何信息的数据) 如何适当选择拓扑工具。还综述了各种拓扑表示、软件包和机器学习向量化方法。最后, 本综述以结束语收尾。

^{1*} 通讯作者。邮箱: weig@msu.edu

MSC Classification: 62R40 , 55-08 , 57R19 , 57K18

目录

1 引言	6
2 代数拓扑方法	8
2.1 持久同调	9
2.1.1 单纯同调	10
2.1.2 过滤与持续性	10
2.1.3 其他变体	12
多参数持久同调	12
Zig-zag 持久同调	12
参数化同调	12
局部化同调	12
演化同调	13
多分辨率持续同调	13
多维持续同调	13
加权持续同调	13
持续路径同调	14
持续超图同调	14
持续超超图同调	14
基于图复形的持续同调	14
扩展持续同调	14
联持续同调	15
持续上同调	15
凯莱持续同调	15
莫尔斯理论	15
康莱指数	15
持久等变上同调	16
偏序集上的持续性	16
2.1.4 其他视角	16
2.1.5 组合拉普拉斯算子	18
2.1.6 持久组合拉普拉斯算子	18
2.1.7 其他变体	19
持久路径拉普拉斯算子	20

持久超（有向）图拉普拉斯算子	20
持久跳跃路径拉普拉斯算子	20
持久有向旗复形拉普拉斯算子	20
用于单纯映射的持久拉普拉斯算子	20
多尺度霍赫希尔德拉普拉斯算子	21
2.2 持久狄拉克算子	21
2.2.1 狄拉克算子	21
2.2.2 持久狄拉克算子	22
2.2.3 其他变体	23
持久路径狄拉克与超图狄拉克算子	23
持久迈耶狄拉克算子	23
霍瓦诺夫狄拉克算子	24
2.3 其他表述	24
2.3.1 持久层理论	24
2.3.2 持久迈耶拓扑	25
2.3.3 持久交互拓扑	25
2.4 带边流形的 de Rham-Hodge 理论	27
2.4.1 de Rham 上同调	28
2.4.2 Hodge 拉普拉斯算子	28
2.4.3 Hodge 分解	29
2.5 持久 de Rham 上同调	30
2.6 持久霍奇拉普拉斯算子	31
2.6.1 拉格朗日表述	32
2.6.2 欧拉表述	32
3 几何拓扑方法	33
3.1 局部化琼斯多项式	35
多尺度琼斯多项式	35
持久琼斯多项式	35
3.2 持久 Khovanov 同调	36
3.3 Khovanov 拉普拉斯算子与 Khovanov 狄拉克算子	37
4 机器学习特征化	38
4.1 输入数据类型与拓扑建模的选择	38

4.1.1	点云数据	38
4.1.2	距离矩阵数据	39
4.1.3	网络数据	40
4.1.4	流形上的数据	40
4.1.5	序列数据	41
4.1.6	纽结、链环、缠结与辫子	42
4.1.7	具有额外非几何信息的数据	43
4.2	拓扑表示方法	44
4.2.1	持久同调/上同调的表示形式	44
	持久条形码/图	44
	持久贝蒂数/贝蒂曲线	44
	持久性景观	45
	持久性图像	45
	持久贝蒂数图像	46
	彩色持久条形码	46
	分级持久条形码	46
4.2.2	持久拉普拉斯算子的表示	47
	特征值表示	47
	特征向量表示	47
	Hodge 分解表示	48
4.2.3	持久狄拉克算子的表示	48
4.2.4	多尺度高斯环绕积分的表示	48
4.2.5	多尺度/持久琼斯多项式的表示	49
4.2.6	软件与代码资源	49
4.3	特征化方法	49
4.3.1	函数化表述	50
4.3.2	分箱计数	50
4.3.3	统计特性	51
4.3.4	代数形式化	51
4.3.5	多维公式化方法	52
4.3.6	基于核的模型	53
4.3.7	持久同调的统计框架	53

1 引言

拓扑数据分析 (TDA) 植根于拓扑技术, 是应用数学和数据科学中一种新兴的方法。TDA 从数据中提取无法通过统计、物理或其他数学方法获得的拓扑信息。由于拓扑学是数学中最抽象的领域之一, TDA 本质上降低了高维数据的维度。此外, 它简化了几何复杂性, 并提供高阶数据表示, 从而扩展了传统的零阶算法。与经典拓扑学或同调论不同, TDA 采用多尺度分析, 通过过滤连接拓扑与几何。

TDA 的一个基石是持续同调 [112, 333], 这是一种用于分析点云或离散数据的代数拓扑工具。持续同调在空间尺度上构建一系列拓扑空间, 捕捉不同维度的拓扑不变量。更多细节请参见 [44, 116]。其标准表示, 即持续条形码 [132] 和持续图 [112], 编码了特征 (例如连通分量、孔洞、腔体) 在过滤过程中的诞生、消亡和持续性。持续同调最初用于定性分析, 现已演变为定量分析和机器学习的强大工具 [42, 313, 317]。其应用涵盖图像处理 [17, 72]、神经科学 [84]、计算化学 [291]、生物学 [37, 38, 128, 178]、纳米材料 [184, 317]、晶体材料 [161] 以及复杂网络 [156]。

尽管持续同调具有实用性, 但它也存在显著的局限性 [310]。它主要捕捉拓扑不变量, 常常忽略过滤过程中当没有拓扑变化发生时几何形状的演变。此外, 它在处理数据中的局部拓扑信息方面存在困难, 并且无法直接分析微分流形或嵌入三维空间的一维曲线 (例如纽结、链环) 上的数据。为将各种数据结构开发持久拓扑拉普拉斯算子, 已付出诸多努力, 这些表示可被整合到机器学习模型中。针对点云数据和图, Wang 等人 [302] 引入了持久组合拉普拉斯算子, 并在近年来得到了广泛研究 [143, 195, 217, 303]。持久组合拉普拉斯算子的调和谱捕捉了拓扑不变量的变化, 这可以恢复持久同调所捕获的拓扑信息, 而非调和谱则编码了过滤过程中的几何形状变化 [217]。除了持久组合拉普拉斯算子外, 针对其他拓扑领域也提出了多种持久拓扑拉普拉斯算子。这些包括用于标记点云数据的持久层拉普拉斯算子 [310]、用于有向图和网络的持久路径拉普拉斯算子 [300]、用于具有复杂关系的图和网络的持久超图拉普拉斯算子 [202] 和持久超有向图拉普拉斯算子 [60], 以及用于旗复形的持久有向旗拉普拉斯算子 [163, 329]。持久拓扑拉普拉斯算子已成功应用于蛋白质-配体结合预测 [58, 219, 282]、相互作用组网络建模 [110]、基因表达分析 [81]、深度突变扫描 [66] 和蛋白质工程 [253]。特别值得一提的是, 持久拓扑拉普拉斯算子最令人印象深刻的成就之一是对新兴主导 SARS-COV-2 变体 BA4 和 BA5 的预测 [65]。

另一种重要的谱方法是量子持久同调或持久狄拉克算子，最初由 Ameyro 等人 [9] 引入。在量子理论中，狄拉克算子对应于动量，而拉普拉斯算子对应于动能，这揭示了它们之间的关系。持久狄拉克算子已在许多拓扑领域中得到研究，并具有多种应用 [287, 308]。对于（微分）流形上的数据，一种自然的方法是持久德拉姆上同调，它植根于微分拓扑或微分几何。然而，持久德拉姆上同调很少被独立实现。相比之下，进化德拉姆-霍奇理论（包含持久德拉姆上同调）由 Chen 等人首次提出，用于处理拉格朗日表示（即四面体网格）中的微分流形数据 [64]。该方法借鉴了微分几何或微分拓扑。最近，持久霍奇拉普拉斯算子在欧拉表示（即由水平集函数定义的笛卡尔网格）中得到了发展 [282]。组合拉普拉斯算子与霍奇拉普拉斯算子之间的相似性和差异性已在 [260] 中进行了深入讨论。然而，“霍奇拉普拉斯算子”这一术语也用于组合设定，这可能有些误导性。本质上，尽管正交分解可以同时组合拉普拉斯算子和霍奇拉普拉斯算子进行，但只有微分流形上向量场的霍奇分解才能产生无旋、无散和调和分量，即所谓的亥姆霍兹-霍奇分解 [181, 324]。持久层理论 [309, 319] 和持久交互拓扑 [193] 可以有效地描述数据中的局部拓扑。对于带边界的流形，发展了一种更精细的保拓扑五分量霍奇分解，在某些边界条件下将调和分量进一步拆分为三个子分量 [248, 249, 281, 283, 324]。霍奇分解是通过提取不同动态特征来分析向量场的重要工具，在计算流体动力学 [318, 320]、几何建模 [304] 和谱数据分析 [171] 中有许多应用。最近，它已被应用于单细胞 RNA 速度的研究 [281]，并与深度学习模型集成用于医学图像分析 [207]。

对于嵌入三维空间的一维曲线数据，自然的方法源于低维拓扑。提出了多尺度高斯环绕积分方法来处理类组结数据 [270]。此外，还引入了多尺度琼斯多项式和持久琼斯多项式 [277]。最近，持久科瓦诺夫同调得到了发展 [194, 268]。虽然科瓦诺夫同调连接了几何拓扑和代数拓扑，但持久科瓦诺夫同调将 TDA 扩展到了嵌入三维空间的一维数据。Cang 和 Wei 于 2017 年首次将持久同调与深度神经网络相结合，包括拓扑深度学习（TDL）[37]。通过利用拓扑的高层抽象，TDL 显著降低了维度、简化了几何复杂性、捕捉了高阶相互作用，并提供了一个可解释的学习框架。基于持久同调的机器学习模型已成功应用于科学、工程、医学、工业、国防等多个领域 [151, 243]。然而，拓扑本质上简化了数据，这意味着某些信息的不可逆丢失。因此，TDL 的竞争性表现主要涉及本质上复杂的数据，例如在生物科学中发现的数据 [40]。或许 TDL 持续展示其相对于其他竞争方法优势

的一些最引人注目的应用实例包括：TDL 在 D3R Grand Challenges 中的胜利 [233, 234]、SARS-CoV-2 进化机制的发现 [63, 301]，以及成功提前约两个月预测 SARS-CoV-2 变体 BA.2[62] 和 BA.4/BA.5[65]。

机器学习通常要求所有样本具有统一的输入向量。因此，通常需要对 TDA 信息进行特征化或向量化，以将拓扑表示（如持久条形码、图、图像、景观、Betti 曲线等）转换为固定长度的特征向量。已有许多尝试来定义核函数 [53, 180, 183, 255]。其他研究则侧重于开发特征化技术，例如统计摘要 [6, 14, 15, 37, 40, 42, 167, 330, 331]、持久性分箱 [37]、拓扑图像 [40] 以及 Wasserstein 度量 [40]。

已有大量综述对持久同调及其特征化进行了探讨 [8, 21, 70, 77, 116, 250]，以及一篇专门关于持久拓扑拉普拉斯算子的综述 [310]。然而，目前尚无关于持久同调的推广及其向量化的综述。本文旨在对超越持久同调的各种 TDA 方法及其机器学习特征化方法提供一个高层次的概述，而不涉及过多的技术细节或公式。这项工作旨在使该领域的新研究人员能够理解，并提供对各种技术及其应用的广泛视角。本文其余部分的组织结构如下。第 2 节专门介绍定义于点云数据上的代数拓扑方法与技术。这些方法包括持久同调及其在各种拓扑域上的推广、各种拓扑域上的持久拓扑拉普拉斯算子、持久狄拉克算子、持久层理论、持久迈耶拓扑以及持久相互作用。第 ?? 节回顾源于微分拓扑或微分几何的方法。我们讨论了带边界流形上数据的德拉姆-霍奇理论，这是各类应用中常用的设定。文中探讨了持久德拉姆-霍奇理论，包括持久德拉姆上同调与持久霍奇拉普拉斯算子。第 3 节致力于介绍各种基于几何拓扑的 TDA 方法，例如多尺度高斯环绕积分、持久琼斯多项式、持久霍瓦诺夫同调以及霍瓦诺夫拉普拉斯算子。

向量化技术在第 4 节中予以评述。我们讨论了常用方法，例如统计摘要、贝蒂曲线、持久景观图与持久图像。我们还提供了适用于谱方法的相关特征化技术，包括特征值、特征向量与霍奇分解。此外，我们探讨了针对不同类型数据集进行有效分析的 TDA 方法选择问题。最后，在第 5 节中，我们给出总结性评论。

2 代数拓扑方法

近年来，点云数据的拓扑数据分析发展迅速，提供了一系列建立在代数拓扑工具之上的方法。这些方法通过过滤过程提取拓扑和几何特征，从而提供点云数据的多尺度表征。由此产生的特征提供了关于底层数据的丰

富信息，并已成功集成到许多下游分析中，包括分类、聚类和其他机器学习任务。

最基本的方法是持续同调 [112, 333]，它捕捉了在过滤过程中不同尺度上拓扑特征（如连通分量、孔洞和腔体）的持续性。然而，它存在一些局限性，因为它主要关注拓扑，而没有考虑过滤过程中的几何演化或与数据点相关的附加结构，并且对于大型数据集计算成本可能很高，参见第 2.1.4 节。

最近发展的方法，例如持续组合拉普拉斯算子 [302] 及其变体 [60, 163, 202, 300, 329]，以及持续狄拉克算子 [9, 10] 及其变体 [286, 287]，推广了持续同调并解决了其部分局限性。持续组合拉普拉斯算子 [302] 将多尺度分析与组合拉普拉斯算子相结合，允许分析不同尺度上的拓扑和几何或组合结构。它们的调和谱完全恢复了持续同调的拓扑信息，而非调和谱则提供了数据的额外几何或组合特征。持续狄拉克算子 [9, 10] 的平方产生持续组合拉普拉斯算子，它提供了基于量子计算的高效算法，与拓扑数据分析中的经典方法相比具有指数级加速。此外，还有基于其他同调理论的表述，例如持续层拉普拉斯算子 [309]，它进一步扩展了持续组合拉普拉斯算子，允许分析带标签或带权重的数据集；迈耶拓扑 [269, 287]；以及持续交互拓扑 [193, 194]。这些工具为捕捉标准同调无法访问的拓扑特征提供了新的视角。

接下来，我们首先回顾持续同调及其变体和局限性，然后转向持续组合拉普拉斯算子及其各种变体，用于分析具有附加结构的点云数据。接着，我们描述持续狄拉克算子及其变体。最后，我们讨论其他表述，包括持续层拓扑、持续迈耶拓扑和持续交互拓扑。

2.1 持久同调

持久同调是单纯同调的一种多尺度扩展，它是代数拓扑学中的一个工具，用于根据单纯复形的同调群对其进行分类。同调群度量了底层单纯复形中的拓扑特征，例如连通分支、空洞和腔体。它们的秩由贝蒂数给出，用于计数这些拓扑特征的数量。例如，第 0 个贝蒂数提供了连通分支的数量，第 1 个贝蒂数给出了圆环或空洞的数量，而第 2 个贝蒂数则代表腔体的数量。

然而，单纯同调不能直接应用于点云数据，因为除非明确构建，否则此类数据没有定义良好的拓扑结构。此外，它对尺度敏感，因为不同的尺度选择可能导致不同的同调群。持久同调通过引入过滤和持续性来解决这些局限性，从而为底层数据提供更稳健的表征。

2.1.1 单纯同调

单纯复形由单纯形构成，其中 k -单纯形定义为 $k+1$ 个仿射独立点 $v_0, v_1, \dots, v_k$ 的凸包，其维数为 k 。例子包括点（0-单纯形）、线段（1-单纯形）、三角形（2-单纯形）和四面体（3-单纯形）。这些点 $v_0, v_1, \dots, v_k$ 称为 k -单纯形的顶点，由所有这些顶点集合的子集形成的单纯形称为面。

单纯复形 K 则定义为满足粘合条件的有限单纯形集合，其中每个单纯形的所有面也属于 K ，且 K 中任意两个单纯形的交集要么为空，要么是两者的公共面。 K 的维数由其单纯形的最大维数给出。 K 的所有 k -单纯形在某个域（通常为 $\mathbb{Z}_2$ ）上的线性组合定义了一个 k -链。所有 k -链的集合，连同加法运算，构成一个阿贝尔群 $\mathcal{C}_k(K)$ ，称为第 k 个链群。 K 的所有 k -单纯形的集合构成了 $\mathcal{C}_k(K)$ 的一组基。

为了定义边缘算子 ∂ ， K 中的每个单纯形都需要被定向（当使用 $\mathbb{Z}_2$ 系数时，由于 $-1 = +1$ ，定向不是必需的）。一个有向 k -单纯形表示为其顶点的有序列表，记作 $[v_0, v_1, \dots, v_k]$ 。定向对于构造链复形和定义同调至关重要，因为它确保了 $\partial\partial = 0$ 。第 k 个边缘算子 $\partial_k : \mathcal{C}_k(K) \rightarrow \mathcal{C}_{k-1}(K)$ 是一个线性映射，作用于每个 k -单纯形，将其映射为其 $(k-1)$ -面的交错和，其中每个面通过从 k -单纯形中移除一个顶点得到，即，

$$\partial_k[v_0, v_1, \dots, v_k] = \sum_i (-1)^i [v_0, \dots, \hat{v}_i, \dots, v_k]$$

边缘算子满足 $\partial_k \partial_{k+1} = 0$ 。链复形由通过边缘算子连接的一系列链群给出：

$$\dots \xrightarrow{\partial_{k+2}} \mathcal{C}_{k+1} \xrightarrow{\partial_{k+1}} \mathcal{C}_k \xrightarrow{\partial_k} \mathcal{C}_{k-1} \xrightarrow{\partial_{k-1}} \dots$$

K 的第 k 个单纯同调群定义为边缘算子 ∂_k 的核模去 ∂_{k+1} 的像的商群：

$$H_k(K) = \ker \partial_k / \operatorname{im} \partial_{k+1},$$

其中 $\ker \partial_k$ 和 $\operatorname{im} \partial_{k+1}$ 分别称为 k -闭链群和 k -边缘链群。同调群 $H_k(K)$ 捕捉了那些不是 k -边缘链的 k -闭链，即单纯复形中的 k 维洞。其秩，称为第 k 个贝蒂数 β_k ，用于计数这些洞的数量。

2.1.2 过滤与持续性

过滤由一系列嵌套的单纯复形序列给出。对于点云数据，需要通过构建单纯复形来表示数据点及其在不同维度上的连接，从而构造这样的过滤。最常用的三种复形是 Vietoris-Rips 复形 [295]、Čech 复形 [114] 和 Alpha

复形 [113]。此外还有其他构造方法，例如见证复形 [88]、覆盖复形 [51] 和切向复形 [159]。

Vietoris-Rips 复形 [295] 的构造方法是：考虑以每个数据点为中心、在固定距离内的球的两两相交，只要其顶点之间存在两两重叠的区域，就形成一个单形。Čech 复形 [114] 要求一个集合中所有球的交集非空，这意味着只有当所有对应球都相交时，才包含一个单形。Alpha 复形的构造方式与 Čech 复形类似，但每个球被限制在与每个点关联的 Voronoi 胞腔内。Alpha 复形 [113] 是 Čech 复形的一个子集，但具有相同的同调。通过改变球的半径，可以得到一个单纯复形的过滤。Čech 复形需要检查大量的相交情况，因此对于大型数据集计算成本显著更高，这使得 Vietoris-Rips 复形成为实际应用中最常见的选择。Čech 复形的一个替代方案是 Alpha 复形，当环境空间的维度为 2 或 3 时，其计算效率尤其更高 [114]。

设 K 是由点云构造出的最大单纯复形。那么该点云的一个过滤是 K 的子复形的一个嵌套序列：

$$\emptyset \subset K^0 \subset K^1 \cdots \subset K^m = K.$$

记 $i^{i,j}$ 为从 K_i 到 K_j 的包含映射，其中 $i < j$ 。它在同调群上诱导的映射 $f_k^{i,j} : H_k(K^i) \rightarrow H_k(K^j)$ 追踪了 k 维空洞在过滤过程中的演化，更准确地说，是追踪 $H_k(K^i)$ 中的 k 维同调类是否仍然存在于 $H_k(K^j)$ 中。记 $\partial_k^i : C_k(K^i) \rightarrow C_{k-1}(K^i)$ 为单纯复形 K^i 上的第 k 个边界算子。第 k 个持续同调群定义为 $f_k^{i,j}$ 的像：

$$H_k^{i,j} = \text{im } f_k^{i,j} = \ker \partial_k^i / (\text{im } \partial_{k+1}^j \cap \ker \partial_k^i),$$

其秩导出对应的第 k 个持续贝蒂数 $\beta_k^{i,j} = \text{rank } H_k^{i,j}$ 。拓扑特征的出生和死亡可以通过检查持续同调群中的元素来定义。如果一个特征首次出现在 K^i ，则称其出生于 K^i ；如果它在 K^j 处与一个在 K^j 之前就已存在的特征合并，则称其死亡于 K^j 。特征 γ 的持续性（即拓扑特征的寿命）由 $j-i$ 给出，如果它在过滤中永不死亡，则被视为无限。

这些拓扑特征的出生和死亡信息催生了持续同调的各种表示方法，例如持续性条形码 [132]、持续性图 [112]、持续贝蒂数、贝蒂曲线、持续性景观 [34]、持续性图像 [4]。关于这些特征化技术的更多细节将在第 4 节中讨论。持久同调已成功应用于从图像处理到复杂网络等多个领域 [17, 37, 38, 72, 84, 128, 156, 161, 178, 184, 291]。其最显著的成就之一是与深度学习模

型的结合，这在 D3R 大挑战 [233, 234] 以及预测 SARS-CoV-2 的进化机制 [63, 301] 中取得了卓越的性能。

2.1.3 其他变体

除了单纯复形持久同调的标准表述外，针对具有不同结构的数据或满足特定应用需求，人们提出了若干变体。下面我们简要回顾这些方法。

多参数持久同调

多参数持久同调最初在 [46] 中被探讨，而尺寸理论中的一个变体则在 [127] 中被引入。该框架通过考虑两个或更多参数而非单一参数来扩展经典同调理论，适用于分析含有异常值或密度变化的数据、配备实值函数的数据以及具有较大局部噪声的函数数据。更多介绍性资源，请参见 [31, 103, 169, 263]。关于计算和软件的讨论可参见 [31]。

Zig-zag 持久同调

Zig-zag 持久同调在 [45] 中被引入，用于处理更一般的设置，其中空间序列通过任意方向的映射连接，这与经典持久同调中包含映射沿同一方向进行形成对比。该框架功能强大，因为它允许过滤中的单纯复形随着单形的插入和删除而演化，这适用于分析动态点云或具有变化顶点连接的动态图 [67, 95, 96, 154]。已提出了多种用于计算 *zigzag* 持久性的软件 [47, 97]。该框架也已扩展到多参数设置 [96, 98]。

参数化同调

参数化同调 [50] 将水平集 *zigzag* 持久同调扩展到连续参数设置。该框架利用矩形测度理论 [56] 定义了四个不同的连续参数持久图，每个图对应于水平集 *zigzag* 条形码中的四种条形类型之一。这些图编码了同调特征，并捕获了关于每个特征在其定义区间两 endpoints 如何消失的详细信息。

局部化同调

局部化同调 [334] 被提出来用于识别拓扑属性（如隧道和空洞）的位置。给定一个具有覆盖的拓扑空间，局部化同调工具可用于确定拓扑特征在空间内的位置（特定的覆盖元素）。具体而言，它构造了一个更大的爆破复形 [267]，该复形与原始空间同伦等价，并且在覆盖元素之间具有清晰的

边界。然后在爆破复形上计算同调基，从而将特征定位到特定的覆盖元素。还为实际应用提供了一种高效算法。

演化同调

Cang 等人 [41] 引入了演化同调 (EH)，这是一种为物理系统内的单个组件生成时间依赖的拓扑不变量 (“演化条形码”) 的方法。EH 通过耦合微分方程或混沌振荡器来模拟系统相互作用，从而创建耦合动力学。在这些振荡器产生的轨迹上，他们使用基于时间演化的过滤定义了单形、单纯复形、代数群和拓扑持久性。这一过程揭示了单个组件的拓扑-功能关系，并且对于分析点云数据中的局部拓扑特别有效。EH 已成功应用于生物物理学中的实际问题。

多分辨率持续同调

多分辨率持续同调是为分析过大规模数据集而提出的 [315, 316]。其核心思想是通过采用由分辨率参数调制的刚性-密度函数，来匹配数据中感兴趣的尺度。通过调整这些参数，原始的大规模数据集可以在一个合适的较低分辨率下表示，从而实现高效的拓扑分析。

多维持续同调

多维持续同调最初于 2007 年被引入，用于分析多重滤过的拓扑结构 [46]。后来，另一种版本的多维持续同调 [314] 被提出，用于将动态数据和单分子数据都转化为基于图像表示。对于动态数据，其图像表示是通过在时间步上对每个数据帧重复应用持续同调来构建的。对于单分子数据，持续同调被应用于分子的体积密度表示在多个空间尺度上，并将得到的拓扑特征聚合以形成最终的图像。

加权持续同调

加权持续同调用于研究加权数据，例如加权单纯复形，其中每个单形都被赋予一个权重。主要有两种方法来捕获权重信息：一种方法使用权重来细化滤过过程 [115, 247]，而另一种方法则通过纳入权重来修正链复形的边缘算子 [87, 257]。加权持续同调已被应用于各种生物分子数据分析应用 [220, 251]。

持续路径同调

持续路径同调已被引入用于分析包含非对称方向信息的有向网络 [69], 它将 TDA 中的滤过方法与路径同调理论相结合。路径同调 [137], 最近更名为 GLMY 同调 [158], 在理论 [104, 138, 140, 186, 187] 和应用 [59, 124, 135, 312] 方面都得到了广泛发展。

持续超图同调

持续超图同调 [33] 是标准持续单纯同调到超图的推广。利用嵌入同调理论, 超图同调适用于处理信息不完整的系统 [201], 例如合著者网络, 其中可能存在三人合作但并非所有两两合作都存在的情况。超图的稳定性结果 [256] 和离散莫尔斯理论 [258] 已经建立, 并且持续超图同调的算法实现 [205] 也已开发出来。

持续超超图同调

持续超超图同调 [136] 提供了一个统一且广义的框架, 将持续单纯同调、持续超图同调和持续 Δ -集合同调都作为其特例。与单纯复形和超图相比, 超超图的一个显著特点是每个超边并非由其顶点唯一确定, 这意味着存在额外的内部结构。这使其成为一个灵活的框架, 能够捕捉各种系统的复杂性 [123, 206]。

基于图复形的持续同调

在拓扑数据分析中, 为数据构建合适的单纯复形, 其重要性堪比机器学习中的数据表示。最常用的构造是 Vietoris-Rips 复形 [332] 和 Alpha 复形 [113], 这主要得益于现有成熟且用户友好的软件包。一些研究探索了使用其他基于图的复形, 例如旗复形 [156, 210]、Dowker 复形 [203]、邻域复形 [200]、Hom-复形 [204] 以及其他复形 [136, 165]。针对特定应用选择最合适的复形, 而非仅仅使用流行的选择, 值得进一步研究。

扩展持续同调

持续图之间的距离常被用来比较不同拓扑空间的拓扑特征。然而, 具有不同贝蒂数的拓扑空间的持续图, 在任何滤过下都可能导致无限距离。扩展持续同调 [74, 292] 通过扩展滤过过程来解决这一限制, 使得所有同调类都被赋予一个出生时刻和一个死亡时刻。

联持续同调

联持续同调 [305] 基于拓扑学中的联运算。其思想是，通过在联过程中使用不同类型的单元，可以从多个视角捕捉不同的拓扑特征。这使得该方法能够揭示数据中多样的结构信息。联持续同调也为具有不同贝蒂数的空间之间持续图距离无限的问题提供了一个解决方案。

持续上同调

持续上同调是持续同调的姊妹理论，在时间和空间上具有计算优势。在实践中，人们通常先计算持续上同调，然后通过对偶性推导出持续同调 [90]，因为前者计算起来可能更高效。GUDHI 软件包 [211] 就是一个例子。许多应用依赖于原始的持续上同调算法 [89]。一些研究探索了将领域特定信息融入上同调类，以增强应用中背景相关信息的表征 [39, 201]。

凯莱持续同调

凯莱持续同调是基于群分次 [27] 构建的。与标准的 $\mathbb{Z}$ -分次持续同调类似，它也具有分解结果。关键区别在于其能够捕捉更灵活的持续模式。它不仅允许持续现象出现在区间和网格上，还允许其出现在由底层群分次引入的更复杂结构上。

莫尔斯理论

莫尔斯理论 [231] 提供了一个分析和刻画形状拓扑的框架。其核心思想是将形状表示为一个配备莫尔斯函数的拓扑空间，该函数通过其临界点捕捉关键的拓扑特征。离散莫尔斯理论已与持久同调相结合，用于无权无向网络的分析 [168]。莫尔斯理论的计算算法已被开发 [145]。莫尔斯分解的持久同调已被应用于组合动力学 [102]。在莫尔斯理论衍生的各种描述子中，里布图可能是应用最广泛的 [29, 130, 254, 323]。里布图的一个关键特性是能够将形状的拓扑结构编码成一维图，且独立于底层流形的内在维度。

康莱指数

动力系统分析的大部分内容涉及不变集的存在性与结构。康莱指数理论由康莱及其追随者发展 [61, 76, 225]，是研究此类不变集的重要拓扑工具。康莱指数理论不分析任意的不变集，而是专注于孤立不变集，这类集合比一般不变集对连续扰动更具鲁棒性。对于一个孤立不变集 S ，可以从其指数对构造一个商空间， S 的同伦康莱指数是该商空间的同伦型，而 S

的上同调康莱指数是该商空间具有整数系数的亚历山大-斯潘尼尔上同调。康莱指数在动力系统的某些形变下保持不变，可用于确定动力系统的不动点和周期轨道的存在性。最近，康莱指数已被扩展至持久化设定以用于数据分析 [100, 101]。

持久等变上同调

对于一个带有群作用的数据集，持久等变上同调不仅捕捉数据集的底层形状，还捕捉群作用的性质，即数据中固有的对称性。在 [5] 中，作者明确描述了圆周在其 Vietoris-Rips 度量加厚上的作用的持久等变上同调。特别地，他们推导了这些 Vietoris-Rips 加厚的持久等变上同调的显式公式。当等变上同调基于自由群作用时，可将其视为扭曲上同调的一个特例，其中的扭曲源于群作用。已有多项研究在不同背景下探索了扭曲（上）同调的理论 [139, 188, 322]。

偏序集上的持续性

偏序集上的持续性 [175] 是一个通用框架，其中持续性模定义在偏序集上，多参数持续性作为其特例，其索引偏序集为 $\mathbf{R}^n$ 。作为多参数持续性中最著名的同调不变量，秩不变量 [46] 通过自然地扩展其定义域，已演变为适用于偏序集上持续性的广义秩不变量 [244]。特别地，对于任何有限维向量空间的区间可分解持续性模，其条形码可以通过容斥原理 [174] 从广义秩不变量中提取。这意味着广义秩不变量是区间可分解持续性模的一个完备不变量，而秩不变量并非区间可分解多参数持续性模的完备不变量 [32]。

2.1.4 其他视角

尽管持久同调具有极大的实用性，但仍有许多方向需要对其进行扩展。这些扩展与主流代数拓扑学（即实际空间和流形的拓扑学，而非点云的拓扑学）中的大量工作相平行。以下是其中几个方向。

- **谱分析：**注意，持久同调未能捕捉到过滤过程中同伦几何形状的变化，这意味着它无法区分具有相同拓扑结构的不同形状 [153]。基于拉普拉斯算子的谱分析，已经发展出多种框架来解决这一局限性 [310]。这些方法不仅从持久同调中恢复拓扑信息，还能捕捉描述过滤过程中同伦几何形状变化的额外信息。
- **分析方法：**从该学科的早期开始，人们就理解到，在流形的情况下，存在使用微分形式计算某种版本的同调（系数为 $\mathbb{R}$ 的同调）的方法。这些

方法依赖于德拉姆上同调 [306]。这些方法的优点在于，它们将同调的定性信息与流形上的分析联系起来。另一个优点是，霍奇定理 [306] 提供了在上同调类中选择一个调和代表元，从而明确了该类的意义。这一分析中的一个关键要素是霍奇拉普拉斯算子，它是微分形式上的一个偏微分算子。

- **层：**在 20 世纪早期同调方法初步发展之后，到 1950 年，人们逐渐认识到，为了更有效地利用同调方法来理解空间，需要更复杂的概念，即由 J. Leray 开创的以层为系数的上同调 [185]。这一概念对于将拓扑技术扩展到代数几何和数论至关重要 [92, 93, 311]。
- **从局部到整体的计算：**使用线性代数方法直接计算拓扑不变量，除了最小的玩具示例外，通常是难以处理的。因此，代数拓扑学家被迫开发并行计算的方法，并利用问题中固有的结构，例如纤维化结构。这些思想的例子包括使用迈耶-菲托里斯长正合序列和谱序列、纤维化的塞尔谱序列、艾伦伯格-穆尔谱序列 [216]。
- **先验知识：**拓扑问题通常配备有先验信息，例如到某个参考基空间的映射，或者空间内某些子空间的选择。同调方法已经得到改进，以在更精细的不变量中捕捉这些额外信息。

为了应对持久同调无法捕捉过滤过程中同伦几何变化的局限性，近期研究引入了持久组合拉普拉斯算子 [302]，以及其他一些持久拉普拉斯算子的变体 [60, 163, 202, 300, 309, 329]，这些算子通过谱同时编码了数据的拓扑结构以及几何或组合结构。与持久同调相比，这些持久拉普拉斯算子能够对数据集进行更深入的分析。它们的调和谱（即零特征值）完全恢复了持久同调产生的拓扑输出，而非调和谱（即非零特征值）则捕捉了关于数据形状的额外几何或组合信息。这些额外信息对于描述过滤过程中持久同调无法检测到的同伦几何形状变化特别有用。Wei 和 Wei [310] 对持久拉普拉斯算子进行了全面的综述。

这些持久拓扑拉普拉斯算子可以视为组合拉普拉斯算子 [111] 的多尺度表述，后者起源于谱图论，并将图拉普拉斯算子 [176] 的概念推广到更高维的单纯复形。研究组合拉普拉斯算子的谱对于理解数据的形状至关重要，近年来受到了广泛关注 [134, 144, 155]。

接下来，我们首先概述组合拉普拉斯算子，然后讨论持久组合拉普拉斯算子，最后介绍几种其他变体的持久拓扑拉普拉斯算子。

2.1.5 组合拉普拉斯算子

组合拉普拉斯算子将经典的图拉普拉斯算子推广到单纯复形 [111]。与仅编码节点间连接的图拉普拉斯算子相比，组合拉普拉斯算子是使用边界算子构建的，这些边界算子捕获了包括顶点、边、三角形以及更高维结构在内的各维单形之间的关系。

第 k 个组合拉普拉斯算子 L_k 作用于第 k 个链群 $\mathcal{C}_k(K)$ 上，定义如下：

$$L_k = \partial_{k+1} \partial_{k+1}^* + \partial_k^* \partial_k,$$

其中 ∂_k^* 是边界算子 ∂_k 关于链群 $\mathcal{C}_k(K)$ 上定义的内积的伴随算子。注意，这里的组合拉普拉斯算子 L_k 是定义在链群上的，相应的构造也可以在余链群上进行，参见 [155]。组合拉普拉斯算子 L_k 是半正定对称的，因此其谱仅由非负实特征值组成。当 K 是一个图时， $L_0 = \partial_1 \partial_1^*$ 简化为图拉普拉斯算子。此外，组合拉普拉斯算子导出了一个组合版本的霍奇分解：

$$\mathcal{C}_k = \text{im } \partial_{k+1} \oplus \ker L_k \oplus \text{im } \partial_k^*,$$

更多细节参见 [191]。

当链群 $\mathcal{C}_k(K)$ 上的内积由克罗内克 δ 函数 $\delta_{i,j}$ 定义时，即 $\mathcal{C}_k(K)$ 中的所有基元素被视为相互正交，边界算子 ∂_k 可以表示为一个大小为 $N_{k-1} \times N_k$ 的矩阵，其伴随算子 ∂_k^* 则为该矩阵的转置。这里 N_k 表示 k -单形的数量。

如 [111] 所示，单纯复形 K 上第 k 个拉普拉斯算子的核对应于其第 k 个单纯同调群：

$$\ker L_k = H_k(K),$$

从而捕获了单纯复形的拓扑信息。其维数由第 k 个贝蒂数给出。此外，非调和谱捕获了底层结构的几何或组合特征。特别地，如图论中所指出的，第一个非零特征值描述了一个图的连通性。

2.1.6 持久组合拉普拉斯算子

为了将持久性的思想融入组合拉普拉斯算子，Wang 等人 [302] 引入了持久组合拉普拉斯算子，这是首个在理论和实践上建立持久同调与组合拉普拉斯算子之间联系的工作。持久拉普拉斯算子的概念也出现在一篇研讨会笔记中 [190]。关于持久组合拉普拉斯算子的全面理论研究可参见 [217]，其稳定性结果则见于 [195]。

给定滤过中的一对单纯复形 $K^i \subset K^j$ ，第 k 个链群 $C_k(K^i)$ 上的第 k 个持久组合拉普拉斯算子定义如下：

$$L_k^{i,j} = \partial_{k+1}^{i,j} (\partial_{k+1}^{i,j})^* + (\partial_k^i)^* \partial_k^i,$$

其中 ∂_k^i 是 K^i 上的第 k 个边界算子， $\partial_{k+1}^{i,j}$ 称为持久边界算子，由 ∂_{k+1}^j 限制到第 $(k+1)$ 个链群 $C_{k+1}(K^j)$ 的一个子群 $C_{k+1}^{i,j}$ 上给出，使得其元素的像在 $C_k(K^i)$ 中，而 $(\partial_k^i)^*$ 和 $(\partial_{k+1}^{i,j})^*$ 分别是它们的伴随算子。当 $i = j$ 时，第 k 个持久边界算子等于标准边界算子，即 $\partial_k^{i,i} = \partial_k^i$ ，因此第 k 个持久组合拉普拉斯算子退化为 K^i 上的标准第 k 个组合拉普拉斯算子。持久组合拉普拉斯算子 $L_k^{i,j}$ 与组合拉普拉斯算子类似，是半正定对称的，其特征值为实数且非负。该算子也导出一个持久的霍奇分解 [190]，如下所示：

$$C_k(K^i) = \text{im } \partial_{k+1}^{i,j} \oplus \ker L_k^{i,j} \oplus \text{im } (\partial_k^i)^*.$$

持久组合拉普拉斯算子的实现已作为一个名为 HERMES 的开源软件包提供 [303]。该算法基于 alpha 复形滤过的一种实用构造 [113]。通过为最终的完整 alpha 复形（即 Delaunay 剖分 [91]）构造一个单的第 k 个边界算子以及某些投影矩阵， $(\partial_{k+1}^{i,j})^*$ 和 $(\partial_k^i)^*$ 的矩阵表示都简单地由表示 $\partial_{k+1}^{i,j}$ 和 ∂_k^i 的矩阵的转置给出。计算持久组合拉普拉斯算子的另一种算法可参见 [217]。

一个直接的结果是，第 k 个持久组合拉普拉斯算子的核同构于第 k 个持久同调群 [190, 217]：

$$\ker L_k^{i,j} = H_k^{i,j},$$

因此其维数即为第 k 个持久贝蒂数。因此，持久组合拉普拉斯算子的调和谱恢复了来自持久同调的拓扑信息，而非调和谱则提供了数据形状的额外几何或组合演化特征。持久组合拉普拉斯算子已被应用于各种生物学问题，例如蛋白质热稳定性 [302]、蛋白质-配体结合 [219] 以及蛋白质-蛋白质结合问题 [307] 等。特别是，它们还成功用于预测 SARS-CoV-2 变体 BA.4 和 BA.5 [65]。相较于持续同调，持久组合拉普拉斯算子在蛋白质工程中的优势已得到证实 [253]。

2.1.7 其他变体

我们现在概述为分析具有其他附加结构（例如方向信息或更复杂关系）的点云数据而提出的各种持久组合拉普拉斯算子变体。

持久路径拉普拉斯算子

持久路径拉普拉斯算子 [300] 由 Wang 和 Wei 引入, 用于分析具有方向信息的点数据, 例如有向图和网络。该框架建立在路径同调 [137] 的基础上, 后来被扩展到有向网络上的持久框架 [69]。针对加权有向图的加权路径同调在 [192] 中被引入。最近, 在 [99] 中提出了一种计算 1 维持久路径同调的有效算法。

持久超（有向）图拉普拉斯算子

持久超图拉普拉斯算子 [202] 和持久超有向图拉普拉斯算子 [60] 分别针对具有和不具有方向信息的复杂系统提出。这些构造基于嵌入同调中的下确界和上确界链复形 [33], 从而能够定义相应的下确界和上确界拉普拉斯算子。特别地, 当超图退化为单纯复形时, 下确界和上确界链复形重合, 恢复了单纯拉普拉斯算子作为特例。

持久跳跃路径拉普拉斯算子

持久跳跃路径拉普拉斯算子 [199] 在两个方面推广了图的 k -跳跃路径拉普拉斯算子 [118]: 首先, 从图扩展到单纯复形和超图; 其次, 将持久性纳入框架。通过选择不同的跳跃参数, 该方法提供了对数据结构内成对、多体、直接和间接相互作用的全面描述。

持久有向旗复形拉普拉斯算子

持久有向旗复形拉普拉斯算子 [163] 基于有向图的旗复形构建, 该复形仅包含满足特定顺序约束的完全子图。通过将有向旗复形与标准单纯拉普拉斯算子相结合, 它为分析呈现非对称方向关系的复杂网络提供了一个高效工具。持久有向旗复形拉普拉斯算子已应用于复杂的生物分子数据 [329]。

用于单纯映射的持久拉普拉斯算子

用于单纯映射的持久拉普拉斯算子推广了定义在具有包含映射的滤链上的标准持久拉普拉斯算子 [143]。它保持了与持久同调的联系, 其中持久拉普拉斯算子的零度等于与单纯映射诱导的空间序列相关联的持久贝蒂数。一个关键区别在于, 其持久性不仅取决于单纯复形序列 (如标准设置中那样), 还取决于单纯映射本身的结构。

多尺度霍赫希尔德拉普拉斯算子

多尺度霍赫希尔德拉普拉斯算子 [150] 通过将霍赫希尔德拉普拉斯算子与多尺度分析相结合，为分析有向图数据提供了一个高效工具。特别地，霍赫希尔德拉普拉斯算子基于有向图的截断路径代数，因为有向环的有向图的完整路径代数是无限维的，这使得它不适合计算和实际应用。与组合拉普拉斯算子类似，霍赫希尔德拉普拉斯算子的核同构于相应维度的霍赫希尔德上同调。

2.2 持久狄拉克算子

近年来，量子算法被引入用于高效计算拓扑和几何特征，以应对持久同调的计算复杂性，特别是针对大规模点云数据 [9, 16, 28, 179, 208]。这些方法允许在量子计算机上以量子并行方式访问数据，并将组合单纯复形编码为量子态，从而实现了相对于经典拓扑数据分析技术的指数级加速。这些方法的核心是单纯复形上的狄拉克算子 [106]，其平方恰好给出所有阶的组合拉普拉斯算子。它捕获了与组合拉普拉斯算子相同的信息，但作为一个线性算子，它对局部拓扑、组合或几何特征更为敏感，从而提供了额外的信息。狄拉克算子已被发现在分析拓扑信号方面特别有用 [36]，并且也已应用于分子表示 [308]。

持久狄拉克算子 [9, 10] 将狄拉克算子扩展到持久性设置，用于分析点云数据。其平方产生持久组合拉普拉斯算子，因此可以看作是持久组合拉普拉斯技术的一种推广，它在捕获相同拓扑信息的同时，编码了底层数据更多的局部拓扑和几何结构。狄拉克算子也被扩展用于追踪路径和超图的持久性 [286]。基于 N -链复形，持久迈耶-狄拉克算子 [287] 已被开发出来，扩展了基于持久狄拉克技术的范围并提高了其适用性。

在下文中，我们简要回顾狄拉克算子和持久狄拉克算子。我们还将讨论针对具有附加结构数据的其他变体。

2.2.1 狄拉克算子

在组合情形中，狄拉克算子也像组合拉普拉斯算子那样，将单纯复形 K 中相邻维度的单形连接起来。它定义为边界算子与其伴随算子的和，即 $D = \partial + \partial^*$ 。它可以视为定义在全链复形（即所有链群的直和 $\mathcal{C}(K) = \bigoplus_k \mathcal{C}_k(K)$ ）上的组合拉普拉斯算子的平方根。当用埃尔米特表示表达时，

其平方得到一个块矩阵，其对角线由不同阶数的组合拉普拉斯算子给出：

$$D^2 = \begin{pmatrix} 0 & \partial_1 & 0 & \cdots \\ \partial_1^* & 0 & \partial_2 & \cdots \\ 0 & \partial_2^* & 0 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}^2 = \begin{pmatrix} L_1 & 0 & 0 & \cdots \\ 0 & L_2 & 0 & \cdots \\ 0 & 0 & L_3 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

与组合拉普拉斯算子（它保持阶数并将 k -链映射到 k -链）相比，狄拉克算子将 k -链映射到 $(k-1)$ -链和 $(k+1)$ -链。此外，狄拉克算子是一阶微分算子，这意味着与作为二阶算子的拉普拉斯算子相比，它对局部几何和拓扑结构更为敏感。狄拉克算子的核编码了单纯复形在所有阶数上的贝蒂数，而非零特征值是组合拉普拉斯算子特征值的平方根。

在拓扑数据分析中使用狄拉克算子的关键优势在于其适用于高效的量子计算。Lloyd 等人 [208] 提出了首个利用狄拉克算子估计贝蒂数的量子算法，相比拓扑数据分析中的经典算法实现了指数级加速。该方法构建一个量子态来表示每个尺度下的单纯复形，然后使用量子相位算法 [235] 来寻找埃尔米特表示下狄拉克算子 D 的核的维数。该方法提供了贝蒂数的多尺度版本，而无需显式地追踪滤过中的持续性。

2.2.2 持久狄拉克算子

Ameneyro 等人 [9] 首次将狄拉克算子扩展到持久化设置中，用于在量子计算中通过狄拉克算子跨不同尺度计算点云的持久性。该框架利用单个 k 维边界算子 ∂_k ，该算子使用定义在滤集中所有可能 k -单形集合上的单量子比特泡利 X 门进行编码，同时还利用了一个投影矩阵 P_k^i ，该矩阵从此集合映射到单纯复形 K^i 中的 k -单形集合。对于滤集中存储为量子态的一对单纯复形 $K^i \subset K^j$ ，其 k 维持久边界算子定义为 $\partial_k^{i,j} = P_{k-1}^i \partial_k P_k^j$ 。[9] 中定义了作为厄米算子的 k 维持久狄拉克算子为

$$D_k^{i,j} = \begin{pmatrix} 0 & \partial_k^{i,i} & 0 \\ (\partial_k^{i,i})^* & 0 & \partial_{k+1}^{i,j} \\ 0 & (\partial_{k+1}^{i,j})^* & 0 \end{pmatrix} - \xi \begin{pmatrix} P_{k-1}^i & 0 & 0 \\ 0 & -P_k^i & 0 \\ 0 & 0 & P_{k+1}^j \end{pmatrix}$$

其中 $\xi \in \mathbb{R}$ ，其平方由下式给出

$$(D_k^{i,j})^2 = \begin{pmatrix} \partial_k^{i,i} (\partial_k^{i,i})^* & 0 & \partial_k^{i,i} \partial_{k+1}^{i,j} \\ 0 & L_k^{i,j} & 0 \\ (\partial_{k+1}^{i,j})^* (\partial_k^{i,i})^* & 0 & (\partial_{k+1}^{i,j})^* \partial_{k+1}^{i,j} \end{pmatrix} + \xi^2 \begin{pmatrix} P_{k-1}^i & 0 & 0 \\ 0 & P_k^i & 0 \\ 0 & 0 & P_{k+1}^j \end{pmatrix}$$

根据其定义，持久狄拉克算子的平方不会像标准情况那样得到一个对角块矩阵，而是仅其中一个块提供了经过 ξ^2 平移的 k 维持久组合拉普拉斯算子。由此可见， k 维持久组合拉普拉斯算子的特征值对应于 k 维狄拉克算子平方特征值的 ξ^2 平移。在计算持久贝蒂数时，平移量 ξ 被选为狄拉克算子的正特征值。如 [9] 所述，设置 $\xi = 0$ 会导致对拉普拉斯算子核中态的重计数，从而得到错误的贝蒂数估计。

持久狄拉克算子已被应用于分析时间序列数据 [10]。Hayakawa [149] 提出了另一种计算持久贝蒂数的量子实现方法，该方法基于持久组合拉普拉斯算子的块编码。虽然这些方法为持久拓扑特征提供了高效计算，但它们的实现需要容错量子计算机，而这在近期内不太可能用于现实的大数据应用。

2.2.3 其他变体

这里我们介绍几种最近针对不同结构数据开发的持久狄拉克算子的变体。

持久路径狄拉克与超图狄拉克算子

路径狄拉克与超图狄拉克算子及其持久化扩展在文献 [286] 中被提出，用于从路径复形和超图中提取有价值的信息。它们在分子结构分析中的应用也已得到探索。

持久迈耶狄拉克算子

N 链复形上的迈耶狄拉克算子与持久迈耶狄拉克算子在文献 [287] 中被提出并应用于分子结构分析。请注意，迈耶同调 [215] 不同于标准同调。在此语境下，边界算子满足 $\partial^N = 0$ (其中 $N \geq 2$)，而非通常的条件 $\partial^2 = 0$ 。关于基于迈耶拓扑的工具描述，请参见第 2.3.2 节。

霍瓦诺夫狄拉克算子

霍瓦诺夫狄拉克算子 [162] 被提出用于分析纽结与链环的全局拓扑特征。它基于霍瓦诺夫同调，这是几何拓扑中研究纽结与链环的一个强大拓扑不变量。此主题将在后面的第 3.2 节进一步讨论。

2.3 其他表述

在本节中，我们概述了拓扑数据分析中最近发展的一些表述，这些表述利用替代的同调理论，扩展了用于分析点云数据的标准同调。

2.3.1 持久层理论

前述方法，如持久同调和持久组合拉普拉斯算子，已被证明在分析数据的拓扑结构方面非常强大 [253]。然而，它们在描述局部特征及其之间的关系方面仍然存在局限，而这些关系在实际应用中通常起着至关重要的作用。

层理论为理解拓扑空间提供了一个更强大、更通用的框架。特别是，它使得研究定义在空间上的结构的局部到全局性质成为可能。近年来，它在拓扑数据分析中找到了多种应用 [78, 79, 133, 147, 148, 321]，特别是通过胞腔层的概念 [271]，这对研究人员来说更易于理解，也更容易进行实际计算实现。对于一个单纯复形，一个胞腔层可以被视为为每个单形分配一个向量空间，连同称为限制映射的线性变换，这些映射通过面关系定义在向量空间之间。这些限制映射必须满足某些一致性条件，从而允许从局部特征确定全局信息。这使得胞腔层对于分析具有局部化性质的数据非常有价值，并可以从中推断出全局特征。

由于限制映射的方向性，层自然地与上同调相关联。一致性条件导致层上链复形上存在一个良定义的上边缘算子 δ ，满足 $\delta\delta = 0$ ，从而定义了层上同调，其中标准上同调是其特例。关于持久同调的层理论视角首次 [83] 中进行了研究，后来在 [261, 319] 中被扩展到持久化设置。[146] 中也提出了持久层的概念。

通过在上链群上引入内积，可以定义层拉普拉斯算子 [148]。它们的核对应于层上同调群，其维数由贝蒂数给出。通过结合持久性，Wei 和 Wei [309] 提出了持久层拉普拉斯算子，以解决持久组合拉普拉斯算子在处理带有标签或权重的数据点时的局限性。该框架推广了持久组合拉普拉斯算子，因为当所有数据点被分配相同的量时，后者可以视为前者的特例。给定一

个滤过中的一对层，持久边缘算子的定义方式与持久组合拉普拉斯算子的情况类似。主要区别在于数据的底层结构以及使用上同调而非同调，同时还有一个由受一致性规则约束的标量乘法定义的上边缘算子。持久层拉普拉斯算子遵循相同的公式，其核同构于持久上同调群，维数由持久贝蒂数给出。此外，持久层拉普拉斯算子的矩阵表示可以按照与持久组合拉普拉斯算子相同的方式计算 [309]。

2.3.2 持久迈耶拓扑

需要注意的是，拓扑数据分析中所有前述方法都依赖于标准链复形的构造，其中边界算子满足 $\partial^2 = 0$ 。这些方法在揭示数据底层结构更复杂信息方面可能存在局限，因为边界算子仅捕获了相邻维度单形之间的关系。

为了解决这个问题，Shen 等人 [269] 引入了持久迈耶同调和持久迈耶拉普拉斯算子，将迈耶同调 [215] 推广到持久化设置，从而能够研究跨多个维度（而不仅仅是相邻维度）的单形之间的连接。该方法建立在一个 N -链复形之上，其边界算子满足更一般的条件 $\partial^N = 0$ ，其中 $N \geq 2$ 。这扩展了当前基于标准同调（其中 $\partial^2 = 0$ ）的现有框架。关于迈耶同调与标准同调之间关系的讨论，请参见 [278]。

与标准情况类似，持久迈耶拉普拉斯算子的核对应于持久迈耶同调群，其秩由持久迈耶贝蒂数给出。然而，与仅由过滤参数控制的标准持久同调不同，每个度 k 的持久迈耶同调和持久迈耶拉普拉斯算子还受一个额外参数的控制。因此，该框架能够编码关于底层结构更丰富的拓扑、几何或组合信息，特别是跨不同维度单形之间的关系。持久迈耶拉普拉斯算子的进一步推广，称为持久迈耶狄拉克算子，已在 [287] 中提出，它对局部特征更为敏感。

持久迈耶拉普拉斯算子和迈耶狄拉克算子已应用于分子结构分析的研究 [269, 287]。持久迈耶同调已被用作预测蛋白质-配体结合亲和力的多通道特征 [122]。

2.3.3 持久交互拓扑

在代数几何中，相交理论研究给定簇内子簇的相交。在拓扑学中，相交（上）同调研究奇异空间。在离散背景下，交互涉及理解复杂系统内各组成部分如何相互影响。这一概念在复杂网络、分子相互作用以及生物系统中生物体相互作用等领域尤为重要。拓扑数据分析中的传统工具通常缺

乏捕捉此类交互的能力，因为它们通常关注全局拓扑特征，而非聚焦于系统内元素之间的局部交互。

最近，受交互上同调概念 [177] 的启发，Liu 等人 [193] 发展了交互拓扑，以深入理解拓扑空间之间的交互，并利用拓扑不变量来刻画这些交互。该理论建立在交互空间范畴之上。在论文中，他们引入了交互空间的概念，研究了其同伦和奇异同调，并证明了交互奇异同调是同伦不变量。此外，他们提出了交互单纯同调和上同调，以促进在点云数据分析中的应用。

基于交互同调，Liu 等人 [194] 提出了持久交互同调和持久交互拉普拉斯算子，并证明了其稳定性。该论文还提供了计算有限点集交互同调和交互拉普拉斯算子的算法。该框架的优势通过对分子内不同类型原子间相互作用的分析得到了展示。

在本节中，我们将注意力转向微分流形上数据的微分拓扑分析。该方法利用微分拓扑的工具，如向量场、微分形式、拉普拉斯-贝尔特拉米算子以及霍奇拉普拉斯算子，并结合其多尺度分析的扩展，来理解微分流形的底层结构。这些工具通过德拉姆-霍奇理论——20 世纪数学的一个里程碑理论——与底层流形的拓扑学紧密相连，因此非常适合分析自然表示为微分流形的数据。例子包括二维曲面、三维实体以及图像数据，例如来自磁共振成像（MRI）或计算机断层扫描（CT）的二维切片或三维体积。这些数据常见于计算机图形学、生物建模和医学成像等领域。

尽管在许多情况下，针对点云数据的代数拓扑分析技术可以通过点云表示应用于数据，但将数据建模为连续或微分流形更为合适。这些数据在观测上本质是连续的，尽管在实际中它们被表示为离散点。仅依赖采样点可能会因其不同的组合表示而导致不一致性，从而在使用代数和组合技术时产生不同的结果。一个更自然的解决方案是在理论上将数据建模为连续或微分流形，仅在实现时进行离散化。这种方式确保了无论采用何种离散化，分析都保持一致性和稳定性，并且结果是收敛的。

此外，微分流形的研究自然地包含了边界条件，例如法向（狄利克雷）和切向（诺伊曼）边界条件，这在边界具有物理或几何意义的应用中（如电磁学和流体动力学）极为重要。这些边界条件提供了约束，支配系统在边界附近的行为，并在求解边值问题时确保解的存在性和唯一性。它还保证了微分算子的适定性以及霍奇拉普拉斯算子在带边界流形上进行微分运算的能力。然而，对于组合拉普拉斯算子而言，并没有内在的域边界概念。

由于复杂的边界条件,德拉姆-霍奇理论的实现多年来一直具有挑战性。早期的方法,如标准有限元方法 [71],不足以捕捉流形拓扑,并且可能导致在法向或切向边界条件下向量拉普拉斯算子的特征值完全错误 [11]。随着最近的进展,例如有限元外微积分 (FEEC) [12] 和离散外微积分 (DEC) [94],该理论的实际实现已成为可能。这些技术确保离散化与连续理论保持一致,从而能够准确计算底层流形的上同调。基于这些技术,已经开发了用于计算霍奇分解、霍奇拉普拉斯算子及其多尺度扩展的计算框架。这些进展使得德拉姆-霍奇理论能够应用于拓扑数据分析,为分析流形上数据的拓扑和几何特征开辟了新的方向。下面,我们首先回顾带边界流形上的德拉姆-霍奇理论,包括德拉姆上同调、霍奇拉普拉斯算子以及霍奇分解,并介绍其近期实现。接着,我们简要讨论持久德拉姆上同调 [64]。我们还将重点介绍近期发展的持久霍奇拉普拉斯算子 [64, 282] 在捕捉二维和三维紧致域拓扑与几何特征方面的应用。我们同时涵盖了德拉姆-霍奇理论的拉格朗日表述 [64] 和欧拉表述 [282],这分别取决于底层流形是使用单纯网格离散化,还是通过水平集函数在笛卡尔网格中表示为区域。

2.4 带边流形的 de Rham-Hodge 理论

de Rham-Hodge 理论通过微分形式为理解流形的拓扑和几何结构提供了一个基础框架。对于带边流形的情况,其表述尤为微妙,此时必须施加适当的边界条件,例如法向和切向边界条件 [272]。这些边界条件对于该理论的核心结果,即调和形式与上同调之间的对应关系,至关重要。

微分形式的概念起初可能显得抽象。然而,它们与向量微积分中熟悉的概念密切相关。例如,在 $\mathbb{R}^3$ 中,一个 0-形式或 3-形式就是一个标量场,而一个 1-形式或 2-形式则对应一个向量场。一般而言,微分形式可以看作是微分流形上标量场和向量场的推广。微分形式与标量场或向量场之间的这些对应关系,为理解 1-形式的边界条件提供了直观认识:一个 1-形式是法向的,如果其对应的向量场与边界垂直;是切向的,如果该场与边界相切。法向和切向边界条件的正式定义,以及微分形式与 $\mathbb{R}^3$ 中向量微积分对应物之间的完整对应关系,可以在 [324] 中找到。这两种边界条件在 Hodge 星算子下彼此对偶。

微分算子 d^k (即外微分) 和余微分算子 δ^k 是构建 de Rham-Hodge 理论的两个基本算子。我们在此简要回顾它们及其与向量微积分中经典算子的对应关系,以便直观理解。微分算子 d^k 将 k -形式映射到 $(k+1)$ -形式,并

满足 $d^k d^{k-1} = 0$ 。它概括并统一了向量分析中的梯度 ∇ 、旋度 $\nabla \times$ 和散度 $\nabla \cdot$ 的概念，它们分别对应于在 $\mathbb{R}^3$ 中将 d 应用于 0-形式、1-形式和 2-形式。余微分 δ^k 可以定义为 d^{k-1} 关于由微分形式空间上的 Hodge 星算子诱导的 Hodge L^2 内积的伴随算子。它将 k -形式映射到 $(k-1)$ -形式，并满足 $\delta^{k-1} \delta^k = 0$ 。在 $\mathbb{R}^3$ 中，当分别应用于 2-形式、1-形式和 0-形式时，它对应于 $-\nabla$ 、 $\nabla \times$ 和 $-\nabla \cdot$ 。

2.4.1 de Rham 上同调

设 Ω_n^k 和 Ω_t^k 分别为定义在 m 维光滑流形 M 上的法向 k -形式空间和切向 k -形式空间。关于它们的正式定义，请参见 [324]。这两个空间在 Hodge 星算子下互为对偶，即 $\Omega_n^k \cong \Omega_t^{m-k}$ 。微分形式的 de Rham 上同调定义在由微分 d^k 和余微分 δ^k 连接的两个序列上：

$$\begin{aligned} \cdots &\xrightarrow{d^{k-2}} \Omega_n^{k-1} \xrightarrow{d^{k-1}} \Omega_n^k \xrightarrow{d^k} \Omega_n^{k+1} \xrightarrow{d^{k+1}} \cdots, \\ \cdots &\xleftarrow{\delta^{k-1}} \Omega_t^{k-1} \xleftarrow{\delta^k} \Omega_t^k \xleftarrow{\delta^{k+1}} \Omega_t^{k+1} \xleftarrow{\delta^{k+2}} \cdots. \end{aligned}$$

这两个复形是良定义的，因为 d 保持法向边界条件，而 δ 保持切向边界条件。由此得到的上同调分别对应于第 k 阶相对 de Rham 上同调 $H_{dR}^k(M, \partial M)$ 和第 k 阶绝对 de Rham 上同调 $H_{dR}^k(M)$ ，如下所示：

$$\begin{aligned} H_{dR}^k(M, \partial M) &= \ker d^k / \operatorname{im} d^{k-1}, \\ H_{dR}^k(M) &= \ker \delta^k / \operatorname{im} \delta^{k+1}, \end{aligned}$$

其中 $\ker d^k$ (相应地, $\ker \delta^k$) 称为闭 (相应地, 余闭) k -形式空间, 而 $\operatorname{im} d^{k-1}$ (相应地, $\operatorname{im} \delta^{k+1}$) 是恰当 (相应地, 余恰当) k -形式空间。 $H_{dR}^k(M, \partial M)$ 和 $H_{dR}^k(M)$ 的秩分别由第 $(m-k)$ 个 Betti 数 β_{m-k} 和第 k 个 Betti 数 β_k 给出。这里, 这些算子的定义域被限制在相应的边界条件下。关于绝对和相对 de Rham 上同调及其对应同构的详细讨论, 请参阅 [266]。

2.4.2 Hodge 拉普拉斯算子

第 k 个 Hodge 拉普拉斯算子 Δ^k 定义在 k -形式空间上, 具体如下：

$$\Delta^k = d^{k-1} \delta^k + \delta^{k+1} d^k.$$

当 $k = 0$ 时, Hodge 拉普拉斯算子退化为作用在流形上函数空间的 Laplace-Beltrami 算子 $\delta^1 d^0$ 。在存在边界的情况下, Hodge 拉普拉斯算子

Δ^k 与流形拓扑没有直接对应关系，因为其核是无限维的。然而，我们可以分别通过将 Hodge 拉普拉斯算子 Δ^k 限制在法向形式空间和切向形式空间上，来定义 Hodge 拉普拉斯算子 Δ_n^k 和 Δ_t^k 。这两种类型的 Hodge 拉普拉斯算子具有有限维的核。空间 $\ker \Delta_n^k$ 对应于相对 de Rham 上同调，而 $\ker \Delta_t^k$ 对应于绝对 de Rham 上同调 [126]。此外，这两个核通过 Poincaré 对偶性相关联，从而得到以下恒等式：

$$\ker \Delta_n^k \cong H_{dR}^k(M, \partial M) \cong H_{dR}^{m-k}(M) \cong \ker \Delta_t^{m-k}$$

$\ker \Delta_n^k$ 中的元素称为法向调和 k -场，而 $\ker \Delta_t^k$ 中的元素称为切向调和 k -场。这些恒等式使得我们可以使用任意一种边界条件来研究底层流形及其边界的拓扑结构。

需要注意的是，与组合情形类似，Hodge 拉普拉斯算子的调和谱捕获了底层流形的拓扑信息，其零特征值的数量由 Betti 数给出。然而，Hodge 拉普拉斯算子的非调和谱编码了丰富的几何信息，例如底层流形的度量和曲率。这与组合情形有根本性的不同，在组合情形中，非调和谱仅反映组合或离散结构信息，而非光滑的几何特征。关于组合拉普拉斯算子与 Hodge 拉普拉斯算子之间相似性与差异的深入讨论，请参见 [260]。

Hodge 拉普拉斯算子的实现已通过 FEEC 在 [12] 中以及通过 DEC [260, 324] 实现，两种方法都提供了准确的特征值结果并保持了底层域的上同调。此外，文献 [260] 引入了一种边界诱导图（BIG）拉普拉斯算子的概念，它定义在具有适当边界条件的笛卡尔域上。它是离散化 Hodge 拉普拉斯算子的一个特例，计算更简单，同时能给出数据的正确拓扑维数。零阶 Hodge 拉普拉斯算子，即 Laplace-Beltrami 算子，已被广泛应用于研究流形的形状。例如，ShapeDNA [259] 利用该算子的谱为形状提供了一个简单的表示。全局点签名（GPS）[262] 使用该算子的缩放特征函数向量对形状进行编码。ShapeDNA 采用标准的有限元方法，而 GPS 则使用 DEC 中的工具。

2.4.3 Hodge 分解

Hodge 分解是 Hodge 理论中的一个核心结果，它将微分 k -形式空间分解为相互正交子空间的直和。微分形式的一个三分量 Hodge 分解，称为 Hodge Morrey 分解 [230]，给出如下：

$$\Omega^k = d\Omega_n^{k-1} \oplus \delta\Omega_t^{k+1} \oplus \mathcal{H}^k$$

这里 $\mathcal{H}^k = \ker d^k \cap \ker \delta^k \subset \ker \Delta^k$, 称为调和 k -场空间。当应用于区域上的向量场时, 此分解表明任何向量场都可以正交分解为一个无旋分量、一个无散分量和一个调和分量, 从而导出经典的 Helmholtz-Hodge 分解 [181]。空间 $\mathcal{H}^k$ 等于 Hodge 拉普拉斯算子的核 $\ker \Delta^k$, 并且同构于第 k 个 de Rham 上同调群。然而, 在存在边界的情况下, 空间 $\mathcal{H}^k$ 是无限维的 [266], 与流形拓扑没有联系。研究表明, 通过施加边界条件, 该空间可以进一步分裂, 从而揭示相对上同调和绝对上同调 [126]。特别地, 对于欧几里得空间中的紧致区域, 存在一个五分量保拓扑 Hodge 分解 [272], 给出如下:

$$\Omega^k = d\Omega_n^{k-1} \oplus \delta\Omega_t^{k+1} \oplus \mathcal{H}_n^k \oplus \mathcal{H}_t^k \oplus (d\Omega^{k-1} \cap \delta\Omega^{k+1}),$$

其中 $\mathcal{H}_n^k = \ker \Delta_n^k$ 和 $\mathcal{H}_t^k = \ker \Delta_t^k$ 分别是 $\mathcal{H}^k$ 在法向形式空间和切向形式空间上的限制, 如前所述, 它们编码了底层流形的相对上同调和绝对上同调。

对于 Hodge 分解的计算框架, 我们在此仅关注完整的五分量保拓扑 Hodge 分解。关于经典的三分量 Helmholtz-Hodge 分解的综述可参见 [26]。向量场的五分量 Hodge 分解的离散化已通过其微分形式表示被提出, 适用于四面体网格 [324] 以及适用于由笛卡尔网格中水平集函数定义的二维和三维紧致区域 [281, 283]。这两种方法都基于 DEC。其他方法, 假设分段常数向量场, 已针对曲面三角形网格 [249] 以及四面体网格 [248] 被提出。关于 $\mathbb{R}^3$ 中紧致区域的五分量 Hodge 分解在向量场和标量场方面的讨论可参见 [43]。

2.5 持久 de Rham 上同调

持久 de Rham 上同调最初由 Chen 等人在 [64] 中引入。该工作详细讨论了在法向和切向边界条件下调和形式的持久性。持久 de Rham 上同调在理论和实际应用中具有与持久同调对于点云数据同等的重要性。它作为一种基础工具展现出潜力, 并为分析可表示为微分流形的数据的拓扑结构开辟了新的方向。

为了定义持久 de Rham 上同调, 我们考虑一个由水平集函数 f 的子水平集定义的流形 M , 即对于 $c \in \mathbb{R}$, $M = f^{-1}([-\infty, c])$ 。通过改变 f 的等值, 可以得到一个带有包含映射的微分流形滤链如下:

$$M_0 \hookrightarrow M_1 \cdots \hookrightarrow M_{s-1} \hookrightarrow M_s,$$

其中每个 M_i 是对应于不同等值的 f 的子水平集。序列中任意一对流形 $M_i \hookrightarrow M_j$ 的包含映射在法向微分形式 $\Omega_n^k(M_i) \rightarrow \Omega_n^k(M_j)$ 上诱导了一个满足特定条件的唯一延拓。该映射进一步在上同调群上诱导了一个映射 $\psi_{i,j}^k : H_{dR,i}^k(M, \partial M) \rightarrow H_{dR,j}^k(M, \partial M)$ ，用于追踪拓扑特征的演化，即法向调和场，因为 $H_{dR,i}^k(M, \partial M) \cong \mathcal{H}_{n,i}^k$ 。这里 $\mathcal{H}_{n,i}^k$ 表示 M_i 上的法向调和 k -场空间。然后，可以将持久相对 de Rham 上同调定义为该映射的像：

$$H_{dR,i,j}^k(M, \partial M) = \text{im } \psi_{i,j}^k = \ker d_i^k / (\text{im } d_j^{k-1} \cap \ker d_i^k).$$

它的秩给出了第 $(m-k)$ 个持久 Betti 数 $\beta_{m-k}^{i,j}$ 。随后，可以通过检查持久上同调群中的元素，类似于组合情形，相应地定义法向调和场的诞生、死亡以及持久性。请注意，这里仅考虑了法向微分形式的空间。在切向边界条件下的对偶表述可以类似地构建 [64]。

2.6 持久霍奇拉普拉斯算子

在同一篇论文 [64] 中，Chen 等人首次从理论上提出了持久霍奇拉普拉斯算子。该论文还提出了一种使用离散外微积分在拉格朗日表述下对多尺度霍奇拉普拉斯算子的实现，即使用单纯形网格离散化的流形。随后，Su 等人在 [282] 中提出了持久霍奇拉普拉斯算子的计算框架，该框架在欧拉表述下，将离散外微积分从单纯形网格适配到规则网格。此背景下的流形被建模为笛卡尔网格中由水平集函数的等值线或等值面所界定的区域。这些发展基于将 de Rham 上同调与微分流形在滤过中的演化相结合，可视为早期关于立方体背景下持久同调工作的扩展 [298, 299]。

给定上一小节提到的滤过中的任意一对流形 $M_i \hookrightarrow M_j$ ，在法向 k -形式空间 $\Omega^k(M_i)$ 上的第 k 个持久霍奇拉普拉斯算子定义如下：

$$\Delta_{i,j}^k = d_{i,j}^{k-1} \delta_{i,j}^k + \delta_i^{k+1} d_i^k,$$

其中 d_i^k 和 δ^k 分别是 M_i 上法向形式的第 k 个外微分算子与余微分算子，而 $d_{i,j}^{k-1}$ 是从 M_j 上的法向 $(k-1)$ -形式到 M_i 上的法向 k -形式的持久微分算子， $\delta_{i,j}^k$ 是其伴随算子。持久霍奇拉普拉斯算子可以类似地定义在切向形式空间上。然而，由于法向与切向边界条件的对偶性，它们是等价的。当 $i = j$ 时，持久霍奇拉普拉斯算子退化为限制在法向形式上的通常的霍奇拉普拉斯算子。 $\Delta_{i,j}^k$ 的核定义了持久调和场。它同构于持久相对 de Rham 上同调，其秩导出持久贝蒂数。

我们现在转向离散化框架，并根据底层流形的离散化方式，简要讨论使用离散外微积分的拉格朗日与欧拉表述。

2.6.1 拉格朗日表述

在拉格朗日表述中，底层流形被离散化为单纯形网格，具体而言，在二维中是三角形网格，在三维中是四面体网格。一个离散的 k -形式就是一个向量，其每个条目被分配给一个 k -单纯形。例如，一个离散的 0-形式是一个将值分配给顶点的向量，而 1-形式则具有与边相对应的值。微分是一个稀疏矩阵，由连续维度单纯形之间的带符号关联矩阵的转置给出。余微分是关联矩阵与离散霍奇星算子的乘积，其形式为对角矩阵。关于这些离散算子的更多细节，请参见 [64, 324]。

拉格朗日表述需要对域进行显式剖分，这依赖于高质量的网格生成工具，例如 CGAL [119]、Gmsh [131]、Pymesh [327] 等。这使得在此背景下实现持久霍奇拉普拉斯算子具有挑战性，因为在过滤过程中生成一致的网格可能存在问题，并且得到的离散算子可能不是稀疏矩阵。拉格朗日表述中霍奇拉普拉斯算子的多尺度版本 [64]，除了依赖于这些网格生成工具外，还有几个局限性。由于紧致域的四面体网格表示存在差异，该方法具有敏感性和数值不一致性。该方法在计算上也很昂贵，因为它需要反复对域进行剖分以创建流形在过滤中的演化。这些局限性使得该框架不适合机器学习任务，因为机器学习任务需要计算相同尺度上的特征表示以保证可比性，同时也需要高效性，这对于计算大型数据集的特征至关重要。

2.6.2 欧拉表述

持久霍奇拉普拉斯算子的欧拉表述 [282] 已被引入，并采用了适配的离散外微积分以解决拉格朗日情况下的局限性。该论文提出了一种用于持久霍奇拉普拉斯算子的计算算法。在此设置中，底层流形被建模为标准笛卡尔网格上水平集函数的子水平集，即由水平集函数的等值线或等值面所界的域。从单纯形网格到规则网格的适配离散外微积分遵循与拉格朗日情况类似的结构。请注意，在欧拉表述中，调整水平集函数的等值会自然地导致过滤中嵌套的网格复形序列，从而使得离散持久霍奇拉普拉斯算子的构造成为可能。

欧拉表示具有若干优势：首先，它消除了显式剖分的需求，从而摆脱了对高质量网格生成工具的依赖。其次，所有对象的拉普拉斯算子计算都

可以在预先设计的笛卡尔网格上进行，因此从不同对象提取的特征对于机器学习任务是统一的且可比较的。此外，由于顶点、边、面和单元在笛卡尔网格中是固定的，数据结构和离散算子得到了显著简化。特别是，通过调整水平集函数的等值，可以轻松获得流形的演化。这些使得在欧拉表述中计算拉普拉斯算子更加高效。该框架在同一篇论文中通过将其集成到机器学习模型中以预测蛋白质-配体结合亲和力得到了演示。

3 几何拓扑方法

本节重点介绍基于几何拓扑学，特别是纽结理论的方法，用于分析嵌入三维空间中的曲线，例如纽结、链环、缠结和类链环。此类数据结构常见于化合物 [241]、DNA [13] 和蛋白质结构 [284] 中。纽结理论研究这些对象在环境同痕下的等价性，非正式地说，指的是不涉及切割和重新连接的连续形变。纽结理论中的关键工具是纽结不变量，这些量在这些形变下保持不变，在区分纽结和链环方面起着至关重要的作用。例子包括交叉数 [1]、桥数 [265]、纽结群 [82]、琼斯多项式 [164]、亚历山大多项式 [7]、Khovanov 同调 [172] 和纽结 Floer 同调 [238]。

纽结理论已应用于多个领域，如物理学 [237]、化学 [189] 和生物学 [223, 285]，但其在实际应用中的成功在一定程度上受到限制。挑战之一在于，纽结理论中的经典工具本质上是全局和拓扑的，对局部几何和拓扑特征提供的洞察有限。这使得这些工具不足以分析生物结构（如 DNA 和蛋白质），这些结构通常具有复杂的局部结构和/或片段间的局部缠结。此外，实际应用中遇到的许多数据集由开放曲线而非闭合环组成，这使得经典纽结不变量不适用。这些挑战凸显了需要开发更有效的工具来分析实际场景中的曲线。

受拓扑数据分析在各个领域成功的启发，文献 [270] 引入了纽结数据分析 (KDA) 的概念。该论文提出了一个称为多尺度高斯环绕积分 (mGLI) 的框架，这是首次将多尺度分析与纽结理论工具相结合。继此工作之后，又提出了其他几种几何拓扑框架，以解决上述经典方法在分析三维空间中曲线时的局限性。这些包括局部化琼斯多项式 [277]、持久 Khovanov 同调 [268]、Khovanov 拉普拉斯算子以及 Khovanov 狄拉克算子 [162]。

接下来，我们将探讨这些最近发展的几何拓扑方法。多尺度高斯环绕积分 (mGLI) [270] 和局部化琼斯多项式 [277] 分别建立在高斯环绕积分 [129] 和开放端纽结图的琼斯多项式 [239] 的基础上，它们是目前已知的仅有的两

种用于三维空间中开放曲线的单条或成对拓扑复杂度的连续度量。这些方法使得能够分析跨越多个空间尺度的局部和全局缠结特性。持久 Khovanov 同调 [268] 通过引入基于平滑变换的链环图滤过, 扩展了 Khovanov 同调, 揭示了传统不变量常常忽略的更精细的拓扑和几何特征。Khovanov 拉普拉斯算子和狄拉克算子 [162] 通过结合谱信息扩展了 Khovanov 同调, 提供了新的描述符, 这些描述符从同调中恢复已知的不变量, 同时编码了额外的非调和信息。

Shen 等人 [270] 提出了多尺度高斯环绕积分 (mGLI), 为分析开放和闭合曲线中片段的局部结构、连通性和缠结提供了一种多尺度方法。这些局部特征对于理解数据 (如化学化合物和生物分子) 的物理性质和功能至关重要。尽管是局部方法, 但当应用足够大的尺度时, 该方法也能恢复全局拓扑特征。该框架建立在高斯环绕积分的基础上, 高斯环绕积分是一个双线积分, 可提供两条曲线的环绕数, 并已成功应用于理解聚合物 [241] 和蛋白质 [18, 19, 240]。

该方法需要对曲线进行分割, 将给定的一对曲线划分为小片段。这些曲线片段之间的成对高斯环绕积分随后产生一个分割矩阵, 其条目编码了成对环绕信息。对于多尺度分析, 随后会纳入这些条目的权重, 这些权重由距离每个片段特定距离范围内的指示函数定义。通过改变距离范围, 此过程生成一系列分割矩阵, 这些矩阵捕捉了不同空间尺度下的局部缠结。跨尺度的累积积分也为局部结构提供了额外的见解, 并在足够大的尺度上揭示了全局关系。对于一条曲线中的每个片段, 在每一距离范围内计算的其与另一曲线所有片段的局部环绕信息, 可通过统计方法用于生成该片段的多尺度特征。该构造也可应用于单条曲线, 通过考虑同一条曲线片段之间的局部环绕信息。

曲线的分割和距离范围对于确定高斯环绕积分在特征提取中的有效性至关重要。因此, 应根据具体应用仔细选择分割策略和距离范围。该框架已与机器学习模型集成, 以解决各种复杂的生物学问题, 包括蛋白质 B 因子预测、蛋白质-配体结合亲和力预测等。该模型始终优于传统的 TDA 模型, 并在某些任务中表现出卓越的性能 [270]。

通过将经典的高斯环绕积分与多尺度分析相结合, mGLI 为分析曲线型数据的局部和全局结构提供了一个强大的框架, 开辟了数据分析和纽结学习的新领域。该框架通过检查曲线片段的局部缠结, 解决了传统 TDA 技术的局限性, 并且可应用于开放曲线。此外, 它的计算效率高, 在个人

计算机上仅需几分钟即可生成特征，这使得分析大型数据集变得切实可行。该方法显示出良好的前景，在各个领域都具有强大的实际应用潜力。

3.1 局部化琼斯多项式

局部化琼斯多项式由 Song 等人 [277] 引入，用于分析不相交开曲线或闭曲线集合的局部和全局纠缠性质。该论文提出了两种模型，称为多尺度琼斯多项式和持久琼斯多项式，它们通过结合空间多尺度分析，扩展了 [20] 中提出的琼斯多项式。[20] 中的方法推广了用于闭曲线的传统琼斯多项式 [164] 以及 [239] 中用于开曲线的方法，为三维空间中开曲线集合的链环复杂性提供了一种连续度量。

同一篇论文中分析了两种提出的局部化琼斯多项式的稳定性，确保了它们在实际应用中的鲁棒性。这些模型也已应用于蛋白质结构分析，提供了超越原子位置本身的纠缠洞察。这些框架展示了在多种实际应用中发挥作用的潜力。

多尺度琼斯多项式

多尺度琼斯多项式 [277] 遵循了与多尺度高斯链环积分 [270] 类似的策略。给定一个具有分割的不相交开曲线或闭曲线集合，该方法为每个曲线段计算一个琼斯多项式，该多项式对应的集合由该曲线段以及所有位于指定距离范围内的其他曲线段组成。通过改变距离区间，该过程为每个段生成一个琼斯多项式向量，从而捕捉多个空间尺度上的拓扑纠缠。通过考虑所有曲线段，该方法最终得到一个琼斯多项式矩阵，编码了曲线集合的局部和全局纠缠性质。在实际应用中，这些琼斯多项式会在一个固定参数处求值，从而得到一个适用于下游分析的实特征矩阵。与多尺度高斯链环积分 [270] 类似，这种特征化依赖于曲线集合分割方式的选择以及距离范围的选择，这两者都可以针对特定应用进行适当调整。

持久琼斯多项式

持久琼斯多项式是通过考虑一个具有分割的不相交开曲线或闭曲线集合的曲线段之间距离矩阵而提出的，该矩阵进而诱导出一个 Vietoris-Rips 复形（也可以使用其他类型的单纯复形）的滤过，其顶点对应于曲线段 [277]。滤过中的每个单形被赋予一个权重，该权重由构成该单形的曲线段集合的琼斯多项式给出，从而产生一个分割的多项式加权滤过。该滤过产生了加权条形码，编码了单形的产生和消亡及其相关的多项式权重。在实

际应用中, 琼斯多项式在一个固定参数值处求值。通过引入滤过, 持久琼斯多项式编码了分割内曲线段之间的局部和全局相互作用。与专注于点云数据中孔洞行为的持久同调相比, 持久琼斯多项式捕捉的是 3 维空间中曲线的纠缠。

3.2 持久 Khovanov 同调

Khovanov 同调 [172] 是纽结理论中最重大的进展之一, 它提供了一个强大的链环不变量, 对 Jones 多项式 [164] 进行了范畴化。它揭示了更丰富的信息, 例如挠元。它还能检测平凡结, 这在一般情况下是一个非常困难的问题, 而 Jones 多项式是否能做到这一点仍是一个悬而未决的问题。为了将持久性分析融入曲线型数据中, Shen 等人 [268] 通过定义从链环图论的交叉点平滑变换中获得的链环滤链, 提出了纽结与链环的持久 Khovanov 同调 (或称演化 Khovanov 同调)。这项工作解决了经典纽结理论主要关注全局拓扑性质而可能忽略曲线型数据重要局部特征的局限性。它能够在滤链的各个尺度上对纽结与链环的拓扑结构和几何形状进行更精细的表征。

从概念上讲, 纽结与链环的 Khovanov 同调与单纯复形的经典同调有相似之处, 尽管它们是在不同的背景下发展起来的。两者都是从链复形构造而来, 链复形由一系列通过微分或边界映射连接起来的阿贝尔群序列组成, 这些映射应用两次后为零。一个关键区别在于分次: Khovanov 同调是双分次的, 既有同调分次又有量子分次, 而单纯同调只有单一的同调分次。Khovanov 同调中的分次 Betti 数反映了分次维数, 相比之下, 单纯同调中的经典 Betti 数则计算每个维数下的“洞”的数量。

该论文提出了两种构建链环图论滤链的方法: 基于距离的滤链和解链滤链。其思想是生成一个交叉点的顺序, 这些交叉点通过特定的平滑操作逐步消解, 最终得到一个由不相交圆组成的简单链环图论。这个过程提供了一个滤链。基于距离的滤链考虑以所有交叉点为中心、由单一半径参数确定的圆盘, 如果一个交叉点的圆盘不与任何其他圆盘相交, 则该交叉点被视为孤立的。从一个较大的初始半径开始, 随着半径逐渐减小, 标记孤立的交叉点从而获得顺序。对于解链滤链, 顺序的选择是从一个初始交叉点开始, 沿着曲线的特定方向移动, 标记链环的交叉点。

即使对于平凡结和非打结的链环, 持久 Khovanov 同调也能捕捉到非平凡的演化信息。这些方法的有效性已在同一篇论文中对 SARS-CoV-2 移码假结的分析中得到验证。后来, Liu 等人 [197] 从理论上提出了缠结的持

久 Khovanov 同调，侧重于表征曲线型数据中的局部拓扑特征。通过实现对多尺度拓扑不变量的持久性分析，这些框架提供了强大的工具，能够捕捉曲线型数据更精细的拓扑细节或局部结构，为数据科学提供了有前景的几何拓扑方法。

3.3 Khovanov 拉普拉斯算子与 Khovanov 狄拉克算子

受组合拉普拉斯算子、霍奇拉普拉斯算子、狄拉克算子在数据科学中的成功及其与（上）同调的联系所启发，Jones 和 Wei [162] 为纽结和链环引入了 Khovanov 拉普拉斯算子和 Khovanov 狄拉克算子，通过将谱分析纳入纽结与链环的研究，扩展了 Khovanov 同调。这些算子的调和谱可以恢复 Khovanov 同调中的拓扑不变量，而非调和谱则揭示了仅通过同调无法获得的额外信息。该框架也可被视为与链环图相关联的有向图上的拉普拉斯算子 [273] 的扩展，从而在图拉普拉斯算子与纽结的关键性质之间建立了联系。这些图拉普拉斯算子自然地引出了链环的 Seifert 矩阵、Alexander 矩阵和 Goeritz 矩阵，以及从它们导出的不变量，包括 Alexander 多项式和 ω -符号差。

Khovanov 拉普拉斯算子与 Khovanov 狄拉克算子的构造，与单纯复形上的组合拉普拉斯算子和狄拉克算子的构造相类似。由于 Khovanov 同调中的微分仅将同调度增加 1 而保持量子度不变，我们可以只限制在具有固定量子度的链复形上。该论文通过假设链群的基元素是正交归一的，从而在其上定义了一个内积，这进而诱导了微分的唯一伴随算子。随后，Khovanov 拉普拉斯算子使用与组合拉普拉斯算子相同的公式定义，而狄拉克算子则遵循相同的矩阵结构。与组合情形类似，Khovanov 拉普拉斯算子的核对应于 Khovanov 同调群。

如论文 [162] 所述，Khovanov 拉普拉斯算子和狄拉克算子的构造也可以推广到其他纽结同调理论，例如纽结 Floer 同调 [238]，该理论将 Alexander 多项式范畴化。这引发了从 Floer 纽结同调导出的拉普拉斯算子与上述有向图上的拉普拉斯算子 [273] 之间可能存在的联系。此外，类比于组合情形和微分流情形，人们可以定义持久 Khovanov 拉普拉斯算子和持久狄拉克算子，从而进一步推广持久 Khovanov 同调 [268] 的框架。

4 机器学习特征化

单纯复形是拓扑数据分析中用于建模点云数据最广泛使用的工具，这归功于其概念简单性和计算效率。然而，它们并非对所有数据类型都是普遍最优的。例如，在网络数据中，合著网络更适合建模为超图而非单纯复形。这是因为三位作者之间存在联合发表，并不必然意味着每对作者都曾独立合作过，而这一条件是单纯复形构造所固有的。类似地，流形上的数据，如图像，通常源自光滑结构，因此具有内在的微分性质和边界信息。这些特性无法被单纯复形的纯组合结构完全捕捉。相反，将数据建模为微分流形提供了一个更合适的框架，以纳入光滑性和边界信息。因此，在 TDA 中选择用于建模数据的数学结构，应基于数据的内在本质和特定分析任务的目标。此外，不同的建模选择自然会导致不同类别的拓扑工具和表示。

在本节中，我们首先对 TDA 中常见的各种数据类型进行分类，包括点云数据、距离矩阵数据、网络数据、流形上的数据、序列数据、纽结与链环数据以及带有额外非几何信息的数据。对于每个类别，我们讨论合适的数学模型及其含义。然后，我们介绍从这些数据结构中提取拓扑表示的方法。最后，我们描述将这些拓扑表示转化为适用于机器学习应用的特征的方法。我们主要关注向量化技术，这些技术将拓扑表示转换为固定大小的特征向量。其他策略，如基于核的方法，也会简要讨论。

4.1 输入数据类型与拓扑建模的选择

4.1.1 点云数据

点云数据是众多领域中最常遇到的数据格式之一。例子包括生物分子（如蛋白质、DNA 和 RNA）中的原子，以及各种网络（如社交网络、交通网络和分子相互作用网络）中的节点。使用有向图、单纯复形和超图等数学对象对点云数据进行建模，使得能够应用先进的拓扑工具，包括持久同调和持久组合拉普拉斯算子，进行全面的数据分析。为点云数据选择合适的数学模型取决于数据的性质以及可用的额外信息。

当数据点没有任何额外信息或需要被平等对待时，Vietoris-Rips 复形和 Alpha 复形是合适的；而对于带有额外标签信息（如类型、质量或颜色）的数据点，加权单纯复形或层则更为适合。有向图或超有向图适用于表示具有不对称性或定向关系的数据，例如基因表达数据集，其中方向性信息

编码了基因调控。超图和超超图可以有效地处理具有复杂关系或不完整结构的数据点。

4.1.2 距离矩阵数据

对于距离矩阵数据，必须强调距离度量构建的灵活性与多样性。虽然欧氏距离应用最为广泛，但它并非在所有场景下都是最优选择。在许多情况下，修改距离度量或采用其他定义方式，能够更准确地提取与底层问题相关的拓扑特征。

交互距离 [38] 旨在捕捉两类不同对象之间的相互作用。以蛋白质-配体相互作用为例，若直接对完整的蛋白质-配体结构应用欧氏距离构建单纯复形，由于蛋白质内部或配体内部相互作用的贡献占主导地位，可能会掩盖具有生物学意义的相互作用。为解决此问题，交互距离对源自不同结构（即蛋白质与配体）的点对赋予原始欧氏距离，而对同一结构内部的点对则赋予无穷大距离。这一策略确保所构建的单纯复形能专门聚焦于跨结构相互作用，从而提供更具针对性的蛋白质-配体相互作用表征。

多层次距离 [40] 的提出是为了突出非共价原子相互作用，例如氢键和范德华力。在此方法中，键合原子对的距离被设为无穷大，因为在大多数情况下键合原子比非键合原子更接近，这使得我们可以专注于非键合、非共价的相互作用。尽管该度量可能违反三角不等式，但它仍适用于构建 Vietoris-Rips 复形，因为后者仅需成对距离。此策略不仅能生成编码非共价相互作用的零维拓扑特征，还能产生更高维的特征，以捕捉同一分子不同构象之间的微小结构波动。

基于核函数的距离 [40] 被引入用于模拟原子相互作用强度，因为这些强度通常与欧氏距离并非线性对应。该框架使用径向基函数的负值来定义基于相关函数的过滤矩阵。更强的相互作用对应更小的距离，并在过滤过程中更早出现。类似地，在基于柔性刚性指数的距离中，采用了具有可调尺度参数的洛伦兹型核函数。通过调整该尺度参数，可以在不同空间分辨率下捕捉结构模式。

基于 KNN 的距离策略 [182] 根据点对之间的相互最近邻关系来分配距离。具体而言，对于点对 (a, b) ，若 a 是 b 的第 s 个最近邻，且 b 是 a 的第 t 个最近邻，则 a 与 b 之间的距离定义为两者中的较小值，即 $\min(s, t)$ 。随后可从点云得到的距离矩阵构建标准的 Vietoris-Rips 或 Alpha 过滤。该策略已被用于分析单细胞 RNA 测序数据 [80]。

4.1.3 网络数据

网络数据由节点和边组成，用于表示实体之间的交互或关系。此类数据广泛出现在众多领域中。例如，在分子网络中，节点对应原子，边对应化学键；在社交网络中，节点代表个体，边表示社交连接；在贸易网络中，节点是国家，边则指示贸易关系。从数学角度，这些网络可以建模为图，从而能够应用图论工具进行成对交互分析。拓扑工具的选择取决于网络的性质以及具体的应用场景。

（有向）无向网络可以自然地建模为一维（有序）单纯复形，其中节点表示 0-单形，边表示 1-单形。为了分析超越成对连接的高阶交互，可以将图扩展为更高维的单纯复形。现有多种构造方法：旗复形（或团复形）[163]，它为每个完全子图包含一个单形；邻域复形 [200]，它编码共享的邻域结构；以及 Hom 复形 [204]，可以将其类比解释为卷积神经网络中的卷积核。此外，超图和其他广义数学对象也可直接用于建模高阶交互 [136, 206]。

4.1.4 流形上的数据

流形上数据的常见示例包括图像，例如来自 MRI 和 CT 扫描的 3D 体数据或 2D 切片，以及等值面，例如流体动力学中表示均匀热分布的等温面和分子可视化中模拟分子轨道的电子密度等值面。尽管它们在原始形式上是离散的，但很自然地将其视为流形上的数据，因为它们通常是从连续或光滑结构中采样得到的。在以往的研究中，对此类数据（尤其是图像数据）的拓扑分析通常使用基于点云的技术进行。例如，医学成像中的一种常见方法是从图像中感兴趣区域选取点，然后从这些选取的点构建单纯复形以进行拓扑分析 [275]。此外，立方复形结构也被用于建模图像以进行拓扑分析 [299]。从数学上讲，单纯复形和立方复形都是组合对象，因此它们能够捕捉流形上数据产生的拓扑结构。然而，由于其固有的组合性质，这些表示忽略了底层流形的微分结构和边界条件，从而限制了它们保留此类数据内在微分性质的能力。

因此，将这些数据建模为微分流形提供了一个更合适的框架，以捕捉其内在的微分性质。在此框架下，可以运用微分拓扑或微分几何中的工具，例如微分形式、向量场和微分算子，以促进数据的定量分析。此外，这些数据（例如图像）本身具有将物体与背景分离的边界，使得边界条件至关重要。这些边界条件不仅施加了约束以控制系统在边界附近的行为，还确保了边值问题解的存在性和唯一性。此外，边界条件修改了微分算子，例

如拉普拉斯算子和狄拉克算子，使其不同于在闭流形（无边界）上定义的对算子。值得注意的是，微分流形上的霍奇拉普拉斯算子与定义在单纯复形上的组合拉普拉斯算子在根本上有所不同 [260]。基于微分拓扑方法的有效性已在多种应用中得到证明，例如单细胞 RNA 速度分析中的霍奇分解 [281]、药物设计与发现中的 PHL [282]，以及医学图像分析中的 MTDL [207]。

基于这一视角，近期工作已将拓扑和几何先验整合到深度学习架构中。Love 等人引入的拓扑卷积神经网络（TCNN）[209] 用反映图像和视频数据结构流形参数化滤波器替代了标准卷积层。这种方法保留了拓扑关系，并利用了跨层的几何定位，从而实现了更快的学习、更好的泛化能力和更高的可解释性。TCNN 也能自然地扩展到 3D 数据，凸显了拓扑在深度学习中的更广泛潜力。

4.1.5 序列数据

序列数据广泛出现在多个领域，例如生物学中的蛋白质和 DNA 序列、自然语言处理中的词序列、时间序列分析中的股票价格时序波动以及视频处理中的帧序列。针对拓扑序列分析（TSA），已发展出多种方法。TSA 的一种策略是直接计算成对距离矩阵 [54]，然后通过改变距离参数来构建 Vietoris-Rips 滤过。对于时间序列数据，一种方法涉及将曲线分割成短片段，并为每个片段构建一个 Vietoris-Rips 滤过 [326]。还有一些 TSA 方法将序列转换为点云，从而能够直接使用针对点云数据的成熟技术。这些策略包括 Takens 延迟嵌入、滑动窗口方法以及 k -mer 拓扑方法。

在 Takens 延迟嵌入 [288] 中，序列 $x_1, x_2, \dots$ 使用两个参数转换为点：嵌入维度 d 和延迟参数 τ 。例如，当 $d = 2$ 时，结果点云中的每个点形式为 $(x_i, x_{i+\tau})$ 。滑动窗口方法类似地使用两个参数：点维度参数 M 和窗口参数 τ 。例如，如果 $M = 3$ ，则嵌入空间中的一个点构造为 $(x_i, x_{i+\tau}, x_{i+2\tau})$ 。滑动窗口方法还有其他变体，例如 SW1PerS [246] 和环形滑动窗口嵌入 [245]。

在 k -mer 拓扑方法 [157] 中，参数 k 指定了沿序列滑动的窗口大小，生成一组 k -mer（长度为 k 的子序列），这些 k -mer 被视为一个点云。然后应用元素特定策略来强调特定类型的点。计算这些点之间的成对距离以构建距离矩阵，该矩阵作为后续使用持久同调或持久拉普拉斯等方法进行拓扑分析的基础。

已有研究提出将 Delta 复形方法用于 TSA [198]。其核心思想是将序列的片段视为单纯形，这些单纯形作为 Δ -复形的构建模块。由于 Δ -复形允许重复元素，它们与生物序列的特性相符。与 k -mer 拓扑不同，基于 Δ -复形的 TSA 方法并不系统分析序列中的 k -mer。这些方法最终利用持久同调或持久拉普拉斯，并且对于大型基因组序列，比早期的 k -mer 拓扑方法更快。

TDL 的最新进展引入了整合序列数据中时序和拓扑结构的新方法，特别是在神经尖峰解码的背景下 [226]。这些方法实现了端到端学习，其中拓扑结构是可学习的模型组件 [170, 243]。在许多情况下，数据由时序有序的事件组成，例如神经尖峰，其中每个观测都参与构建一个捕获实体间多路关系（例如，在短时间窗口内一起发放的神经元）的单纯复形。这些复形编码了超越简单成对连接的高阶相互作用，提供了更丰富的结构表示。相较于关注单个时间点或固定大小的窗口，一些拓扑深度学习方法追踪这些单纯复形的时间演化，从而产生一系列拓扑状态。在诸如尖峰解码之类的事件驱动场景中，这种演化通常通过离散时间或状态空间过程来建模。其他方法，[117, 228]，则利用连续时间动力学和偏微分方程来建模拓扑特征在复形上的演化。在这些情况下，每个单纯复形都可以通过为拓扑空间设计的神经架构（例如单纯消息传递网络 [30] 或胞腔复形编码器）嵌入为一个可学习的向量。

其结果是一个统一的、数据驱动的框架，能够同时捕捉时间动态和拓扑结构。在神经解码等应用中，这使得模型能够学习协同激活模式如何随时间变化，并与行为、刺激或潜在神经状态相关联。通过将序列表示为演化的拓扑对象，拓扑深度学习提供了一种灵活且富有表现力的方法来分析结构化时间序列数据，从而能够发现嵌入在时间和拓扑中的复杂模式。

4.1.6 纽结、链环、缠结与辫子

纽结、链环、缠结与辫子是基本的拓扑对象，可以自然地建模为嵌入三维空间中的曲线 [268, 270, 277]。在实际应用中，此类数据结构广泛存在于众多领域。例子包括绳索、鞋带、聚合物、DNA、RNA、核小体和染色体。

将这些对象表示为三维空间中的曲线具有优势，因为它允许使用纽结理论中的工具来分析复杂的结构关系。该方法已在多项研究中被证明是有效的。例如，聚合物链的缠结可以通过其打结和链接特性进行研究，高斯链接积分与聚合物材料的物理性质相关 [241]。此外，研究表明高斯链接积分

与蛋白质缠结有关，特别是在理解蛋白质折叠动力学方面 [240]。它也被应用于 SARS-CoV-2 刺突蛋白的研究 [19]。基于纽结的拓扑框架的有效性也在蛋白质柔性分析、蛋白质-配体相互作用 [270]、蛋白质结构与功能 [277] 以及 SARS-CoV-2 移码假结 [268] 的研究中得到了证实。

目前已开发出诸如 KnotProt [160] 和 LinkProt [85] 等数据库来支持蛋白质纽结与链环的研究。Python 包 Topoly [86] 提供了计算拓扑多项式不变量的工具，用于区分纽结、滑结、链环和空间图。

4.1.7 具有额外非几何信息的数据

对于具有额外非几何信息的数据，我们指的是所有前述数据类型，这些数据在几何结构之外进一步丰富了与背景相关的属性。我们将此设为一个独立的数据类型，因为此类数据在现实应用中很常见，并且补充信息通常在解决特定领域问题中起着关键作用。例如，蛋白质结构不仅包含原子的三维坐标（几何信息），还包括残基类型、部分电荷和溶剂可及性（非几何生物信息），这些信息对于蛋白质稳定性和蛋白质-配体相互作用至关重要。类似地，在网络数据中，除了节点和边的拓扑结构外，还可能具有节点关联的属性，例如社交网络中的用户兴趣，这对于聚类 and 链接预测任务至关重要。

元素特异性方法 [37, 38, 40] 是一个强大的框架，用于将不同的原子和分子相互作用系统地建模到一个统一的拓扑系统中。例如，给定一个分子原子的点云，可以根据原子的元素类型构建元素特异性单纯复形。这使我们能够专注于特定的原子相互作用，例如共价键、氢键、范德华力和其他非共价相互作用。元素特异性策略与标准持续同调的结合已在各种生物数据分析任务中展现出巨大潜力，例如蛋白质-配体结合亲和力和预测、蛋白质-蛋白质相互作用分析和蛋白质稳定性分析。

另一种整合非几何信息的方法是将其编码为权重，并将这些权重整合到基础数学框架中。例如，在富集条形码方法 [39] 中，持续上同调是从蛋白质原子的基础单纯复形建模中计算出来的，额外的生化信息作为权重嵌入到上同调代表元中。这产生了一个富集的或彩色的持续条形码，它同时捕获了拓扑和化学性质。在持续层拉普拉斯方法 [310] 中，原子属性被编码到层构造中，特别是边界算子的构造中。因此，导出的持续层上同调和层拉普拉斯算子将自动携带这些额外信息。

4.2 拓扑表示方法

4.2.1 持久同调/上同调的表示形式

在域系数下计算时，持久同调与持久上同调会产生相同的条形码 [90]，这也是实际应用中最常见的选择。因此，为简化起见，本文仅关注持久同调的情况。一旦为给定数据集建立了合适的拓扑模型，就可以计算相应的持久同调以提取有意义的拓扑表示，例如单纯复形的持久单纯同调、超图的持久超图同调以及层结构的持久层同调。需要注意的是，持久同调可以通过多种形式进行可视化和编码，每种形式都提供了观察拓扑特征的不同视角。接下来，我们总结几种常见的持久同调表示格式。

持久条形码/图

持久同调的两种标准表示形式——持久条形码 [48] 和持久图 [112]，都提供了直观的方式来呈现过滤过程中拓扑特征的“诞生”与“消亡”。持久条形码总结了不同维度下拓扑特征（如连通分量、孔洞、腔体）的生命周期。每个条形码由若干水平线段组成，其中每条线段的左端点代表拓扑特征的诞生时间，右端点则表示其消亡时间。持久图与条形码等价，但将相同的拓扑信息编码为二维散点图，其中 x 坐标表示诞生时间， y 坐标表示消亡时间。由于特征的消亡时间总是晚于其诞生时间，持久图中的所有点都位于对角线 $y = x$ 的上方。条形码中较长的线段通常对应显著的拓扑特征，而较短的线段则常被视为噪声。类似地，在持久图中，远离对角线的特征通常被认为是重要的，而靠近对角线的特征则常被当作噪声处理。然而，在考虑物理、化学和生物数据时，这一假设可能并不成立，因为短线段或靠近对角线的特征可能携带重要的物理信息，例如键长、苯环大小及其他性质 [313]。此外，对于多参数持久同调，还存在一种格拉斯曼流形持久图的构造方法 [141, 142]。持久条形码/图能有效捕捉数据的拓扑特征，并已应用于图像块 [2, 49]、手写字母 [75] 以及病毒演化中的异常事件 [54] 等研究中。

持久贝蒂数/贝蒂曲线

持久贝蒂数 [112] 和贝蒂曲线是贝蒂数的多尺度类比，用于统计在过滤过程中持续存在的拓扑特征数量。持久贝蒂数定义为持久同调群的秩，通常可视化为贝蒂曲线，后者提供了基于阶梯函数的持久同调表示。这种表示将持久条形码/图转化为函数表示。函数的向量空间结构使得加法、标量

乘法等基本运算成为可能,从而使贝蒂曲线适用于计算均值、方差等统计任务。这些运算在持久条形码/图上并无自然的定义。Betti 曲线简单且易于计算。此外,由于微小扰动通常会引入短暂的生命周期,这些生命周期对整体 Betti 数分布的影响极小,因此它们对噪声也具有鲁棒性。然而,Betti 曲线的一个缺点是其表达能力有限,因为它们仅包含拓扑特征的计数。此外,从图表到曲线的映射不是单射的 [68],这意味着不同的图表可能产生相同的曲线。

持久性景观

一种名为持久性景观的稳定持久同伦表示 [34, 35],提供了持久性图表更结构化、更具表达力的表示,同时保持了与统计和机器学习框架的兼容性。它们被引入以将持久性图表转换为分段线性函数的序列,这可以看作是持久性图表的水平版本。与仅追踪拓扑特征计数的 Betti 曲线相比,持久性景观编码了生灭对及其持久性,并与持久性图表保持双射对应关系,这使得后者在需要详细拓扑分析时更受青睐。最近,它已被扩展到多参数情况下的多参数持久性景观 (MPPL) [296]。

持久性景观的一个关键特征是其层次结构,其中不同级别的函数捕获具有不同显著性的拓扑特征。具有最低生命周期下标的函数捕获最持久的拓扑特征,而具有较高生命周期下标的函数则捕获持久性较弱的特征。持久性景观已被用于研究蛋白质结合中的构象变化 [178]、微观结构分析 [109]、从时间序列构建的时间依赖功能网络 [279],以及图像分类任务和轨道分类 [173]。

持久性图像

持久性图像 [4] 作为一种替代的稳定表示被引入,它将持久性图表转换为固定大小的、基于网格的函数表示,这使得它们特别适用于卷积神经网络 (CNN)。持久性图像是通过计算持久性曲面在网格上的积分来构建的,该网格是通过离散化 $\mathbb{R}^2$ 的一个子域获得的。这里,持久性曲面被定义为以持久性图表中每个点为中心的高斯函数的加权和,其中加权函数控制每个点的显著性。在同一篇论文中,持久性图像已被证明相对于持久性图表之间的 1-Wasserstein 距离是稳定的。

持久性图像的一个关键优势是易于计算,并在三个选择上提供了灵活性:分辨率、分布 (及其相关参数) 以及加权函数。然而,这些选择是非规范的,这意味着没有指导原则来设置这些参数以在机器学习任务中获得

最佳性能。PI-Net [276]，一个简单的一步可微架构，是第一个提出使用深度学习直接从数据计算持久性图像的方法。持久性图像也已扩展到多参数设置，从而产生了多参数持久性图像（MPPI）[52]。

持久贝蒂数图像

多维持久性的概念在文献 [314] 中被提出，用于将动态生物分子数据转化为持久贝蒂数图像，通过编码分子系统随时间的拓扑演化。具体而言，给定一个表示动态过程的数据帧序列，对每一帧应用持久同调，并将得到的持久贝蒂数编码为一维向量。通过在所有时间步上堆叠这些向量，构建出一个反映系统时间拓扑变化的二维图像。同一论文中提出的多尺度多维持久性进一步在单个图像内编码了不同空间尺度下的分子结构。特别是，使用具有可调尺度参数的柔性-刚性函数来生成分子的体积密度表示。对于特定选择的尺度参数，计算持久贝蒂数并将其记录为一维向量，然后通过在所有尺度上组装这些向量，形成一个二维、三维或高维图像。

彩色持久条形码

已有多种方法被提出，用以丰富持久条形码的附加信息，从而产生了彩色持久条形码。例如，在持久富集条形码方法 [39] 中，首先计算持久上同调，并通过特定函数将与单形相关的补充权重信息纳入上同调代表元，从而为相应的条形分配颜色。在持久琼斯多项式方法 [277] 中，为每个单形分配一个琼斯多项式，并在选定值处计算与条形对应的正单形相关联的多项式，以确定其颜色。这些增强的条形码有效地编码了背景相关信息，从而提供了信息更丰富的拓扑表征。

分级持久条形码

最常用的持久条形码源自单分级持久同调。然而，也存在提供多分级持久同调表示的方法。例如，在持久迈耶同调方法 [269] 中， N 链复形中的附加分级决定了一种特定类型的边界算子。通过改变分级索引，可以构造一系列链复形，从而产生一个持久同调序列，即一个双分级持久同调。类似地，在持久科瓦诺夫同调方法 [197] 中，一个由交叉点的平滑类型决定的附加量子分级被引入到上链复形中，从而产生一个能捕获更丰富结构信息的双分级持久同调。这些分级持久同调自然地引出了分级持久条形码表示。

4.2.2 持久拉普拉斯算子的表示

拉普拉斯算子的表示主要涉及其谱性质，即其特征值和特征向量，它们编码了底层数据集的拓扑结构以及组合或几何结构的基本信息。另一个重要方面是，霍奇拉普拉斯算子能够通过霍奇分解将向量场分解为三个或五个正交分量，为分析数据中的流、梯度和循环提供了强大工具。接下来，我们将详细描述这些表示。

特征值表示

拓扑拉普拉斯算子的一个基本性质是其核与相应上同调群之间的同构。在实践中，计算通常是在域系数下进行的，在此系数下上同调与同调同构。这意味着拓扑拉普拉斯算子的零特征值的重数等于相应维度的贝蒂数。这一结果可推广到持久情形：持久拉普拉斯算子表现出类似的同构，其零特征值的重数对应于持久贝蒂数 [217]。因此，持久拉普拉斯算子的零特征值完整编码了持久同调信息。相比之下，非零特征值提供了底层数据结构的额外几何与组合洞察。拉普拉斯矩阵是对称且半正定的，这保证了所有非零特征值均为正。对于流形上的霍奇拉普拉斯算子，较大的特征值与相应特征函数的高频分量相关联。这些高频模式反映了精细尺度的结构变化或局部不规则性，可能代表噪声，尤其是当流形表现出非光滑特征（如尖锐拐角）时。将拉普拉斯算子的特征值与机器学习技术相结合，已成功应用于多个领域，包括药物设计与发现、计算生物学与化学以及材料科学。

特征向量表示

众所周知，与拓扑拉普拉斯算子相关联的特征向量捕获了关于底层对象的丰富拓扑与几何信息。例如，在形状分析中，全局点签名（GPS）[262]——一种利用拉普拉斯-贝尔特拉米算子的缩放特征函数定义的曲面表示——已被证明携带了足够的信息，可用于各种形状处理任务，包括形状分类、分割和对应。霍奇拉普拉斯算子的特征向量，包括在某些边界条件下的调和特征场、梯度特征场和旋度特征场，已被应用于生物大分子的分析 [325]。这些特征向量既可以单独作为机器学习模型的输入，也可以作为特征值特征的补充。

对于持久拓扑拉普拉斯算子，虽然已知其特征值能够捕获过滤过程中的拓扑与几何变化，然而，其特征向量的解释仍不明确，需要进一步研究。

Hodge 分解表示

Hodge 分解将向量场正交地分解为梯度、旋度和调和分量。这种分解通过提取不同的动态特征，使得对向量场的分析更加细致，特别有助于理解场的底层机制。它在电磁学 [222]、流体与动力系统 [318, 320]、几何建模 [304] 以及谱数据分析 [171] 中有众多应用。

最广为人知的 Hodge 分解是三分量 Helmholtz-Hodge 分解 [181]。对于欧几里得空间中的紧致区域，存在一种更精细的五分量向量场 Hodge 分解 [272]，它保持了底层区域的拓扑结构。离散的五分量 Hodge 分解已被提出用于曲面三角形网格 [249]、四面体网格 [248, 324]，以及由笛卡尔网格中水平集函数定义的区域 [281, 283]。Hodge 分解已成功应用于单细胞 RNA 速度的研究，通过利用细胞的基因表达来提取其不同的动态信息 [280]。此外，基于 Hodge 分解技术的流形拓扑深度学习 (MTDL) [207] 最近被提出用于医学图像分析。

4.2.3 持久狄拉克算子的表示

在组合情形下，持久狄拉克算子可被视为持久组合拉普拉斯算子 [9, 308] 的推广。它捕获了与持久组合拉普拉斯算子相同的拓扑信息，其特征值对应于所有维度上持久组合拉普拉斯算子特征值的平方根。然而，作为一阶算子，与二阶拉普拉斯算子相比，它对局部特征更为敏感，并且其矩阵耦合了不同的拓扑维度。

持久狄拉克算子的一个显著优势在于它能够实现高效的量子计算，相比经典的拓扑数据分析算法提供指数级加速。该算子不仅能够从持久同调中恢复拓扑输出，还能导出点云数据的谱特征。持久狄拉克算子也可以类似地表述于微分流形，从而推广微分拓扑设置中的霍奇-狄拉克算子，便于分析流形上的数据。

4.2.4 多尺度高斯环绕积分的表示

多尺度高斯环绕积分方法 [270] 是为分析一维曲线数据（包括纽结、链环和缠结）而开发的。该方法首先将曲线分解为一系列短线段，然后计算所有线段对之间的成对高斯环绕积分。这些积分构成一个分割矩阵，其条目量化了曲线段之间的拓扑环绕信息。接着，将线段之间的成对距离作为权重纳入条目中，得到一个精化的分割矩阵，该矩阵编码了跨越多个空间尺度的环绕结构。通过系统地改变尺度参数，可以构建一系列这样的矩阵，

每个矩阵捕获不同分辨率下的局部拓扑环绕信息。这些矩阵共同为底层曲线结构提供了全面的多尺度拓扑表示。

4.2.5 多尺度/持久琼斯多项式的表示

多尺度与持久琼斯多项式 [277] 将经典琼斯多项式 [20] 推广到多尺度设置，从而能够分析不相交开曲线和闭曲线集合的局部与全局纠缠。给定特定的曲线分割，多尺度琼斯多项式框架提供一个琼斯多项式矩阵，其中每一行对应一个曲线段的特征向量，该向量由在不同距离范围内计算的琼斯多项式确定。特征向量的每个条目是以下曲线集合的琼斯多项式：该集合由该曲线段以及所有落在与该段特定距离范围内的其他曲线段组成。持久琼斯多项式建立在由曲线段的成对距离矩阵构造的 Vietoris-Rips 复形之上，这引出了复形中面的出生、消亡和持久性信息。通过纳入各个面的琼斯多项式，该框架产生一个加权条形码，其权重由相关面的琼斯多项式给出。

4.2.6 软件与代码资源

表 1 列出了几种广泛用于计算持续同调、持续拉普拉斯算子及霍奇分解的软件包。除此之外，另一个流行的工具是 Mapper [274]，它能够以单纯复形的形式为高维数据集提供简化表示。以点云数据为例，首先使用聚类算法将数据划分为若干簇。随后基于这些簇构建一个单纯复形：每个簇对应一个顶点，而一组 n 个簇若其交集非空，则构成一个 $(n-1)$ -单形。所得单纯复形的一维骨架通常被称为 Mapper 图，它提供了对数据的简洁描述，并捕捉了其拓扑结构的重要信息。已有多个软件工具实现了 Mapper 算法，包括 KeplerMapper [294]、giotto-tda [289]、GUDHI [211] 以及 Mapper Interactive [328]。

4.3 特征化方法

持久同调和持久琼斯多项式可以编码为持久性条形码，其由一系列（出生，死亡）对组成，表示拓扑特征在过滤过程中的生命周期。相比之下，多尺度高斯链环积分和多尺度琼斯多项式通常由分割矩阵表示，其中条目量化了底层数据段之间的局部链环信息。对于持久拉普拉斯算子和持久狄拉克算子，谱信息（特征值和特征向量）通常用于特征提取。这些表示产生了三种类型的拓扑描述符：持久性条形码、持久性谱和分割矩阵。除此之

表 1 用于计算持续同调和持续拉普拉斯算子的软件包。

软件	单纯复形	立方体复形	持续同调	持续上同调	持续拉普拉斯算子	霍奇分解
https://appliedtopology.github.io/javaplex/ [3]	是		是			
https://people.maths.ox.ac.uk/naanda/perseus/index.html [224]	是	是	是			
https://mrzv.org/software/dionysus2/ [229]	是		是	是		
https://gudhi.inria.fr/ [211]	是	是	是	是		
https://riposter.scikit-tda.org/en/latest/ [22]	是		是	是		
https://github.com/xoltar/phant [24]	是	是	是			
https://github.com/DIPHA/dipha/ [23]	是	是	是			
https://cran.r-project.org/web/packages/TDA/index.html [121]	是	是	是	是		
https://giotto-ai.github.io/gtda-docs/0.5.1/library.html [289]	是	是	是			
https://github.com/rodrigo/OpenPH [218]	是		是			
https://github.com/appliedtopology/ctl	是	是	是			
https://github.com/henselman-petrusek/Eirene.jl [152]	是	是	是			
https://bitbucket.org/hubwag/cubicle/src/master/ [297]		是	是			
https://github.com/shizuo-kaji/CubicalRipser_3dim [166]		是	是			
https://topology-tool-kit.github.io/ [290]	是	是	是			
https://www.sthu.org/code/libstick/ [114]	是		是			
https://weilab.math.msu.edu/HERMES/ [303]	是				是	
https://github.com/ndag/Persistent-Laplacian [217]	是				是	
https://github.com/zhesu1/HHH [280]		是				是
https://github.com/zhesu1/5ComponentHD [281]		是				是
https://github.com/rdzhao/3DHodgeDecomposition [324]	是					是

外，霍奇拉普拉斯算子实现了向量场的三分量和五分量正交分解，这自然地在欧拉设定中为原始向量场提供了多通道图像表示。接下来，我们将描述将这些拓扑描述符转化为适用于机器学习算法的特征向量的方法。

4.3.1 函数化表述

持久性条形码/图不能直接应用于机器学习任务，因为它们本身不具备固定大小特征向量的结构。持久性条形码包含数量可变、长度不同的区间，而持久性图则包含数量可变的无序点。向量化持久性条形码/图的一种直接方法是使用其函数化表述，这些表述可以通过在选定点对所得函数进行采样，直接离散化为机器学习输入。常用的函数化表述包括贝蒂曲线、持久性景观 [34]、持久性曲面和持久性图像 [4] 等。

4.3.2 分箱计数

另一种向量化持久性条形码的方法是分箱法 [40]。在该方法中，将等长的过滤范围划分为一组箱子，并统计每个箱子内的出生数、死亡数和持久数。这一过程产生三个相应的特征向量：出生计数、死亡计数和持久计数。该方法有效地捕捉了结构特性，例如键长，包括生物分子中的非共价相互作用，并已在各种拓扑数据分析研究中被广泛采用 [37, 38, 233]。

4.3.3 统计特性

对于持久性条形码，一种基础且广泛使用的向量化方法是提取其统计特性 [8, 14, 40, 42]。例如，可以计算条形长度、出生时间、死亡时间和中位数的描述性统计量，包括最大值、最小值、总和、中位数、均值、标准差、方差和熵。这将产生一个维度为 $4k$ 的特征向量，其中 k 表示四种量中每种量的统计度量数量。通过将过滤范围划分为 s 个固定区间并在每个区间内计算统计特性，可以获得更细粒度的表示。例如，统计出生-死亡区间覆盖每个区间的条形数量会产生一个 s 维向量，而记录每个区间内的最大和最小出生值则会产生一个 $2s$ 维向量。

对于持久谱，常见的做法是将过滤范围划分为均匀区间，并在每个区间计算相应的拉普拉斯矩阵，然后提取这些矩阵的特征值和特征向量以形成特征表示 [202, 219]。基本的统计度量，如最大值、最小值、总和、中位数、均值、标准差、方差和熵，可以应用于每个拉普拉斯矩阵的特征值，从而产生捕捉跨尺度拓扑、几何和组合特征的特征向量。然而，当拉普拉斯矩阵较大时，计算完整谱的计算成本很高。在这种情况下，通常只保留最小的 k 个非零特征值以及贝蒂数，它们捕捉了最全局和最稳定的谱分量。这种截断的谱表示不仅计算高效，而且对噪声具有鲁棒性。

分割矩阵编码了给定曲线对之间各分段的成对链接信息。一种直接的向量化策略是计算矩阵所有条目的全局统计特性，例如最大值、最小值、总和、中位数、均值、标准差、方差和熵，以构建特征向量。或者，可以通过对每行或每列的条目求和来捕捉局部链接模式，从而量化单个分段的总体链接贡献。然后，可以对这些跨所有分段的局部值应用统计度量，以生成保留局部结构信息的特征向量。

4.3.4 代数形式化

对于持久性条形码，代数向量化主要通过从条形码构造的多项式映射实现。例如，在 Adcock-Carlsson 坐标方法 [6] 中，给定一个包含 n 个区间的条形码，会构造一个代数函数环，即满足特定性质的 $2n$ 个变量的多项式。然后通过从该环中选择 k 个代数函数，并在 n 个（出生，死亡）对上求值，得到一个 k 维特征向量。在热带坐标方法 [167] 中，对于一个包含 n 个区间的条形码，仅使用最大值、最小值、加法和减法运算构造一个涉及 $2n$ 个变量的函数。该函数在变量置换下保持不变。特征向量通过对

所有 n 个（出生，死亡）对或（出生，持久性）对求值该函数获得。还有一些方法利用定义在条形码区间上的复多项式来生成特征向量 [105, 125]。

对于持久性谱，向量化主要涉及对相关拉普拉斯矩阵的特征值应用函数。例如，在持久属性方法 [219] 中，将过滤范围划分为均匀的区域，并在每个区间内计算特征值的谱指数。这些谱指数 [252] 包括拉普拉斯图能量、广义图能量、广义平均图能量、谱半径、谱直径、Ivanciuc 矩阵谱算子、谱矩、Lovász-Pelikán 指数和拟维纳指数。除了这些谱描述符外，其他谱性质，如代数连通性、模块性、Cheeger 常数、顶点/边扩展，以及从流、随机游走和热核导出的量，也可以纳入向量化过程。除了这些经典谱性质外，更高级的函数，如黎曼 zeta 函数 [203] 和对称函数 [25]，也已被应用于特征值以进行特征提取。

4.3.5 多维公式化方法

多种公式化方法将多个参数或索引纳入特征生成过程。例如，Mayer 同调在过滤过程中包含一个额外的索引 [269]，从而产生三维持久性条形码。此外，多维持久同调为将动态分子数据转换为图像表示提供了一个有效框架，而多尺度多维持久性进一步在单张图像内编码了不同空间尺度下的分子结构 [314]。

对于持久谱，生成多维特征向量的一种方法是使用过滤值作为 x 轴，并在 y 轴上绘制前 k 个特征值或整个特征值谱的统计特性。另一种策略是将持久图像的思想扩展到谱特征。具体而言，对于每个过滤值，计算前 k 个特征值或完整谱的 k 个统计量，从而得到 k 个（过滤值，特征属性）对。这些对可以类比于持久性条形码中的（出生，死亡）对进行处理，从而允许构建持久图像。如果在整个过滤过程中收集所有这样的对，则可以得到二维图像表示。或者，如果在每个过滤值处构建单独的图像，并沿过滤轴将它们连接起来，则可以导出三维图像。

此外，当将霍奇拉普拉斯算子应用于笛卡尔网格时，可以通过霍奇分解直接获得图像表示。例如，在网格上应用三分量分解会产生无旋分量、无散分量和谐波分量，每个分量都具有与原始一形式相同的空间维度。然后可以通过沿通道轴连接这三个分量来构建多通道图像。

4.3.6 基于核的模型

基于核的机器学习模型依赖核函数将数据隐式映射到高维特征空间，从而能够建模复杂的非线性关系，而无需显式计算这些空间中的坐标。这些方法的核心组件是核函数，它充当所有数据点对之间的相似性度量。

为了将持久性图等拓扑表示整合到基于核的学习框架中，必须定义此类图之间的可比性概念。一种自然的方式是在持久性图的空间上定义度量结构。这些度量结构导出的距离可以量化持久性条形码/图之间的差异。已经研究了几种度量，例如豪斯多夫距离、瓶颈距离 [73] 和瓦瑟斯坦距离 [40, 221]，并证明它们对小扰动具有鲁棒性。然而，这些距离的计算，特别是对于大型数据集，可能在计算上非常昂贵 [105]。定义一个合适的平均过程也很具挑战性，因为局部均值可能不唯一 [221, 232]。特别是，这些度量主要用于基于距离的学习方法，例如 k-近邻 (KNN) 和一些聚类算法。因此，它们不适用于需要希尔伯特空间结构或固定大小特征输入的机器学习技术，例如支持向量机 (SVM)、主成分分析 (PCA)、决策树分类和深度神经网络。

基于核的模型通过定义一个将持久性图映射到希尔伯特空间的核来解决这个问题，从而允许它们直接与基于核的机器学习技术（如 SVM 和 PCA）集成。该核通过在希尔伯特空间中计算内积来编码持久性图之间的相似性。基于这种构造，已经提出了各种基于持久同调的核，例如持久尺度空间核 [255]、持久加权高斯核 [180]、切片瓦瑟斯坦核 [53] 和持久费希尔核 [183]，并且如相关论文所述，它们在形状分类、形状分割、纹理识别等应用中取得了成功。

4.3.7 持久同调的统计框架

过去十年中，通过统计方法研究持久性图取得了显著进展，解决了由其无序性和可变基数带来的挑战，尤其是在存在小数据扰动的情況下。图空间的度量结构，特别是在 Wasserstein 距离或瓶颈距离下，自然地引出了集中趋势的统计概念，例如 Fréchet 均值和中位数 [73, 221, 293]。

为了促进经典统计原理在拓扑数据分析中的应用，持久性图越来越多地被建模为随机变量。将持久性图嵌入到更易处理的数学空间中的函数表示法的发展，在推动这一进展中发挥了关键作用。例如，持久景观 [34] 将持久性图嵌入到巴拿赫空间中，允许直接计算均值、方差和置信带，从而将拓扑摘要更直接地整合到既定的统计方法中。类似地，持久图像 [4] 提

供了一种互补的方法，将图转换为稳定的、有限维的向量表示，从而易于支持标准的统计分析。这些嵌入促进了在 Wasserstein 距离下持久性图的中心极限定理（CLT）以及各种函数表示法的大数定律（LLN）类似物的建立 [34, 108]，加强了 TDA 作为一个更稳健、更具统计基础的领域，并提升了其在更广泛的科学和工程领域的适用性。此外，还发展了自助法来评估拓扑摘要的总体水平差异 [55, 57]，通过构建置信集和分析拓扑特征的渐近行为，实现组间的正式比较 [120]。

充分统计量概括了样本中与基础概率分布相关的所有信息。一个基于热带几何的框架为持久同调构建了充分统计量 [227]。所开发的模型将条形码映射到单射且稳定的热带坐标中。这种通过热带几何嵌入到欧几里得空间的方法，保留了参数建模所需的完整拓扑信息，同时实现了与经典统计技术的无缝集成。

基于核密度估计（KDE）的框架直接在持久性图空间上工作。一些方法利用点过程理论，将期望图定义为拉东测度空间中的平均对象 [107]，而另一些方法则利用 Wasserstein 距离和瓶颈距离来捕捉拓扑特征的内在几何结构 [213]。这些方法无需将图转换为向量表示即可估计拓扑特征的分布，从而提供了对其变异性的更内在且几何忠实度更高的表征。

Maroulas 等人 [213] 引入了利用随机有限集框架为持久性图量身定制的非参数密度估计技术。他们使用概率假设密度（PHD）来估计拓扑特征的分布，无需限制性假设，从而能够稳健地将有意义的拓扑特征与噪声分离，这对于分析复杂或嘈杂的数据至关重要。他们提供了理论收敛保证，包括平均绝对瓶颈偏差的界限，确保密度估计收敛到真实分布。在另一个互补的方向上，已发展出一种用于持续同调的贝叶斯框架，其中持续图被建模为来自具有先验强度的泊松点过程的实现，从而支持对拓扑特征分布进行后验推断，并为拓扑摘要提供概率解释 [214]。在一项专注于生成建模的相关进展中，Papamarkou 等人 [242] 引入了一种基于成对交互点过程和 RJ-MCMC 采样来生成合成持续图的方法，能够在捕获特征间依赖关系的同时，实现对拓扑特征分布的真实模拟。这有助于在拓扑数据分析中进行统计分析，特别是在数据有限的情况下，例如在材料科学中。一个相关模型将此概率框架扩展到生物网络的分类，通过将持续图建模为独立同分布的聚类点过程，使用高斯混合模型来捕捉空间分布，并使用二项分布来建模拓扑特征数量的变异性 [212]。此外，贝叶斯拓扑信号处理进一步推进了

这项工作以处理时间序列数据，支持对噪声或演化信号中动态拓扑特征进行不确定性感知的分类 [236]。

5 结论性评述

在人工智能（AI）的助力下，拓扑数据分析（TDA）已成为应用数学和数据科学中一个快速发展的领域。TDA 的一项关键技术是持续同调，这是一种多尺度代数拓扑工具，已在科学、工程、医学、工业和国防等不同学科中展现出令人瞩目的成功。然而，基于单纯复形的持续同调面临若干局限性，包括：无法处理非几何信息、依赖对高阶环路的定性描述、无法追踪非拓扑变化、无法处理有向网络，以及对超图等结构化数据不敏感。此外，虽然代数拓扑技术通常分析点云数据，但它们不能直接应用于微分流形上的数据或嵌入三维空间的一维曲线。这些 TDA 中的挑战在过去十年中推动了重大的进展。

本文全面综述了为应对持续同调的局限性而发展的 TDA 技术，着重阐述了它们的数学基础和优势。一些技术将持续同调从单纯复形扩展到其他拓扑领域，例如胞腔复形、路径复形、有向旗复形、层复形和超（有向）图。另一些技术则引入了替代的拓扑表述，包括拉普拉斯算子 [302]、狄拉克算子 [9]、层理论、迈耶拓扑 [269] 和交互拓扑 [193]。对于微分流形上的数据，已发展出基于微分拓扑的方法，例如持续德拉姆上同调、持续霍奇拉普拉斯算子和霍奇分解 [64, 282]。对于三维空间中一维曲线上的数据，则提出了来自几何拓扑的工具，例如高斯环绕积分 [270]、琼斯多项式 [277] 和霍瓦诺夫同调 [197, 268]。

TDA 的快速增长是由机器学习驱动的，例如拓扑深度学习（TDL）[37] 和数学人工智能。然而，来自 TDA 的拓扑表示无法在没有适当向量化的情况下直接在机器学习中实现。本文还回顾了针对不同输入数据格式的拓扑算法选择、它们相关的拓扑表示，以及在机器学习背景下的拓扑向量化方法。

TDA 和 TDL 是动态且快速发展的领域。TDA 和 TDL 的未来发展将由理论探索 and 实际需求共同驱动，包括对可解释深度神经网络的需求。我们预见未来将在以下几个方向取得进展。

目前，单个数据点周围的局部几何和/或拓扑可以通过持续上同调 [39]、演化同调 [41]、交互拓扑 [193] 和持续层拉普拉斯算子 [309] 来描述。需要进一步努力完善局部拓扑方法以用于实际应用。

目前大多数 TDA 方法是为点云数据开发的。然而，序列数据在 DNA 测序、自然语言处理和脑电图（EEG）分析等应用中被广泛使用。这些领域需要新颖的 TDA 方法论。

在微分几何中，阿蒂亚-辛格指标理论建立了一个拓扑指标。针对紧致流形上的数据，可以发展用于椭圆微分算子族的持续指标理论。低维拓扑方法的发展对于分析嵌入三维空间的一维曲线（例如纠缠聚合物和神经网络）至关重要。持久弗洛尔同调可能为模拟蛋白质-蛋白质结合相互作用提供一个有效的框架。此外，稳健的计算算法用于持久科瓦诺夫同调和持久科瓦诺夫拉普拉斯算子仍然是紧迫的优先事项。

最后，大语言模型（LLMs）预示着人工智能的新时代，为各学科创造了机遇。像 DeepSeek 和 ChatGPT 这样的聊天机器人可以将抽象数学理论——包括计算拓扑学——转化为实用工具 [196]。预计未来几年，人工智能辅助的拓扑学以及拓扑学增强的人工智能将快速增长。

TDA 是一个广阔的跨学科领域，涵盖代数拓扑、微分拓扑和几何拓扑；计算算法；人工智能驱动的方法论；以及现实世界的应用。尽管本文旨在全面综述超越持久同调的 TDA 和 TDL，但由于该领域的广度，我们不可避免地遗漏了许多重要贡献。我们注意到，自 2017 年 TDL 引入以来 [37]，人们在开发拓扑神经网络方面付出了巨大努力。为了专注于 TDA，我们限制了自己详细阐述这一发展。感兴趣的读者可以参考最近一篇关于 TDL 各个方面的综述 [243]。我们希望这项工作能为探索拓扑技术的研究人员提供指导，并帮助他们为分析不同领域的特定问题选择最佳方法。

致谢

这项工作得到了 NIH 资助 R01AI164266 和 R35GM148196、NSF 资助 DMS-2052983、密歇根州立大学研究基金会以及百事美施贵宝 65109 的部分支持。VM 的部分资金来自美国国家科学基金会资助 DMS-2012609、DMR-2309083、DRL-2314155、DMS-1821241、MCB-1715794 和 DGE-2152168；美国陆军研究实验室（ARL）合同 W911NF-22-2-0143、W911NF-21-2-0186 和 W911NF-19-2-0328；美国陆军研究办公室（ARO）合同

W911NF-21-1-0094 和 W911NF-17-1-0313; 以及 Thor Industries/ARL 合同 W911NF-17-2-0141。

References

- [1] Adams, C.C.: The Knot Book: An Elementary Introduction to the Mathematical Theory of Knots. American Mathematical Society, (2004)
- [2] Adams, H., Carlsson, G.: On the nonlinear statistics of range image patches. *SIAM Journal on Imaging Sciences* **2**(1), 110–117 (2009)
- [3] Adams, H., Tausz, A., Vejdemo-Johansson, M.: Javaplex: a research software package for persistent (co)homology. In: *Mathematical Software-ICMS 2014: 4th International Congress*, Seoul, South Korea, August 5-9, 2014. *Proceedings 4*, pp. 129–136 (2014). Springer
- [4] Adams, H., Emerson, T., Kirby, M., Neville, R., Peterson, C., Shipman, P., Chepushtanova, S., Hanson, E., Motta, F., Ziegelmeier, L.: Persistence images: a stable vector representation of persistent homology. *Journal of Machine Learning Research* **18**(8), 1–35 (2017)
- [5] Adams, H., Lagoda, E., Moy, M., Sadovek, N., De Saha, A.: Persistent equivariant cohomology. *arXiv preprint arXiv:2408.17331* (2024)
- [6] Adcock, A., Carlsson, E., Carlsson, G.: The ring of algebraic functions on persistence bar codes. *Homology, Homotopy and Applications* **18**(1), 381–402 (2016)
- [7] Alexander, J.W.: Topological invariants of knots and links. *Transactions of the American Mathematical Society* **30**(2), 275–306 (1928)

- [8] Ali, D., Asaad, A., Jimenez, M.-J., Nanda, V., Paluzo-Hidalgo, E., Soriano-Trigueros, M.: A survey of vectorization methods in topological data analysis. *IEEE Transactions on Pattern Analysis and Machine Intelligence* **45**(12), 14069–14080 (2023)
- [9] Amenityro, B., Maroulas, V., Siopsis, G.: Quantum persistent homology. *Journal of Applied and Computational Topology* **8**(7), 1961–1980 (2024)
- [10] Amenityro, B., Siopsis, G., Maroulas, V.: Quantum persistent homology for time series. In: *APS March Meeting Abstracts*, vol. 2023, pp. 73–003 (2023)
- [11] Arnold, D.N.: *Finite Element Exterior Calculus*. SIAM, (2018)
- [12] Arnold, D.N., Falk, R.S., Winther, R.: Finite element exterior calculus, homological techniques, and applications. *Acta numerica* **15**, 1–155 (2006)
- [13] Arsuaga, J., Vazquez, M., McGuirk, P., Trigueros, S., Sumners, D.W., Roca, J.: DNA knots reveal a chiral organization of DNA in phage capsids. *Proceedings of the National Academy of Sciences* **102**(26), 9165–9169 (2005)
- [14] Asaad, A., Ali, D., Majeed, T., Rashid, R.: Persistent homology for breast tumor classification using mammogram scans. *Mathematics* **10**(21), 4039 (2022)
- [15] Atienza, N., Gonzalez-Diaz, R., Rucco, M.: Persistent entropy for separating topological features from noise in Vietoris-Rips complexes. *Journal of Intelligent Information Systems* **52**, 637–655 (2019)
- [16] Baccini, F., Geraci, F., Bianconi, G.: Weighted simplicial complexes and their representation power of higher-order network data and topology. *Physical Review E* **106**(3), 034319 (2022)

- [17] Bae, W., Yoo, J., Chul Ye, J.: Beyond deep residual learning for image restoration: Persistent homology-guided manifold simplification. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops, pp. 145–153 (2017)
- [18] Baldwin, Q., Panagiotou, E.: The local topological free energy of proteins. *Journal of Theoretical Biology* **529**, 110854 (2021)
- [19] Baldwin, Q., Sumpter, B., Panagiotou, E.: The local topological free energy of the SARS-CoV-2 spike protein. *Polymers* **14**(15), 3014 (2022)
- [20] Barkataki, K., Panagiotou, E.: The Jones polynomial of collections of open curves in 3-space. *Proceedings of the Royal Society A* **478**(2267), 20220302 (2022)
- [21] Barnes, D., Polanco, L., Perea, J.A.: A comparative study of machine learning methods for persistence diagrams. *Frontiers in Artificial Intelligence* **4**, 681174 (2021)
- [22] Bauer, U.: Ripser: efficient computation of Vietoris–Rips persistence barcodes. *Journal of Applied and Computational Topology* **5**(3), 391–423 (2021)
- [23] Bauer, U., Kerber, M., Reininghaus, J.: Dipha (a distributed persistent homology algorithm). Software available at <https://github.com/DIPHA/dipha> (2014)
- [24] Bauer, U., Kerber, M., Reininghaus, J., Wagner, H.: Phat–persistent homology algorithms toolbox. *Journal of symbolic computation* **78**, 76–90 (2017)
- [25] Behler, J., Parrinello, M.: Generalized neural-network representation of high-dimensional potential-energy surfaces. *Physical review letters* **98**(14), 146401 (2007)

- [26] Bhatia, H., Norgard, G., Pascucci, V., Bremer, P.-T.: The Helmholtz-Hodge decomposition - a survey. *IEEE Transactions on visualization and computer graphics* **19**(8), 1386–1404 (2012)
- [27] Bi, W., Li, J., Liu, J., Wu, J.: On the Cayley-persistence algebra. *arXiv preprint arXiv:2205.10796* (2022)
- [28] Bianconi, G.: The topological Dirac equation of networks and simplicial complexes. *Journal of Physics: Complexity* **2**(3), 035022 (2021)
- [29] Biasotti, S., Giorgi, D., Spagnuolo, M., Falcidieno, B.: Reeb graphs for shape analysis and applications. *Theoretical computer science* **392**(1-3), 5–22 (2008)
- [30] Bodnar, C., Frasca, F., Wang, Y., Otter, N., Montúfar, G.F., Liò, P., Bronstein, M.: Weisfeiler and lehman go topological: Message passing simplicial networks. In: *Proceedings of the 38th International Conference on Machine Learning*, pp. 1026–1037 (2021)
- [31] Botnan, M., Lesnick, M.: An introduction to multiparameter persistence. In: *Representations of Algebras and Related Structures*, pp. 77–150 (2023)
- [32] Botnan, M.B., Lebovici, V., Oudot, S.: On rectangle-decomposable 2-parameter persistence modules. In: *Leibniz International Proceedings in Informatics*, vol. 164, pp. 22–1 (2020). Leibniz-Zentrum für Informatik
- [33] Bressan, S., Li, J., Ren, S., Wu, J.: The embedded homology of hypergraphs and applications. *Asian Journal of Mathematics* **23**(3), 479–500 (2019)
- [34] Bubenik, P.: Statistical topological data analysis using persistence landscapes. *Journal of Machine Learning Research* **16**(1), 77–102 (2015)

- [35] Bubenik, P., Dłotko, P.: A persistence landscapes toolbox for topological statistics. *Journal of Symbolic Computation* **78**, 91–114 (2017)
- [36] Calmon, L., Schaub, M.T., Bianconi, G.: Dirac signal processing of higher-order topological signals. *New Journal of Physics* **25**(9), 093013 (2023)
- [37] Cang, Z., Wei, G.-W.: Topologynet: Topology based deep convolutional and multi-task neural networks for biomolecular property predictions. *PLoS computational biology* **13**(7), 1005690 (2017)
- [38] Cang, Z., Wei, G.-W.: Integration of element specific persistent homology and machine learning for protein-ligand binding affinity prediction. *International journal for numerical methods in biomedical engineering* **34**(2), 2914 (2018)
- [39] Cang, Z., Wei, G.-W.: Persistent cohomology for data with multi-component heterogeneous information. *SIAM journal on mathematics of data science* **2**(2), 396–418 (2020)
- [40] Cang, Z., Mu, L., Wei, G.-W.: Representability of algebraic topology for biomolecules in machine learning based scoring and virtual screening. *PLoS computational biology* **14**(1), 1005929 (2018)
- [41] Cang, Z., Munch, E., Wei, G.-W.: Evolutionary homology on coupled dynamical systems with applications to protein flexibility analysis. *Journal of applied and computational topology* **4**(4), 481–507 (2020)
- [42] Cang, Z., Mu, L., Wu, K., Opron, K., Xia, K., Wei, G.-W.: A topological approach for protein classification. *Computational and Mathematical Biophysics* **3**(1) (2015)
- [43] Cantarella, J., DeTurck, D., Gluck, H.: Vector calculus and the topology of domains in 3-space. *The American Mathematical Monthly* **109**(5), 409–442 (2002)

- [44] Carlsson, G.: Topology and data. *Bulletin of the American Mathematical Society* **46**(2), 255–308 (2009)
- [45] Carlsson, G., De Silva, V.: Zigzag persistence. *Foundations of computational mathematics* **10**, 367–405 (2010)
- [46] Carlsson, G., Zomorodian, A.: The theory of multidimensional persistence. In: *Proceedings of the Twenty-third Annual Symposium on Computational Geometry*, pp. 184–193 (2007)
- [47] Carlsson, G., De Silva, V., Morozov, D.: Zigzag persistent homology and real-valued functions. In: *Proceedings of the Twenty-fifth Annual Symposium on Computational Geometry*, pp. 247–256 (2009)
- [48] Carlsson, G., Zomorodian, A., Collins, A., Guibas, L.: Persistence barcodes for shapes. In: *Proceedings of the 2004 Eurographics/ACM SIGGRAPH Symposium on Geometry Processing*, pp. 124–135 (2004)
- [49] Carlsson, G., Ishkhanov, T., De Silva, V., Zomorodian, A.: On the local behavior of spaces of natural images. *International journal of computer vision* **76**, 1–12 (2008)
- [50] Carlsson, G., De Silva, V., Kališnik, S., Morozov, D.: Parametrized homology via zigzag persistence. *Algebraic & Geometric Topology* **19**(2), 657–700 (2019)
- [51] Carrière, M.: Cover complex. In: *GUDHI User and Reference Manual*, (2025)
- [52] Carriere, M., Blumberg, A.: Multiparameter persistence image for topological machine learning. *Advances in Neural Information Processing Systems* **33**, 22432–22444 (2020)
- [53] Carriere, M., Cuturi, M., Oudot, S.: Sliced Wasserstein kernel for persistence diagrams. In: *International Conference on Machine Learning*, pp. 664–673 (2017). PMLR

- [54] Chan, J.M., Carlsson, G., Rabadan, R.: Topology of viral evolution. *Proceedings of the National Academy of Sciences* **110**(46), 18566–18571 (2013)
- [55] Chazal, F., Fasy, B.T., Lecci, F., Rinaldo, A., Wasserman, L.: Stochastic convergence of persistence landscapes and silhouettes. In: *Proceedings of the Thirtieth Annual Symposium on Computational Geometry*, pp. 474–483 (2014)
- [56] Chazal, F., De Silva, V., Glisse, M., Oudot, S.: *The Structure and Stability of Persistence Modules* vol. 10. Springer, (2016)
- [57] Chazal, F., Fasy, B.T., Lecci, F., Michel, B., Rinaldo, A., Wasserman, L.: Robust topological inference: Distance to a measure and kernel distance. *Journal of Machine Learning Research* **18**(159), 1–40 (2018)
- [58] Chen, D., Liu, J., Wei, G.-W.: Multiscale topology-enabled structure-to-sequence transformer for protein–ligand interaction predictions. *Nature Machine Intelligence* **6**(7), 799–810 (2024)
- [59] Chen, D., Liu, J., Wu, J., Wei, G.-W., Pan, F., Yau, S.-T.: Path topology in molecular and materials sciences. *The journal of physical chemistry letters* **14**(4), 954–964 (2023)
- [60] Chen, D., Liu, J., Wu, J., Wei, G.-W.: Persistent hyperdigraph homology and persistent hyperdigraph Laplacians. *Foundations of Data Science* **5**(4), 558–588 (2023)
- [61] Chen, G., Mischaikow, K., Laramée, R.S., Zhang, E.: Efficient Morse decompositions of vector fields. *IEEE Transactions on Visualization and Computer Graphics* **14**(4), 848–862 (2008)
- [62] Chen, J., Wei, G.-W.: Omicron BA. 2 (B. 1.1. 529.2): high potential for becoming the next dominant variant. *The journal of physical chemistry letters* **13**(17), 3840–3849 (2022)

- [63] Chen, J., Wang, R., Wang, M., Wei, G.-W.: Mutations strengthened SARS-CoV-2 infectivity. *Journal of molecular biology* **432**(19), 5212–5226 (2020)
- [64] Chen, J., Zhao, R., Tong, Y., Wei, G.-W.: Evolutionary de Rham-Hodge method. *Discrete and continuous dynamical systems. Series B* **26**(7), 3785 (2021)
- [65] Chen, J., Qiu, Y., Wang, R., Wei, G.-W.: Persistent Laplacian projected Omicron BA. 4 and BA. 5 to become new dominating variants. *Computers in Biology and Medicine* **151**, 106262 (2022)
- [66] Chen, J., Woldring, D.R., Huang, F., Huang, X., Wei, G.-W.: Topological deep learning based deep mutational scanning. *Computers in biology and medicine* **164**, 107258 (2023)
- [67] Chen, Y., Segovia, I., Gel, Y.R.: Z-GCNETs: time zigzags at graph convolutional networks for time series forecasting. In: *International Conference on Machine Learning*, pp. 1684–1694 (2021). PMLR
- [68] Chevyrev, I., Nanda, V., Oberhauser, H.: Persistence paths and signature features in topological data analysis. *IEEE transactions on pattern analysis and machine intelligence* **42**(1), 192–202 (2018)
- [69] Chowdhury, S., Mémoli, F.: Persistent path homology of directed networks. In: *Proceedings of the Twenty-Ninth Annual ACM-SIAM Symposium on Discrete Algorithms*, pp. 1152–1169 (2018). SIAM
- [70] Chung, Y.-M., Lawson, A.: Persistence curves: A canonical framework for summarizing persistence diagrams. *Advances in Computational Mathematics* **48**(1), 6 (2022)
- [71] Ciarlet, P.G.: *The Finite Element Method for Elliptic Problems*. SIAM, (2002)
- [72] Clough, J.R., Byrne, N., Oksuz, I., Zimmer, V.A., Schnabel, J.A., King, A.P.: A topological loss function for deep-learning based

- image segmentation using persistent homology. *IEEE transactions on pattern analysis and machine intelligence* **44**(12), 8766–8778 (2020)
- [73] Cohen-Steiner, D., Edelsbrunner, H., Harer, J.: Stability of persistence diagrams. In: *Proceedings of the Twenty-first Annual Symposium on Computational Geometry*, pp. 263–271 (2005)
 - [74] Cohen-Steiner, D., Edelsbrunner, H., Harer, J.: Extending persistence using Poincaré and Lefschetz duality. *Foundations of Computational Mathematics* **9**(1), 79–103 (2009)
 - [75] Collins, A., Zomorodian, A., Carlsson, G., Guibas, L.J.: A barcode shape descriptor for curve point cloud data. *Computers & Graphics* **28**(6), 881–894 (2004)
 - [76] Conley, C.C.: *Isolated Invariant Sets and the Morse Index* vol. 38. American Mathematical Soc., (1978)
 - [77] Conti, F., Moroni, D., Pascali, M.A.: A topological machine learning pipeline for classification. *Mathematics* **10**(17), 3086 (2022)
 - [78] Cooperband, Z., Ghrist, R.: Unified origami kinematics via cosheaf homology. *arXiv preprint arXiv:2501.02581* (2025)
 - [79] Cooperband, Z., Ghrist, R., Hansen, J.: A cosheaf theory of reciprocal figures: Planar and higher genus graphic statics. *arXiv preprint arXiv:2311.12946* (2023)
 - [80] Cottrell, S., Hozumi, Y., Wei, G.-W.: K-nearest-neighbors induced topological PCA for single cell RNA-sequence data analysis. *Computers in biology and medicine* **175**, 108497 (2024)
 - [81] Cottrell, S., Wang, R., Wei, G.-W.: PLPCA: persistent Laplacian-enhanced PCA for microarray data analysis. *Journal of chemical information and modeling* **64**(7), 2405–2420 (2023)

- [82] Crowell, R.H., Fox, R.H.: Introduction to Knot Theory vol. 57. Springer, (2012)
- [83] Curry, J.M.: Sheaves, Cosheaves and Applications. University of Pennsylvania, (2014)
- [84] Dabaghian, Y., Mémoli, F., Frank, L., Carlsson, G.: A topological paradigm for hippocampal spatial map formation using persistent homology (2012)
- [85] Dabrowski-Tumanski, P., Jarmolinska, A.I., Niemyska, W., Rawdon, E.J., Millett, K.C., Sulkowska, J.I.: Linkprot: a database collecting information about biological links. Nucleic acids research, 976 (2016)
- [86] Dabrowski-Tumanski, P., Rubach, P., Niemyska, W., Gren, B.A., Sulkowska, J.I.: Topoly: Python package to analyze topology of polymers. Briefings in Bioinformatics **22**(3), 196 (2021)
- [87] Dawson, R.J.M.: Homology of weighted simplicial complexes. Cahiers de Topologie et Géométrie Différentielle Catégoriques **31**(3), 229–243 (1990)
- [88] De Silva, V., Carlsson, G.E.: Topological estimation using witness complexes. In: PBG, pp. 157–166 (2004)
- [89] De Silva, V., Vejdemo-Johansson, M.: Persistent cohomology and circular coordinates. In: Proceedings of the Twenty-fifth Annual Symposium on Computational Geometry, pp. 227–236 (2009)
- [90] De Silva, V., Morozov, D., Vejdemo-Johansson, M.: Dualities in persistent (co)homology. Inverse Problems **27**(12), 124003 (2011)
- [91] Delaunay, B.: Sur la sphere vide. Izvestia Akademii Nauk SSSR **7**, 793–800 (1934)
- [92] Deligne, P.: La conjecture de weil. i. Publications Mathématiques de l’Institut des Hautes Études Scientifiques **43**, 273–307 (1974)

- [93] Deligne, P.: La conjecture de weil: Ii. Publications Mathématiques de l’IHÉS **52**, 137–252 (1980)
- [94] Desbrun, M., Kanso, E., Tong, Y.: Discrete differential forms for computational modeling. In: ACM SIGGRAPH 2006 Courses, pp. 39–54 (2006)
- [95] Dey, T.K., Hou, T.: Computing zigzag persistence on graphs in near-linear time. In: 37th International Symposium on Computational Geometry (2021)
- [96] Dey, T.K., Hou, T.: Updating zigzag persistence and maintaining representatives over changing filtrations. arXiv preprint arXiv:2112.02352 (2021)
- [97] Dey, T.K., Hou, T.: Fast computation of zigzag persistence. In: 30th Annual European Symposium on Algorithms (ESA 2022). Leibniz International Proceedings in Informatics (LIPIcs), vol. 244 (2022). pp. 43:1–43:15
- [98] Dey, T.K., Kim, W., Mémoli, F.: Computing generalized rank invariant for 2-parameter persistence modules via zigzag persistence and its applications. Discrete & Computational Geometry **71**(1), 67–94 (2024)
- [99] Dey, T.K., Li, T., Wang, Y.: An efficient algorithm for 1-dimensional (persistent) path homology. Discrete & Computational Geometry **68**(4), 1102–1132 (2022)
- [100] Dey, T.K., Mrozek, M., Slechta, R.: Persistence of the Conley index in combinatorial dynamical systems. In: 36th International Symposium on Computational Geometry (SoCG 2020). Leibniz International Proceedings in Informatics (LIPIcs), vol. 164 (2020). pp. 37:1–37:17
- [101] Dey, T.K., Mrozek, M., Slechta, R.: Persistence of Conley-Morse

- graphs in combinatorial dynamical systems. *SIAM Journal on Applied Dynamical Systems* **21**(2), 817–839 (2022)
- [102] Dey, T.K., Juda, M., Kapela, T., Kubica, J., Lipiński, M., Mrozek, M.: Persistent homology of Morse decompositions in combinatorial dynamics. *SIAM Journal on Applied Dynamical Systems* **18**(1), 510–530 (2019)
- [103] Dey, T.K., Wang, Y.: *Computational Topology for Data Analysis*. Cambridge University Press, (2022)
- [104] Di, S., Ivanov, S.O., Mukoseev, L., Zhang, M.: On the path homology of cayley digraphs and covering digraphs. *Journal of Algebra* **653**, 156–199 (2024)
- [105] Di Fabio, B., Ferri, M.: Comparing persistence diagrams through complex vectors. In: *Image Analysis and Processing-ICIAP 2015: 18th International Conference, Genoa, Italy, September 7-11, 2015, Proceedings, Part I* 18, pp. 294–305 (2015). Springer
- [106] Dirac, P.A.M.: The quantum theory of the electron. *Proceedings of the Royal Society of London. Series A, Containing Papers of a Mathematical and Physical Character* **117**(778), 610–624 (1928)
- [107] Divol, V., Chazal, F.: The density of expected persistence diagrams and its kernel based estimation. *Journal of Computational Geometry* **10**(2), 1–31 (2019). <https://doi.org/10.20382/jocg.v10i2a7>
- [108] Divol, V., Lacombe, T.: Understanding the topology and the geometry of the space of persistence diagrams via optimal partial transport. *Journal of Applied and Computational Topology* **5**(1), 1–53 (2021). <https://doi.org/10.1007/s41468-020-00061-z>
- [109] Dłotko, P., Wanner, T.: Topological microstructure analysis using persistence landscapes. *Physica D: Nonlinear Phenomena* **334**, 60–81 (2016)

- [110] Du, H., Wei, G.-W., Hou, T.: Multiscale topology in interactomic network: from transcriptome to antiaddiction drug repurposing. *Briefings in Bioinformatics* **25**(2), 054 (2024)
- [111] Eckmann, B.: Harmonische funktionen und randwertaufgaben in einem komplex. *Commentarii Mathematici Helvetici* **17**(1), 240–255 (1944)
- [112] Edelsbrunner, Letscher, Zomorodian: Topological persistence and simplification. *Discrete & computational geometry* **28**, 511–533 (2002)
- [113] Edelsbrunner, H.: Alpha shapes - a survey. In: *Tessellations in the Sciences: Virtues, Techniques and Applications of Geometric Tilings*, (2011)
- [114] Edelsbrunner, H., Harer, J.: *Computational Topology: An Introduction*. American Mathematical Soc., (2010)
- [115] Edelsbrunner, H., Morozov, D.: *Persistent Homology: Theory and Practice*. eScholarship, University of California, (2013)
- [116] Edelsbrunner, H., Harer, J., *et al.*: Persistent homology - a survey. *Contemporary mathematics* **453**(26), 257–282 (2008)
- [117] Einzade, A., Thanou, D., Malliaros, F.D., Giraldo, J.H.: *Cosmos: Continuous simplicial neural networks*. arXiv preprint arXiv:2503.12919 (2025)
- [118] Estrada, E.: Path Laplacian matrices: introduction and application to the analysis of consensus in networks. *Linear algebra and its applications* **436**(9), 3373–3391 (2012)
- [119] Fabri, A., Pion, S.: CGAL: the computational geometry algorithms library. In: *Proceedings of the 17th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems*, pp. 538–539 (2009)

- [120] Fasy, B.T., Lecci, F., Rinaldo, A., Wasserman, L., Balakrishnan, S., Singh, A.: Confidence sets for persistence diagrams. *The Annals of Statistics* **42**(6), 2301–2339 (2014). <https://doi.org/10.1214/14-AOS1252>
- [121] Fasy, B.T., Kim, J., Lecci, F., Maria, C.: Introduction to the R package TDA. arXiv preprint arXiv:1411.1830 (2014)
- [122] Feng, H., Shen, L., Liu, J., Wei, G.-W.: Mayer-homology learning prediction of protein-ligand binding affinities. *Journal of Computational Biophysics and Chemistry*, 1–14 (2024)
- [123] Feng, L., Gong, H., Zhang, S., Liu, X., Wang, Y., Che, J., Dong, A., Griffin, C.H., Gragnoli, C., Wu, J., Yau, S.-T., Wu, R.: Hypernetwork modeling and topology of high-order interactions for complex systems. *Proceedings of the National Academy of Sciences* **121**(40), 2412220121 (2024)
- [124] Feng, L., Yang, D., Wu, S., Xue, C., Sang, M., Liu, X., Che, J., Wu, J., Gragnoli, C., Griffin, C., Wang, C., Yau, S.-T., Wu, R.: Network modeling and topology of aging. *Physics reports* **1101**, 1–65 (2025)
- [125] Ferri, M., Landi, C.: Representing size functions by complex polynomials. *Proc. Math. Met. in Pattern Recognition* **9**, 16–19 (1999)
- [126] Friedrichs, K.O.: Differential forms on Riemannian manifolds. *Communications on Pure and Applied Mathematics* **8**(4), 551–590 (1955)
- [127] Frosini, P., Mulazzani, M.: Size homotopy groups for computation of natural size distances. *Bulletin of the Belgian Mathematical Society-Simon Stevin* **6**(3), 455–464 (1999)
- [128] Gameiro, M., Hiraoka, Y., Izumi, S., Kramar, M., Mischaikow, K., Nanda, V.: A topological measurement of protein compressibility. *Japan Journal of Industrial and Applied Mathematics* **32**, 1–17 (2015)

- [129] Gauss, C.F.: Zur Mathematischen Theorie der Electrodynamischen Wirkungen, pp. 601–630. Springer, Berlin, Heidelberg (1877)
- [130] Ge, X., Safa, I., Belkin, M., Wang, Y.: Data skeletonization via Reeb graphs. *Advances in neural information processing systems* **24** (2011)
- [131] Geuzaine, C., Remacle, J.-F.: Gmsh: a 3-D finite element mesh generator with built-in pre- and post-processing facilities. *International journal for numerical methods in engineering* **79**(11), 1309–1331 (2009)
- [132] Ghrist, R.: Barcodes: the persistent topology of data. *Bulletin of the American Mathematical Society* **45**(1), 61–75 (2008)
- [133] Ghrist, R.W.: *Elementary Applied Topology* vol. 1. Createspace Seattle, (2014)
- [134] Goldberg, T.E.: *Combinatorial Laplacians of simplicial complexes*. PhD thesis, Citeseer (2002)
- [135] Gong, H., Wang, H., Wang, Y., Zhang, S., Liu, X., Che, J., Wu, S., Wu, J., Sun, X., Zhang, S., Yau, S.-T., Wu, R.: Topological change of soil microbiota networks for forest resilience under global warming. *Physics of Life Reviews* (2024)
- [136] Grbić, J., Wu, J., Xia, K., Wei, G.-W.: Aspects of topological approaches for data science. *Foundations of data science* (Springfield, Mo.) **4**(2), 165 (2022)
- [137] Grigor’yan, A., Lin, Y., Muranov, Y., Yau, S.-T.: Homologies of path complexes and digraphs. *arXiv preprint arXiv:1207.2834* (2012)
- [138] Grigor’yan, A.: Advances in path homology theory of digraphs. *Notices of the International Consortium of Chinese Mathematicians* **10**(2), 61–124 (2022)

- [139] Grigor'yan, A., Muranov, Y., Yau, S.-T.: On a cohomology of digraphs and hochschild cohomology. *Journal of Homotopy and Related Structures* **11**(2), 209–230 (2016)
- [140] Grigor'yan, A., Lin, Y., Muranov, Y., Yau, S.-T.: Homotopy theory for digraphs. *Pure and Applied Mathematics Quarterly* **10**(4), 619–674 (2023)
- [141] Gülen, A.B., Mémoli, F., Wan, Z.: Orthogonal möbius inversion and Grassmannian persistence diagrams. *arXiv preprint arXiv:2311.06870* (2023)
- [142] Gülen, A.B., Mémoli, F., Wan, Z.: Grassmannian persistence diagrams: Special properties in the 1-parameter setting. *arXiv preprint arXiv:2504.06077* (2025)
- [143] Gülen, A.B., Mémoli, F., Wan, Z., Wang, Y.: A Generalization of the Persistent Laplacian to Simplicial Maps. In: 39th International Symposium on Computational Geometry (SoCG 2023). *Leibniz International Proceedings in Informatics (LIPIcs)*, vol. 258 (2023). pp. 37:1–37:17
- [144] Gundert, A., Szedlák, M.: Higher dimensional Cheeger inequalities. In: *Proceedings of the Thirtieth Annual Symposium on Computational Geometry*, pp. 181–188 (2014)
- [145] Günther, D., Reininghaus, J., Wagner, H., Hotz, I.: Efficient computation of 3D Morse–Smale complexes and persistent homology using discrete Morse theory. *The Visual Computer* **28**, 959–969 (2012)
- [146] Hang, H., Mio, W.: Correspondence modules and persistence sheaves: a unifying perspective on one-parameter persistent homology. *Japan Journal of Industrial and Applied Mathematics* **40**(1), 41–93 (2023)
- [147] Hansen, J.: Laplacians of cellular sheaves: Theory and applications.

PhD thesis, University of Pennsylvania (2020)

- [148] Hansen, J., Ghrist, R.: Toward a spectral theory of cellular sheaves. *Journal of Applied and Computational Topology* **3**(4), 315–358 (2019)
- [149] Hayakawa, R.: Quantum algorithm for persistent Betti numbers and topological data analysis. *Quantum* **6**, 873 (2022)
- [150] He, Y., Liu, J.: Multi-scale hochschild spectral analysis on graph data. *AIMS Mathematics* **10**(1), 1384–1406 (2025)
- [151] Hensel, F., Moor, M., Rieck, B.: A survey of topological machine learning methods. *Frontiers in Artificial Intelligence* **4**, 681108 (2021)
- [152] Henselman, G., Ghrist, R.: Matroid filtrations and computational persistent homology. arXiv preprint arXiv:1606.00199 (2016)
- [153] Hernández-García, P., Serrano, D.H., Gómez, D.S.: From persistence to resilience: New betti numbers for analyzing robustness in simplicial complex networks. arXiv preprint arXiv:2505.10467 (2025)
- [154] Holme, P., Saramäki, J.: Temporal networks. *Physics reports* **519**(3), 97–125 (2012)
- [155] Horak, D., Jost, J.: Spectra of combinatorial Laplace operators on simplicial complexes. *Advances in Mathematics* **244**, 303–336 (2013)
- [156] Horak, D., Maletić, S., Rajković, M.: Persistent homology of complex networks. *Journal of Statistical Mechanics: Theory and Experiment* **2009**(03), 03034 (2009)
- [157] Hozumi, Y., Wei, G.-W.: Revealing the shape of genome space via k-mer topology. arXiv preprint arXiv:2412.20202 (2024)
- [158] Ivanov, S.O., Pavutnitskiy, F.: Simplicial approach to path homology

- of quivers, marked categories, groups and algebras. *Journal of the London Mathematical Society* **109**(1), 12812 (2024)
- [159] Jamin, C.: Tangential complex. In: *GUDHI User and Reference Manual*, (2025)
- [160] Jamroz, M., Niemyska, W., Rawdon, E.J., Stasiak, A., Millett, K.C., Sułkowski, P., Sulkowska, J.I.: Knotprot: a database of proteins with knots and slipknots. *Nucleic acids research* **43**(D1), 306–314 (2015)
- [161] Jiang, Y., Chen, D., Chen, X., Li, T., Wei, G.-W., Pan, F.: Topological representations of crystalline compounds for the machine-learning prediction of materials properties. *npj computational materials* **7**(1), 28 (2021)
- [162] Jones, B., Wei, G.-W.: Khovanov Laplacian and Khovanov Dirac for knots and links. *Journal of Physics: Complexity* **6**(2), 025014 (2025)
- [163] Jones, B., Wei, G.-W.: Persistent directed flag Laplacian. *Foundations of Data Science* **7**(3), 737–758 (2025)
- [164] Jones, V.F.: A polynomial invariant for knots via von Neumann algebras. In: *Fields Medallists' Lectures*, pp. 448–458. World Scientific, (1997)
- [165] Jonsson, J.: *Simplicial Complexes of Graphs* vol. 1928. Springer, (2008)
- [166] Kaji, S., Sudo, T., Ahara, K.: Cubical Ripser: Software for computing persistent homology of image and volume data. *arXiv preprint arXiv:2005.12692* (2020)
- [167] Kališnik, S.: Tropical coordinates on the space of persistence barcodes. *Foundations of Computational Mathematics* **19**(1), 101–129 (2019)
- [168] Kannan, H., Saucan, E., Roy, I., Samal, A.: Persistent homology of

- unweighted complex networks via discrete Morse theory. *Scientific reports* **9**(1), 13817 (2019)
- [169] Karagüler, D.: A survey on multidimensional persistence theory. Master's thesis, Middle East Technical University (Turkey) (2021)
- [170] Karan, A., Kaygun, A.: Time series classification via topological data analysis. *Expert Systems with Applications* **183**, 115326 (2021). <https://doi.org/10.1016/j.eswa.2021.115326>
- [171] Keros, A., Subr, K.: Spectral coarsening with Hodge Laplacians. In: *ACM SIGGRAPH 2023 Conference Proceedings*, pp. 1–11 (2023)
- [172] Khovanov, M.: A categorification of the Jones polynomial (2000)
- [173] Kim, K., Kim, J., Zaheer, M., Kim, J., Chazal, F., Wasserman, L.: Pllay: Efficient topological layer based on persistent landscapes. *Advances in Neural Information Processing Systems* **33**, 15965–15977 (2020)
- [174] Kim, W., Mémoli, F.: Generalized persistence diagrams for persistence modules over posets. *Journal of Applied and Computational Topology* **5**(4), 533–581 (2021)
- [175] Kim, W., Mémoli, F.: Persistence over posets. *Notices of the American Mathematical Society* **70**(08) (2023)
- [176] Kirchhoff, G.: Ueber die auflösung der gleichungen, auf welche man bei der untersuchung der linearen vertheilung galvanischer ströme geführt wird. *Annalen der Physik* **148**(12), 497–508 (1847)
- [177] Knill, O.: The cohomology for Wu characteristics. arXiv preprint arXiv:1803.06788 (2018)
- [178] Kovacev-Nikolic, V., Bubenik, P., Nikolić, D., Heo, G.: Using persistent homology and dynamical distances to analyze protein binding. *Statistical applications in genetics and molecular biology* **15**(1),

19–38 (2016)

- [179] Krishnagopal, S., Bianconi, G.: Topology and dynamics of higher-order multiplex networks. *Chaos, Solitons & Fractals* **177**, 114296 (2023)
- [180] Kusano, G., Hiraoka, Y., Fukumizu, K.: Persistence weighted Gaussian kernel for topological data analysis. In: *International Conference on Machine Learning*, pp. 2004–2013 (2016). PMLR
- [181] Ladyzhenskaya, O.A.: *The Mathematical Theory of Viscous Incompressible Flow*. Gordon & Breach, (1969)
- [182] Le, M.Q., Taylor, D.: Persistent homology with k-nearest-neighbor filtrations reveals topological convergence of pagerank. *Foundations of Data Science* **7**(2), 536–567 (2025)
- [183] Le, T., Yamada, M.: Persistence Fisher kernel: A Riemannian manifold kernel for persistence diagrams. *Advances in neural information processing systems* **31** (2018)
- [184] Lee, Y., Barthel, S.D., Dłotko, P., Moosavi, S.M., Hess, K., Smit, B.: Quantifying similarity of pore-geometry in nanoporous materials. *Nature communications* **8**(1), 1–8 (2017)
- [185] Leray, J.: L’anneau d’homologie d’une représentation. *C.R. Acad. Sci. Paris* (222), 1366–1368 (1946)
- [186] Li, J., Muranov, Y., Wu, J., Yau, S.-T.: On singular homology theories of digraphs and quivers (2024)
- [187] Li, J., Muranov, Y., Wu, J., Yau, S.-T.: Primitive path homology. *arXiv preprint arXiv:2411.18955* (2024)
- [188] LI, J., VERSHININ, V., WU, J.: Twisted simplicial groups and twisted homology of categories. *Homology, Homotopy & Applications* **19**(2) (2017)

- [189] Liang, C., Mislow, K.: Knots in proteins. *Journal of the American Chemical Society* **116**(24), 11189–11190 (1994)
- [190] Lieutier, A.: Talk: Persistent harmonic forms (2014)
- [191] Lim, L.-H.: Hodge Laplacians on graphs. *Siam Review* **62**(3), 685–715 (2020)
- [192] Lin, Y., Ren, S., Wang, C., Wu, J.: Weighted path homology of weighted digraphs and persistence. *arXiv preprint arXiv:1910.09891* (2019)
- [193] Liu, J., Chen, D., Wei, G.-W.: Interaction homotopy and interaction homology. *arXiv preprint arXiv:2311.16322* (2023)
- [194] Liu, J., Chen, D., Wei, G.-W.: Persistent interaction topology in data analysis. *arXiv preprint arXiv:2404.11799* (2024)
- [195] Liu, J., Li, J., Wu, J.: The algebraic stability for persistent Laplacians. *Homology, Homotopy and Applications* **26**(2), 297–323 (2024)
- [196] Liu, J., Shen, L., Wei, G.-W.: ChatGPT for computational topology. *Foundations of data science* **6**(2), 221–250 (2024)
- [197] Liu, J., Shen, L., Wei, G.-W.: Persistent Khovanov homology of tangles. *arXiv preprint arXiv:2409.18312* (2024)
- [198] Liu, J., Shen, L., Chen, D., Wei, G.-W.: Topological sequence analysis of genomes: Delta complex approaches. *arXiv preprint arXiv:2507.05452* (2025)
- [199] Liu, R., Liu, X., Wu, J.: Persistent path-spectral (pps) based machine learning for protein–ligand binding affinity prediction. *Journal of chemical information and modeling* **63**(3), 1066–1075 (2023)
- [200] Liu, X., Xia, K.: Neighborhood complex based machine learning (NCML) models for drug design. In: *International Workshop on*

- Interpretability of Machine Intelligence in Medical Image Computing, and Topological Data Analysis and Its Applications for Medical Data, pp. 87–97 (2021)
- [201] Liu, X., Wang, X., Wu, J., Xia, K.: Hypergraph-based persistent cohomology (HPC) for molecular representations in drug design. *Briefings in Bioinformatics* **22**(5), 411 (2021)
 - [202] Liu, X., Feng, H., Wu, J., Xia, K.: Persistent spectral hypergraph based machine learning (PSH-ML) for protein-ligand binding affinity prediction. *Briefings in Bioinformatics* **22**(5), 127 (2021)
 - [203] Liu, X., Feng, H., Wu, J., Xia, K.: Dowker complex based machine learning (DCML) models for protein-ligand binding affinity prediction. *PLoS computational biology* **18**(4), 1009943 (2022)
 - [204] Liu, X., Feng, H., Wu, J., Xia, K.: Hom-complex-based machine learning (HCML) for the prediction of protein-protein binding affinity changes upon mutation. *Journal of chemical information and modeling* **62**(17), 3961–3969 (2022)
 - [205] Liu, X., Feng, H., Wu, J., Xia, K.: Computing hypergraph homology. *Foundations of Data Science* **6**(2), 172–194 (2024)
 - [206] Liu, X., Liu, R., Li, J., Wu, R., Wu, J.: Intcomplex for high-order interactions. *arXiv preprint arXiv:2412.02806* (2024)
 - [207] Liu, X., Su, Z., Shi, Y., Tong, Y., Wang, G., Wei, G.-W.: Manifold topological deep learning for biomedical data. *arXiv preprint arXiv:2503.00175* (2025)
 - [208] Lloyd, S., Garnerone, S., Zanardi, P.: Quantum algorithms for topological and geometric analysis of data. *Nature communications* **7**(1), 10138 (2016)
 - [209] Love, E.R., Filippenko, B., Maroulas, V., Carlsson, G.: Topological convolutional layers for deep learning. *Journal of Machine Learning*

Research **24**(59), 1–35 (2023)

- [210] Lütgehetmann, D., Govc, D., Smith, J.P., Levi, R.: Computing persistent homology of directed flag complexes. *Algorithms* **13**(1), 19 (2020)
- [211] Maria, C., Boissonnat, J.-D., Glisse, M., Yvinec, M.: The GUDHI library: simplicial complexes and persistent homology. In: *Mathematical Software–ICMS 2014: 4th International Congress*, Seoul, South Korea, August 5–9, 2014. *Proceedings 4*, pp. 167–174 (2014). Springer
- [212] Maroulas, V., Micucci, C.P., Nasrin, F.: Bayesian topological learning for classifying the structure of biological networks. *Bayesian Analysis* **17**(3), 711–736 (2022). <https://doi.org/10.1214/21-BA1270>
- [213] Maroulas, V., Mike, J.L., Oballe, C.: Nonparametric estimation of probability density functions of random persistence diagrams. *Journal of Machine Learning Research* **20**(196), 1–49 (2019)
- [214] Maroulas, V., Nasrin, F., Oballe, C.: A Bayesian framework for persistent homology. *SIAM Journal on Mathematics of Data Science* **2**(1), 48–74 (2020). <https://doi.org/10.1137/19M1268719>
- [215] Mayer, W.: A new homology theory. *Annals of Mathematics* **43**(2), 370–380 (1942)
- [216] McCleary, J.: *A User’s Guide to Spectral Sequences* vol. 58. Cambridge University Press, (2001)
- [217] Mémoli, F., Wan, Z., Wang, Y.: Persistent Laplacians: Properties, algorithms and implications. *SIAM Journal on Mathematics of Data Science* **4**(2), 858–884 (2022)
- [218] Mendoza-Smith, R., Tanner, J.: Parallel multi-scale reduction of persistent homology filtrations. *arXiv preprint arXiv:1708.04710*

(2017)

- [219] Meng, Z., Xia, K.: Persistent spectral-based machine learning (Perspect ML) for protein-ligand binding affinity prediction. *Science advances* **7**(19), 5329 (2021)
- [220] Meng, Z., Anand, D.V., Lu, Y., Wu, J., Xia, K.: Weighted persistent homology for biomolecular data analysis. *Scientific reports* **10**(1), 2079 (2020)
- [221] Mileyko, Y., Mukherjee, S., Harer, J.: Probability measures on the space of persistence diagrams. *Inverse Problems* **27**(12), 124007 (2011)
- [222] Miller, B.P.: Interpretations from Helmholtz' theorem in classical electromagnetism. *American Journal of Physics* **52**(10), 948–950 (1984)
- [223] Millett, K.C., Rawdon, E.J., Stasiak, A., Sułkowska, J.I.: Identifying knots in proteins. *Biochemical Society Transactions* **41**(2), 533–537 (2013)
- [224] Mischaikow, K., Nanda, V.: Morse theory for filtrations and efficient computation of persistent homology. *Discrete & Computational Geometry* **50**, 330–353 (2013)
- [225] Mischaikow, K., Mrozek, M., Zgliczyński, P.: *Conley Index Theory* vol. 47. Springer, (1999)
- [226] Mitchell, E.C., Story, B., Boothe, D., Franaszczuk, P.J., Maroulas, V.: A topological deep learning framework for neural spike decoding. *Biophysical Journal* **123**(17), 2781–2789 (2024). <https://doi.org/10.1016/j.bpj.2024.01.025>
- [227] Monod, A., Kališnik, S., Patiño-Galindo, J.Á., Crawford, L.: Tropical sufficient statistics for persistent homology. *SIAM Journal on Applied Algebra and Geometry* **3**(2), 337–371 (2019). <https://doi.org/10.1137/19M1337>

[org/10.1137/17M1148037](https://doi.org/10.1137/17M1148037)

- [228] Montagna, M., Scardapane, S., Telyatnikov, L.: Topological deep learning with state-space models: A mamba approach for simplicial complexes. arXiv preprint arXiv:2409.12033 (2024)
- [229] Morozov, D.: Dionysus, a C++ library for computing persistent homology (2007)
- [230] Morrey, C.B.: A variational method in the theory of harmonic integrals, ii. American Journal of Mathematics **78**(1), 137–170 (1956)
- [231] Morse, M.: Relations between the critical points of a real function of n independent variables. Transactions of the American Mathematical Society **27**(3), 345–396 (1925)
- [232] Munch, E., Turner, K., Bendich, P., Mukherjee, S., Mattingly, J., Harer, J.: Probabilistic Fréchet means for time varying persistence diagrams. Electronic Journal of Statistics **9**, 1173–1204 (2015)
- [233] Nguyen, D.D., Cang, Z., Wu, K., Wang, M., Cao, Y., Wei, G.-W.: Mathematical deep learning for pose and binding affinity prediction and ranking in D3R Grand Challenges. Journal of computer-aided molecular design **33**, 71–82 (2019)
- [234] Nguyen, D.D., Gao, K., Wang, M., Wei, G.-W.: Mathdl: mathematical deep learning for D3R Grand Challenge 4. Journal of computer-aided molecular design **34**, 131–147 (2020)
- [235] Nielsen, M.A., Chuang, I.L.: Quantum Computation and Quantum Information. Cambridge university press, (2010)
- [236] Oballe, C., Cherne, A., Boothe, D., Kerick, S., Franaszczuk, P.J., Maroulas, V.: Bayesian topological signal processing. Discrete and Continuous Dynamical Systems - Series S **15**(4), 797–817 (2022). <https://doi.org/10.3934/dcdss.2021084>

- [237] Ohtsuki, T.: Quantum Invariants: a Study of Knots, 3-manifolds, and Their Sets vol. 29. World Scientific, (2001)
- [238] Ozsváth, P., Szabó, Z.: Holomorphic disks and knot invariants. *Advances in Mathematics* **186**(1), 58–116 (2004)
- [239] Panagiotou, E., Kauffman, L.H.: Knot polynomials of open and closed curves. *Proceedings of the Royal Society A* **476**(2240), 20200124 (2020)
- [240] Panagiotou, E., Plaxco, K.W.: A topological study of protein folding kinetics. *Topol. Geom. Biopolym. AMS Contemp. Math. Ser* **746**, 223–233 (2020)
- [241] Panagiotou, E., Millett, K.C., Atzberger, P.J.: Topological methods for polymeric materials: characterizing the relationship between polymer entanglement and viscoelasticity. *Polymers* **11**(3), 437 (2019)
- [242] Papamarkou, T., Nasrin, F., Lawson, A., Gong, N., Rios, O., Maroulas, V.: A random persistence diagram generator. *Statistics and Computing* **32**(88) (2022). <https://doi.org/10.1007/s11222-022-10141-y>
- [243] Papamarkou, T., Birdal, T., Bronstein, M.M., Carlsson, G., Curry, J., Gao, Y., Hajij, M., Kwitt, R., Liò, P., Di Lorenzo, P., Maroulas, V., Miolane, N., Nasrin, F., Natesan Ramamurthy, K., Rieck, B., Scardapane, S., Schaub, M.T., Veličković, P., Wang, B., Wang, Y., Wei, G.-W., Zamzmi, G.: Position: Topological deep learning is the new frontier for relational learning. *Proceedings of Machine Learning Research* **235**, 39529–39555 (2024). 41st International Conference on Machine Learning (ICML 2024)
- [244] Patel, A.: Generalized persistence diagrams. *Journal of Applied and Computational Topology* **1**(3), 397–419 (2018)

- [245] Perea, J.A.: Persistent homology of toroidal sliding window embeddings. In: 2016 IEEE International Conference on Acoustics, Speech and Signal Processing (icassp), pp. 6435–6439 (2016). IEEE
- [246] Perea, J.A., Harer, J.: Sliding windows and persistence: an application of topological methods to signal analysis. *Foundations of computational mathematics* **15**, 799–838 (2015)
- [247] Petri, G., Scolamiero, M., Donato, I., Vaccarino, F.: Topological strata of weighted complex networks. *PloS one* **8**(6), 66506 (2013)
- [248] Poelke, K.: Hodge-type decompositions for piecewise constant vector fields on simplicial surfaces and solids with boundary. PhD thesis (2017)
- [249] Poelke, K., Polthier, K.: Boundary-aware Hodge decompositions for piecewise constant vector fields. *Computer-Aided Design* **78**, 126–136 (2016)
- [250] Pun, C.S., Lee, S.X., Xia, K.: Persistent-homology-based machine learning: a survey and a comparative study. *Artificial Intelligence Review* **55**(7), 5169–5213 (2022)
- [251] Pun, C.S., Yong, B.Y.S., Xia, K.: Weighted-persistent-homology-based machine learning for RNA flexibility analysis. *PloS one* **15**(8), 0237747 (2020)
- [252] Puzyn, T., Leszczynski, J., Cronin, M.T.: Recent advances in QSAR studies: methods and applications (2010)
- [253] Qiu, Y., Wei, G.-W.: Persistent spectral theory-guided protein engineering. *Nature computational science* **3**(2), 149–163 (2023)
- [254] Reeb, G.: Sur les points singuliers d’une forme de pfaff complètement intégrable ou d’une fonction numérique [on the singular points of a completely integrable pfaff form or of a numerical function]. *Comptes Rendus Acad. Sciences Paris* **222**, 847–849 (1946)

- [255] Reininghaus, J., Huber, S., Bauer, U., Kwitt, R.: A stable multi-scale kernel for topological machine learning. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 4741–4748 (2015)
- [256] Ren, S., Wu, J.: The stability of persistent homology of hypergraphs. arXiv preprint arXiv:2002.02237 (2020)
- [257] Ren, S., Wu, C., Wu, J.: Weighted persistent homology. The Rocky Mountain Journal of Mathematics **48**(8), 2661–2687 (2018)
- [258] Ren, S., Wang, C., Wu, C., Wu, J.: On the discrete Morse functions for hypergraphs. arXiv preprint arXiv:2108.02384 (2021)
- [259] Reuter, M., Wolter, F.-E., Peinecke, N.: Laplace-Beltrami spectra as ‘Shape-DNA’ of surfaces and solids. Computer-Aided Design **38**(4), 342–366 (2006)
- [260] Ribando-Gros, E., Wang, R., Chen, J., Tong, Y., Wei, G.-W.: Combinatorial and Hodge Laplacians: Similarity and difference. SIAM Review **66**(3), 575–601 (2024)
- [261] Russold, F.: Persistent sheaf cohomology. arXiv preprint arXiv:2204.13446 (2022)
- [262] Rustamov, R.M., *et al.*: Laplace-Beltrami eigenfunctions for deformation invariant shape representation. In: Symposium on Geometry Processing, vol. 257, pp. 225–233 (2007)
- [263] Schenck, H.: Algebraic Foundations for Applied Topology and Data Analysis. Springer, (2022)
- [264] Schlick, T., Zhu, Q., Dey, A., Jain, S., Yan, S., Laederach, A.: To knot or not to knot: multiple conformations of the SARS-CoV-2 frameshifting RNA element. Journal of the American Chemical Society **143**(30), 11404–11422 (2021)

- [265] Schubert, H.: Über eine numerische knoteninvariante. *Mathematische Zeitschrift* **61**(1), 245–288 (1954)
- [266] Schwarz, G.: *Hodge Decomposition - A Method for Solving Boundary Value Problems*. Springer, (2006)
- [267] Segal, G.: Classifying spaces and spectral sequences. *Publications Mathématiques de l’IHÉS* **34**, 105–112 (1968)
- [268] Shen, L., Liu, J., Wei, G.-W.: Evolutionary Khovanov homology. *AIMS Mathematics* **9**(9), 26139–26165 (2024)
- [269] Shen, L., Liu, J., Wei, G.-W.: Persistent Mayer homology and persistent Mayer Laplacian. *Foundations of Data Science* **6**(4), 584–612 (2024)
- [270] Shen, L., Feng, H., Li, F., Lei, F., Wu, J., Wei, G.-W.: Knot data analysis using multiscale Gauss link integral. *Proceedings of the National Academy of Sciences* **121**(42), 2408431121 (2024)
- [271] Shepard, A.D.: *A Cellular Description of the Derived Category of a Stratified Space*. Brown University, (1985)
- [272] Shonkwiler, C.: *Poincaré duality angles on Riemannian manifolds with boundary*. PhD thesis, University of Pennsylvania (2009)
- [273] Silver, D.S., Williams, S.G.: Knot invariants from Laplacian matrices. *Journal of Knot Theory and Its Ramifications* **28**(09), 1950058 (2019)
- [274] Singh, G., Mémoli, F., Carlsson, G.E., *et al.*: Topological methods for the analysis of high dimensional data sets and 3D object recognition. *PBG@ Eurographics* **2**, 091–100 (2007)
- [275] Singh, Y., Farrelly, C.M., Hathaway, Q.A., Leiner, T., Jagtap, J., Carlsson, G.E., Erickson, B.J.: Topological data analysis in medical imaging: current state of the art. *Insights into Imaging* **14**(1), 58

(2023)

- [276] Som, A., Choi, H., Ramamurthy, K.N., Buman, M.P., Turaga, P.: Pi-net: A deep learning approach to extract topological persistence images. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, pp. 834–835 (2020)
- [277] Song, R., Li, F., Wu, J., Lei, F., Wei, G.-W.: Multi-scale jones polynomial and persistent jones polynomial for knot data analysis. *AIMS Mathematics* **10**(1), 1463–1487 (2025)
- [278] Spanier, E.H.: The Mayer homology theory. *Bull. Amer. Math. Soc.* **55**(12), 102–112 (1949)
- [279] Stolz, B.J., Harrington, H.A., Porter, M.A.: Persistent homology of time-dependent functional networks constructed from coupled time series. *Chaos: An Interdisciplinary Journal of Nonlinear Science* **27**(4) (2017)
- [280] Su, Z., Tong, Y., Wei, G.-W.: Hodge decomposition of single-cell RNA velocity. *Journal of chemical information and modeling* **64**(8), 3558–3568 (2024)
- [281] Su, Z., Tong, Y., Wei, G.-W.: Hodge decomposition of vector fields in Cartesian grids. In: SIGGRAPH Asia 2024 Conference Papers, pp. 1–10 (2024)
- [282] Su, Z., Tong, Y., Wei, G.-W.: Persistent de Rham-Hodge Laplacians in Eulerian representation for manifold topological learning. *AIMS Mathematics* **9**(10), 27438–27470 (2024)
- [283] Su, Z., Tong, Y., Wei, G.-W.: Topology-preserving Hodge decomposition in the Eulerian representation. *arXiv preprint arXiv:2408.14356* (2024)
- [284] Sulkowska, J.I., Rawdon, E.J., Millet, K.C., Onuchic, J.N., Stasiak, A.: Conservation of complex knotting and slipknotting patterns in

- poteins. Biophysical Journal
- 102**
- (3), 253 (2012)
- [285] Summers, D.: The role of knot theory in DNA research. In: Geometry and Topology, pp. 297–318. CRC Press, (2020)
 - [286] Suwayyid, F., Wei, G.-W.: Persistent Dirac of paths on digraphs and hypergraphs. Foundations of data science (Springfield, Mo.) **6**(2), 124 (2024)
 - [287] Suwayyid, F., Wei, G.-W.: Persistent Mayer Dirac. Journal of Physics: Complexity **5**(4), 045005 (2024)
 - [288] Takens, F.: Detecting strange attractors in turbulence. In: Dynamical Systems and Turbulence, Warwick 1980: Proceedings of a Symposium Held at the University of Warwick 1979/80, pp. 366–381 (2006). Springer
 - [289] Tauzin, G., Lupo, U., Tunstall, L., Pérez, J.B., Caorsi, M., Medina-Mardones, A.M., Dassatti, A., Hess, K.: giotto-tda: A topological data analysis toolkit for machine learning and data exploration. Journal of Machine Learning Research **22**(39), 1–6 (2021)
 - [290] Tierny, J., Favelier, G., Levine, J.A., Gueunet, C., Michaux, M.: The topology toolkit. IEEE transactions on visualization and computer graphics **24**(1), 832–842 (2017)
 - [291] Townsend, J., Micucci, C.P., Hymel, J.H., Maroulas, V., Vogiatzis, K.D.: Representation of molecular structures with persistent homology for machine learning applications in chemistry. Nature communications **11**(1), 3230 (2020)
 - [292] Turner, K., Robins, V., Morgan, J.: The extended persistent homology transform of manifolds with boundary. Journal of Applied and Computational Topology **8**(7), 2111–2154 (2024)
 - [293] Turner, K., Mileyko, Y., Mukherjee, S., Harer, J.: Fréchet means for distributions of persistence diagrams. Discrete & Computational

- Geometry **52**(1), 44–70 (2014)
- [294] Van Veen, H.J., Saul, N., Eargle, D., Mangham, S.W.: Kepler Mapper: a flexible Python implementation of the Mapper algorithm. *Journal of Open Source Software* **4**(42), 1315 (2019)
- [295] Vietoris, L.: Über den höheren zusammenhang kompakter räume und eine klasse von zusammenhangstreuen abbildungen. *Mathematische Annalen* **97**(1), 454–472 (1927)
- [296] Vipond, O.: Multiparameter persistence landscapes. *Journal of Machine Learning Research* **21**(61), 1–38 (2020)
- [297] Wagner, H.: Slice, simplify and stitch: Topology-preserving simplification scheme for massive voxel data. In: 39th International Symposium on Computational Geometry (SoCG 2023) (2023). Schloss Dagstuhl-Leibniz-Zentrum für Informatik
- [298] Wagner, H., Chen, C., Vuçini, E.: Efficient computation of persistent homology for cubical data. In: *Topological Methods in Data Analysis and Visualization II: Theory, Algorithms, and Applications*, pp. 91–106. Springer, (2011)
- [299] Wang, B., Wei, G.-W.: Object-oriented persistent homology. *Journal of computational physics* **305**, 276–299 (2016)
- [300] Wang, R., Wei, G.-W.: Persistent path Laplacian. *Foundations of data science (Springfield, Mo.)* **5**(1), 26 (2023)
- [301] Wang, R., Chen, J., Wei, G.-W.: Mechanisms of SARS-CoV-2 evolution revealing vaccine-resistant mutations in Europe and America. *The journal of physical chemistry letters* **12**(49), 11850–11857 (2021)
- [302] Wang, R., Nguyen, D.D., Wei, G.-W.: Persistent spectral graph. *International Journal for Numerical Methods in Biomedical Engineering* **36**(9), 3376 (2020)

- [303] Wang, R., Zhao, R., Ribando-Gros, E., Chen, J., Tong, Y., Wei, G.-W.: HERMES: Persistent spectral graph software. *Foundations of Data Science* **3**(1), 67–97 (2021)
- [304] Wang, S., Chern, A.: Computing minimal surfaces with differential forms. *ACM Transactions on Graphics (TOG)* **40**(4), 1–14 (2021)
- [305] Wang, Y., Liu, X., Zhang, Y., Wang, X., Xia, K.: Join persistent homology (JPH)-based machine learning for metalloprotein–ligand binding affinity prediction. *Journal of Chemical Information and Modeling* (2025)
- [306] Warner, F.W.: *Foundations of Differentiable Manifolds and Lie Groups* vol. 94. Springer, (1983)
- [307] Wee, J., Xia, K.: Persistent spectral based ensemble learning (PerSpect-EL) for protein-protein binding affinity prediction. *Briefings in Bioinformatics* **23**(2), 024 (2022)
- [308] Wee, J., Bianconi, G., Xia, K.: Persistent Dirac for molecular representation. *Scientific Reports* **13**(1), 11183 (2023)
- [309] Wei, X., Wei, G.-W.: Persistent sheaf Laplacians. *Foundations of Data Science* **7**(2), 446–463 (2025)
- [310] Wei, X., Wei, G.-W.: Persistent topological Laplacians – a survey. *Mathematics* **13**(2), 208 (2025)
- [311] Weil, A.: Numbers of solutions of equations in finite fields. *Bulletin of the American Mathematical Society* **55**(5), 497–508 (1949)
- [312] Wu, S., Liu, X., Dong, A., Gagnoli, C., Griffin, C., Wu, J., Yau, S.-T., Wu, R.: The metabolomic physics of complex diseases. *Proceedings of the National Academy of Sciences* **120**(42), 2308496120 (2023)

- [313] Xia, K., Wei, G.-W.: Persistent homology analysis of protein structure, flexibility, and folding. *International journal for numerical methods in biomedical engineering* **30**(8), 814–844 (2014)
- [314] Xia, K., Wei, G.-W.: Multidimensional persistence in biomolecular data. *Journal of computational chemistry* **36**(20), 1502–1520 (2015)
- [315] Xia, K., Zhao, Z., Wei, G.-W.: Multiresolution persistent homology for excessively large biomolecular datasets. *The Journal of chemical physics* **143**(13) (2015)
- [316] Xia, K., Zhao, Z., Wei, G.-W.: Multiresolution topological simplification. *Journal of Computational Biology* **22**(9), 887–891 (2015)
- [317] Xia, K., Feng, X., Tong, Y., Wei, G.W.: Persistent homology for the quantitative prediction of fullerene stability. *Journal of computational chemistry* **36**(6), 408–422 (2015)
- [318] Yang, S., Xiong, S., Zhang, Y., Feng, F., Liu, J., Zhu, B.: Clebsch gauge fluid. *ACM Transactions on Graphics (TOG)* **40**(4), 1–11 (2021)
- [319] Yegnesh, K.: Persistence and sheaves. *arXiv preprint arXiv:1612.03522* (2016)
- [320] Yin, H., Nabizadeh, M.S., Wu, B., Wang, S., Chern, A.: Fluid cohomology. *ACM Trans. Graph.* **42**(4) (2023)
- [321] Yoon, H.R.: Cellular sheaves and cosheaves for distributed topological data analysis. PhD thesis, University of Pennsylvania (2018)
- [322] Zhang, M.M., Li, J.Y., Wu, J.: The twisted homology of simplicial set. *Acta Mathematica Sinica, English Series* **38**(10), 1781–1802 (2022)
- [323] Zhao, R., Cang, Z., Tong, Y., Wei, G.-W.: Protein pocket detection via convex hull surface evolution and associated reeb graph.

- Bioinformatics **34**(17), 830–837 (2018)
- [324] Zhao, R., Desbrun, M., Wei, G.-W., Tong, Y.: 3D Hodge decompositions of edge- and face-based vector fields. *ACM Transactions on Graphics (TOG)* **38**(6), 1–13 (2019)
 - [325] Zhao, R., Wang, M., Chen, J., Tong, Y., Wei, G.-W.: The de Rham–Hodge analysis and modeling of biomolecules. *Bulletin of mathematical biology* **82**, 1–38 (2020)
 - [326] Zheng, J., Feng, Z., Ekstrom, A.D.: Towards analysis of multivariate time series using topological data analysis. *Mathematics* **12**(11), 1727 (2024)
 - [327] Zhou, Q.: Pymesh-geometry processing library for Python. Software available for download at <https://github.com/PyMesh/PyMesh> **7** (2019)
 - [328] Zhou, Y., Chalapathi, N., Rathore, A., Zhao, Y., Wang, B.: Mapper interactive: a scalable, extendable, and interactive toolbox for the visual exploration of high-dimensional data. In: 2021 IEEE 14th Pacific Visualization Symposium (PacificVis), pp. 101–110 (2021). IEEE
 - [329] Zia, M., Jones, B., Feng, H., Wei, G.-W.: Persistent directed flag Laplacian (PDFL)-based machine learning for protein–ligand binding affinity prediction. *Journal of Chemical Theory and Computation* **21**(8), 4276–4285 (2025)
 - [330] Zieliński, B., Lipiński, M., Juda, M., Zeppelzauer, M., Dłotko, P.: Persistence bag-of-words for topological data analysis. In: Proceedings of the 28th International Joint Conference on Artificial Intelligence, pp. 4489–4495 (2019)
 - [331] Zieliński, B., Lipiński, M., Juda, M., Zeppelzauer, M., Dłotko, P.: Persistence codebooks for topological data analysis. *Artificial*

Intelligence Review **54**, 1969–2009 (2021)

- [332] Zomorodian, A.: Fast construction of the Vietoris-Rips complex. *Computers & Graphics* **34**(3), 263–271 (2010)
- [333] Zomorodian, A., Carlsson, G.: Computing persistent homology. *Discrete & Computational Geometry* **33**(2), 249–274 (2005)
- [334] Zomorodian, A., Carlsson, G.: Localized homology. *Computational Geometry* **41**(3), 126–148 (2008)