

从 Grokking 学习动力学中推导特征涌现的可证明缩放定律

Yuandong Tian

Meta Superintelligence Labs (FAIR) & 独立研究员

yuandong.tian@gmail.com

Abstract

尽管延迟泛化的现象（即 grokking）已被广泛研究，但对于复杂结构化输入，是否存在一个数学框架能够刻画何种特征会涌现、如何以及在何种条件下发生，并且仍然与训练的梯度动力学紧密相连，这仍然是一个开放性问题。我们提出了一个名为 Li_2 的新框架，它捕捉了双层非线性网络 grokking 行为的三个关键阶段：(I) 惰性学习，(II) 独立特征学习 和 (III) 交互式特征学习。在惰性学习阶段，顶层过拟合于随机的隐藏表示，模型表现出记忆现象；同时，来自顶层的反向传播梯度 G_F 携带了关于目标标签的信息，并具有特定的结构，使得每个隐藏节点能够独立地学习其表示。此外，这种独立动力学精确地遵循能量函数 $\mathcal{E}$ 的梯度上升，其局部最大值正是涌现的特征。我们研究了这些由局部最优诱导的特征是否可泛化、它们的表示能力，以及在群算术任务中它们如何随样本大小变化。当隐藏节点在学习的后期阶段开始交互时，我们可证明地展示了 G_F 如何变化以聚焦于需要学习的缺失特征。我们的研究揭示了权重衰减、学习率和样本大小等关键超参数在 grokking 中所扮演的角色，导出了特征涌现、记忆和泛化的可证明缩放定律，并从梯度动力学的基本原理揭示了为何最近如 Muon 等优化器可能有效的根本原因。我们的分析可以扩展到多层架构。代码已公开¹。

1 引言

尽管 Transformer 等现代深度模型已取得令人印象深刻的实证性能，但此类模型如何在训练过程中获取知识仍是一个谜。关于模型是否能真正泛化到训练数据之外，还是仅仅记住了数据集并在分布外（OOD）数据上表现不佳，一直存在持续的争论 (Wang et al., 2024b; Chu et al., 2025; Mirzadeh et al., 2024)。

对记忆与泛化行为进行建模一直是许多工作的目标。其中一种被称为 顿悟 (Power et al., 2022; Doshi et al., 2024; Nanda et al., 2023; Wang et al., 2024a; Varma et al., 2023; Liu et al., 2023; Thilak et al., 2022) 的行为表明，模型最初会过拟合训练集，然后在持续训练后突然泛化到未见过的测试样本。对此存在多种解释，例如有效理论 (Liu et al., 2022; Clauw et al., 2024)、记忆与泛化电路效率 (Varma et al., 2023)、将权重衰减作为先验的贝叶斯解释 (Millidge, 2022) 等。大多数工作侧重于对其经验行为的直接解释，或利用极宽网络的性质 (Barak et al., 2022; Mohamadi et al., 2024; Rubin et al., 2024)，但很少有研究通过分析权重上的梯度动力学来深入探索顿悟学习过程的细节。

¹<https://github.com/yuandong-tian/understanding/tree/main/ssl/real-dataset/cogo>

在本工作中，我们提出了一个数学框架 Li_2 ，将两层非线性网络的顿悟动力学划分为三个主要阶段（图 ??）。

2 何时发生顿悟现象？

我们首先需要澄清，顿悟（即延迟泛化）是一种现象/观察结果，它可能暗示着多种潜在情况。当我们观察到“顿悟发生”时，通常是训练在转向特征学习之前，会在一段时间内陷入惰性学习。另一方面，当我们观察到“顿悟没有发生”时，我们可能陷入三种截然不同的情况之一：(1) 训练完全陷入惰性训练，(2) 特征学习发生得非常早，训练和测试性能之间的差距一直很小，或者 (3) 特征学习由于例如数据不足或噪声而收敛到不可泛化的解，因此测试性能从未得到改善。请注意，(2) 是非常好的结果，而 (1) 和 (3) 是糟糕的结果。

因此，直接将超参数与顿悟行为联系起来是棘手的。相反，使用 Li_2 框架，我们专注于将它们与反向传播梯度 G_F 以及更根本的底层特征学习过程联系起来。只有当 G_F 变大并将足够“量”的关键项 $\tilde{Y}\tilde{Y}^\top F$ 传递到隐藏层时，顿悟才可能发生。在这里，我们将这些因素分为几类。

学习率。(Gromov, 2023) 报告称，在没有正则化但初始学习率较大的情况下会发生顿悟（作者已验证）。这对应于在学习初始阶段增加 $G_F(t) \propto t\tilde{Y}\tilde{Y}^\top F$ 的强度，使得隐藏层接收到足够的正确梯度信号以启动特征学习。

在过拟合前停留更长时间。(Prieto et al., 2025) 在计算概率时使用稳定的 softmax（线性形式）而非常规的 softmax（指数形式）。这防止了模型过快过拟合到标签，从而维持了一个非零的反向传播梯度，该梯度可用于特征学习。(Kumar et al., 2024) 也报告称，在没有正则化、使用普通 SGD 优化器的情况下会发生顿悟。我们的解释是，SGD 收敛到 V_{ridge} 可能比 Adam 需要更长的时间，而在此期间，隐藏层已经积累了足够量的正确梯度信号。

权重初始化。(Liu et al., 2023) 报告称，无论权重衰减如何，在小初始化下都会发生顿悟。从我们的框架来看，这是显而易见的，因为 $G_F(t) = O(\alpha) + t\tilde{Y}\tilde{Y}^\top F + O(\alpha t) + O(t^2)$ ，如果权重初始化 α 很小，那么 $G_F(t)$ 由清晰的信号项 $t\tilde{Y}\tilde{Y}^\top \tilde{F}$ 主导，这导致快速的特征学习。如果 α 很大，那么 $O(\alpha)$ 项很大， G_F 的初始阶段包含太多噪声，我们需要依赖由权重衰减 η 控制的 G_F 收敛阶段提供的信号。这与 (Liu et al., 2023) 的发现一致，即对于大的权重初始化，需要正则化才能使顿悟发生，而小的正则化会导致顿悟转变缓慢。**输出缩放因子 β 。**(Kumar et al., 2024; Chizat et al., 2019) 报告指出，将输出缩放一个因子 $\beta > 1$ 会使顿悟发生得更快。从 Li_2 框架来看，这对应于优化 $J_\beta(V) = \|\tilde{Y} - \beta\tilde{F}V\|_F^2 + \eta\|V\|_F^2$ 。遵循与第 C 节类似的推导，在第 C.3 节中我们可以证明，在初始阶段，反向传播的梯度 $G_F(t) = O(\alpha) + t[\beta\tilde{Y}\tilde{Y}^\top \tilde{F} + O(\beta^2\alpha) + O(\beta^3\alpha^2)] + O(t^2)$ 。因此，如果 $\beta > 1$ 很大且初始化 $\alpha \ll 1$ ，那么信号项 $t\beta\tilde{Y}\tilde{Y}^\top \tilde{F}$ 会比 $\beta = 1$ 的情况更占主导地位，顿悟发生得更快。然而，如果 β 相对于 α 过大，那么 $O(\beta^2\alpha)$ 项可能会对特征学习造成干扰，并且最终的 $G_F(+\infty)$ 会变小（公式 59）。等价地，如果我们对目标标签进行降尺度处理，同样的理论也适用 (Kumar et al., 2024)。

权重衰减 η 。根据公式 ??，由于 $G_F(+\infty) \propto \eta\tilde{Y}\tilde{Y}^\top F$ ，显然权重衰减 η 成为了特征学习过程的学习率。这与实证研究 (Power et al., 2022; Clauw et al., 2024) 的发现一致，即低正则化会导致缓慢的顿悟转变。这也与开始顿悟 (Liu et al., 2023) 或达到最大测试性能所需时间 $t \sim 1/\eta$ 的规律相符 (Lewkowycz & Gur-Ari, 2020)。

数据量 n 。我们的样本分析（定理 ??）表明，只要有足够数量的样本 ($n \gtrsim M \log M$)，局部极大值就可以被保留。直观上，更多的样本会带来噪声更少、形状更好的局部极大值，从而

使特征学习更快，这与 (Power et al., 2022; Nanda et al., 2023; Wang et al., 2024a; Gromov, 2023; Abramov et al., 2025) 的结论一致。

隐藏节点数量 K 。我们的分析要求需要足够数量的隐藏节点 K 来覆盖 $\mathcal{E}$ 的多样化局部极大值集合。另一方面，引理 ?? 表明，非常大的 K 可能会降低 $|G_F(+\infty)|$ 并使顿悟变慢。这与 (Chizat et al., 2019) 的发现以及 NTK 机制 (Du et al., 2018; Jacot et al., 2018) 一致，即特征学习不会发生。

早停。模型在泛化后可能会过拟合 Montanari & Urbani (2025)。我们的框架表明，如果数据稀缺，泛化的能量低于记忆解。如果训练时间足够长，权重将移向具有更大 $\mathcal{E}$ 的解。

3 讨论

顿悟与正则化之间的关系。 Li_2 框架的一个关键见解是，非零的反向传播梯度 G_F 启动了特征学习过程，为优化决定学习哪些特征以及如何学习的能量函数 $\mathcal{E}$ 奠定了基础。直观地说，只要惰性学习阶段产生一个与目标标签 Y 相关的足够大的非零 G_F ，就会触发特征学习。

存在多种方法来确保这个非零梯度。正则化机制，例如权重衰减，有助于保证非零 G_F 的存在，并且方便地允许我们以数学上严谨的方式展示特征学习过程。然而，我们想强调，正则化并不是唯一的选择。例如， G_F 可能在惰性学习期间变大，随后由于完美的过拟合而消失（参见公式 ??）。值得注意的是，(Prieto et al., 2024) 用稳定的 softmax（线性项）替换了标准的 softmax（指数项），从 Li_2 框架的角度来看，这减缓了对标签的过拟合。这维持了非零的反向传播梯度，从而保留了后续特征学习的潜力。

总之，我们的框架表明，权重衰减可以是特征学习（以及顿悟）的一个充分条件，但不是必要条件。

两种不同的记忆化。从分析中可以清楚地看出，顿悟中的记忆化源于对随机特征的过拟合，这与由于数据有限/有噪声而遵循特征学习动态达到记忆化解是不同的（定理 ??）。从这个角度来看，顿悟并非从记忆化切换到泛化，而是从过拟合切换到泛化。

平坦与尖锐的极值点。普遍认知通常将平坦的极值点视为可泛化的解，而尖锐的极值点视为记忆化/过拟合。从 Li_2 的角度来看，尖锐的极值点发生在模型对随机特征过拟合时（第 ??节），因此权重的微小变化会极大地改变损失。另一方面，我们可以证明来自 $\mathcal{E}$ 的局部极值点是平坦的（推论 ??），因此权重在特定方向上的微小变化不会改变 $\mathcal{E}$ 。如果模型是过参数化的，那么多个节点可能学习相同（或相似）的特征集，这为损失函数变得平坦创造了自由度。如果我们由于数据有限/有噪声而学习记忆化特征（定理 ??），那么需要更多的节点参与以“解释”目标，并且整体权重看起来会不那么平坦。

小学习率与大学习率。根据我们的分析，在第一阶段，我们需要大的学习率来快速学习岭解 V ，以便反向传播梯度 G_F 变得有意义，从而触发第二阶段。在第二阶段，最佳学习率取决于可用数据的数量。如果有大量数据，我们可以承受更大的学习率来快速找到特征。如果数据有限，我们可能需要更小的学习率以保持在可泛化特征的盆地内（图 ??），这可能与普遍认知相矛盾。

4 相关工作

关于顿悟现象的解释。目前存在多种对顿悟现象的解释，例如泛化与记忆电路的竞争 (Merrill et al., 2023)、从惰性态到丰富态的转变 Kumar et al. (2024) 等。顿悟的动态过程已在特定

情境下得到分析，例如针对聚类数据 (Xu et al., 2023)、线性网络 (Dominé et al., 2024) 等。相比之下，我们的工作研究了在群算术任务中，由反向传播驱动的深度非线性网络特征涌现的完整动态过程，并提供了一个关于特征涌现内容与方式的系统性数学框架，以及关于记忆与泛化之间转变发生时刻的标度律。

群结构的运用。近期研究利用群论来探究最终顿悟解的结构 (Tian, 2025; Morwani et al., 2023; Shutman et al., 2025)。它们均未像我们的工作这样，在数据存在底层结构的情况下探讨顿悟的动态过程。

记忆与泛化的标度律。先前的研究已经识别出记忆/泛化的标度律 (Nguyen & Reddy, 2025; Wang et al., 2024a; Abramov et al., 2025; Doshi et al., 2023)，但缺乏系统的理论解释。我们的工作将这种转变建模为可泛化的局部最优解在数据采样下是否保持稳定的问题，并从第一性原理出发提供了理论框架。

特征学习。先前的研究将神经正切核 (NTK) 视为一个整体对象，并研究其如何偏离惰性态，例如，它变得与任务相关方向更相关 (Kumar et al., 2024; Ba et al., 2022; Damian et al., 2022)，或适应数据分布 (Rubin et al., 2025; Karp et al., 2021) 等。与之相反，我们的工作聚焦于单个特征的显式学习动态、它们之间的相互作用，以及随着样本增加从记忆到泛化的转变过程。

5 结论、局限性与未来工作

我们为两层网络中的顿悟动力学开发了一个原则性的数学框架 Li_2 。 Li_2 识别了三个阶段：惰性学习、独立特征学习和交互式特征学习，每个阶段都以反向传播梯度 G_F 的独特结构为标志。权重衰减使得隐藏节点能够通过一个定义良好的能量函数 $\mathcal{E}$ 独立提取与标签相关的特征，然后交叉相互作用将这些特征巩固起来。该分析阐明了权重衰减、学习率和样本大小等超参数如何塑造顿悟现象，并为理解现代优化器（例如 Muon）为何有效提供了第一性原理的见解。我们还将我们的框架扩展到了更深层的网络。

局限性。虽然能量 $\mathcal{E}$ 的推导适用于任何输入，但对其局部最大值的分析依赖于输入具有群结构的限制性假设。此外，我们的分析没有包含连续学习阶段之间的过渡时间。我们将这些问题留待未来工作。

关于使用大语言模型的声明

我们广泛使用了最先进的大语言模型来集思广益，以证明本文中提出的数学陈述。具体来说，我们设定研究方向，提供问题设置和直觉，提出陈述供大语言模型分析和证明，指出生成证明中的关键问题，相应地调整陈述并进行迭代。我们还进行了大量实验来验证最终的陈述。大语言模型提出的许多证明存在细微的错误，需要大量的编辑和修正。我们已仔细修订了本工作中呈现的所有证明，并对其正确性承担全部责任。

伦理声明

这项工作旨在研究神经网络的各种理论和经验特性。我们不依赖任何敏感或专有数据，也不使用任何可能产生有害内容的现有开源模型。

可复现性声明

本工作中使用的所有数据集均可通过合成方式生成。模型是从头开始预训练的，计算量非常小。我们将发布代码以支持完全复现。

参考文献

- Roman Abramov, Felix Steinbauer, and Gjergji Kasneci. Grokking in the wild: Data augmentation for real-world multi-hop reasoning with transformers. arXiv preprint arXiv:2504.20752, 2025.
- Jimmy Ba, Murat A Erdogdu, Taiji Suzuki, Zhichao Wang, Denny Wu, and Greg Yang. High-dimensional asymptotics of feature learning: How one gradient step improves the representation. *Advances in Neural Information Processing Systems*, 35:37932–37946, 2022.
- Suresh Balakrishnama and Aravind Ganapathiraju. Linear discriminant analysis-a brief tutorial. *Institute for Signal and information Processing*, 18(1998):1–8, 1998.
- Boaz Barak, Benjamin Edelman, Surbhi Goel, Sham Kakade, Eran Malach, and Cyril Zhang. Hidden progress in deep learning: Sgd learns parities near the computational limit. *Advances in Neural Information Processing Systems*, 35:21750–21764, 2022.
- Lenaic Chizat, Edouard Oyallon, and Francis Bach. 关于可微分编程中的惰性训练. *Advances in neural information processing systems*, 32, 2019.
- Tianzhe Chu, Yuexiang Zhai, Jihan Yang, Shengbang Tong, Saining Xie, Dale Schuurmans, Quoc V Le, Sergey Levine, and Yi Ma. SFT 记忆，RL 泛化：基础模型后训练的对比研究. arXiv preprint arXiv:2501.17161, 2025.
- Kenzo Clauw, Sebastiano Stramaglia, and Daniele Marinazzo. 信息论进展度量揭示顿悟是一种涌现的相变. arXiv preprint arXiv:2408.08944, 2024.
- Alexandru Damian, Jason Lee, and Mahdi Soltanolkotabi. 神经网络可以通过梯度下降学习表示. In *Conference on Learning Theory*, pp. 5413–5452. PMLR, 2022.

- Clémentine CJ Dominé, Nicolas Anguita, Alexandra M Proca, Lukas Braun, Daniel Kunin, Pedro AM Mediano, and Andrew M Saxe. 从惰性到丰富：深度线性网络中的精确学习动力学。arXiv preprint arXiv:2409.14623, 2024.
- Darshil Doshi, Aritra Das, Tianyu He, and Andrey Gromov. 顿悟与否：在损坏的算法数据集上解耦泛化与记忆。arXiv preprint arXiv:2310.13061, 2023.
- Darshil Doshi, Tianyu He, Aritra Das, and Andrey Gromov. 顿悟模多项式。arXiv preprint arXiv:2406.03495, 2024.
- Simon S Du, Xiyu Zhai, Barnabas Poczos, and Aarti Singh. 梯度下降可证明优化过参数化神经网络。arXiv preprint arXiv:1810.02054, 2018.
- Philippe Flajolet, Daniele Gardy, and Loÿs Thimonier. 生日悖论、优惠券收集、缓存算法与自组织搜索。Discrete Applied Mathematics, 39(3):207–229, 1992.
- William Fulton and Joe Harris. Representation theory: a first course, volume 129. Springer Science & Business Media, 2013.
- Andrey Gromov. 顿悟模运算。arXiv preprint arXiv:2301.02679, 2023.
- Yufei Huang, Shengding Hu, Xu Han, Zhiyuan Liu, and Maosong Sun. 顿悟、双下降与涌现能力的统一视角：基于电路竞争的视角。arXiv preprint arXiv:2402.15175, 2024.
- Arthur Jacot, Franck Gabriel, and Clément Hongler. 神经正切核：神经网络中的收敛与泛化。Advances in neural information processing systems, 31, 2018.
- Keller Jordan, Yuchen Jin, Vlado Boza, Jiacheng You, Franz Cesista, Laker Newhouse, and Jeremy Bernstein. Muon：神经网络隐藏层的优化器。2024. URL <https://kellerjordan.github.io/posts/muon/>.
- Stefani Karp, Ezra Winston, Yuanzhi Li, and Aarti Singh. 局部信号自适应性：超越核方法的神经网络可证明特征学习。Advances in Neural Information Processing Systems, 34: 24883–24897, 2021.
- Tanishq Kumar, Blake Bordelon, Samuel J. Gershman, and Cengiz Pehlevan. 顿悟作为从惰性到丰富训练动态的转变，2024. URL <https://arxiv.org/abs/2310.06110>.
- Aitor Lewkowycz and Guy Gur-Ari. 关于带有 l_2 正则化的深度网络的训练动态。Advances in Neural Information Processing Systems, 33:4790–4799, 2020.
- Ziming Liu, Ouail Kitouni, Niklas S Nolte, Eric Michaud, Max Tegmark, and Mike Williams. 理解顿悟：表示学习的有效理论。Advances in Neural Information Processing Systems, 35:34651–34663, 2022.
- Ziming Liu, Eric J Michaud, and Max Tegmark. Omnigrok：超越算法数据的顿悟。In The Eleventh International Conference on Learning Representations, 2023. URL <https://openreview.net/forum?id=zDiHoIWa0q1>.
- William Merrill, Nikolaos Tsilivis, and Aman Shukla. 两个电路的故事：顿悟作为稀疏与稠密子网络的竞争。arXiv preprint arXiv:2303.11873, 2023.

- Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg S Corrado, and Jeffrey Dean. 词与短语的分布式表示及其组合性。Advances in neural information processing systems, 26, 2013.
- Beren Millidge. 理解“顿悟”, 2022. URL <https://www.beren.io/2022-01-11-Grokking-Grokking/>.
- Iman Mirzadeh, Keivan Alizadeh, Hooman Shahrokhi, Oncel Tuzel, Samy Bengio, and Mehrdad Farajtabar. Gsm-symbolic: 理解大语言模型数学推理的局限性. arXiv preprint arXiv:2410.05229, 2024.
- Mohamad Amin Mohamadi, Zhiyuan Li, Lei Wu, and Danica J Sutherland. 你为何顿悟? 模加运算顿悟现象的理论分析. arXiv preprint arXiv:2407.12332, 2024.
- Andrea Montanari and Pierfrancesco Urbani. 大型两层网络中泛化与过拟合的动态解耦, 2025. URL <https://arxiv.org/abs/2502.21269>.
- Depen Morwani, Benjamin L Edelman, Costin-Andrei Oncescu, Rosie Zhao, and Sham Kakade. 通过边际最大化实现特征涌现: 代数任务案例研究. arXiv preprint arXiv:2311.07568, 2023.
- Neel Nanda, Lawrence Chan, Tom Lieberum, Jess Smith, and Jacob Steinhardt. 通过机制可解释性度量顿悟进展. In The Eleventh International Conference on Learning Representations, 2023. URL <https://openreview.net/forum?id=9XFSbDPmdW>.
- Alex Nguyen and Gautam Reddy. 差分学习动力学支配着上下文学习中从记忆到泛化的转变. In The Thirteenth International Conference on Learning Representations, 2025. URL <https://openreview.net/forum?id=INyi7qUdjZ>.
- Alethea Power, Yuri Burda, Harri Edwards, Igor Babuschkin, and Vedant Misra. 顿悟: 在小规模算法数据集上超越过拟合的泛化. arXiv preprint arXiv:2201.02177, 2022.
- Lucas Prieto, Melih Barsbey, Pedro AM Mediano, and Tolga Birdal. 数值稳定性边缘的顿悟. arXiv preprint arXiv:2403.03507, 2024.
- Lucas Prieto, Melih Barsbey, Pedro AM Mediano, and Tolga Birdal. 数值稳定性边缘的顿悟. arXiv preprint arXiv:2501.04697, 2025.
- Noa Rubin, Inbar Seroussi, and Zohar Ringel. 顿悟作为双层网络中的一阶相变. ICLR, 2024.
- Noa Rubin, Kirsten Fischer, Javed Lindner, David Dahmen, Inbar Seroussi, Zohar Ringel, Michael Krämer, and Moritz Helias. 从核到特征: 一种多尺度自适应的特征学习理论. arXiv preprint arXiv:2502.03210, 2025.
- Wei Shen, Ruichuan Huang, Minhui Huang, Cong Shen, and Jiawei Zhang. 关于 Muon 的收敛性分析. arXiv preprint arXiv:2505.23737, 2025.
- Maor Shutman, Oren Louidor, and Ran Tessler. 分组学习词汇: 融合代数、张量秩与顿悟. arXiv preprint arXiv:2509.06931, 2025.
- Benjamin Steinberg. 有限群的表示理论. Carleton University, 2009.

Vimal Thilak, Etai Littwin, Shuangfei Zhai, Omid Saremi, Roni Paiss, and Joshua Susskind. 弹弓机制：自适应优化器与顿悟现象的实证研究。arXiv preprint arXiv:2206.04817, 2022.

Yuandong Tian. 理解对比学习训练动态中非线性的作用。In The Eleventh International Conference on Learning Representations, 2023. URL https://openreview.net/forum?id=s130rTE3U_X.

田远东. 通过神经网络中的代数对象组合推理任务的全局解。NeurIPS, 2025.

田远东、于澜涛、陈新雷、Surya Ganguli. 通过双深度网络理解自监督学习。arXiv 预印本 arXiv:2010.00578, 2020.

Joel A Tropp. 随机矩阵和用户友好的尾部边界。计算数学基础, 12(4):389–434, 2012.

Amund Tveit, Bjørn Remseth, Arve Skogvold. Muon 优化器加速顿悟现象。arXiv 预印本 arXiv:2504.16041, 2025.

Vikrant Varma, Rohin Shah, Zachary Kenton, János Kramár, Ramana Kumar. 通过电路效率解释顿悟现象。arXiv 预印本 arXiv:2309.02390, 2023.

王博识、岳翔、苏宇、孙欢. 已顿悟的 Transformer 是隐式推理器：通往泛化边缘的机制之旅。arXiv 预印本 arXiv:2405.15071, 2024a.

王欣怡、Antonis Antoniadis, Yanai Elazar, Alfonso Amayuelas, Alon Albalak, 张可迅、William Yang Wang. 泛化 vs 记忆：追溯语言模型能力至预训练数据。arXiv 预印本 arXiv:2407.14985, 2024b.

徐志伟、王宇彤、Spencer Frei, Gal Vardi, 胡威. ReLU 网络在 XOR 簇数据中的良性过拟合与顿悟现象。arXiv 预印本 arXiv:2310.02541, 2023.

赵佳伟、张振宇、陈贝迪、王张洋、Anima Anandkumar、田远东. Galore：通过梯度低秩投影实现内存高效的大语言模型训练。ICML, 2024.

A 独立特征学习（第 ?? 节）

Lemma 1. 令 $\phi_n(z) := \text{He}_n(z)/\sqrt{n!}$ 为 $L^2(\gamma)$ 上的标准正交 Hermite 函数系。若 (Z_1, Z_2) 是相关系数为 ρ 的标准正态变量，则

$$\mathbb{E}[\phi_n(Z_1) \phi_m(Z_2)] = \rho^n \delta_{nm} \quad (n, m \geq 0).$$

引理 1 的证明. 利用生成函数² $\exp(tz - \frac{t^2}{2}) = \sum_{k \geq 0} \phi_k(z) t^k$ ，其中 $z \sim \mathcal{N}(0, 1)$ 。那么，对于相关系数为 ρ 的联合正态变量 (Z_1, Z_2) ，

$$\mathbb{E}\left[e^{tZ_1 - \frac{t^2}{2}} e^{uZ_2 - \frac{u^2}{2}}\right] = \exp(\rho tu) = \sum_{k \geq 0} \rho^k (tu)^k.$$

将左侧用生成函数展开并匹配 $t^n u^m$ 的系数，即得 $\mathbb{E}[\phi_n(Z_1) \phi_m(Z_2)] = \rho^n \delta_{nm}$ 。

为了说明为何 $\mathbb{E}\left[e^{tZ_1 - \frac{t^2}{2}} e^{uZ_2 - \frac{u^2}{2}}\right] = \exp(\rho tu)$ 成立，将 (Z_1, Z_2) 分解为独立的高斯随机变量 (X, Y) ：

$$Z_1 := X, \quad Z_2 := \rho X + \sqrt{1 - \rho^2} Y,$$

于是我们有

$$\begin{aligned} \mathbb{E}\left[e^{tZ_1 - \frac{t^2}{2}} e^{uZ_2 - \frac{u^2}{2}}\right] &= \mathbb{E}\left[e^{tX - \frac{t^2}{2}} e^{u(\rho X + \sqrt{1 - \rho^2} Y) - \frac{u^2}{2}}\right] \\ &= \mathbb{E}\left[e^{(t + \rho u)X - \frac{t^2}{2}}\right] \mathbb{E}\left[e^{u\sqrt{1 - \rho^2} Y - \frac{u^2}{2}}\right]. \end{aligned}$$

对于 $G \sim \mathcal{N}(0, 1)$ ，我们有 $\mathbb{E}[e^{aG}] = e^{a^2/2}$ ，因此由引理 2 可得 $\mathbb{E}\left[e^{aG - \frac{a^2}{2}}\right] = 1$ 。应用此结果两次，

$$\begin{aligned} \mathbb{E}\left[e^{(t + \rho u)X - \frac{t^2}{2}}\right] &= \exp\left(\frac{(t + \rho u)^2}{2} - \frac{t^2}{2}\right) = \exp\left(\rho tu + \frac{\rho^2 u^2}{2}\right), \\ \mathbb{E}\left[e^{u\sqrt{1 - \rho^2} Y - \frac{u^2}{2}}\right] &= \exp\left(\frac{u^2(1 - \rho^2)}{2} - \frac{u^2}{2}\right) = \exp\left(-\frac{\rho^2 u^2}{2}\right). \end{aligned}$$

将两个因子相乘得到

$$\exp\left(\rho tu + \frac{\rho^2 u^2}{2}\right) \exp\left(-\frac{\rho^2 u^2}{2}\right) = \exp(\rho tu),$$

如所声称。 □

Lemma 2 (矩恒等式). 对于 $X \sim \mathcal{N}(0, 1)$ ，有 $\mathbb{E}[e^{tX}] = \exp(t^2/2)$ 。等价地， $\mathbb{E}[e^{tX - t^2/2}] = 1$ 。

证明. 配平方：

$$\mathbb{E}[e^{tX}] = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{tx} e^{-x^2/2} dx = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{-(x-t)^2/2} e^{t^2/2} dx = \exp\left(\frac{t^2}{2}\right).$$

□

*

²https://en.wikipedia.org/wiki/Hermite_polynomials

证明. 接下来, 我们将证明 (1) $\tilde{F}^\top \tilde{F}$ 是单位矩阵的倍数, 以及 (2) $FF^\top \propto \alpha I + \beta 11^\top$. 不失一般性, 我们假设 W 的条目服从标准正态分布 $\mathcal{N}(0, 1)$.

$\tilde{F}^\top \tilde{F}$ 是单位矩阵的倍数。由于 $\tilde{F}$ 的每一列都是 $P_1^\perp \sigma(Xw_j)$, 这是一个零均值的 n 维随机向量, 且由于 W 的列相互独立, 这些列是独立同分布的。当宽度 K 很大时, $\tilde{F}^\top \tilde{F}$ 成为单位矩阵的倍数。 $FF^\top$ 是一个对角矩阵加上一个全常数矩阵。注意 F 的第 i 行是 $[\sigma(w_1^\top x_i), \sigma(w_2^\top x_i), \dots, \sigma(w_K^\top x_i)]$, 当宽度 K 很大时, F 的第 i 行与第 j 行的内积近似于 $K\mathcal{K}(i, j)$, 其中 $\mathcal{K}(i, j)$ 定义如下:

$$\mathcal{K}(i, j) = \mathbb{E}_w[\sigma(w^\top x_i)\sigma(w^\top x_j)] \quad (1)$$

为了估计元素 $\mathcal{K}(i, j)$, 我们首先进行标准化, 设 $Z_1 := w^\top x_i / s_i$ 和 $Z_2 := w^\top x_j / s_j$, 其中 $s_i = \|x_i\|_2$ 且 $s_j = \|x_j\|_2$ 。那么 (Z_1, Z_2) 是标准正态变量, 且 $\text{Corr}(Z_1, Z_2) = \rho_{ij}$, 并且 $\mathcal{K}(i, j) = \mathbb{E}[\sigma(s_i Z_1)\sigma(s_j Z_2)]$ 。

令 $\phi_l(z) := \text{He}_l(z)/\sqrt{l!}$ 为 $L^2(\gamma)$ 上的标准正交 Hermite 系统, 其中 γ 是标准高斯测度, 且 He_l 是 Hermite 多项式。对于 $s \geq 0$, 定义 $f_s(z) := \sigma(sz)$ 。根据 $L^2(\gamma)$ 假设, $f_s = \sum_{n=0}^{\infty} a_l(s) \phi_l$, 其中

$$a_l(s) = \langle f_s, \phi_l \rangle_{L^2(\gamma)} = \frac{1}{\sqrt{l!}} \mathbb{E}[\sigma(sZ) \text{He}_l(Z)]$$

因此

$$\sigma(s_i Z_1) = \sum_{l \geq 0} a_l(s_i) \phi_l(Z_1), \quad \sigma(s_j Z_2) = \sum_{l \geq 0} a_l(s_j) \phi_l(Z_2)$$

由双线性和引理 1,

$$\begin{aligned} \mathcal{K}(i, j) &= \mathbb{E} \left[\sum_{l \geq 0} a_l(s_i) \phi_l(Z_1) \sum_{m \geq 0} a_m(s_j) \phi_m(Z_2) \right] = \sum_{l, m \geq 0} a_l(s_i) a_m(s_j) \mathbb{E}[\phi_l(Z_1) \phi_m(Z_2)] \\ &= \sum_{l \geq 0} a_l(s_i) a_l(s_j) \rho_{ij}^l \end{aligned}$$

如果 $s_i \equiv s$ 且对于 $i \neq j$ 有 $\|\rho_{ij} - \rho\|_2 \leq \epsilon$, 那么

$$\mathcal{K}(i, i) = \sum_{l \geq 0} a_l^2(s) =: a$$

令 $c := \sum_{l \geq 1} l a_l^2(s) < +\infty$ (由于分母中的大因子 $l!$, 它是收敛的)。令 $b := \sum_{l \geq 0} a_l^2(s) \rho^l$, 则对于所有 $i \neq j$:

$$\|\mathcal{K}(i, j) - b\|_2 \leq \sum_{l \geq 0} a_l^2(s) \|\rho_{ij}^l - \rho^l\|_2 \leq \sum_{l \geq 1} l a_l^2(s) \epsilon = c\epsilon$$

这是因为对于所有 $l \geq 1$ 和某个介于 ρ_{ij} 与 ρ 之间的 ξ , 有 $\|\rho_{ij}^l - \rho^l\|_2 \leq l \xi^{l-1} \epsilon$ 。因此 $\mathcal{K}(i, j) = (a - b)\delta_{ij} + b + O(\epsilon)$, 从而 $FF^\top = K(a - b)I + Kb11^\top + O(K\epsilon)11^\top$ 。注意, 根据 Parseval 恒等式, $a = \mathbb{E}_{Z \sim \mathcal{N}(0, 1)}[\sigma^2(sZ)]$ 。

因此, $\tilde{F}\tilde{F}^\top = K(a - b + O(\epsilon))P_1^\perp = K(a - b + O(\epsilon))(I - 11^\top/n) + O(K\epsilon)11^\top$ 且 $P_\eta \tilde{Y} = \frac{\eta}{K(a-b)+\eta} \tilde{Y}$ 。由于 $\tilde{F}^\top \tilde{F}$ 与单位矩阵成比例, $(\tilde{F}^\top \tilde{F} + \eta I)^{-1}$ 也与单位矩阵成比例, 结论随之成立。□

A.1 能量函数 $\mathcal{E}$ (第 ?? 节)

*

证明. 对 $\mathcal{E}$ 关于 w_j 取梯度, 我们有 $\cdot w_j = X^\top D_j \tilde{Y} \tilde{Y}^\top \sigma(X w_j)$, 这便证明了该定理。 $\square$

*

证明. 在此设定下, 若按目标值排序, 我们可以写出数据矩阵 $X = [X_{h_1}; X_{h_2}; \dots X_{h_M}]$ (即每个 X_h 占据 X 的 M 行), 其中每个 $X_h = [R_h^\top, P] \in \mathbb{R}^{M \times 2M}$ 。这里 R_h 是群元素 h 的正则表示 (置换表示的一种特殊情况), 使得对所有 $h_1, h_2 \in H$ 有 $e_{h_1 h_2} = R_{h_1} e_{h_2}$, 而 P 是群逆算子, 使得 $P e_h = e_{h^{-1}}$ 。这是因为 X 中对应目标 h 的每一行可以写成 $[e_{h h_1}^\top, e_{h_1^{-1}}^\top] = [e_{h_1}^\top R_h^\top, e_{h_1}^\top P]$ 。将所有导致目标 h 的行堆叠起来, 并按 h_1 排序, 我们便得到 $X_h = [R_h^\top, P]$ 。

令 $w = [u; P v]$ 。令矩阵 $S_{ij} := \sigma(u_i + v_j)$, 由于 R_h 是置换矩阵, 则 $\sigma(X_h w) = \sigma(R_h^\top u + v)$ 是 S 的行重排。因此, $\sigma(X_h w) = \text{diag}(R_h^\top S) \mathbf{1}_M$, 其中 $\text{diag}(\cdot)$ 表示矩阵的对角线。注意, 在此目标标签排序下, 我们有 $Y = I_M \otimes \mathbf{1}_M$ 。所以对于 Y 的每一列 h , 我们有 $y_h = e_h \otimes \mathbf{1}_M$ 。所以

$$z_h := y_h^\top \sigma(X w) = \mathbf{1}_M^\top \sigma(X_h w) = \mathbf{1}_M^\top \text{diag}(R_h^\top S) \mathbf{1}_M = \text{tr}(R_h^\top S) = \langle R_h, S \rangle_F \quad (2)$$

其中 $\langle A, B \rangle_F := \text{tr}(A^\top B)$ 是 Frobenius 内积。能量 $\mathcal{E}$ 可以写为:

$$\mathcal{E}(w) = \frac{1}{2} \sum_h (z_h - \bar{z})^2 \quad (3)$$

其中 $\bar{z} := \frac{1}{M} \sum_h z_h = \frac{1}{M} \sum_h \langle R_h, S \rangle_F = \langle \frac{1}{M} \sum_h R_h, S \rangle_F = \frac{1}{M} \langle \mathbf{1}_M \mathbf{1}_M^\top, S \rangle_F$ 。因此, 利用 $R_h \mathbf{1}_M = \mathbf{1}_M$, $\mathcal{E}(w)$ 可以写为:

$$\mathcal{E}(w) = \frac{1}{2} \sum_h \langle \tilde{R}_h, S \rangle_F^2 \quad (4)$$

其中 $\tilde{R}_h = R_h P_1^\perp$ 。现在我们研究其性质。我们将 $\{\tilde{R}_h\}$ 分解为复不可约表示:

$$\tilde{R}_h = Q \left(\bigoplus_{k \neq 0} \bigoplus_{r=1}^{m_k} C_k(h) \right) Q^* \quad (5)$$

其中 $C_k(h)$ 是 R_h 的第 k 个不可约表示块, Q 是酉矩阵 (且 Q^* 是 Q 的共轭转置), m_k 是第 k 个不可约表示的重数。由于 $\tilde{R}_h$ 是零均值表示, 我们移除了平凡表示 $C_0(h)$, 因此 $Q^* \mathbf{1} = 0$ 。令 $\hat{S} = Q^\top S Q$ 。则

$$\langle \tilde{R}_h, S \rangle_F = \langle Q \left(\bigoplus_{k \neq 0} \bigoplus_{r=1}^{m_k} C_k(h) \right) Q^*, S \rangle_F = \langle \bigoplus_{k \neq 0} \bigoplus_{r=1}^{m_k} C_k(h), \hat{S} \rangle_F = \sum_{k \neq 0} \sum_{r=1}^{m_k} \text{tr}(C_k^*(h) \hat{S}_{k,r}) \quad (6)$$

其中 $\hat{S}_{k,r}$ 是 $\hat{S}$ 的第 (k, r) 个主 (对角) 块。因此, 我们有:

$$\sum_h \langle \tilde{R}_h, S \rangle_F^2 = \sum_h \sum_{(k,r), (k',r')} \text{tr}(C_k^*(h) \hat{S}_{k,r}) \text{tr}(C_{k'}^*(h) \hat{S}_{k',r'}) \quad (7)$$

$$= \sum_{(k,r), (k',r')} \text{vec}^*(\hat{S}_{k,r}) \left[\sum_h \text{vec}(C_k(h)) \text{vec}(C_{k'}^*(h)) \right] \text{vec}(\hat{S}_{k',r'}) \quad (8)$$

情形 1. 如果 $k \neq k'$ 是维度分别为 d_k 和 $d_{k'}$ 的不等价不可约表示, 那么我们可以证明 $\sum_h \text{vec}(C_k(h)) \text{vec}(C_{k'}^*(h)) = 0$ 。为了说明这一点, 令 $A_{k,k'}(Z) = \sum_h C_k(h) Z C_{k'}^{-1}(h)$, 则 $A_{k,k'}(Z)$ 是一个从 d_k 维空间到 $d_{k'}$ 维空间的 H -不变线性映射。因此, 根据舒尔引理, 对于任意 Z , 有 $A_{k,k'}(Z) = 0$ 。但由于 $\text{vec}(A_{k,k'}(Z)) = (\sum_h \bar{C}_{k'}(h) \otimes C_k(h)) \text{vec}(Z)$, 我们得到 $\sum_h \bar{C}_{k'}(h) \otimes C_k(h) = 0$ 。展开每个分量, 我们有 $\sum_h \text{vec}(C_k(h)) \text{vec}(C_{k'}^*(h)) = 0$ 。

情形 2. 如果 $k = k'$ 是等价的不可约表示 (且两者维度均为 d_k)，那么我们可以证明 $\sum_h \text{vec}(C_k(h)) \text{vec}(C_k^*(h)) = \frac{M}{d_k} \text{vec}(I_{d_k}) \text{vec}^*(I_{d_k})$ 。然后利用舒尔平均引理，我们有 $A_{kk}(Z) = \frac{M}{d_k} \text{tr}(Z) I_{d_k}$ 。向量化后得到 $(\sum_h \bar{C}_k(h) \otimes C_k(h)) \text{vec}(Z) = \frac{M}{d_k} \text{tr}(Z) \text{vec}(I_{d_k})$ 。注意到 $\text{vec}^*(I_{d_k}) \text{vec}(Z) = \text{tr}(Z)$ ，我们便得出结论。

因此，对于目标函数，我们有：

$$\mathcal{E}(\mathbf{w}) = \frac{1}{2} \sum_h \langle \tilde{R}_h, S \rangle_F^2 = \frac{M}{2} \sum_{k \neq 0} \frac{1}{d_k} \left| \sum_r \text{tr}(\hat{S}_{k,r}) \right|^2 \quad (9)$$

二次激活的特殊情形. 如果 $\sigma(x) = x^2$ ，那么我们有 $S = (\mathbf{u} \circ \mathbf{u}) \mathbf{1}^\top + \mathbf{1}(\mathbf{v} \circ \mathbf{v}) + \mathbf{u} \mathbf{v}^\top$ ，因此 $\hat{S} = \hat{\mathbf{u}} \hat{\mathbf{v}}^*$ ，其中 $\hat{\mathbf{u}} = Q^* \mathbf{u}$ 且 $\hat{\mathbf{v}} = Q^* \mathbf{v}$ 。所以，由于 $Q^* \mathbf{1} = 0$ ，有 $\hat{S}_{k,r} = \hat{\mathbf{u}}_{k,r} \hat{\mathbf{v}}_{k,r}^*$ 且 $\text{tr}(\hat{S}_{k,r}) = \hat{\mathbf{u}}_{k,r}^* \hat{\mathbf{v}}_{k,r}$ 。因此，利用柯西-施瓦茨不等式，我们有

$$\mathcal{E} = \frac{1}{2} \sum_h \langle \tilde{R}_h, S \rangle_F^2 = \frac{M}{2} \sum_{k \neq 0} \frac{1}{d_k} \left| \sum_r \hat{\mathbf{u}}_{k,r}^* \hat{\mathbf{v}}_{k,r} \right|^2 \leq \frac{M}{2} \sum_{k \neq 0} \frac{1}{d_k} \left(\sum_r |\hat{\mathbf{u}}_{k,r}|^2 \right) \left(\sum_r |\hat{\mathbf{v}}_{k,r}|^2 \right) \quad (10)$$

令 $a_k = \sum_r |\hat{\mathbf{u}}_{k,r}|^2$ ， $b_k = \sum_r |\hat{\mathbf{v}}_{k,r}|^2$ ，以及 $c_k = a_k + b_k \geq 0$ 。那么我们有：

$$\mathcal{E} = \frac{1}{2} \sum_h \langle \tilde{R}_h, S \rangle_F^2 \leq \frac{M}{2} \sum_{k \neq 0} \frac{a_k b_k}{d_k} \leq \frac{M}{8} \sum_{k \neq 0} \frac{c_k^2}{d_k}, \quad \text{subject to } \sum_{k \neq 0} c_k = 1 \quad (11)$$

它有一个全局最大值 (即对于 $k_0 = \arg \min_k d_k$ ，有 $c_{k_0} = 1$) 和多个局部最大值。当且仅当对所有 r 有 $\hat{\mathbf{u}}_{k_0,r} = \pm \hat{\mathbf{v}}_{k_0,r}$ 且 $\sum_r |\hat{\mathbf{u}}_{k_0,r}|^2 = \sum_r |\hat{\mathbf{v}}_{k_0,r}|^2 = 1/2$ 时，达到最大值。**局部极大值。** 对于每个不可约表示 k_0 ， $c_{k_0} = 1$ 是一个局部极大值。这是因为对于微小的扰动 ϵ ，它将解从 $c_k = \mathbb{I}(k = k_0)$ 移动到 $c'_k = \begin{cases} 1 - \epsilon & \text{if } k = k_0 \\ \epsilon_k & \text{if } k \neq k_0 \end{cases}$ ，其中 $\epsilon_k \geq 0$ 且 $\sum_{k \neq k_0} \epsilon_k = \epsilon$ ，对于 $\mathcal{E} = \mathcal{E}(\{c_k\})$ 和 $\mathcal{E}' = \mathcal{E}(\{c'_k\})$ ，我们有：

$$\mathcal{E}' = \frac{M}{8} \sum_{k \neq 0} \frac{(c'_k)^2}{d_k} = \frac{M}{8} \left(\frac{(c_{k_0} - \epsilon)^2}{d_{k_0}} + \sum_{k \neq k_0, 0} \frac{c_k^2}{d_k} \right) \quad (12)$$

$$\leq \frac{M}{8} \left(\frac{c_{k_0}^2}{d_{k_0}} - \frac{2\epsilon}{d_{k_0}} \right) + O(\epsilon^2) < \frac{M}{8} \frac{c_{k_0}^2}{d_{k_0}} = \frac{M}{8} \sum_{k \neq 0} \frac{c_k^2}{d_k} = \mathcal{E} \quad (13)$$

所有局部极大值都是平坦的，因为我们总是可以在 $\hat{\mathbf{u}}_{k,r}$ 和 $\hat{\mathbf{v}}_{k,r}$ 内移动，而目标函数保持不变。□

在实数域中优化。 上述分析使用了复不可约表示。对于实向量 $\mathbf{w}$ ，对于共轭不可约表示 k 和 $-k$ ， $\hat{S}_{k,r}$ 将是 $\hat{S}_{-k,r}$ 的复共轭。这意味着我们可以将方程 9 中的和划分为实部和复部：

$$\mathcal{E}(\mathbf{w}) = \frac{M}{2} \sum_{k \neq 0, k \text{ real}} \frac{1}{d_k} \left| \sum_r \text{tr}(\hat{S}_{k,r}) \right|^2 + M \sum_{k \neq 0, k \text{ complex, take one}} \frac{1}{d_k} \left| \sum_r \text{tr}(\hat{S}_{k,r}) \right|^2 \quad (14)$$

上述方程成立是因为 R_g 是实的，并且对于任何复不可约表示 k ，其共轭表示 $-k$ 也被包含在内。因此，为了在实数域 $\mathbb{R}$ 中优化 $\mathcal{E}$ ，我们只需在实数部分加上复共轭对中取一个的复部分上，在复数域 $\mathbb{C}$ 中进行优化。

零均值独热表示。 注意，如果我们使用零均值独热表示 $\tilde{\mathbf{e}}_h = P_1^\perp \mathbf{e}_h$ ，那么 $R_{h_1} \tilde{\mathbf{e}}_{h_2} = \tilde{\mathbf{e}}_{h_1 h_2}$ 和 $P \tilde{\mathbf{e}}_h = \tilde{\mathbf{e}}_{h-1}$ 仍然成立，并且 $\tilde{X}_h = P_1^\perp X_h = P_1^\perp [R_h^\top, P] = [R_h^\top, P][P_1^\perp; P_1^\perp]$ 。这意味着我们仍然可以使用 X_h ，但对 $\mathbf{u}$ 和 $\mathbf{v}$ 施加零均值约束，这已经包含在内，因为 $Q^* \mathbf{1} = 0$ 。

*

证明. 对于阿贝尔群 H , 其中 $|H| = M > 2$, 所有不可约表示都是 1 维的, 并且至少有一个是复的。由于在优化中将 $\mathbb{C}$ 视为 2 维空间, 它至少有 1 个自由度可以在不改变其函数值的情况下变化 (方程 14)。所以海森矩阵至少有 1 个零特征值。对于非阿贝尔群, 至少有一个不可约表示 k 的维数大于 1, 这意味着它至少有 1 个自由度可以改变 $\hat{S}_{k,r}$, 而不改变 $|\sum_r \text{tr}(\hat{S}_{k,r})|^2$, 从而不改变其函数值 (方程 14)。所以海森矩阵至少有 1 个零特征值。 $\square$

A.2 学习特征的重构能力 (第 ?? 节)

*

证明. 对于每个非平凡不可约表示 k , 令 Π_k 为投影到等型子空间 $\mathcal{H}_k = I_{m_k} \otimes \mathbb{C}^{d_k}$ 上的中心幂等投影子 (对于正则表示, $m_k = d_k$)。令 $\text{End}(\mathcal{H}_k)$ 为所有将 $\mathcal{H}_k$ 映射到自身的线性算子的空间。注意 $\mathcal{H}_k$ 的维数为 $D_k := m_k d_k$ 。

令 $w_j = [u_j, P v_j]$ 为通过优化能量函数 $\mathcal{E}$ (使用二次激活 $\sigma(x) = x^2$) 学习到的权重。由定理 ??, 我们知道在局部最优处, $u_j = \pm v_j$ 且 $1^\top u_j = 0$ 。因此, 特征 $\tilde{f}_{j,h} \in \mathbb{R}^M$ 由下式给出 (表示哈达玛积)

$$\tilde{f}_{j,h} = \pm 2(R_h^\top u_j) \circ u_j + (R_h^\top u_j)^{\circ 2} - \frac{1}{M} \sum_h (R_h^\top u_j)^{\circ 2}$$

第三项 $u^{\circ 2}$ 在所有 h 上是常数, 并在零均值投影中被移除。根据我们的假设, 我们同时存在具有正号和负号的节点 j 和 j' 。因此 $\frac{1}{2}(\tilde{f}_{j,h} - \tilde{f}_{j',h}) = 2(R_h^\top u_j) \circ u_j$ 。如果 $\{\tilde{f}_j\}$ 的线性表示能够完美重构目标 $\tilde{Y}$, 那么原始表示也能做到。所以目前我们只令特征 $\tilde{f}_{j,h} = 2(R_h^\top u_j) \circ u_j = 2\text{diag}(R_h^\top u_j u_j^*)$ 。令 $U_j := u_j u_j^*$, 它是 $\text{End}(\mathcal{H}_k)$ 中的厄米特矩阵, 则 $\tilde{f}_{j,h} = 2\text{diag}(R_h^\top U_j)$ 。

格拉姆矩阵块对角化。 对于每个不可约表示 k , 令 J_k 为所有收敛到第 k 个不可约表示的节点 j 的集合。对于任何支撑在 $\mathcal{H}_k$ 上的厄米特算子 U (即 $U = \Pi_k U \Pi_k$), 定义中心化二次交叉特征

$$c_U(h) := 2\text{diag}(R_h^\top U) \in \mathbb{C}^M,$$

并将 $c_{U_j} = [c_{U_j}(h)]_{h \in H} \in \mathbb{C}^{M^2}$ 写作一个拼接向量。

对于 $U, V \in \text{End}(\mathcal{H}_k)$, 定义 $\mathcal{G}(U, V) := \sum_{h \in H} \langle c_U(h), c_V(h) \rangle$ 。在 $\mathcal{H}_k$ 上, $R_h = I_{m_k} \otimes C_k(h)$, 因此映射 $U \mapsto c_U(h)$ 是线性的, 并且双线性形式 $\mathcal{G}$ 在变换 $U \mapsto (I \otimes C_k(g))U(I \otimes C_k(g))^*$ 下保持不变。根据舒尔引理, $\mathcal{G}(U, V) = \alpha_k \langle U, V \rangle = \alpha_k \text{tr}(UV^*)$, 其中 α_k 为某个标量。在秩为一的 $U = V$ 上计算 (或通过直接计算) 得到 $\alpha_k = 4$, 因此

$$\sum_h \langle c_U(h), c_V(h) \rangle = 4 \text{tr}(UV^*).$$

对于来自 $\mathcal{H}_k$ 和 $\mathcal{H}_\ell$ (且 $k \neq \ell$) 的 $U_j = u_j u_j^*$ 和 $U_\ell = u_\ell u_\ell^*$, 我们有

$$\begin{aligned} \sum_h \langle c_{U_j}(h), c_{U_\ell}(h) \rangle &= 4 \mathbf{1}^\top \sum_h \text{diag}(R_h^\top u_j u_j^*) \circ \text{diag}(R_h^\top \bar{u}_\ell \bar{u}_\ell^*) \\ &= 4 \mathbf{1}^\top \sum_h (R_h^\top u_j) \circ \bar{u}_j \circ R_h^\top \bar{u}_\ell \circ u_\ell = 4 \mathbf{1}^\top \left[\left(\sum_h R_h \right) (u_j \circ \bar{u}_\ell) \right] \circ \bar{u}_j \circ u_\ell \\ &= 4 |u_j^* u_\ell|^2 \end{aligned}$$

这意味着 $\langle \tilde{f}_j, \tilde{f}_\ell \rangle = \langle c_{U_j}, c_{U_\ell} \rangle = 0$ 。因此格拉姆矩阵 $G := \tilde{F}^\top \tilde{F}$ 是块对角的, 每个块 G_k 对应一个不可约表示子空间 k 。这里 $G_k \in \mathbb{C}^{N_k \times N_k}$ 。注意, 由于我们采样了 $D_k^2 = m_k^2 d_k^2$ 个权重, 那么 $\{U_j\}_{j \in J_k}$ 成为一组完备基 (不一定是正交基), 因此 G_k 是可逆的。 $\square$

右侧。对于任意 $U \in \text{End}(\mathcal{H}_k)$,

$$r_U(h') = \sum_x c_U(h')_x = 2 \text{tr}((\Pi_k R_{h'} \Pi_k) U) = 2 \text{tr}((I_{m_k} \otimes C_k(h')) U).$$

并且我们有 $[\tilde{f}_j^\top Y]_{h'} = [\tilde{f}_j^\top \tilde{Y}]_{h'} = r_{U_j}(h')$ 。

求解 LS。 现在我们尝试求解 LS 问题 $GV = \tilde{F}^\top \tilde{Y}$ 。由于块对角结构，这可以独立地对每个 G_k 求解。考虑 $G_k V_k = \tilde{F}_k^\top \tilde{Y}$ 。这里 $\tilde{F}_k = [\tilde{f}_j]_{j \in J_k}$ 收集了来自 $\tilde{F}$ 的子集列 J_k 。

因此， $V_k = G_k^{-1} \tilde{F}_k^\top \tilde{Y}$ ，且 $v_j(h')$ 作为 V_k 的 (j, h') 元素，有 $v_j(h') = \sum_l [G_k^{-1}]_{jl} r_{U_l}(h') = 2 \sum_l [G_k^{-1}]_{jl} \text{tr}((I_{m_k} \otimes C_k(h')) U_l)$ 。然后我们有 $\hat{Y}^{(k)} = \tilde{F}_k V_k$ ：

$$\hat{Y}_{(\cdot, h), h'}^{(k)} = \sum_{j \in J_k} v_j(h') c_{U_j}(h) = 4 \sum_{j \in J_k} \sum_l [G_k^{-1}]_{jl} \text{tr}((I \otimes C_k(h')) U_l) \cdot \text{diag}(R_h^\top U_j).$$

通过 U 的线性以及 $\{U_j\}$ 的完备性（Hermitian 基张成了 $\mathcal{H}_k$ 中的所有算子），对于任意 $A \in \text{End}(\mathcal{H}_k)$ ，我们有：

$$4 \sum_{jl} [G_k^{-1}]_{jl} \text{tr}(A U_l) \text{diag}(R_h^\top U_j) = 4 \text{diag} \left(R_h^\top \left(\sum_{jl} [G_k^{-1}]_{jl} \langle A, U_l \rangle U_j \right) \right) = \text{diag}(R_h^\top A)$$

最后一个等式成立是因为注意到 $\langle A, U_l \rangle = \text{vec}^*(U_l) \text{vec}(A)$ ，因此 $4 \sum_{jl} [G_k^{-1}]_{jl} \langle A, U_l \rangle U_j = A$ 。取 $A = I \otimes C_k(h') = \Pi_k R_{h'} \Pi_k \in \text{End}(\mathcal{H}_k)$ ，我们得到：

$$\boxed{\hat{Y}_{(\cdot, h), h'}^{(k)} = \text{diag}(R_h^\top \Pi_k R_{h'} \Pi_k) \quad (h, h' \in H).}$$

为了解为何 $\hat{Y} = \tilde{Y}$ ，我们有：

$$\hat{Y}_{(\cdot, h), h'}^{(k)} = \text{diag}(R_h^\top (\Pi_k R_{h'} \Pi_k)) \Rightarrow \sum_{k \neq 0} \hat{Y}_{(\cdot, h), h'}^{(k)} = \text{diag} \left(R_h^\top \left(\sum_{k \neq 0} \Pi_k R_{h'} \Pi_k \right) \right).$$

由于 $\sum_k \Pi_k = I$ 且 $\Pi_k R_{h'} = R_{h'} \Pi_k$ ，

$$\sum_{k \neq 0} \Pi_k R_{h'} \Pi_k = R_{h'} - \Pi_0.$$

其中 $\Pi_0 = \frac{1}{M} 1_M 1_M^\top$ 是投影到平凡不可约表示的中心幂等投影子。因此

$$\sum_{k \neq 0} \hat{Y}_{(\cdot, h), h'}^{(k)} = \text{diag}(R_h^\top R_{h'}) - \text{diag}(R_h^\top \Pi_0) = \begin{cases} (1 - \frac{1}{M}) 1_M, & h = h', \\ -\frac{1}{M} 1_M, & h \neq h', \end{cases}$$

因为 $\text{diag}(R_h^\top R_{h'}) = 1_M$ 当且仅当 $h = h'$ ，否则为 0，而 $\text{diag}(R_h^\top \Pi_0) = \frac{1}{M} 1_M$ 对所有 h 成立。因此 $\sum_{k \neq 0} \hat{Y}^{(k)} = P_1^\perp Y = \tilde{Y}$ 。

备注。 上述证明对于实向量 w 也成立，因为我们可以总是对 R_h 进行实分解，且上述所有步骤均成立。

平方项的性质。 对于二次特征，节点 j 和块 h 的类中心化列分解为 $\tilde{F} = [A, B]$ ，其中对于 B ，每一列 j （及块 h ）为 $b_{j,h} := R_h^\top (u_j^2) - \frac{\|u_j\|_2^2}{M} 1_M$ （“平方”部分），而对于 A ，每一列 j （及块 h ）为 $a_{j,h} := 2(R_h^\top u_j) \circ u_j$ （我们上面讨论的“交叉”部分）。向量 b_j 是逐项均值为零的，即对所有 h 有 $\sum_x b_j(x) = 0$ ，因此它与任何类中心化的目标列 $\tilde{Y}_{(\cdot, h')} \propto 1$ 的

相关系数为零: $(b_{j,h}^\top \tilde{Y})_{h'} = \sum_x b_{j,h'}(x) = 0$ 。此外, 在 $1^\top u_j = 1^\top u_\ell = 0$ 的条件下, 有 $\sum_h \langle b_{j,h}, a_{\ell,h} \rangle = 0$ 。因此正规方程变为

$$\tilde{F}^\top \tilde{F} V = \begin{bmatrix} A^\top A & A^\top B \\ B^\top A & B^\top B \end{bmatrix} V = \begin{bmatrix} A^\top \tilde{Y} \\ B^\top \tilde{Y} \end{bmatrix}$$

由此得到

$$\begin{bmatrix} A^\top A & 0 \\ 0 & B^\top B \end{bmatrix} V = \begin{bmatrix} A^\top \tilde{Y} \\ 0 \end{bmatrix}$$

所以即使在 $\tilde{F}$ 中包含平方项 B , V 在它们上的系数仍将为零。

A.3 记忆与泛化的标度律 (第 ?? 节)

*

证明. 概述. 我们沿用提示中定理的设置和符号 (群 H , $|H| = M$, 二次激活, 定义如前的 S , $z_h = \langle R_h, S \rangle = \text{tr}(R_h^\top S)$, 零均值移除已并入 $\tilde{R}_h$)。我们分析随机行子采样, 并证明当保留的行数满足 $n \gtrsim M \log(M/\delta)$ 时, 经验目标函数保持相同的局部极大值结构。

设置. 共有 M^2 行, 由对 $(h_1, h_2) \in H \times H$ 索引, 目标为 $h = h_1 h_2$ 。对于每个 $h \in H$, 恰好有 M 行映射到 h ; 我们按照证明中按 h_1 排序后, 用 $j \in [M]$ 索引它们, 并记

$$s_{h,j} := (R_h^\top S)_{jj}. \quad \text{因此} \quad z_h = \sum_{j=1}^M s_{h,j} = \langle R_h, S \rangle.$$

我们以保留概率 $p \in (0, 1]$ 独立地子采样行。令 $\xi_{h,j} \in \{0, 1\}$ 为行 (h, j) 的保留指示符:

$$\Pr(\xi_{h,j} = 1) = p, \quad \text{对 } (h, j) \text{ 独立同分布.}$$

目标 h 的保留行数为

$$\hat{m}_h := \sum_{j=1}^M \xi_{h,j} \sim \text{Bin}(M, p), \quad \mathbb{E}[\hat{m}_h] = pM, \quad \text{Var}(\hat{m}_h) = Mp(1-p).$$

z_h 的估计量。 我们使用线性/无偏 (Horvitz–Thompson) 逐目标估计量

$$\hat{z}_h := \frac{1}{p} \sum_{j=1}^M \xi_{h,j} s_{h,j}. \quad \Rightarrow \quad \mathbb{E}[\hat{z}_h | S] = z_h.$$

定义对角采样矩阵

$$W_h^{\text{HT}} := \text{diag}\left(\frac{\xi_{h,1}}{p}, \dots, \frac{\xi_{h,M}}{p}\right), \quad \text{故} \quad \hat{z}_h = \text{tr}(R_h^\top S W_h^{\text{HT}}) = \langle R_h W_h^{\text{HT}}, S \rangle.$$

经验 Gram 算子. 设定归一化的每目标权重

$$w_h := \frac{\hat{m}_h}{pM}, \quad \mathbb{E}[w_h] = 1, \quad \text{Var}(w_h) = \frac{1-p}{pM} \leq \frac{1}{pM}.$$

将 W_h^{HT} 分解为其均值部分和零均值部分:

$$W_h^{\text{HT}} = w_h I + \Delta_h, \quad \text{tr}(\Delta_h) = 0, \quad \mathbb{E}[\Delta_h | \hat{m}_h] = 0.$$

因此

$$\hat{z}_h = \langle R_h (w_h I + \Delta_h), S \rangle = w_h z_h + \varepsilon_h, \quad \varepsilon_h := \langle R_h \Delta_h, S \rangle, \quad \mathbb{E}[\varepsilon_h | S, \hat{m}_h] = 0. \quad (15)$$

利用分解式

$$z_h = \sum_{k \neq 0} \sum_{r=1}^{m_k} \text{tr}(C_{k,h}^* \hat{S}_{k,r}) = \sum_{k \neq 0} \sum_{r=1}^{m_k} \text{vec}(\hat{S}_{k,r})^* \text{vec}(C_{k,h}),$$

我们得到

$$\sum_h \hat{z}_h^2 = \sum_h (w_h z_h + \varepsilon_h)^2 = \underbrace{\sum_h w_h^2 z_h^2}_{\text{信号}} + 2 \underbrace{\sum_h w_h z_h \varepsilon_h}_{\text{混合}} + \underbrace{\sum_h \varepsilon_h^2}_{\text{噪声}}. \quad (16)$$

信号项可以写成不可约表示块上的二次型：

$$\sum_h w_h^2 z_h^2 = \sum_{(k,r),(k',r')} \text{vec}(\hat{S}_{k,r})^* \left[\sum_h w_h^2 \text{vec}(C_{k,h}) \text{vec}(C_{k',h})^* \right] \text{vec}(\hat{S}_{k',r'}). \quad (17)$$

回顾全数据算子为

$$A_{k,k'} := \frac{1}{M} \sum_h \bar{C}_{k',h} \otimes C_{k,h}.$$

而 $\text{vec}(C_{k,h}) \text{vec}(C_{k',h})^*$ 正是 $\bar{C}_{k',h} \otimes C_{k,h}$ 的列与行重排。下文我们将研究 $A_{k,k'}$ 的近似误差。令

$$\hat{A}_{k,k'}^{(2)} := \frac{1}{M} \sum_h w_h^2 \bar{C}_{k',h} \otimes C_{k,h} \quad \text{和} \quad \hat{A}_{k,k'} := \frac{1}{M} \sum_h w_h \bar{C}_{k',h} \otimes C_{k,h}$$

分别为二阶加权和一阶加权经验 Gram 算子。由构造, $\mathbb{E}[\hat{A}_{k,k'}] = A_{k,k'}$ 且 $\mathbb{E}[\hat{A}_{k,k'}^{(2)}] = A_{k,k'} + \frac{1-p}{pM} A_{k,k'}$ (一个量级为 $1/(pM)$ 的微小偏差)。每个 (k, k') 块的误差界。我们将控制三个偏差, 对所有 (k, k') 一致成立:

$$\text{E1:} \quad \left\| \hat{A}_{k,k'} - A_{k,k'} \right\|_{\text{op}} \leq c_1 \sqrt{\frac{\log(M/\delta)}{Mp}}, \quad (18)$$

$$\text{E2:} \quad \left\| \hat{A}_{k,k'}^{(2)} - \hat{A}_{k,k'} \right\|_{\text{op}} \leq c_2 \sqrt{\frac{\log(M/\delta)}{Mp}} + \frac{c'_2}{Mp}, \quad (19)$$

$$\text{E3:} \quad \left| \sum_h w_h z_h \varepsilon_h \right| \leq c_3 \|z\|_2 \sqrt{\frac{M \log(M/\delta)}{p}}, \quad \sum_h \varepsilon_h^2 \leq c_4 \frac{M \log(M/\delta)}{p}, \quad (20)$$

对于数值常数 c_i, c'_i , 概率至少为 $1 - \delta/3$ 。

工具: 矩阵伯恩斯坦 (自伴随扩张形式) (Tropp, 2012)。设 $\{X_i\}$ 是独立的、均值为零的 $d \times d$ 随机矩阵, 满足 $\|X_i\| \leq L$ 且 $\|\sum_i \mathbb{E}[X_i X_i^*]\| \leq v$ 。则对所有 $t > 0$,

$$\Pr\left(\left\| \sum_i X_i \right\| \geq t\right) \leq 2d \exp\left(-\frac{t^2/2}{v + Lt/3}\right),$$

证明 (18)。 固定 (k, k') 并定义 $B_h := \bar{C}_{k',h} \otimes C_{k,h}$ (酉矩阵, 故 $\|B_h\| = 1$)。考虑

$$X_h := \frac{1}{M} (w_h - 1) B_h, \quad \mathbb{E}[X_h] = 0, \quad \|X_h\| \leq \frac{|w_h - 1|}{M} \leq \frac{1}{M}.$$

我们有

$$\mathbb{E}[X_h X_h^*] = \frac{\mathbb{E}[(w_h - 1)^2]}{M^2} B_h B_h^* = \frac{\text{Var}(w_h)}{M^2} I \preceq \frac{1}{pM^3} I.$$

对 h 求和得到方差代理 $v \leq M \cdot \frac{1}{pM^3} = \frac{1}{pM^2}$ 。由于 $d \leq M$, 以至少 $1 - \delta/3$ 的概率, 矩阵伯恩斯坦给出

$$\left\| \hat{A}_{k,k'} - A_{k,k'} \right\|_{\text{op}} = \left\| \sum_h X_h \right\| \lesssim \sqrt{\frac{\log(M/\delta)}{Mp}},$$

此即 (18)。

证明 (19)。 记

$$\hat{\mathbf{A}}_{k,k'}^{(2)} - \hat{\mathbf{A}}_{k,k'} = \frac{1}{M} \sum_h (w_h^2 - w_h) B_h = \underbrace{\frac{1}{M} \sum_h ((w_h - 1)^2 + (w_h - 1)) B_h}_{:= \Sigma_1 + \Sigma_2}.$$

对于 Σ_2 , 我们重用 (18) 的论证。对于 Σ_1 , 注意 $\mathbb{E}[(w_h - 1)^2] = \text{Var}(w_h) \leq 1/(pM)$, 且 $(w_h - 1)^2$ 是次指数型的, 尺度为 $\mathcal{O}(1/(pM))$, 因此矩阵伯恩斯坦再次给出以至少 $1 - \delta/3$ 的概率,

$$\|\Sigma_1\|_{\text{op}} \lesssim \sqrt{\frac{\log(M/\delta)}{Mp}} + \frac{1}{Mp}.$$

结合两者即得 (19)。

(20) 中混合项与噪声项的界。 在给定 S 和 $\{w_h\}$ 的条件下, $\{\varepsilon_h\}$ 是独立的、均值为零的, 且

$$|\varepsilon_h| = |\langle R_h \Delta_h, S \rangle| \leq \|R_h \Delta_h\|_F \|S\|_F \leq \|\Delta_h\|_F \|S\|_F, \quad \mathbb{E}[\varepsilon_h^2 | S, w_h] \lesssim \frac{\|S\|_F^2}{p}.$$

因此由标量伯恩斯坦不等式 (以及对混合和式使用柯西-施瓦茨不等式),

$$\left| \sum_h w_h z_h \varepsilon_h \right| \leq \|w\|_\infty \|z\|_2 \|\varepsilon\|_2 \lesssim \|z\|_2 \sqrt{\frac{M \log(M/\delta)}{p}}, \quad \sum_h \varepsilon_h^2 \lesssim \frac{M \log(M/\delta)}{p},$$

以至少 $1 - \delta/3$ 的概率成立, 此即 (20)。

结合以上三个界, 我们知道以至少 $1 - \delta$ 的概率, (18)–(20) 同时成立。**局部极大值的稳定性。**对于二次情形 (去除均值后), 在局部极大值所要求的共线且等长的 u 和 v 条件下, $\mathcal{E}$ 可以写成关于块质量 c_k 的半正定二次型 (公式 11):

$$\mathcal{E}(c) = \frac{M}{8} \sum_{k \neq 0} \frac{c_k^2}{d_k}, \quad \sum_{k \neq 0} c_k = 1, \quad c_k \geq 0.$$

经验能量具有如下形式:

$$\hat{\mathcal{E}}(c) = \frac{M}{8} c^\top (D + E) c + (\text{与 } c \text{ 无关的项}),$$

其中 $D = \text{diag}(1/d_k)$, E 是由将 $\mathbf{A}_{k,k'}$ 替换为 $\hat{\mathbf{A}}_{k,k'}^{(2)}$, 以及混合/噪声项引入的对称扰动。根据 (18)–(20),

$$\|E\|_{\text{op}} \lesssim \sqrt{\frac{\log(M/\delta)}{Mp}} + \frac{1}{Mp} \quad (21)$$

以至少 $1 - \delta$ 的概率成立。

顶点处的方向斜率 (无需间隙)。 考虑一个纯不可约表示顶点 $c = e_a$, 并将 ε 的质量泄漏到任意其他坐标 $b \neq a$: $c'_a = 1 - \varepsilon$, $c'_b = \varepsilon$, 其余为 0。总体变化为:

$$\Delta \mathcal{E} = \frac{M}{8} \left(\frac{(1 - \varepsilon)^2 - 1}{d_a} + \frac{\varepsilon^2}{d_b} \right) = -\frac{M}{4d_a} \varepsilon + \mathcal{O}(\varepsilon^2).$$

因此, 即使多个 d_k 相等, 每个泄漏方向都以速率 $\frac{M}{4d_a}$ 严格下降。因此, $\Delta \hat{\mathcal{E}}$ 的一阶近似为:

$$\Delta \hat{\mathcal{E}} = \Delta \mathcal{E} + \frac{M}{8} \Delta(c^\top E c) = -\frac{M}{4d_a} \varepsilon + \mathcal{O}(\varepsilon^2) + \frac{M}{4} \mathcal{O}(\|E\|_{\text{op}} \varepsilon).$$

因此，对于所有充分小的 $\varepsilon > 0$ ，只要满足

$$\frac{M}{4} \|E\|_{\text{op}} < \frac{M}{4d_a} \iff \|E\|_{\text{op}} < \frac{1}{d_a},$$

就有 $\Delta\hat{\mathcal{E}} < 0$ 。结合(21)，一个充分的采样条件是：

$$\sqrt{\frac{\log(M/\delta)}{Mp}} + \frac{1}{Mp} < \frac{1}{Cd_a} \Rightarrow Mp \gtrsim d_a^2 \log \frac{M}{\delta},$$

其中 C 是一个通用的数值常数。由于保留的总行数为 $n = pM^2$ ，这恰好等价于：

$$n \gtrsim M d_a^2 \log \frac{M}{\delta}$$

(相差一个通用常数倍)。在此条件下，以至少 $1 - \delta$ 的概率，每个纯不可约表示顶点仍然是经验目标函数的严格局部极大值（能量偏移量为 $\mathcal{O}(\sqrt{\log(M/\delta)/(Mp)})$ ）。当多个不可约表示具有相同的 d_k （能量相等）时，哪一个全局极大值可能会交换，但局部极大值集合保持不变。 $\square$

A.4 记忆化

设定。 固定一个群元素 h 。允许的训练对为 $(g, g^{-1}h)$ ，其中 $g \in H$ ，其概率为 $p_g := p_{g, g^{-1}h}$ ，并且在 g^* 处存在唯一最大值，即对所有 $g \neq g^*$ 有 $p_{g^*} > p_g$ 。令 $w = [u; v] \in \mathbb{R}^{2M}$ ，其预算为 $\|u\|_2^2 + \|v\|_2^2 = 1$ 。定义对和 $s_g := u_g + v_{g^{-1}h} \geq 0$ 。则有 $\sum_g s_g^2 \leq 2$ ，且（单目标）目标函数简化为

$$F(s) := \sum_g p_g \sigma(s_g) \quad \text{约束条件为} \quad s_g \geq 0, \quad \sum_g s_g^2 \leq 2,$$

其中 $\sigma \in C^1([0, \infty))$ 在 $(0, \infty)$ 上严格递增。最大化能量 $\mathcal{E}$ 等价于（相差一个固定的正因子）最大化 F 。

Lemma 3 (通过 $\phi = \sigma'/x$ 的 KKT 刻画). 假设对于 $x > 0$ 有 $\sigma'(x) > 0$ ，并定义 $\phi(x) := \sigma'(x)/x$ （当 $x > 0$ ）。令 s^* 为一个最优解。则存在 $\lambda \geq 0$ ，使得对每个 g ：

$$p_g \phi(s_g^*) = 2\lambda, \quad \text{若 } s_g^* > 0, \quad (22)$$

此外，预算约束是紧的： $\sum_g (s_g^*)^2 = 2$ （因此 $\lambda > 0$ ）。若 ϕ 在 $(0, \infty)$ 上严格单调，则对于每个活跃坐标 $s_g^* > 0$ ，

$$s_g^* = \phi^{-1}\left(\frac{2\lambda}{p_g}\right). \quad (23)$$

证明。 考虑拉格朗日函数 $L(s, \lambda, \mu) = \sum_g p_g \sigma(s_g) - \lambda(\sum_g s_g^2 - 2) - \sum_g \mu_g s_g$ ，其中 $\lambda \geq 0$ ， $\mu_g \geq 0$ 。平稳性条件给出 $p_g \sigma'(s_g) - 2\lambda s_g - \mu_g = 0$ 。若 $s_g > 0$ ，则 $\mu_g = 0$ 且 $p_g \sigma'(s_g) = 2\lambda s_g$ ，即 $p_g \phi(s_g) = 2\lambda$ 。若 $s_g = 0$ ，互补松弛性允许 $\mu_g \geq 0$ ，平稳性条件变为 $p_g \sigma'(0) - \mu_g = 0$ 。将 $\phi(0^+) := \lim_{x \downarrow 0} \sigma'(x)/x$ （可能为 $+\infty$ ）解释为右极限，不等式 $p_g \phi(0^+) \leq 2\lambda$ 编码了激活 $s_g > 0$ 会违反 KKT 平衡条件的事实。由于 $\sigma' > 0$ 且目标函数在每个 s_g 上递增，最优解处预算约束必须是紧的，因此 $\sum_g s_g^2 = 2$ 且 $\lambda > 0$ 。若 ϕ 严格单调，则 (22) 唯一地确定了 s_g 如 (23) 所示。 $\square$

Lemma 4 (通过 ϕ 单调性的记忆化与扩散). 在上述设定下，并假设 $\phi(x) = \sigma'(x)/x$ 在 $(0, \infty)$ 上连续：

(A) 若 ϕ 在 $(0, \sqrt{2}]$ 上非减, 则唯一的极大化子是记忆化(尖峰)解

$$s_{g^*}^* = \sqrt{2}, \quad s_{g \neq g^*}^* = 0,$$

由 $u = \frac{1}{\sqrt{2}}e_{g^*}$, $v = \frac{1}{\sqrt{2}}e_{(g^*)^{-1}h}$ 实现。

(B) 若 ϕ 在 $(0, \infty)$ 上严格递减, 则唯一的极大化子扩散, 并由下式给出

$$s_g^* = \phi^{-1}\left(\frac{2\lambda}{p_g}\right) \quad (\text{对所有满足 } 2\lambda/p_g < \phi(0^+) \text{ 的 } g),$$

且对于任何满足 $2\lambda/p_g \geq \phi(0^+)$ 的 g , 有 $s_g^* = 0$ (若 $\phi(0^+) < \infty$)。乘子 $\lambda > 0$ 由预算约束 $\sum_g (s_g^*)^2 = 2$ 唯一确定。特别地, 若 $\phi(0^+) = \infty$ (例如, $[0, \infty)$ 上的 ReLU: $\phi(x) = 1/x$; SiLU: $\phi(x) = \frac{\text{sigmoid}(x)}{x} + \text{sigmoid}(x)(1 - \text{sigmoid}(x))$), 则所有坐标都严格为正, 且

$$p_i > p_j \implies s_i^* > s_j^* > 0.$$

证明. (A) 当 ϕ 非减时的尖峰化。取任意可行解 s , 其有两个正坐标 $s_i \geq s_j > 0$ 且 $p_i > p_j$ 。定义一个保持 $\sum s_g^2$ 不变的平方质量转移: $s_i(t) := \sqrt{s_i^2 + t}$, $s_j(t) := \sqrt{s_j^2 - t}$, 并令 $\Psi(t) := p_i \sigma(s_i(t)) + p_j \sigma(s_j(t))$ 。则

$$\Psi'(t) = \frac{1}{2}[p_i \phi(s_i(t)) - p_j \phi(s_j(t))] \geq \frac{1}{2}[(p_i - p_j)\phi(s_j(t))] > 0,$$

因为 $s_i(t) \geq s_j(t)$ 且 ϕ 非减。因此 Ψ 随 t 增加, 所以任何具有两个支撑点的解都可以通过将质量推向更大的 p 来严格改进。迭代此坍塌过程即得到单支撑边界解 $s_{g^*}^* = \sqrt{2}$, 其余为 0。唯一性源于严格不等式以及 p_{g^*} 的唯一性。□

(B) 当 ϕ 严格递减时的扩散情况。根据引理 3, 最优活跃坐标满足 $p_g \phi(s_g^*) = 2\lambda$ 。由于 ϕ 严格递减, ϕ^{-1} 存在且严格递减, 从而在活跃集上得到 $s_g^* = \phi^{-1}(2\lambda/p_g)$; 当 $\phi(0^+) < \infty$ 时, 互补松弛条件给出了阈值化行为。预算约束 $\sum_g (s_g^*)^2 = 2$ 确定了 λ , 而严格单调性意味着轮廓严格按 p_g 排序。

*

证明. 结论直接由定理 4 得出。□

一些讨论。我们知道

- 对于幂次激活函数 $\sigma(x) = x^q$ ($q \geq 2$), 有 $\phi(x) = q x^{q-2}$ 非递减; 定理 4(A) 给出了记忆化。在所有情况下, 峰值解通过均匀分割实现: $u = \frac{1}{\sqrt{2}}e_{g^*}$, $v = \frac{1}{\sqrt{2}}e_{(g^*)^{-1}h}$; 任何轮廓 s^* 都可以通过例如 $u_g = v_{g^{-1}h} = s_g^*/2$ 实现。
- 在 $[0, \infty)$ 上的 ReLU: $\sigma(x) = x$, $\phi(x) = 1/x$ 严格递减; 定理 4(B) 得出 $s^* \propto p$ 。
- SiLU/Swish/Tanh/Sigmoid: ϕ 严格递减且 $\phi(0^+) = \infty$; 定理 4(B) 给出了严格排序的扩散轮廓 $s_g^* = \phi^{-1}(2\lambda/p_g)$ 。

B 交互式特征学习 (第 ?? 节)

B.1 特征排斥 (第 ?? 节)

*

证明. 令 $Q := (\tilde{F}^\top \tilde{F} + \eta I)^{-1}$. 不失一般性 (通过保持相应逆矩阵元素符号的列置换相似变换), 重新排列列使得对 (j, ℓ) 变为 $(1, 2)$. 写出分块形式

$$\tilde{F} = [\tilde{f}_1 \ \tilde{f}_2 \ \tilde{F}_r], \quad \tilde{F}_r := \tilde{F}_{-(1,2)} \in \mathbb{R}^{n \times (K-2)}.$$

则岭格拉姆矩阵 $G = \tilde{F}^\top \tilde{F} + \eta I_K$ 具有 2×2 / 剩余块形式

$$G = \begin{bmatrix} a & b & \mathbf{u}^\top \\ b & c & \mathbf{v}^\top \\ \mathbf{u} & \mathbf{v} & H \end{bmatrix}, \quad \text{其中} \quad \begin{aligned} a &:= \tilde{f}_1^\top \tilde{f}_1 + \eta, & b &:= \tilde{f}_1^\top \tilde{f}_2, & \mathbf{u} &:= \tilde{F}_r^\top \tilde{f}_1, \\ c &:= \tilde{f}_2^\top \tilde{f}_2 + \eta, & \mathbf{v} &:= \tilde{F}_r^\top \tilde{f}_2, & H &:= \tilde{F}_r^\top \tilde{F}_r + \eta I. \end{aligned}$$

因为 $\eta > 0$, H 是正定的, 因此可逆. 分块矩阵的逆由舒尔补决定. 定义 2×2 舒尔补

$$S := \begin{bmatrix} a & b \\ b & c \end{bmatrix} - \begin{bmatrix} \mathbf{u}^\top \\ \mathbf{v}^\top \end{bmatrix} H^{-1} \begin{bmatrix} \mathbf{u} & \mathbf{v} \end{bmatrix} = \begin{bmatrix} \alpha & \beta \\ \beta & \gamma \end{bmatrix},$$

其中元素为

$$\alpha = a - \mathbf{u}^\top H^{-1} \mathbf{u}, \quad \beta = b - \mathbf{u}^\top H^{-1} \mathbf{v}, \quad \gamma = c - \mathbf{v}^\top H^{-1} \mathbf{v}.$$

标准的分块求逆公式 (例如, 通过舒尔补) 给出 G^{-1} 的左上角 2×2 块等于 S^{-1} . 特别地, $Q = G^{-1}$ 中索引 $(1, 2)$ 对应的非对角元素是 S^{-1} 的非对角元素. 由于

$$S^{-1} = \frac{1}{\alpha\gamma - \beta^2} \begin{bmatrix} \gamma & -\beta \\ -\beta & \alpha \end{bmatrix} \quad \text{且} \quad \alpha\gamma - \beta^2 > 0$$

(因为 $G \succ 0$ 蕴含 $S \succ 0$), 我们得到

$$q_{12} = (S^{-1})_{12} = -\frac{\beta}{\alpha\gamma - \beta^2}.$$

现在需要用关于 $\tilde{F}_r$ 的岭残差来识别 α, β, γ . 注意

$$H = \tilde{F}_r^\top \tilde{F}_r + \eta I \implies \tilde{F}_r H^{-1} \tilde{F}_r^\top = I_n - P_{\eta, r},$$

根据定义 $P_{\eta, r} := I - \tilde{F}_r H^{-1} \tilde{F}_r^\top$. 因此

$$\begin{aligned} \alpha &= \tilde{f}_1^\top \tilde{f}_1 + \eta - \tilde{f}_1^\top \tilde{F}_r H^{-1} \tilde{F}_r^\top \tilde{f}_1 = \eta + \tilde{f}_1^\top (I - \tilde{F}_r H^{-1} \tilde{F}_r^\top) \tilde{f}_1 = \eta + \tilde{f}_1^\top P_{\eta, r} \tilde{f}_1, \\ \beta &= \tilde{f}_1^\top \tilde{f}_2 - \tilde{f}_1^\top \tilde{F}_r H^{-1} \tilde{F}_r^\top \tilde{f}_2 = \tilde{f}_1^\top (I - \tilde{F}_r H^{-1} \tilde{F}_r^\top) \tilde{f}_2 = \tilde{f}_1^\top P_{\eta, r} \tilde{f}_2, \\ \gamma &= \eta + \tilde{f}_2^\top P_{\eta, r} \tilde{f}_2. \end{aligned}$$

将这些恒等式代入 q_{12} 的表达式得到

$$q_{12} = -\frac{\tilde{f}_1^\top P_{\eta, r} \tilde{f}_2}{(\eta + \tilde{f}_1^\top P_{\eta, r} \tilde{f}_1)(\eta + \tilde{f}_2^\top P_{\eta, r} \tilde{f}_2) - (\tilde{f}_1^\top P_{\eta, r} \tilde{f}_2)^2}.$$

分母严格为正 (它是正定 2×2 矩阵 S 的行列式), 因此

$$\text{sign}(q_{12}) = -\text{sign}(\tilde{f}_1^\top P_{\eta, r} \tilde{f}_2).$$

撤销初始的置换操作, 对原始索引 (j, ℓ) 得到相同公式, 这证明了符号断言. $\square$

最后, 由于 Q 是带岭逆的 Gram 矩阵, $\tilde{F}Q$ 的第 j 列为

$$(\tilde{F}Q)_{\bullet, j} = \sum_{m=1}^K q_{mj} \tilde{f}_m = q_{jj} \tilde{f}_j + \sum_{m \neq j} q_{mj} \tilde{f}_m.$$

因为 q_{mj} 的符号与岭残差相似度 $\tilde{f}_m^\top P_{\eta, -mj} \tilde{f}_j$ 相反, 那些 (残差) 与 $\tilde{f}_j$ 相似的特征以负系数进入, 从而沿着这些方向从 $(\tilde{F}Q)_{\bullet, j}$ 中减去——这“排斥”了相似特征并促进了特化. 证明完成.

B.2 自上而下的调制（第 ?? 节）

*

证明. 固定一个非平凡同型（不可约表示） k ，我们有

$$\hat{Y}_{(\cdot, h), h'}^{(k)} = \text{diag}\left(R_h^\top (\Pi_k R_{h'} \Pi_k)\right).$$

由于 Π_k 是中心且幂等的，它与 $R_{h'}$ 可交换且 $\Pi_k^2 = \Pi_k$ ，因此

$$\Pi_k R_{h'} \Pi_k = \Pi_k R_{h'} = R_{h'} \Pi_k.$$

在群代数中使用西不可约表示 $\{C_k\}$ 和特征标 χ_k 展开中心幂等元：

$$\Pi_k = \frac{d_k}{M} \sum_{g \in H} \overline{\chi_k(g)} R_g = \frac{d_k}{M} \sum_{g \in H} \chi_k(g^{-1}) R_g. \quad (24)$$

因此

$$\Pi_k R_{h'} = \frac{d_k}{M} \sum_{g \in H} \overline{\chi_k(g)} R_g R_{h'} = \frac{d_k}{M} \sum_{g \in H} \overline{\chi_k(g)} R_{gh'}.$$

左移 $R_h^\top$ 后取对角线得到

$$\text{diag}(R_h^\top (\Pi_k R_{h'})) = \frac{d_k}{M} \sum_{g \in H} \overline{\chi_k(g)} \text{diag}(R_h^\top R_{gh'}).$$

由于 $R_h^\top R_{gh'} = R_{h^{-1}gh'}$ ，我们有

$$\text{diag}(R_h^\top R_{gh'}) = \begin{cases} 1_M, & h^{-1}gh' = e, \\ 0, & \text{否则}. \end{cases}$$

只有唯一的项 $g = hh'^{-1}$ 保留下来，所以

$$\text{diag}(R_h^\top (\Pi_k R_{h'})) = \frac{d_k}{M} \overline{\chi_k(hh'^{-1})} 1_M = \frac{d_k}{M} \chi_k(h'^{-1}h) 1_M,$$

这里我们使用了西不可约表示的 $\overline{\chi_k(a)} = \chi_k(a^{-1})$ 。因此，

$$\hat{Y}_{(\text{对应于块 } h \text{ 的行}), h'}^{(k)} = \frac{d_k}{M} \chi_k(h'^{-1}h) 1_M.$$

对一个同型子集 $\mathcal{S}$ 求和得到

$$\hat{Y}_{(\text{对应于块 } h \text{ 的行}), h'} = \sum_{k \in \mathcal{S}} \hat{Y}_{(\text{对应于块 } h \text{ 的行}), h'}^{(k)} = \frac{1}{M} \sum_{k \in \mathcal{S}} d_k \chi_k(h) \overline{\chi_k(h')} 1_M.$$

由于对所有 $k \neq 0$ 求和得到 $\hat{Y} = \tilde{Y}$ （定理 ??），对于残差 $\hat{Y} - \tilde{Y}$ ，我们有

$$[\hat{Y} - \tilde{Y}]_{(\text{对应于块 } h \text{ 的行}), h'} = \frac{1}{M} \sum_{k \neq 0, k \notin \mathcal{S}} d_k \chi_k(h) \overline{\chi_k(h')} 1_M.$$

这意味着 $\hat{Y} - \tilde{Y} = \Phi_{\Phi^* \otimes 1_M}$ ，其中 $\Phi_{\cdot} = \left[\sqrt{\frac{d_k}{M}} \chi_k(\cdot) \right]_{k \neq 0, k \notin \mathcal{S}} \in \mathbb{C}^{M \times (\kappa(H) - || - 1)}$ 。由于

$\tilde{Y} = P_1^\perp \otimes 1_M$ ，我们有：

$$G_F \propto (\hat{Y} - \tilde{Y}) \tilde{Y}^\top F = \left(\Phi_{\Phi^* \otimes 1_M} 1_M^\top \right) F = (\Phi_\otimes 1_M) (\Phi_\otimes 1_M)^* F$$

因此，能量函数 $\mathcal{E}$ 现在变为

$$\mathcal{E} = \frac{1}{2} \|(\Phi_\otimes 1_M)^* F\|_2^2 = \frac{1}{2} \|\Phi_{*z}\|_2^2$$

其中 $z = [z_h] = [\langle R_h, S \rangle_F] \in \mathbb{C}^M$ 由方程 2 定义。计算 Φ_{*z} 的每一行 k 并利用投影矩阵 Π_k 的性质（方程 24），我们有：

$$[\Phi_{*z}]_k = \langle \sum_{h \in H} \sqrt{\frac{d_k}{M}} \chi_k(h) R_h, S \rangle = \sqrt{\frac{M}{d_k}} \langle \Pi_k, S \rangle$$

在 Q 空间中，我们有 $\langle \Pi_k, S \rangle = \sum_{r=1}^{m_k} \text{tr}(\hat{S}_{k,r})$ ，因此

$$\mathcal{E} = \frac{1}{2} \sum_{k \neq 0, k \notin S} \frac{M}{d_k} |\langle \Pi_k, S \rangle|^2 = \frac{M}{2} \sum_{k \neq 0, k \notin S} \frac{1}{d_k} \left| \sum_r \text{tr}(\hat{S}_{k,r}) \right|^2$$

这正是定理 ?? 中分解（方程 9）的相同形式（但推导过程更简洁）。因此， $\mathcal{E}$ 的所有局部极大值仍然具有与定理 ?? 相同的形式，但我们只是移除了那些位于同型/不可约表示 $k \in$ 中的局部极大值，而专注于缺失的那些。□

B.3 Muon 优化器促进多样性（第 ?? 节）

*

证明. 令 $G = [\nabla_{w_1} \mathcal{E}, \nabla_{w_2} \mathcal{E}, \dots, \nabla_{w_K} \mathcal{E}]$ 为梯度矩阵。令 $G = UDV^\top$ 为其奇异值分解。则 Muon 方向为 $\hat{G} = UV^\top$ ，因此 $\hat{G}$ 与 G 的内积为

$$\langle \hat{G}, G \rangle_F = \text{tr}(\hat{G}^\top G) = \text{tr}(VU^\top UDV^\top) = \text{tr}(D) \geq 0 \quad (25)$$

所以 Muon 总是沿着梯度方向并改进目标函数。此外， $\langle \hat{G}, G \rangle_F = 0$ 当且仅当 $D = 0$ ，这意味着 $G = 0$ 。因此 Muon 动力学与原始梯度动力学的驻点是相同的。□

Lemma 5 (Fréchet / log-Gumbel 选择的命题). 令 $x_1, \dots, x_n$ 为独立同分布的正随机变量，其 Fréchet(α) 累积分布函数为

$$F(x) = \exp(-x^{-\alpha}), \quad x > 0, \quad \alpha > 0,$$

并令 $w_1, \dots, w_n > 0$ 为固定权重。定义

$$i^* = \arg \max_{1 \leq j \leq n} w_j x_j.$$

则

$$\Pr(i^* = i) = \frac{w_i^\alpha}{\sum_{j=1}^n w_j^\alpha}, \quad i = 1, \dots, n.$$

特别地，当 $\alpha = 1$ 时，

$$\Pr(i^* = i) = \frac{w_i}{\sum_{j=1}^n w_j}.$$

证明. 令 $Y_j := w_j x_j$ 。对于 $t > 0$ ，

$$\Pr(\max_j Y_j \leq t) = \prod_{j=1}^n F\left(\frac{t}{w_j}\right) = \exp\left(-\sum_{j=1}^n (w_j/t)^\alpha\right).$$

求导可得最大值的密度函数：

$$f_{\max}(t) = \frac{d}{dt} \Pr(\max_j Y_j \leq t) = \left(\sum_{j=1}^n \alpha w_j^\alpha t^{-\alpha-1} \right) \exp\left(-\sum_{j=1}^n (w_j/t)^\alpha\right).$$

“ i 在水平 t 处达到最大值” 的密度为

$$f_{Y_i}(t) \prod_{j \neq i} F\left(\frac{t}{w_j}\right) = \alpha w_i^\alpha t^{-\alpha-1} \exp\left(-\sum_{j=1}^n (w_j/t)^\alpha\right).$$

因此, 给定 $\max_j Y_j = t$ 时 i 是 $\arg\max$ 的条件概率为

$$\Pr(i^* = i \mid \max_j Y_j = t) = \frac{\alpha w_i^\alpha t^{-\alpha-1}}{\sum_{j=1}^n \alpha w_j^\alpha t^{-\alpha-1}} = \frac{w_i^\alpha}{\sum_{j=1}^n w_j^\alpha},$$

该概率与 t 无关。对 t 取平均即得所述结果。 $\square$

Lemma 6 (式 ?? 中动力学的性质). 该动力学总是收敛到 ζ_{l^*} , 其中 $l^* = \arg \max_l \mu_l \alpha_l(0)$ 。也就是说, 初始的领先者总是获胜。

证明. 注意, 由于 $\{\zeta_l\}$ 的正交性, 动力学可以写为

$$\dot{\alpha}_j = \mu_j \alpha_j^2, \quad \mu_j > 0,$$

约束条件为 $\sum_{j=1}^L \alpha_j^2 \leq 1$ 。定义

$$r_j := \mu_j \alpha_j.$$

内部。在内部, 我们有

$$\dot{r}_j = \mu_j \dot{\alpha}_j = \mu_j (\mu_j \alpha_j^2) = r_j^2.$$

对于任意一对 i, k , 定义比值

$$\rho_{ik} := \frac{r_i}{r_k}.$$

其导数为

$$\dot{\rho}_{ik} = \frac{\dot{r}_i}{r_k} - \frac{r_i}{r_k^2} \dot{r}_k = \frac{r_i^2}{r_k} - \frac{r_i}{r_k^2} r_k^2 = \rho_{ik} (r_i - r_k).$$

等价地,

$$\frac{d}{dt} \log \frac{r_i}{r_k} = r_i - r_k. \quad (1)$$

因此, 如果 $r_\ell(0) > r_j(0)$, 则 $\frac{d}{dt} \log(r_\ell/r_j) > 0$ 且 $\rho_{\ell j}(t)$ 严格递增。因此, 在内部, r 的严格领先者不会被超越。

边界区域 ($\sum_j \alpha_j^2 = 1$)。在单位球面上, 投影动力学为

$$\dot{\alpha}_j = \mu_j \alpha_j^2 - \lambda \alpha_j, \quad \lambda = \sum_{k=1}^L \mu_k \alpha_k^3.$$

用 r_j 表示,

$$\dot{r}_j = r_j(r_j - \nu), \quad \nu = \sum_{k=1}^L \alpha_k^2 r_k = \sum_{k=1}^L \frac{r_k^2}{\mu_k^2} r_k.$$

对于比值 $\rho_{ik} = r_i/r_k$, 我们再次得到

$$\dot{\rho}_{ik} = \rho_{ik}(r_i - r_k) \implies \frac{d}{dt} \log \frac{r_i}{r_k} = r_i - r_k. \quad (2)$$

$\square$

比值单调性。由 (1)-(2), 若 $r_\ell(0) > r_j(0)$, 则

$$\frac{d}{dt} \log \frac{r_\ell}{r_j} > 0 \quad \forall t,$$

因此 $\rho_{\ell j}(t) = r_\ell(t)/r_j(t)$ 对每个 $j \neq \ell$ 严格递增。故严格领导者 ℓ 将始终保持为唯一领导者。

收敛到顶点。定义权重

$$w_j := \alpha_j^2 = \frac{r_j^2}{\mu_j^2}, \quad \sum_j w_j = 1.$$

其动力学为

$$\dot{w}_j = 2w_j(r_j - \nu).$$

取比值,

$$\frac{d}{dt} \log \frac{w_i}{w_k} = 2(r_i - r_k).$$

特别地, $\frac{w_\ell}{w_j}$ 对每个 $j \neq \ell$ 严格递增。因此

$$\frac{w_j(t)}{w_\ell(t)} \rightarrow 0 \quad (j \neq \ell),$$

这意味着 $w_\ell(t) \rightarrow 1$ 且 $w_j(t) \rightarrow 0$ 。因此

$$\boldsymbol{\alpha}(t) \rightarrow \mathbf{e}_\ell \quad \text{当 } t \rightarrow \infty.$$

Lemma 7 (Muon 投影). 对于矩阵 $A = [Q, \mathbf{v}]$, 其中 Q 是列正交矩阵, $\mathbf{v}$ 是一个小范数向量, 其 Muon 正则化版本 $\hat{A} = [\hat{A}_1, \hat{\mathbf{v}}]$ 具有以下形式:

$$\hat{\mathbf{v}} = \left(\frac{\mathbf{v}_\perp}{\|\mathbf{v}_\perp\|} + \frac{\mathbf{v}_\parallel}{1 + \|\mathbf{v}_\perp\|} \right) + O(\|\mathbf{v}_\perp\|^2) \quad (26)$$

其中 $\mathbf{v}_\parallel = QQ^\top \mathbf{v}$ 且 $\mathbf{v}_\perp = I - QQ^\top \mathbf{v}$ 。

证明. 给定 $A = [Q, B]$ 且 $Q^\top Q = I_k$, 记 $B = QC + B_\perp$, 其中 $C := Q^\top B \in \mathbb{R}^{k \times m}$ 且 $B_\perp := (I - QQ^\top)B$ 。

令 $T := B_\perp^\top B_\perp \succ 0$ 。对于 $c > 0$, 定义

$$\hat{A}^{(c)} = A(A^\top A)^{-1/c}, \quad \hat{A}^{(c)} = [\hat{A}_1^{(c)}, \hat{A}_2^{(c)}].$$

我们推导最后一个块 $\hat{A}_2^{(c)}$ 关于 C 的一阶公式。

精确的 Gram 矩阵为

$$G := A^\top A = \begin{bmatrix} I_k & C \\ C^\top & C^\top C + T \end{bmatrix} = G_0 + H, \quad G_0 := \text{diag}(I_k, T), \quad H := \begin{bmatrix} 0 & C \\ C^\top & C^\top C \end{bmatrix}.$$

将 C 视为小量。关于 C 到一阶, 我们可以忽略二次项块:

$$H = \begin{bmatrix} 0 & C \\ C^\top & 0 \end{bmatrix} + O(\|C\|^2).$$

对角化 T 。令 $T = U\Lambda U^\top$, 其中 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$, $\lambda_j > 0$ 。定义分块正交基变换

$$P := \text{diag}(I_k, U) \Rightarrow \tilde{G} := P^\top G P, \quad \tilde{G}_0 := P^\top G_0 P = \text{diag}(I_k, \Lambda), \quad \tilde{H} := P^\top H P = \begin{bmatrix} 0 & \tilde{C} \\ \tilde{C}^\top & 0 \end{bmatrix},$$

其中 $\tilde{C} := CU$ 。所有一阶结论可在此基下进行, 然后通过 P 变换回去。

一阶泰勒展开。现在进行泰勒展开。记

$$\tilde{G} = \tilde{G}_0 + \tilde{H} = \tilde{G}_0^{1/2} \left(I + \underbrace{\tilde{G}_0^{-1/2} \tilde{H} \tilde{G}_0^{-1/2}}_{=: E} \right) \tilde{G}_0^{1/2}.$$

由于 $\tilde{G}_0 = \text{diag}(I_k, \Lambda)$,

$$E = \begin{bmatrix} 0 & \tilde{C} \Lambda^{-1/2} \\ \Lambda^{-1/2} \tilde{C}^\top & 0 \end{bmatrix} \quad \text{是 } O(\|C\|).$$

对于标量函数 $f(x) = x^{-1/c}$,

$$(I + E)^{-1/c} = I - \frac{1}{c} E + O(\|E\|^2).$$

因此

$$\tilde{G}^{-1/c} = \tilde{G}_0^{-1/2} (I + E)^{-1/c} \tilde{G}_0^{-1/2} = \tilde{G}_0^{-1/c} - \frac{1}{c} \tilde{G}_0^{-1/2} E \tilde{G}_0^{-1/2} + O(\|C\|^2).$$

利用 $\tilde{G}_0^{-1/2} = \text{diag}(I_k, \Lambda^{-1/2})$ 计算分块:

$$\tilde{G}_0^{-1/2} E \tilde{G}_0^{-1/2} = \begin{bmatrix} 0 & \tilde{C} \Lambda^{-1} \\ \Lambda^{-1} \tilde{C}^\top & 0 \end{bmatrix}.$$

因此, 到一阶,

$$\tilde{G}^{-1/c} = \begin{bmatrix} I_k & 0 \\ 0 & \Lambda^{-1/c} \end{bmatrix} - \frac{1}{c} \begin{bmatrix} 0 & \tilde{C} \Lambda^{-1} \\ \Lambda^{-1} \tilde{C}^\top & 0 \end{bmatrix} + O(\|C\|^2). \quad (27)$$

回到原始空间。现在

$$G^{-1/c} = P \tilde{G}^{-1/c} P^\top.$$

利用 (27) 和 $P = \text{diag}(I_k, U)$,

$$G^{-1/c} = \begin{bmatrix} I_k & 0 \\ 0 & U \Lambda^{-1/c} U^\top \end{bmatrix} - \frac{1}{c} \begin{bmatrix} 0 & C U \Lambda^{-1} U^\top \\ U \Lambda^{-1} U^\top C^\top & 0 \end{bmatrix} + O(\|C\|^2).$$

由于 $U \Lambda^{-1} U^\top = T^{-1}$ 且 $U \Lambda^{-1/c} U^\top = T^{-1/c}$,

$$G^{-1/c} = \begin{bmatrix} I_k & 0 \\ 0 & T^{-1/c} \end{bmatrix} - \frac{1}{c} \begin{bmatrix} 0 & C T^{-1} \\ T^{-1} C^\top & 0 \end{bmatrix} + O(\|C\|^2).$$

现在计算乘积

$$\hat{A}^{(c)} = [Q, QC + B_\perp] G^{-1/c}.$$

取最后 m 列 (第二个块) 并保留一阶项:

$$\begin{aligned} \hat{A}_2^{(c)} &= Q \left(-\frac{1}{c} C T^{-1} \right) + (QC + B_\perp) T^{-1/c} + O(\|C\|^2) \\ &= B_\perp T^{-1/c} + Q \left(C T^{-1/c} - \frac{1}{c} C T^{-1} \right) + O(\|C\|^2). \end{aligned}$$

通过 T 的谱演算对 Q 部分进行列分解。若 $T = U \Lambda U^\top$, 则对每个特征值 λ , 标量因子为

$$\lambda^{-1/c} - \frac{1}{c} \lambda^{-1} = \frac{1 - \lambda^{1-1/c}}{1 - \lambda}.$$

因此, 以矩阵形式表示,

$$C T^{-1/c} - \frac{1}{c} C T^{-1} = C (I - T^{1-1/c}) (I - T)^{-1}.$$

于是我们得到

$$\boxed{\hat{A}_2^{(c)} = B_\perp T^{-1/c} + B_\parallel (I - T^{1-1/c}) (I - T)^{-1} + O(\|C\|^2).} \quad (28)$$

其中 $B_\parallel = Q Q^\top B$ 。

对于极坐标情形 $c = 2$, 算子变为 $(I - T^{1/2})(I - T)^{-1}$ 。对于 $B = v$, 我们有 $T = B_\perp^\top B_\perp = \|v_\perp\|_2^2$, 结论随之成立。 $\square$

Lemma 8 (T_0 的界).

$$T_0 \geq \max \left(\min_{l=1}^L 1/p_l, L \sum_{l=1}^L 1/l \right). \quad (29)$$

证明. $T_0 \geq \min_l 1/p_l$, 因为收集所有优惠券的期望时间总是大于单独收集最稀有优惠券的时间。

为证明 $T_0 \geq L \sum_{l=1}^L 1/l$, 固定 $t > 0$ 并考虑函数

$$h(p) = \log(1 - e^{-pt}), \quad p > 0.$$

直接计算可得

$$h''(p) = -\frac{t^2}{4 \sinh^2(pt/2)} < 0,$$

所以 h 是凹函数。由 Jensen 不等式及 $\sum_i p_i = 1$,

$$\sum_{i=1}^L \log(1 - e^{-p_i t}) \leq L \log(1 - e^{-t/L}).$$

取指数得到逐点界

$$\prod_{i=1}^L (1 - e^{-p_i t}) \leq (1 - e^{-t/L})^L.$$

因此

$$\mathbb{E}[T_0] \geq \int_0^\infty \left(1 - (1 - e^{-t/L})^L\right) dt.$$

为计算该积分, 令 $u = e^{-t/L}$, 则 $dt = -L du/u$ 且 $t: 0 \rightarrow \infty$ 映射为 $u: 1 \rightarrow 0$:

$$\int_0^\infty \left(1 - (1 - e^{-t/L})^L\right) dt = L \int_0^1 \frac{1 - (1 - u)^L}{u} du = L \int_0^1 \sum_{l=0}^{L-1} (1 - u)^l du = L \sum_{l=0}^{L-1} \frac{1}{l+1}$$

因此结论成立。当且仅当 $p_1 = \dots = p_L = 1/L$ 时取等号, 因为这是 Jensen 不等式取等的情形。□

*

证明. 由引理 6, 我们知道节点最终收敛到的模式 ζ_l 是具有最大初始 α_l 的那个:

$$\Pr[w \rightarrow \zeta_l] = \Pr[l = \arg \max_{l'} \mu_{l'} \alpha_{l'}(0)] \quad (30)$$

由引理 5, 我们有 $\Pr[w \rightarrow \zeta_l] = p_l := \mu_l^a / \sum_l \mu_l^a$.

独立特征学习。在这种情况下, 获得所有局部模式 $\{\zeta_l\}$ 等同于收集 L 张优惠券的问题。根据分布的性质 (引理 5), 我们知道获得第 l 个局部最大值的概率为 $p_l := \mu_l^a / \sum_l \mu_l^a$ 。因此, 收集所有局部极大值的期望试验次数为 (Flajolet et al., 1992):

$$T_0 = \int_0^{+\infty} \left(1 - \prod_{l=1}^L (1 - e^{-p_l t})\right) dt \quad (31)$$

注意 $T_0 \geq \max \left(1 / \min_l p_l, L \sum_{l=1}^L 1/l\right)$ (引理 29)。由于每个节点是独立优化的, 我们需要 $K \sim T_0$ 才能以高概率在 K 个隐藏节点中收集到所有局部极大值。

缪子引导。考虑以下设置, 我们“增量式”地优化隐藏节点。在学习节点 j 的权重时, 我们假设所有先前的节点 (节点 1 到节点 $j-1$) 都已学习完毕, 即它们已收敛到某个真实基

$\{\zeta_l\}$ 之一，但在繆子更新中仍保留它们的梯度（去重后）。令 $S_{j-1} \subseteq [L] = \{1, \dots, L\}$ 为已收集到的局部极大值的子集。

根据引理 7，我们知道

$$\hat{g}_j = \frac{1}{\|g_{j,\perp}\|} \left(g_{j,\perp} + \frac{\|g_{j,\perp}\|}{1 + \|g_{j,\perp}\|} g_{j,\parallel} \right) + O(\|g_{j,\perp}\|^2) \quad (32)$$

其中 $g_{j,\parallel} = P_{j-1} P_{j-1}^\top g_j$ 且 $g_{j,\perp} = g_j - g_{j,\parallel}$ 。这里 $P_{j-1} = [\zeta_s]_{s \in S_{j-1}}$ 是由前 $j-1$ 个节点形成的投影矩阵。由于

$$\|g_{j,\perp}\| \leq \|g_j\| = \left\| \sum_l \lambda_l(\alpha_l) \alpha_l \zeta_l \right\| = \left| \sum_l (\lambda_l(\alpha_l) \alpha_l)^2 \right| \leq \left| \sum_l \alpha_l^2 \right| \leq 1 \quad (33)$$

我们有 $\frac{\|g_{j,\perp}\|}{1 + \|g_{j,\perp}\|} \leq 1/2$ 。因此，这意味着梯度中与先前 $j-1$ 个节点重复的分量（即平行分量）相比于正交分量（即指向新局部极大值的方向）被抑制了至少 $1/2$ 。这等价于将所有出现在 P_{j-1} 中的 l 对应的 μ_l 除以（至少）2。根据引理 5，对于节点 j ，收敛到 S_{j-1} 之外的新局部极大值的概率为

$$p_{\text{new}, S_{j-1}} \geq \frac{\sum_{l \notin S_{j-1}} p_l}{2^{-a} \sum_{l \in S_{j-1}} p_l + \sum_{l \notin S_{j-1}} p_l} \quad (34)$$

我们依次对节点 j 、节点 $j+1$ 等执行此过程。令 $m = |S_{j-1}|$ 为已发现的局部极大值的数量。那么我们发现一个新局部极大值的期望时间为：

$$\mathbb{E}[\tilde{T}_{m \rightarrow m+1}] = \frac{1}{p_{\text{new}, S_{j-1}}} \leq 2^{-a} \mathbb{E}[T_{m \rightarrow m+1}] + 1 - 2^{-a} \quad (35)$$

其中 $\mathbb{E}[T_{m \rightarrow m+1}] = 1 / \sum_{l \notin S_{j-1}} p_l$ 是原始优惠券收集问题在给定已知 S_{j-1} 的情况下选取一个新局部极大值的期望时间。将期望时间相加，我们得到

$$T_a = \sum_{m=0}^{L-1} \mathbb{E}[\tilde{T}_{m \rightarrow m+1}] \leq 2^{-a} T_0 + (1 - 2^{-a})L \quad (36)$$

注意，所有期望时间都以已知局部极大值序列为条件。但由于这些值与具体序列无关，它们也是整体的期望时间。 $\square$

C 关于第一阶段（惰性学习）的更详细分析

为了更彻底地分析第一阶段，我们考虑输出层权重 V 的梯度流动力学。

令 $\tilde{F} \in \mathbb{R}^{n \times K}$ 为一个固定的特征矩阵，且 $\tilde{Y} \in \mathbb{R}^{n \times M}$ 。

我们始终假设

- (A1) $\tilde{F}$ 具有满列秩 K ，且
 - (A2) $\text{col}(\tilde{Y}) \subseteq \text{col}(\tilde{F})$ ，即存在 $V^* \in \mathbb{R}^{K \times M}$ 使得 $\tilde{Y} = \tilde{F}V^*$ 。
 - (A3) $V(0)$ 的条目进行小且独立的随机初始化，均值为零，方差为 α^2 ，其中 $0 < \alpha \ll 1$ ，因此以高概率有 $\|V(0)\|_F = O(\alpha\sqrt{KM})$ 。
 - (A4) 零均值中心化： $1^\top \tilde{F} = 0$ 且 $1^\top \tilde{Y} = 0$ 。
- $G_{\tilde{F}}(t)$ 的小时间展开，并证明
 - $G_{\tilde{F}}(t)$ 的长时间衰减行为，针对
 - 对于小的 t ， $G_{\tilde{F}}(t)$ 中的主导项是

- 对于 $\eta = 0$ 且 $\tilde{Y} \in \text{col}(\tilde{F})$ 可实现时,
- 对于 $\eta > 0$, $E(t)$ 和 $V(t)$ 指数收敛到
- 不同标记上的总概率 $q(t) := \sum_{l \in \mathcal{D}_i} p_{il}(t)$ 满足
- 对于每个常见标记 $l \in \mathcal{C}_i$,
- $\dot{q} \geq q(1-q)\Gamma$ 且对所有 $t \geq T$ 有 $q(t) \geq \gamma$;

注意 (A4) 是可选的。它简化了一些解释, 但主要分析并不需要它。

我们通过最小化以下目标来训练一个线性读出器 $V \in \mathbb{R}^{K \times M}$

$$J(V) = \frac{1}{2}(\|\tilde{Y} - \tilde{F}V\|_F^2 + \eta\|V\|_F^2), \quad \eta \geq 0. \quad (37)$$

我们定义 (矩阵) 预测误差和反向传播到 $\tilde{F}$ 的梯度 $G_{\tilde{F}}$ 为

$$E(t) := \tilde{Y} - \tilde{F}V(t) \in \mathbb{R}^{n \times M}, \quad G_{\tilde{F}}(t) := E(t)V(t)^\top \in \mathbb{R}^{n \times K}. \quad (38)$$

注意, 在正文中, 我们使用 G_F 表示未中心化特征矩阵 F 上的反向传播梯度, 即 $G_F = P_1^\perp G_{\tilde{F}}$, 其中 $P_1^\perp := I - 11^\top/n$ 是沿样本维度的零均值投影矩阵。如下文所示, $G_{\tilde{F}}$ 的主导项是 $\tilde{Y}\tilde{Y}^\top \tilde{F}$, 因此

$$G_F = P_1^\perp G_{\tilde{F}} \propto P_1^\perp \tilde{Y}\tilde{Y}^\top \tilde{F} = \tilde{Y}\tilde{Y}^\top \tilde{F} = \tilde{Y}\tilde{Y}^\top F. \quad (39)$$

因为 $1^\top \tilde{F} = 0$ 且 $1^\top \tilde{Y} = 0$ 。

我们考虑 V 的连续时间梯度流:

$$\frac{dV(t)}{dt} = -\nabla_V J(V(t)). \quad (40)$$

J 关于 V 的梯度为

$$\nabla_V J(V) = \tilde{F}^\top (\tilde{F}V - \tilde{Y}) + \eta V = AV - B, \quad A := \tilde{F}^\top \tilde{F} + \eta I_K, \quad B := \tilde{F}^\top \tilde{Y}. \quad (41)$$

我们研究梯度流动力学

$$\frac{dV}{dt} = -\nabla_V J(V) = -AV + B. \quad (42)$$

定义误差矩阵和反向传播到 $\tilde{F}$ 的梯度为

$$E(t) := \tilde{Y} - \tilde{F}V(t) \in \mathbb{R}^{n \times M}, \quad G_{\tilde{F}}(t) := E(t)V(t)^\top \in \mathbb{R}^{n \times K}.$$

我们的目标是理解:

主导项是 $\tilde{Y}\tilde{Y}^\top \tilde{F}$; 以及 $\eta = 0$ 和 $\eta > 0$ 的情况。

C.1 $G_{\tilde{F}}$ 在初始时间点的动力学

C.1.1 短时展开与主导项

将 $t = 0$ 处的泰勒展开写为

$$V(t) = V_0 + tV_1 + O(t^2), \quad E(t) = E_0 + tE_1 + O(t^2),$$

其中 $V_0 := V(0)$, $E_0 := \tilde{Y} - \tilde{F}V_0$ 。由 (42),

$$V_1 = \left. \frac{dV}{dt} \right|_{t=0} = -AV_0 + B = -(\tilde{F}^\top \tilde{F} + \eta I_K)V_0 + \tilde{F}^\top \tilde{Y}. \quad (43)$$

对 $E(t) = \tilde{Y} - \tilde{F}V(t)$ 求导得

$$E_1 = \left. \frac{dE}{dt} \right|_{t=0} = -\tilde{F}V_1 = \tilde{F}(\tilde{F}^\top \tilde{F} + \eta I_K)V_0 - \tilde{F}\tilde{F}^\top \tilde{Y}. \quad (44)$$

现在展开 $G_{\tilde{F}}(t)$:

$$G_{\tilde{F}}(t) = E(t)V(t)^\top = (E_0 + tE_1)(V_0 + tV_1)^\top + O(t^2) = E_0V_0^\top + t(E_0V_1^\top + E_1V_0^\top) + O(t^2).$$

利用 $E_0 = \tilde{Y} - \tilde{F}V_0$ 及 (43) 中的 V_1 ,

$$\begin{aligned} E_0V_1^\top &= (\tilde{Y} - \tilde{F}V_0)(-V_0^\top(\tilde{F}^\top \tilde{F} + \eta I_K) + \tilde{Y}^\top \tilde{F}) \\ &= \tilde{Y}\tilde{Y}^\top \tilde{F} - \tilde{F}V_0\tilde{Y}^\top \tilde{F} - \tilde{Y}V_0^\top(\tilde{F}^\top \tilde{F} + \eta I_K) + \tilde{F}V_0V_0^\top(\tilde{F}^\top \tilde{F} + \eta I_K). \end{aligned}$$

除 $\tilde{Y}\tilde{Y}^\top \tilde{F}$ 外, 每一项都包含 (至少一个因子) V_0 , 因此在 Frobenius 范数下为 $O(\alpha)$ 。此外, $E_1V_0^\top$ 也包含 V_0 :

$$E_1V_0^\top = \tilde{F}(\tilde{F}^\top \tilde{F} + \eta I_K)V_0V_0^\top - \tilde{F}\tilde{F}^\top \tilde{Y}V_0^\top,$$

故 $\|E_1V_0^\top\|_F = O(\alpha)$ 。

因此我们得到短时展开

$$G_{\tilde{F}}(t) = \underbrace{\tilde{Y}V_0^\top}_{O(\alpha)} + t\tilde{Y}\tilde{Y}^\top \tilde{F} + tR_1(V_0) + O(t^2), \quad (45)$$

其中 $R_1(V_0)$ 收集了所有包含 V_0 的 t 阶项, 因而满足 $\|R_1(V_0)\|_F = O(\alpha)$ 。

C.1.2 为什么 $\tilde{Y}\tilde{Y}^\top \tilde{F}$ 是主导项

我们现在使用范数不等式比较确定性项 $\tilde{Y}\tilde{Y}^\top \tilde{F}$ 与依赖于 V_0 的项。

Lemma 9 ($\|\tilde{Y}\tilde{Y}^\top \tilde{F}\|_F$ 的下界). 设 $\tilde{F}$ 列满秩且 $\tilde{Y}$ 非零。则

$$\|\tilde{Y}\tilde{Y}^\top \tilde{F}\|_F \geq \sigma_{\min}(\tilde{F}) \|\tilde{Y}\tilde{Y}^\top\|_F > 0,$$

其中 $\sigma_{\min}(\tilde{F})$ 是 $\tilde{F}$ 的最小奇异值。

证明. 对于任意矩阵 A, B , $\|AB\|_F^2 = \text{tr}(BB^\top A^\top A)$ 。取 $A = \tilde{Y}\tilde{Y}^\top$, $B = \tilde{F}$ 。由于 $BB^\top$ 是半正定的, 其特征值下界为 $\sigma_{\min}(\tilde{F})^2$,

$$\|AB\|_F^2 = \text{tr}(BB^\top A^\top A) \geq \sigma_{\min}(\tilde{F})^2 \text{tr}(A^\top A) = \sigma_{\min}(\tilde{F})^2 \|A\|_F^2.$$

取平方根即得结果。 $\square$

接下来, 界定依赖于 V_0 的部分。为具体起见, 考虑项 $\tilde{F}\tilde{F}^\top \tilde{Y}V_0^\top$ (其他混合项可用类似方式界定)。利用 $\|AB\|_F \leq \|A\|_F \|B\|_F$,

$$\|\tilde{F}\tilde{F}^\top \tilde{Y}V_0^\top\|_F \leq \|\tilde{F}\tilde{F}^\top \tilde{Y}\|_F \|V_0\|_F.$$

在方差为 α^2 的独立同分布初始化下, $\|V_0\|_F = O(\alpha\sqrt{KM})$, 因此

$$\|\tilde{F}\tilde{F}^\top \tilde{Y}V_0^\top\|_F = O(\alpha).$$

同样的论证适用于 $R_1(V_0)$ 中所有其他依赖于 V_0 的 t 阶项。

将引理 9 与这些上界结合, 得到

$$\frac{\|R_1(V_0)\|_F}{\|\tilde{Y}\tilde{Y}^\top \tilde{F}\|_F} \leq C(\tilde{F}, \tilde{Y}, K, M) \alpha$$

其中常数 C 与 α 无关。因此, 在极限 $\alpha \rightarrow 0$ (小随机初始化) 下, 项 $\tilde{Y}\tilde{Y}^\top \tilde{F}$ 是 t 阶上唯一的主导贡献。

Proposition 1 ($G_{\tilde{F}}$ 的小时间主导项). 在假设 (A1)–(A2) 及尺度 $\alpha \ll 1$ 的小随机初始化下,

$$G_{\tilde{F}}(t) = \tilde{Y}V_0^\top + t\tilde{Y}\tilde{Y}^\top\tilde{F} + O(t\alpha + t^2)$$

按 Frobenius 范数成立。特别地, 当 $\alpha \rightarrow 0$ 时,

$$\frac{G_{\tilde{F}}(t) - \tilde{Y}V_0^\top}{t} \rightarrow \tilde{Y}\tilde{Y}^\top\tilde{F}, \quad \text{且} \quad \|G_{\tilde{F}}(t)\|_F \sim t \|\tilde{Y}\tilde{Y}^\top\tilde{F}\|_F$$

对于固定的较小 t 成立, 无论 $\eta = 0$ 还是 $\eta > 0$ 。

关于 η 作用的备注。 权重衰减参数 η 仅出现在涉及 V_0 的乘积中, 因此所有依赖于 η 的 t 阶贡献在范数上也是 $O(\alpha)$ 。所以主导确定性项 $\tilde{Y}\tilde{Y}^\top\tilde{F}$ 对于 $\eta = 0$ 和 $\eta > 0$ 是相同的。

C.2 $G_{\tilde{F}}$ 的长时间衰减

我们现在分析 $G_{\tilde{F}}(t)$ 当 $t \rightarrow \infty$ 时的行为, 同样针对 $\eta = 0$ 和 $\eta > 0$ 两种情况。

C.2.1 梯度流的通解

由 (42), 梯度流是一个常系数线性常微分方程。唯一的固定点 V^* 满足

$$AV^* = B \quad \Rightarrow \quad V^* = A^{-1}B.$$

定义 $\Delta V(t) := V(t) - V^*$ 。那么

$$\frac{d}{dt}\Delta V(t) = -A\Delta V(t), \quad \Delta V(t) = e^{-At}\Delta V(0),$$

因此

$$V(t) = e^{-At}(V(0) - V^*) + V^*. \quad (46)$$

令 $\lambda_{\min}(A)$ 表示 A 的最小特征值。由于 $A \succeq \tilde{F}^\top\tilde{F}$ 且 $\tilde{F}$ 列满秩, 当 $\eta = 0$ 时 $\lambda_{\min}(A) \geq \sigma_{\min}(\tilde{F})^2$, 当 $\eta > 0$ 时 $\lambda_{\min}(A) \geq \sigma_{\min}(\tilde{F})^2 + \eta$ 。矩阵指数的标准界给出

$$\|\Delta V(t)\|_F \leq e^{-\lambda_{\min}(A)t} \|\Delta V(0)\|_F. \quad (47)$$

误差满足

$$E(t) = \tilde{Y} - \tilde{F}V(t) = \tilde{Y} - \tilde{F}V^* - \tilde{F}\Delta V(t) =: E^* - \tilde{F}\Delta V(t),$$

其中 $E^* := \tilde{Y} - \tilde{F}V^*$ 是最小值点处的残差。利用 $\|\tilde{F}\Delta V(t)\|_F \leq \|\tilde{F}\|_2 \|\Delta V(t)\|_F$ 和 (47),

$$\|E(t) - E^*\|_F \leq \|\tilde{F}\|_2 e^{-\lambda_{\min}(A)t} \|\Delta V(0)\|_F. \quad (48)$$

C.2.2 情形 $\eta = 0$

当 $\eta = 0$ 时, 我们有 $A = \tilde{F}^\top\tilde{F}$ 。根据假设 (A2), 模型恰好能实现 $\tilde{Y} = \tilde{F}V^*$, 所以 $E^* = 0$, 即

$$\lim_{t \rightarrow \infty} E(t) = 0.$$

方程 (47) 和 (48) 意味着指数衰减:

$$\|V(t) - V^*\|_F \leq e^{-\sigma_{\min}(\tilde{F})^2 t} \|V(0) - V^*\|_F, \quad \|E(t)\|_F \leq \|\tilde{F}\|_2 e^{-\sigma_{\min}(\tilde{F})^2 t} \|V(0) - V^*\|_F.$$

现在我们可以界定 $G_{\tilde{F}}(t)$:

$$G_{\tilde{F}}(t) = E(t)V(t)^\top,$$

所以

$$\|G_{\tilde{F}}(t)\|_F \leq \|E(t)\|_F \|V(t)\|_2 \leq \|E(t)\|_F (\|V^*\|_2 + \|V(t) - V^*\|_2). \quad (49)$$

利用上述指数界以及 $\|V(t) - V^*\|_2 \leq \|V(t) - V^*\|_F$ 这一事实，我们得到

$$\|G_{\tilde{F}}(t)\|_F \leq C_0 e^{-\sigma_{\min}(\tilde{F})^2 t}$$

其中常数 C_0 依赖于 $\tilde{F}$ 、 V^* 和 $V(0)$ ，但不依赖于 t 。

因此，在可实现的、无正则化的情形下，反向传播的梯度指数衰减到零。

Proposition 2 ($\eta = 0$ 时 $G_{\tilde{F}}$ 的指数衰减). 假设 (A1)–(A2) 且 $\eta = 0$ 。那么

$$\lim_{t \rightarrow \infty} G_{\tilde{F}}(t) = 0,$$

且存在 $C_0 > 0$ 使得

$$\|G_{\tilde{F}}(t)\|_F \leq C_0 e^{-\sigma_{\min}(\tilde{F})^2 t} \quad \text{对所有 } t \geq 0.$$

使用奇异值分解 $\tilde{F} = U\Sigma W^\top$ 的更精细分析表明， $G_{\tilde{F}}(t)$ 的每个奇异方向都是指数函数 $e^{-(\sigma_i^2 + \sigma_{i'}^2)t}$ 和 $e^{-\sigma_i^2 t}$ 的有限线性组合，因此 Frobenius 范数中最慢的衰减速率确实是 $e^{-\sigma_{\min}(\tilde{F})^2 t}$ 。

C.2.3 情形 $\eta > 0$

当 $\eta > 0$ 时，最小化子 $V^* = A^{-1}\tilde{F}^\top \tilde{Y}$ 是岭解。通常它并不精确插值 $\tilde{Y}$ ，且残差

$$E^* := \tilde{Y} - \tilde{F}V^*$$

非零。因此，极限反向传播梯度

$$G_{\tilde{F}}^* := \lim_{t \rightarrow \infty} G_{\tilde{F}}(t) = E^* V^{*\top}$$

通常也非零。

为研究收敛性，记

$$G_{\tilde{F}}(t) - G_{\tilde{F}}^* = E(t)V(t)^\top - E^* V^{*\top} = (E(t) - E^*)V(t)^\top + E^*(V(t) - V^*)^\top.$$

利用 (47)–(48) 及 $\|AB\|_F \leq \|A\|_F \|B\|_2$ ，我们得到

$$\begin{aligned} \|G_{\tilde{F}}(t) - G_{\tilde{F}}^*\|_F &\leq \|E(t) - E^*\|_F \|V(t)\|_2 + \|E^*\|_F \|V(t) - V^*\|_2 \\ &\leq (\|\tilde{F}\|_2 \|V(0) - V^*\|_F \|V(t)\|_2 + \|E^*\|_F \|V(0) - V^*\|_F) e^{-\lambda_{\min}(A)t}. \end{aligned}$$

由于 $\|V(t)\|_2$ 有界（它收敛于 $\|V^*\|_2$ ），这表明 $G_{\tilde{F}}(t)$ 以指数速度收敛到 $G_{\tilde{F}}^*$ 。因此，我们有以下命题：

Proposition 3 ($\eta > 0$ 时 $G_{\tilde{F}}$ 的指数收敛性). 假设 (A1)–(A2) 且 $\eta > 0$ 。则

$$\lim_{t \rightarrow \infty} G_{\tilde{F}}(t) = G_{\tilde{F}}^* := E^* V^{*\top} \neq 0 \quad \text{通常成立,}$$

且存在 $C_1 > 0$ 使得

$$\|G_{\tilde{F}}(t) - G_{\tilde{F}}^*\|_F \leq C_1 e^{-\lambda_{\min}(A)t}, \quad \lambda_{\min}(A) \geq \sigma_{\min}(\tilde{F})^2 + \eta.$$

最后，注意

$$G_{\tilde{F}}^* = E^* V^{*\top} = P_\eta \tilde{Y} V^{*\top} = \eta(\tilde{F} \tilde{F}^\top + \eta I)^{-1} \tilde{Y} \tilde{Y}^\top \tilde{F}(\tilde{F}^\top \tilde{F} + \eta I)^{-1} \quad (50)$$

其中 $P_\eta := I - \tilde{F}(\tilde{F}^\top \tilde{F} + \eta I)^{-1} \tilde{F}^\top = \eta(\tilde{F} \tilde{F}^\top + \eta I)^{-1}$ ，由 Woodbury 矩阵公式可得。

总结。

$t \tilde{Y} \tilde{Y}^\top \tilde{F}$ ，与 η 无关。所有其他项（包括涉及 $V(0)$ 和 η 的项）在初始化尺度 α 下均为低阶项。误差 $E(t)$ 和 $G_{\tilde{F}}(t)$ 均以至少 $\sigma_{\min}(\tilde{F})^2$ 的速率指数衰减至零。 (E^*, V^*) ，且 $G_{\tilde{F}}(t)$ 指数收敛于一个非零极限 $G_{\tilde{F}}^* = E^* V^{*\top}$ 。

C.3 通过 β 缩放网络输出

我们现在通过在网络输出前插入一个标量因子 $\beta > 0$ 来修改目标函数：

$$J(V) = \frac{1}{2} \|\tilde{Y} - \beta \tilde{F} V\|_F^2, \quad \tilde{F} \in \mathbb{R}^{n \times K}, \tilde{Y} \in \mathbb{R}^{n \times M}, V \in \mathbb{R}^{K \times M}. \quad (51)$$

我们研究 V 的梯度流动力学，特别是 $\tilde{F}$ 上反向传播梯度的初始行为，

$$G_{\tilde{F}}(t) := E(t)V(t)^\top, \quad E(t) := \tilde{Y} - \beta \tilde{F} V(t).$$

如前所述，我们假设一个小的随机初始化 $V(0) = V_0$ ，其元素独立同分布，均值为零，方差为 α^2 ，因此当 $\alpha \ll 1$ 时，有 $\|V_0\|_F = O(\alpha\sqrt{KM})$ 。

带输出缩放的梯度流。 J 关于 V 的梯度为

$$\nabla_V J(V) = \beta \tilde{F}^\top (\beta \tilde{F} V - \tilde{Y}) = \beta^2 \tilde{F}^\top \tilde{F} V - \beta \tilde{F}^\top \tilde{Y}. \quad (52)$$

梯度流为

$$\frac{dV}{dt} = -\nabla_V J(V) = -\beta^2 \tilde{F}^\top \tilde{F} V + \beta \tilde{F}^\top \tilde{Y}. \quad (53)$$

我们定义

$$E(t) := \tilde{Y} - \beta \tilde{F} V(t), \quad G_{\tilde{F}}(t) := E(t)V(t)^\top.$$

在 $t = 0$ 时，

$$V_0 := V(0), \quad E_0 := E(0) = \tilde{Y} - \beta \tilde{F} V_0.$$

$G_{\tilde{F}}(t)$ 的小时间展开我们展开

$$V(t) = V_0 + tV_1 + O(t^2), \quad E(t) = E_0 + tE_1 + O(t^2),$$

其中 $V_1 = \frac{dV}{dt}|_{t=0}$, $E_1 = \frac{dE}{dt}|_{t=0}$ 。由 (53)，

$$V_1 = -\beta^2 \tilde{F}^\top \tilde{F} V_0 + \beta \tilde{F}^\top \tilde{Y}. \quad (54)$$

对 $E(t) = \tilde{Y} - \beta \tilde{F} V(t)$ 求导得

$$E_1 = \frac{dE}{dt}|_{t=0} = -\beta \tilde{F} V_1 = \beta^3 \tilde{F} \tilde{F}^\top \tilde{F} V_0 - \beta^2 \tilde{F} \tilde{F}^\top \tilde{Y}. \quad (55)$$

现在展开 $G_{\tilde{F}}(t)$ ：

$$\begin{aligned} G_{\tilde{F}}(t) &= E(t)V(t)^\top \\ &= (E_0 + tE_1)(V_0 + tV_1)^\top + O(t^2) \\ &= E_0 V_0^\top + t(E_0 V_1^\top + E_1 V_0^\top) + O(t^2). \end{aligned}$$

t 的零阶项。利用 $E_0 = \tilde{Y} - \beta \tilde{F} V_0$,

$$G_{\tilde{F}}(0) = E_0 V_0^\top = \tilde{Y} V_0^\top - \beta \tilde{F} V_0 V_0^\top. \quad (56)$$

因此在 $t = 0$ 时，我们有一个 $O(\beta^0)$ 项和一个 $O(\beta^1)$ 项，两者都与随机初始化成正比。

t 的一阶项。接下来我们计算 $E_0 V_1^\top$ 和 $E_1 V_0^\top$ ，并跟踪 β 的所有幂次。

由 (54)， $V_1^\top = -\beta^2 V_0^\top \tilde{F}^\top \tilde{F} + \beta \tilde{Y}^\top \tilde{F}$ ，因此

$$\begin{aligned} E_0 V_1^\top &= (\tilde{Y} - \beta \tilde{F} V_0)(-\beta^2 V_0^\top \tilde{F}^\top \tilde{F} + \beta \tilde{Y}^\top \tilde{F}) \\ &= \tilde{Y}(-\beta^2 V_0^\top \tilde{F}^\top \tilde{F}) + \tilde{Y}(\beta \tilde{Y}^\top \tilde{F}) - \beta \tilde{F} V_0(-\beta^2 V_0^\top \tilde{F}^\top \tilde{F}) - \beta \tilde{F} V_0(\beta \tilde{Y}^\top \tilde{F}) \\ &= \underbrace{\beta \tilde{Y} \tilde{Y}^\top \tilde{F}}_{\text{不含 } V_0, \text{ 阶数 } \beta} - \beta^2 \tilde{Y} V_0^\top \tilde{F}^\top \tilde{F} + \beta^3 \tilde{F} V_0 V_0^\top \tilde{F}^\top \tilde{F} - \beta^2 \tilde{F} V_0 \tilde{Y}^\top \tilde{F}. \end{aligned}$$

由 (55),

$$E_1 V_0^\top = \beta^3 \tilde{F} \tilde{F}^\top \tilde{F} V_0 V_0^\top - \beta^2 \tilde{F} \tilde{F}^\top \tilde{Y} V_0^\top.$$

将它们相加,

$$\begin{aligned} E_0 V_1^\top + E_1 V_0^\top &= \beta \tilde{Y} \tilde{Y}^\top \tilde{F} \\ &\quad - \beta^2 (\tilde{Y} V_0^\top \tilde{F}^\top \tilde{F} + \tilde{F} V_0 \tilde{Y}^\top \tilde{F} + \tilde{F} \tilde{F}^\top \tilde{Y} V_0^\top) \\ &\quad + \beta^3 (\tilde{F} V_0 V_0^\top \tilde{F}^\top \tilde{F} + \tilde{F} \tilde{F}^\top \tilde{F} V_0 V_0^\top). \end{aligned} \quad (57)$$

合并同类项。将 V_0 无关项和 V_0 相关项分开处理较为方便。定义

$$\begin{aligned} R_2(V_0) &:= -(\tilde{Y} V_0^\top \tilde{F}^\top \tilde{F} + \tilde{F} V_0 \tilde{Y}^\top \tilde{F} + \tilde{F} \tilde{F}^\top \tilde{Y} V_0^\top), \\ R_3(V_0) &:= \tilde{F} V_0 V_0^\top \tilde{F}^\top \tilde{F} + \tilde{F} \tilde{F}^\top \tilde{F} V_0 V_0^\top. \end{aligned}$$

则式 (57) 可写为

$$E_0 V_1^\top + E_1 V_0^\top = \beta \tilde{Y} \tilde{Y}^\top \tilde{F} + \beta^2 R_2(V_0) + \beta^3 R_3(V_0).$$

因此, $G_{\tilde{F}}(t)$ 的小时间展开为

$$\boxed{G_{\tilde{F},\beta}(t) = \underbrace{\tilde{Y} V_0^\top - \beta \tilde{F} V_0 V_0^\top}_{G_{\tilde{F},\beta}(0)} + t \left[\beta \tilde{Y} \tilde{Y}^\top \tilde{F} + \beta^2 R_2(V_0) + \beta^3 R_3(V_0) \right] + O(t^2).} \quad (58)$$

β 的阶次与小初始化的相互作用。在小初始化假设 $\|V_0\|_F = O(\alpha\sqrt{KM})$ 以及 $\tilde{F}, \tilde{Y}$ 有界的条件下, 我们有

$$\|R_2(V_0)\|_F = O(\|V_0\|_F) = O(\alpha), \quad \|R_3(V_0)\|_F = O(\|V_0\|_F^2) = O(\alpha^2).$$

因此, 对于固定的 β ,

$$\beta^2 \|R_2(V_0)\|_F = O(\beta^2 \alpha), \quad \beta^3 \|R_3(V_0)\|_F = O(\beta^3 \alpha^2).$$

相比之下, V_0 无关项 $\beta \tilde{Y} \tilde{Y}^\top \tilde{F}$ 的范数为

$$\|\beta \tilde{Y} \tilde{Y}^\top \tilde{F}\|_F = \beta \|\tilde{Y} \tilde{Y}^\top \tilde{F}\|_F,$$

其中因子 $\|\tilde{Y} \tilde{Y}^\top \tilde{F}\|_F$ 在 $\tilde{Y} \neq 0$ 且 $\tilde{F}$ 列满秩时严格为正。

因此, 在小随机初始化 ($\alpha \ll 1$) 的机制下, $G_{\tilde{F},\beta}(t)$ 的 $O(t)$ 主导贡献为

$$t \beta \tilde{Y} \tilde{Y}^\top \tilde{F},$$

而 V_0 相关的修正项则被因子 $\beta^2 \alpha$ 和 $\beta^3 \alpha^2$ 所抑制。

类似地, $G_{\tilde{F},\beta}(+\infty)$ 的最终不动点可以通过将式 50 中的 $\tilde{Y}$ 替换为 $\tilde{Y}/\beta$ 来计算:

$$G_{\tilde{F},\beta}^* = \frac{1}{\beta^2} G_{\tilde{F}}^* \quad (59)$$

因此, 如果 $\beta > 1$ 较大, 那么 $G_{\tilde{F},\beta}(+\infty)$ 的最终不动点会导致更小的反向传播梯度 G_F , 并可能延迟顿悟现象。




图 1: 在模加法任务中 ($M = 71$), 当隐藏节点数 K 相对于 M 较小时, Adam 优化器与 Muon 优化器的对比。Muon 优化器取得了比 Adam 更低的测试损失。




图 2: 使用具有 ReLU 激活函数的 2、3 和 4 层网络训练模加法任务。左图: 训练准确率和损失。右图: 最底层学习到的特征。随着层数增加, 训练时间变长, 顿悟 (延迟泛化) 现象变得更加显著。然而, 最底层的特征仍然是傅里叶基的 (扭曲版本), 这与第 ?? 节的分析一致。

D 更多实验

D.1 使用群算法编程 (GAP) 获取非阿贝尔群

GAP (<https://www.gap-system.org/>) 是一种编程语言, 拥有一个包含数千个用于创建和操作群的函数库。使用 GAP, 可以轻松枚举所有规模 $M \leq 127$ 的非阿贝尔群并创建它们的乘法表, 这正是我们在此所做的工作。从这些非阿贝尔群中, 对于每个群规模 M , 我们选取一个用于我们的标度律实验 (图 ?? 右下), 其中 $\max_k d_k = 2$ 。

D.2 零初始化加速特征学习过程




图 3: 使用实数权重训练模加法任务 ($M = 23, 41, 89, 127$)。学习率为 0.005, 权重衰减为 $5e-5$ 。隐藏节点数 $K = 256$ 。测试样本为完整 M^2 集合的 20%。使用 Adam 优化器。对 5 个随机种子取平均。这是一个基线。




图 4: 使用复数权重训练模加法任务 ($M = 23, 41, 89, 127$)。学习率为 0.005, 权重衰减为 $5e-5$ 。隐藏节点数 $K = 256$ 。测试样本为完整 M^2 集合的 20%。使用 Adam 优化器。对 5 个随机种子取平均。与实数情况 (图 3) 相比, 使用复数权重的模型似乎更快地实现了“顿悟”。




图 5: 使用实数权重训练模加法任务 ($M = 23, 41, 89, 127$)。在每次梯度更新中, 我们不再使用梯度下降来更新顶层权重 V , 而是使用关于当前 F 的岭回归解 V_{ridge} (命题 ??)。学习率为 0.005, 权重衰减为 $5e-5$ 。隐藏节点数 $K = 256$ 。测试样本为完整 M^2 集合的 20%。使用 Adam 优化器。对 5 个随机种子取平均。“顿悟”现象仍然发生 (对于 $M = 23$, 为完整起见请查看图 6)。与基线 (图 3) 相比, 对于 $M = 23$ 它发生得更慢, 但对于 $M = 41, 89, 127$ 实际上更快。




图 6: 使用实数权重训练模加法任务 $M = 23$ 共 500 个周期, 使用 V_{ridge} 作为顶层权重。“顿悟”现象仍然发生, 但对于 $M = 23$ 比基线 (图 3) 更慢。




图 7: 零初始化加速了 $M = 41$ 时的特征学习过程。超参数设置请参见图 9。蓝色线表示对 V 进行零初始化 (即 $V(0) = 0$), 红色线表示常规初始化。




图 8: 零初始化加速了 $M = 89$ 时的特征学习过程。超参数设置请参见图 9。蓝色线表示对 V 进行零初始化 (即 $V(0) = 0$), 红色线表示常规初始化。




图 9: 零初始化加速了 $M = 127$ 时的特征学习过程。学习率为 0.005。使用 Adam 优化器。 $\eta = 5e-5$ 。 $K = 1024$ 。 $\sigma(x) = x^2$ 且使用 MSE 损失。Top_layer_init_multiplier = 0 表示 $V(0) = 0$ ，即顶层初始化为 0（蓝色线）。若 Top_layer_init_multiplier = 1，则 V 为常规初始化（红色线）。显然，零初始化比常规初始化导致更快的顿悟（以及特征学习），尤其是在数据稀疏时。




图 10: 零初始化加速了多层设置下的特征学习过程。other_layers = 1 表示在顶层 V 和底层 W 之间添加一个带有残差连接的额外隐藏层, 依此类推。学习率为 0.005。使用 Adam 优化器。

$\eta = 1e-4$ 。 $K = 2048$ 。 $\sigma(x) = \text{ReLU}(x)$ 且使用均方误差损失。Top_layer_init_multiplier = 0 表示 $V(0) = 0$, 即顶层初始化为 0 (蓝色线条)。如果 Top_layer_init_multiplier = 1, 则 V 按常规方式初始化 (红色线条)。显然, 在多层设置中, 零初始化比常规初始化能带来快得多的特征学习速度 (通常快 $10\times$)。