

从 Grokking 学习动力学中推导特征涌现的可证明缩放定律

Yuandong Tian

Meta Superintelligence Labs (FAIR) & 独立研究员

yuandong.tian@gmail.com

Abstract

尽管延迟泛化的现象（即 grokking）已被广泛研究，但对于复杂结构化输入，是否存在一个数学框架能够刻画何种特征会涌现、如何以及在何种条件下发生，并且仍然与训练过程的梯度动力学紧密相连，这仍然是一个开放性问题。我们提出了一个名为 Li_2 的新框架，该框架捕捉了双层非线性网络 grokking 行为的三个关键阶段：(I) 惰性 学习，(II) 独立 特征学习，以及 (III) 交互 特征学习。在惰性学习阶段，顶层过拟合于随机的隐藏层表示，模型表现出记忆现象；与此同时，来自顶层的反向传播梯度 G_F 携带了关于目标标签的信息，并具有特定的结构，使得每个隐藏节点能够独立地学习其表示。此外，这种独立动力学精确地遵循能量函数 $\mathcal{E}$ 的梯度上升过程，其局部极大值点正是涌现的特征。我们研究了这些由局部最优诱导的特征是否可泛化、它们的表示能力，以及在群算术任务中它们如何随样本量变化。当隐藏节点在学习的后期阶段开始交互时，我们可证明地展示了 G_F 如何变化以聚焦于需要学习的缺失特征。我们的研究揭示了权重衰减、学习率和样本量等关键超参数在 grokking 中所扮演的角色，推导了特征涌现、记忆和泛化的可证明缩放定律，并从梯度动力学的基本原理揭示了为何近期优化器（如 Muon）可能有效的根本原因。我们的分析可以扩展到多层架构。代码已公开¹。

1 引言

尽管 Transformer 等现代深度模型已取得令人瞩目的实证性能，但这些模型如何在训练过程中获取知识仍是一个谜。关于模型是否能真正泛化到训练数据之外，还是仅仅记忆数据集并在分布外（OOD）数据上表现不佳，一直存在持续的争论 (???)。

对记忆与泛化行为进行建模一直是许多工作的目标。其中一种被称为 顿悟 (grokking) 的行为 (?????) 表明，模型最初会过拟合训练集，然后在持续训练后突然泛化到未见过的测试样本。对此存在多种解释，例如有效理论 (??)、记忆与泛化电路效率 (?)、以及将权重衰减视为先验的贝叶斯解释 (?) 等。大多数工作侧重于直接解释其经验行为，或利用极宽网络的性质 (???)，但很少有研究通过分析权重上的梯度动力学来深入探索顿悟学习过程的细节。

在本工作中，我们提出了一个数学框架 Li_2 ，将双层非线性网络的顿悟动力学划分为三个主要阶段（图 1）。阶段 I: 惰性学习 (Lazy Learning): 训练开始时，顶层（输出层）首先利用隐藏层的随机特征进行学习，同时，反向传播到隐藏层的梯度 G_F 开始携带关于目标标

¹<https://github.com/yuandong-tian/understanding/tree/main/ssl/real-dataset/cogo>




图 1: 我们的框架 Li_2 概述。 Li_2 提出了学习过程的三个阶段: (I) 懒 惰学习、(II) 独 立特征学习以及 (III) 交 互特征学习, 用以解释网络先记忆后泛化的“顿悟”动态 (详见 Fig. ??)。我们的分析超越了神经正切核 (NTK) 和平均场机制, 并借助能量函数 $\mathcal{E}$ (Thm. ??) 以及影响过程的多个关键因素, 具体刻画了特征如何从梯度动态中涌现。具体而言, 我们将学习到的特征刻画为 $\mathcal{E}$ 的局部极大值 (Thm. ??), 并给出了维持这些特征所需的样本量 (Thm. ??), 从而建立了泛化/记忆的标度律。

签的有用信号 (命题 ??)。阶段 II: 独立特征学习 (Independent feature learning): G_F 驱动隐藏层表示的学习。在此阶段, 第 j 个神经元 (节点) 的反向传播梯度仅取决于其自身的激活, 从而触发每个节点的独立特征学习。阶段 III: 交互式特征学习 (Interactive feature learning): 当隐藏层权重被更新且不再独立时, 节点间的相互作用会调整已学习的特征以最小化损失。

我们对每个阶段进行了详细研究。在阶段 I 中, 我们表明反向传播梯度 G_F 所携带的信号要么出现在初始阶段 (Proposition ??), 这取决于顶层的初始化; 要么出现在最终阶段 (Lemma ??), 这取决于权重衰减 η 。在阶段 II 中, 我们发现支配独立特征学习的动态过程精确地遵循能量函数 $\mathcal{E}$ 的梯度上升 (Thm. ??), 这对应于输入 X 与目标 Y 之间的非线性典型相关分析 (CCA)。在群算术任务中, 我们完整刻画了 $\mathcal{E}$ 的局部极大值结构 (Thm. ??), 每个极大值代表一个学习到的特征。我们进一步证明, 训练样本的数量决定了这些特征/局部最优是否保持稳定 (Thm. ??), 决定了它们是否可泛化, 从而决定了泛化与记忆的标度律。在阶段 III 中, 我们可证明地表明, 当一部分特征被学习后, 具有相似激活的隐藏节点之间存在一种促进多样性的推力 (Thm. ??), 反向传播梯度 G_F 会发生变化, 推动模型关注缺失的特征以最小化损失 (Thm. ??), 而像 Muon (?) 这样的优化器则进一步提升了多样性 (Thm. ??)。在图算术任务上的实验支持了我们的主张, 例如, 所证明的关于泛化/记忆边界的标度律 (Thm. ??) 与实验数据吻合良好 (Fig. ??)。与现有顿悟框架的比较。我们的框架从第一性原理 (即梯度动力学) 提供了理论基础, 解释了经验假设?: “泛化电路 C_{gen} 比记忆电路 C_{mem} 更高效但学习更慢”。具体而言, 我们表明数据分布决定了优化景观, 而优化景观进而控制权重收敛到哪个局部最优解, 从而导致记忆或泛化的行为。我们还表明, 初始的记忆化, 或称惰性学习 (阶段 I), 必须发生在特征学习 (阶段 II-III) 之前, 因为前者为后者开始发展提供了有意义的反向传播梯度 G_F 。相比之下, (?) 也提供了一个三阶段的顿悟框架, 但主要基于经验观察。利用我们的框架, 我们提供了一个系统性的框架来解释顿悟何时以及为何发生, 这与许多经验观察结果一致 (第 ??节)。

我们的研究超越了神经正切核 (NTK) (??) 和平均场机制 (?), 在这些机制中隐藏权重从初始化开始没有发生实质性更新。我们的框架具体展示了特征如何从梯度动力学中涌现, 以及影响该过程的多个关键因素。

摘要。 我们的框架 Li_2 将网络训练过程划分为三个阶段 (Lazy、independent、interactive), 并提供了对顿悟动态和特征学习的见解。

- 顿悟行为的解释。在顿悟开始时, 惰性学习对应于记忆, 其中顶层利用随机特征找到一个 (临时的) 解决方案来解释目标。此后, 反向传播的梯度 G_F 才变得有意义, 并导致隐藏层学习可泛化的、涌现的特征。正则化会加速顿悟。

- 涌现特征 是控制独立阶段的能量函数 $\mathcal{E}$ 的局部最大值。这些特征在标签预测上比简单的记忆更高效。
- 数据 控制着 $\mathcal{E}$ 的景观。充足的训练数据维持这些可泛化局部最大值的形状，而数据不足则会导致不可泛化的局部最大值。
- 特征涌现、泛化与记忆的缩放定律 可以通过检查景观如何随数据分布变化而推导出来。
- 独立特征学习。 $\Pr[w \rightarrow \zeta_l] = p_l := \mu_l^a / \sum_l \mu_l^a$ 。那么获得所有局部最大值的期望节点数为 $T_0 \geq \max\left(1/\min_l p_l, \sum_{l=1}^L 1/l\right)$ 。
- Muon 引导。如果我们使用 Muon 优化器顺序优化 K 个节点，那么获得所有局部最大值的期望节点数为 $T_a = 2^{-a}T_0 + (1 - 2^{-a})L$ 。对于大的 a ， $T_a \sim L$ 。

(A) 如果 ϕ 在 $(0, \sqrt{2}]$ 上非递减，则唯一的极大值是记忆（峰值）解

$$s_{g^*}^* = \sqrt{2}, \quad s_{g \neq g^*}^* = 0,$$

由 $u = \frac{1}{\sqrt{2}}e_{g^*}$ ， $v = \frac{1}{\sqrt{2}}e_{(g^*)^{-1}h}$ 实现。

(B) 如果 ϕ 在 $(0, \infty)$ 上严格递减，则唯一的极大值分散，并由下式给出

$$s_g^* = \phi^{-1}\left(\frac{2\lambda}{p_g}\right) \quad (\text{对所有满足 } 2\lambda/p_g < \phi(0^+) \text{ 的 } g),$$

且对于任何满足 $2\lambda/p_g \geq \phi(0^+)$ 的 g （如果 $\phi(0^+) < \infty$ ），有 $s_g^* = 0$ 。乘子 $\lambda > 0$ 由预算 $\sum_g (s_g^*)^2 = 2$ 唯一确定。特别地，如果 $\phi(0^+) = \infty$ （例如， $[0, \infty)$ 上的 ReLU: $\phi(x) = 1/x$ ；SiLU: $\phi(x) = \frac{\text{sigmoid}(x)}{x} + \text{sigmoid}(x)(1 - \text{sigmoid}(x))$ ），则所有坐标都严格为正，且

$$p_i > p_j \implies s_i^* > s_j^* > 0.$$

- 对于幂激活函数 $\sigma(x) = x^q$ ($q \geq 2$)，有 $\phi(x) = q x^{q-2}$ 非递减；定理 ??(A) 给出记忆解。在所有情况下，峰值解由均等分割实现 $u = \frac{1}{\sqrt{2}}e_{g^*}$ ， $v = \frac{1}{\sqrt{2}}e_{(g^*)^{-1}h}$ ；任何分布 s^* 都可以用例如 $u_g = v_{g^{-1}h} = s_g^*/2$ 实现。
- $[0, \infty)$ 上的 ReLU: $\sigma(x) = x$ ， $\phi(x) = 1/x$ 严格递减；定理 ??(B) 得出 $s^* \propto p$ 。
- SiLU/Swish/Tanh/Sigmoid: ϕ 严格递减且 $\phi(0^+) = \infty$ ；定理 ??(B) 给出严格有序的分散解 $s_g^* = \phi^{-1}(2\lambda/p_g)$ 。

(A1) $\tilde{F}$ 具有满列秩 K ，且

(A2) $\text{col}(\tilde{Y}) \subseteq \text{col}(\tilde{F})$ ，即存在 $V^* \in K \times M$ 使得 $\tilde{Y} = \tilde{F}V^*$ 。

(A3) 对 $V(0)$ 的条目进行小且独立的随机初始化，均值为零，方差为 α^2 ，其中 $0 < \alpha \ll 1$ ，因此以高概率有 $\|V(0)\|_F = O(\alpha\sqrt{KM})$ 。

(A4) 零均值中心化: $1^\top \tilde{F} = 0$ 且 $1^\top \tilde{Y} = 0$ 。

- 小时间展开 $G_{\tilde{F}}(t)$ 并证明其主导项为 $\tilde{Y}\tilde{Y}^\top \tilde{F}$ ；以及
- 长时间衰减行为 $G_{\tilde{F}}(t)$ ，针对 $\eta = 0$ 和 $\eta > 0$ 两种情况。

1.1 $G_{\tilde{F}}$ 在初始时间戳处的动力学

1.1.1 小时间展开与主导项

在 $t = 0$ 处写出泰勒展开式：

$$V(t) = V_0 + tV_1 + O(t^2), \quad E(t) = E_0 + tE_1 + O(t^2),$$

其中 $V_0 := V(0)$ 且 $E_0 := \tilde{Y} - \tilde{F}V_0$ 。由 (??),

$$V_1 = \frac{dV}{dt}\Big|_{t=0} = -AV_0 + B = -(\tilde{F}^\top \tilde{F} + \eta I_K)V_0 + \tilde{F}^\top \tilde{Y}. \quad (1)$$

对 $E(t) = \tilde{Y} - \tilde{F}V(t)$ 求导得

$$E_1 = \frac{dE}{dt}\Big|_{t=0} = -\tilde{F}V_1 = \tilde{F}(\tilde{F}^\top \tilde{F} + \eta I_K)V_0 - \tilde{F}\tilde{F}^\top \tilde{Y}. \quad (2)$$

现在展开 $G_{\tilde{F}}(t)$:

$$G_{\tilde{F}}(t) = E(t)V(t)^\top = (E_0 + tE_1)(V_0 + tV_1)^\top + O(t^2) = E_0V_0^\top + t(E_0V_1^\top + E_1V_0^\top) + O(t^2).$$

利用 $E_0 = \tilde{Y} - \tilde{F}V_0$ 和来自 (1) 的 V_1 ,

$$\begin{aligned} E_0V_1^\top &= (\tilde{Y} - \tilde{F}V_0)(-V_0^\top(\tilde{F}^\top \tilde{F} + \eta I_K) + \tilde{Y}^\top \tilde{F}) \\ &= \tilde{Y}\tilde{Y}^\top \tilde{F} - \tilde{F}V_0\tilde{Y}^\top \tilde{F} - \tilde{Y}V_0^\top(\tilde{F}^\top \tilde{F} + \eta I_K) + \tilde{F}V_0V_0^\top(\tilde{F}^\top \tilde{F} + \eta I_K). \end{aligned}$$

除 $\tilde{Y}\tilde{Y}^\top \tilde{F}$ 外, 每一项都包含 (至少一个因子) V_0 , 因此在 Frobenius 范数下是 $O(\alpha)$ 。此外, $E_1V_0^\top$ 也包含 V_0 :

$$E_1V_0^\top = \tilde{F}(\tilde{F}^\top \tilde{F} + \eta I_K)V_0V_0^\top - \tilde{F}\tilde{F}^\top \tilde{Y}V_0^\top,$$

所以 $\|E_1V_0^\top\|_F = O(\alpha)$ 同样成立。因此我们得到小时间展开式:

$$G_{\tilde{F}}(t) = \underbrace{\tilde{Y}V_0^\top}_{O(\alpha)} + t\tilde{Y}\tilde{Y}^\top \tilde{F} + tR_1(V_0) + O(t^2), \quad (3)$$

其中 $R_1(V_0)$ 收集了所有包含 V_0 的一阶 t 项, 因此满足 $\|R_1(V_0)\|_F = O(\alpha)$ 。

1.1.2 为何 $\tilde{Y}\tilde{Y}^\top \tilde{F}$ 是主导项

我们现在使用范数不等式比较确定性项 $\tilde{Y}\tilde{Y}^\top \tilde{F}$ 与依赖于 V_0 的项。

Lemma 1 ($\|\tilde{Y}\tilde{Y}^\top \tilde{F}\|_F$ 的下界). 设 $\tilde{F}$ 列满秩且 $\tilde{Y}$ 非零。则

$$\|\tilde{Y}\tilde{Y}^\top \tilde{F}\|_F \geq \sigma_{\min}(\tilde{F}) \|\tilde{Y}\tilde{Y}^\top\|_F > 0,$$

其中 $\sigma_{\min}(\tilde{F})$ 是 $\tilde{F}$ 的最小奇异值。

证明. 对于任意矩阵 A, B , $\|AB\|_F^2 = \text{tr}(BB^\top A^\top A)$ 。取 $A = \tilde{Y}\tilde{Y}^\top$, $B = \tilde{F}$ 。由于 $BB^\top$ 是半正定的, 其特征值下界为 $\sigma_{\min}(\tilde{F})^2$,

$$\|AB\|_F^2 = \text{tr}(BB^\top A^\top A) \geq \sigma_{\min}(\tilde{F})^2 \text{tr}(A^\top A) = \sigma_{\min}(\tilde{F})^2 \|A\|_F^2.$$

取平方根即得结果。 $\square$

接下来, 界定依赖于 V_0 的部分。为具体起见, 考虑项 $\tilde{F}\tilde{F}^\top \tilde{Y}V_0^\top$ (其他混合项可用类似方式界定)。利用 $\|AB\|_F \leq \|A\|_F \|B\|_F$,

$$\|\tilde{F}\tilde{F}^\top \tilde{Y}V_0^\top\|_F \leq \|\tilde{F}\tilde{F}^\top \tilde{Y}\|_F \|V_0\|_F.$$

在方差为 α^2 的独立同分布初始化下, $\|V_0\|_F = O(\alpha\sqrt{KM})$, 因此

$$\|\tilde{F}\tilde{F}^\top \tilde{Y}V_0^\top\|_F = O(\alpha).$$

同样的论证适用于 $R_1(V_0)$ 中所有其他依赖于 V_0 的 t 阶项。将引理 1 与这些上界结合, 得到

$$\frac{\|R_1(V_0)\|_F}{\|\tilde{Y}\tilde{Y}^\top \tilde{F}\|_F} \leq C(\tilde{F}, \tilde{Y}, K, M) \alpha$$

其中常数 C 与 α 无关。因此, 在极限 $\alpha \rightarrow 0$ (小随机初始化) 下, 项 $\tilde{Y}\tilde{Y}^\top \tilde{F}$ 是 t 阶上唯一的主导贡献。

Proposition 1 ($G_{\tilde{F}}$ 的小时间主导项). 在假设 (A1)–(A2) 及尺度 $\alpha \ll 1$ 的小随机初始化下,

$$G_{\tilde{F}}(t) = \tilde{Y}V_0^\top + t\tilde{Y}\tilde{Y}^\top\tilde{F} + O(t\alpha + t^2)$$

在 Frobenius 范数意义下成立。特别地, 当 $\alpha \rightarrow 0$ 时,

$$\frac{G_{\tilde{F}}(t) - \tilde{Y}V_0^\top}{t} \rightarrow \tilde{Y}\tilde{Y}^\top\tilde{F}, \quad \text{且} \quad \|G_{\tilde{F}}(t)\|_F \sim t \|\tilde{Y}\tilde{Y}^\top\tilde{F}\|_F$$

对于固定的较小 t 成立, 且与 $\eta = 0$ 或 $\eta > 0$ 无关。

关于 η 作用的备注。 权重衰减参数 η 仅出现在涉及 V_0 的乘积中, 因此所有依赖于 η 的 t 阶贡献在范数上也是 $O(\alpha)$ 。所以, 主导的确定性项 $\tilde{Y}\tilde{Y}^\top\tilde{F}$ 对于 $\eta = 0$ 和 $\eta > 0$ 是相同的。

1.2 $G_{\tilde{F}}$ 的长时间衰减

我们现在分析 $G_{\tilde{F}}(t)$ 在 $t \rightarrow \infty$ 时的行为, 同样针对 $\eta = 0$ 和 $\eta > 0$ 两种情况。

1.2.1 梯度流的通解

由 (??), 梯度流是一个常系数线性常微分方程。唯一的固定点 V^* 满足

$$AV^* = B \quad \Rightarrow \quad V^* = A^{-1}B.$$

定义 $\Delta V(t) := V(t) - V^*$ 。那么

$$\frac{d}{dt}\Delta V(t) = -A\Delta V(t), \quad \Delta V(t) = e^{-At}\Delta V(0),$$

因此

$$V(t) = e^{-At}(V(0) - V^*) + V^*. \quad (4)$$

令 $\lambda_{\min}(A)$ 表示 A 的最小特征值。由于 $A \succeq \tilde{F}^\top\tilde{F}$ 且 $\tilde{F}$ 列满秩, 当 $\eta = 0$ 时 $\lambda_{\min}(A) \geq \sigma_{\min}(\tilde{F})^2$, 当 $\eta > 0$ 时 $\lambda_{\min}(A) \geq \sigma_{\min}(\tilde{F})^2 + \eta$ 。矩阵指数的标准界给出

$$\|\Delta V(t)\|_F \leq e^{-\lambda_{\min}(A)t} \|\Delta V(0)\|_F. \quad (5)$$

误差满足

$$E(t) = \tilde{Y} - \tilde{F}V(t) = \tilde{Y} - \tilde{F}V^* - \tilde{F}\Delta V(t) =: E^* - \tilde{F}\Delta V(t),$$

其中 $E^* := \tilde{Y} - \tilde{F}V^*$ 是最小值点处的残差。利用 $\|\tilde{F}\Delta V(t)\|_F \leq \|\tilde{F}\|_2 \|\Delta V(t)\|_F$ 和 (5),

$$\|E(t) - E^*\|_F \leq \|\tilde{F}\|_2 e^{-\lambda_{\min}(A)t} \|\Delta V(0)\|_F. \quad (6)$$

1.2.2 情形 $\eta = 0$

当 $\eta = 0$ 时, 我们有 $A = \tilde{F}^\top\tilde{F}$ 。根据假设 (A2), 模型恰好能实现 $\tilde{Y} = \tilde{F}V^*$, 所以 $E^* = 0$, 即

$$\lim_{t \rightarrow \infty} E(t) = 0.$$

方程 (5) 和 (6) 意味着指数衰减:

$$\|V(t) - V^*\|_F \leq e^{-\sigma_{\min}(\tilde{F})^2 t} \|V(0) - V^*\|_F, \quad \|E(t)\|_F \leq \|\tilde{F}\|_2 e^{-\sigma_{\min}(\tilde{F})^2 t} \|V(0) - V^*\|_F.$$

现在我们可以界定 $G_{\tilde{F}}(t)$:

$$G_{\tilde{F}}(t) = E(t)V(t)^\top,$$

因此

$$\|G_{\tilde{F}}(t)\|_F \leq \|E(t)\|_F \|V(t)\|_2 \leq \|E(t)\|_F (\|V^*\|_2 + \|V(t) - V^*\|_2). \quad (7)$$

利用上述指数界以及 $\|V(t) - V^*\|_2 \leq \|V(t) - V^*\|_F$ 这一事实，我们得到

$$\|G_{\tilde{F}}(t)\|_F \leq C_0 e^{-\sigma_{\min}(\tilde{F})^2 t}$$

其中常数 C_0 依赖于 $\tilde{F}$ 、 V^* 和 $V(0)$ ，但不依赖于 t 。因此，在可实现且无正则化的情形下，反向传播的梯度指数衰减至零。

Proposition 2 ($\eta = 0$ 时 $G_{\tilde{F}}$ 的指数衰减). 假设 (A1)–(A2) 且 $\eta = 0$ 。那么

$$\lim_{t \rightarrow \infty} G_{\tilde{F}}(t) = 0,$$

且存在 $C_0 > 0$ 使得

$$\|G_{\tilde{F}}(t)\|_F \leq C_0 e^{-\sigma_{\min}(\tilde{F})^2 t} \quad \text{对所有 } t \geq 0.$$

使用奇异值分解 $\tilde{F} = U\Sigma W^\top$ 的更精细分析表明， $G_{\tilde{F}}(t)$ 的每个奇异方向都是指数函数 $e^{-(\sigma_i^2 + \sigma_{i'}^2)t}$ 和 $e^{-\sigma_i^2 t}$ 的有限线性组合，因此 Frobenius 范数下的最慢衰减速率确实是 $e^{-\sigma_{\min}(\tilde{F})^2 t}$ 。

1.2.3 情形 $\eta > 0$

当 $\eta > 0$ 时，最小化器 $V^* = A^{-1}\tilde{F}^\top \tilde{Y}$ 是岭回归解。通常它并不精确插值 $\tilde{Y}$ ，且残差

$$E^* := \tilde{Y} - \tilde{F}V^*$$

非零。因此，极限反向传播梯度

$$G_{\tilde{F}}^* := \lim_{t \rightarrow \infty} G_{\tilde{F}}(t) = E^*V^{*\top}$$

通常也非零。为研究收敛性，记

$$G_{\tilde{F}}(t) - G_{\tilde{F}}^* = E(t)V(t)^\top - E^*V^{*\top} = (E(t) - E^*)V(t)^\top + E^*(V(t) - V^*)^\top.$$

利用 (5)–(6) 及 $\|AB\|_F \leq \|A\|_F \|B\|_2$ ，我们得到

$$\begin{aligned} \|G_{\tilde{F}}(t) - G_{\tilde{F}}^*\|_F &\leq \|E(t) - E^*\|_F \|V(t)\|_2 + \|E^*\|_F \|V(t) - V^*\|_2 \\ &\leq \left(\|\tilde{F}\|_2 \|V(0) - V^*\|_F \|V(t)\|_2 + \|E^*\|_F \|V(0) - V^*\|_F \right) e^{-\lambda_{\min}(A)t}. \end{aligned}$$

由于 $\|V(t)\|_2$ 有界（它收敛到 $\|V^*\|_2$ ），这表明 $G_{\tilde{F}}(t)$ 以指数速度收敛到 $G_{\tilde{F}}^*$ 。因此，我们有以下命题：

Proposition 3 ($\eta > 0$ 时 $G_{\tilde{F}}$ 的指数收敛性). 假设 (A1)–(A2) 且 $\eta > 0$ 。则

$$\lim_{t \rightarrow \infty} G_{\tilde{F}}(t) = G_{\tilde{F}}^* := E^*V^{*\top} \neq 0 \quad \text{通常成立,}$$

且存在 $C_1 > 0$ 使得

$$\|G_{\tilde{F}}(t) - G_{\tilde{F}}^*\|_F \leq C_1 e^{-\lambda_{\min}(A)t}, \quad \lambda_{\min}(A) \geq \sigma_{\min}(\tilde{F})^2 + \eta.$$

最后，注意

$$G_{\tilde{F}}^* = E^*V^{*\top} = P_\eta \tilde{Y}V^{*\top} = \eta(\tilde{F}\tilde{F}^\top + \eta I)^{-1} \tilde{Y}\tilde{Y}^\top \tilde{F}(\tilde{F}^\top \tilde{F} + \eta I)^{-1} \quad (8)$$

其中 $P_\eta := I - \tilde{F}(\tilde{F}^\top \tilde{F} + \eta I)^{-1} \tilde{F}^\top = \eta(\tilde{F}\tilde{F}^\top + \eta I)^{-1}$ ，由 Woodbury 矩阵公式可得。

总结。

- 对于小的 t ， $G_{\tilde{F}}(t)$ 中的主导项是 $t\tilde{Y}\tilde{Y}^\top \tilde{F}$ ，与 η 无关。所有其他项（包括涉及 $V(0)$ 和 η 的项）在初始化尺度 α 下都是低阶的。

- 对于 $\eta = 0$ 且 $\tilde{Y} \in \text{col}(\tilde{F})$ 可实现的情形, 误差 $E(t)$ 和 $G_{\tilde{F}}(t)$ 均以至少 $\sigma_{\min}(\tilde{F})^2$ 的速率指数衰减到零。
- 对于 $\eta > 0$, $E(t)$ 和 $V(t)$ 指数收敛到 (E^*, V^*) , 且 $G_{\tilde{F}}(t)$ 指数收敛到一个非零极限 $G_{\tilde{F}}^* = E^* V^{*\top}$ 。
- 在独特标记上的总概率 $q(t) := \sum_{l \in \mathcal{D}_i} p_{il}(t)$ 满足 $\dot{q} \geq q(1-q)\Gamma$ 且对所有 $t \geq T$ 有 $q(t) \geq \gamma$;
- 对每个常见标记 $l \in \mathcal{C}_i$,

$$\dot{p}_{il}(t) \leq -q(t)\Gamma(t)p_{il}(t), \quad p_{il}(t) \leq p_{il}(T) \exp\left(-\int_T^t q(s)\Gamma(s)ds\right) \rightarrow 0.$$

证明. 由定理 ??, $\dot{p}_{il} = p_{il}(r_{il} - \bar{r}_i)$ 。对 $l \in \mathcal{D}_i$ 与 $l \in \mathcal{C}_i$ 分别取平均得

$$\dot{q} = \sum_{l \in \mathcal{D}_i} p_{il}(r_{il} - \bar{r}_i) = \underbrace{\sum_{l \in \mathcal{D}_i} p_{il}r_{il}}_A - q\bar{r}_i = (1-q)A - q(1-q) \underbrace{\sum_{l \in \mathcal{C}_i} \frac{p_{il}}{1-q}r_{il}}_{\leq c(t)} \geq q(1-q)\Gamma(t),$$

其中 $\Gamma(t) := d(t) - c(t)$, 且我们使用了 $A \geq qd(t)$ 。此外, 对每个常见标记 l ,

$$\dot{p}_{il} = p_{il}(r_{il} - \bar{r}_i) \leq p_{il}(c(t) - [qd(t) + (1-q)c(t)]) = -q(t)\Gamma(t)p_{il}.$$

由引理 ??, 在 $t = 0$ 时我们有 $\Gamma(0) \geq \delta_0 - \varepsilon > 0$, 因此 $\dot{q} \geq q(1-q)\Gamma(0)$ 且 $q(t)$ 以逻辑增长方式上升, 在有限时间 T 内穿过任意固定的 $\gamma \in (0, 1)$ 。对于 $t \geq T$, 有 $q(t) \geq \gamma$ 且 $\Gamma(t) \geq \delta_0 - \varepsilon - (2\sqrt{2} + C)R\text{TV}_{\max}(t)$ 。由于 $\text{TV}_{\max}(t)$ 保持有界 (且通常随着质量转移到独特标记而减小), 积分 $\int_T^t q(s)\Gamma(s)ds$ 发散, 从而得到 $p_{il}(t) \rightarrow 0$ 。更进一步, 如果注意力保持足够分散使得 $\Gamma(t) \geq \delta_0 - \varepsilon - \epsilon_\star > 0$, 那么 $p_{il}(t) \leq p_{il}(T)e^{-\gamma(\delta_0 - \varepsilon - \epsilon_\star)(t-T)}$ 呈指数衰减。□