

通过可扩展查找实现的条件记忆： 大语言模型稀疏性的新维度

程欣^{1,2}, 曾望鼎², 戴大迈², 陈沁宇², 王炳轩²,
谢振达², 黄科钊², 余星凯², 郝哲文², 李宇坤², 张晗²,
张辉帅¹, 赵东岩¹, 梁文锋²
¹ 北京大学 ² 深度求索人工智能公司
{zhanghuishuai, zhaody}@pku.edu.cn
{chengxin, zengwangding, damai.dai}@deepseek.com

Abstract

虽然专家混合模型 (MoE) 通过条件计算扩展了模型容量, 但 Transformer 缺乏原生的知识查找原语, 迫使其通过计算低效地模拟检索过程。为解决此问题, 我们引入了条件记忆作为补充的稀疏化维度, 并通过 **Engram** 模块实现, 该模块将经典的 N -gram 嵌入现代化, 用于 $O(1)$ 查找。通过形式化 *Sparsity Allocation* 问题, 我们发现了一个 U 形缩放定律, 该定律优化了神经计算 (MoE) 与静态记忆 (Engram) 之间的权衡。在此定律指导下, 我们将 Engram 扩展到 270 亿参数, 其性能优于严格的等参数和等 FLOPs 的 MoE 基线。最值得注意的是, 虽然预期记忆模块有助于知识检索 (例如 MMLU +3.4; CMMLU +4.0), 但我们观察到在通用推理 (例如 BBH +5.0; ARC-Challenge +3.7) 和代码/数学领域 (HumanEval +3.0; MATH +2.4) 有更大的增益。机制分析表明, Engram 解除了主干网络早期层进行静态重构的负担, 有效地加深了网络以进行复杂推理。此外, 通过将局部依赖关系委托给查找操作, 它释放了注意力机制处理全局上下文的能力, 从而显著提升了长上下文检索性能 (例如 Multi-Query NIAH: 84.2 $\rightarrow$ 97.0)。最后, Engram 实现了面向基础设施的效率: 其确定性寻址机制支持从主机内存进行运行时预取, 产生的开销可忽略不计。我们设想条件记忆将成为下一代稀疏模型中不可或缺的建模原语。代码发布于: <https://github.com/deepseek-ai/Engram>

Contents

1	Introduction	2
2	Architecture	4
2.1	Overview	4
2.2	Sparse Retrieval via Hashed N -grams	5
2.3	Context-aware Gating	5

15	2.4	Integration with Multi-branch Architecture	6
16	2.5	System Efficiency: Decoupling Compute and Memory	7
17	3	Large Scale Pre-training	7
18	3.1	Experimental Setup	9
19	3.2	Experimental Results	10
20	4	Long Context Training	10
21	4.1	Experimental Setup	11
22	4.2	Experimental Results	11
23	5	Analysis	12
24	5.1	Is Engram functionally equivalent to increasing the model' s depth?	12
25	5.1.1	Accelerated Prediction Convergence	14
26	5.1.2	Representational Alignment and Effective Depth	14
27	5.2	Structural Ablation and Layer Sensitivity	15
28	5.3	Sensitivity Analysis	16
29	5.4	System Efficiency	17
30	5.5	Case Study: Gating Visualization	18
31	6	Related Work	18
32	7	Conclusion	20
33	A	Detailed Model Architecture and Hyper Parameters	33
34	B	Full Benchmark Curves	33
35	C	Case Study of Tokenizer Compression	35

36 1. Introduction

37 稀疏性是智能系统的一个反复出现的设计原则，从生物神经回路 (Lennie, 2003; Olshausen and
38 Field, 1997) 到现代大语言模型 (LLMs) 皆是如此。目前，这一原则主要通过混合专家 (MoE)

(Dai et al., 2024; Shazeer et al., 2017) 实现，它通过条件计算来扩展模型容量。得益于其能够大幅增加模型规模而无需按比例增加计算量，MoE 已成为前沿模型 (Comanici et al., 2025; Guo et al., 2025; Team et al., 2025) 的事实标准。

尽管这种条件计算范式取得了成功，但语言信号的内在异质性表明在 *structural optimization* 方面仍有巨大改进空间。具体而言，语言建模包含两个性质不同的子任务：组合推理和知识检索。前者需要深度、动态的计算，而文本的很大一部分——例如命名实体和公式化模式——是局部的、静态的且高度刻板的 (Constant et al., 2017; Erman, 2000)。经典的 N -gram 模型 (Brants et al., 2007; Liu et al., 2024b; Nguyen, 2024) 在捕捉此类局部依赖关系方面的有效性意味着，这些规律性很自然地表现为计算成本低廉的查找操作。由于标准 Transformer (Vaswani et al., 2017) 缺乏原生的知识查找原语，当前的大语言模型被迫 **simulate retrieval through computation**。例如，解析一个常见的多词元实体需要消耗注意力机制和前馈网络 (Ghandeharioun et al., 2024; Jin et al., 2025) 的多个早期层（参见表 3）。这个过程本质上相当于对一个静态查找表进行昂贵的运行时重建，将宝贵的序列深度浪费在琐碎的操作上，而这些深度本可以分配给更高层次的推理。

为了使模型架构与这种语言二元性保持一致，我们主张一个互补的稀疏性维度：条件记忆。条件计算稀疏地激活参数以处理动态逻辑 (Bengio et al., 2013; Shazeer et al., 2017)，而条件记忆则依赖于稀疏的查找操作来检索固定知识的静态嵌入。作为对该范式的初步探索，我们重新审视 N -gram 嵌入 (Bojanowski et al., 2017) 作为一种典型实例：局部上下文作为键，通过恒定时间的 $O(1)$ 查找 (Huang et al., 2025a; Pagnoni et al., 2025; Tito Svenstrup et al., 2017; Yu et al., 2025) 来索引一个庞大的嵌入表。我们的研究表明，或许令人惊讶的是，这种静态检索机制可以成为现代 MoE 架构的理想补充——但前提是设计得当。在本文中，我们提出 **Engram**，这是一个基于经典 N -gram 结构的条件记忆模块，但配备了现代化的改进，例如分词器压缩、多头哈希、上下文门控和多分支集成（详见节 2）。为了量化这两种基本组件之间的协同效应，我们提出了 *Sparsity Allocation* 问题：在固定的总参数量预算下，应如何在 MoE 专家和 Engram 记忆之间分配容量？我们的实验揭示了一个独特的 U 形缩放定律，表明即使是简单的查找机制，当被视为一等建模基元时，也能作为神经计算的重要补充。

依据此分配定律的指导，我们将 Engram 扩展为一个 270 亿参数的模型。与严格同参数、同 FLOPs 的 MoE 基线相比，Engram-27B 在多个领域实现了更优的效率。关键的是，其优势不仅限于知识密集型任务（例如，MMLU: +3.4; CMMLU: +4.0; MMLU-Pro: +1.8），在这些任务中记忆容量直观上是有益的；我们甚至在通用推理（例如，BBH: +5.0; ARC-Challenge: +3.7; DROP: +3.3）以及代码/数学领域（例如，HumanEval: +3.0; MATH: +2.4; GSM8K: +2.2）观察到了更显著的改进。

通过 LogitLens (nostalgebraist, 2020) 和 CKA (Hendrycks et al., 2021a) 进行的机制分析揭示了这些收益的来源：Engram 减轻了主干网络在早期层重构静态知识的负担，从而增加了可用于复杂推理的有效深度。此外，通过将局部依赖关系委托给查找操作，Engram 释放了注意力容量以专注于全局上下文，从而在长上下文场景中实现了卓越的性能——在 LongPPL (Fang et al.)

75 和 RULER (Hsieh et al.) 上显著优于基线（例如，Multi-Query NIAH: 97.0 vs. 84.2; Variable
76 Tracking: 89.0 vs. 77.0）。

77 最后，我们将基础设施感知的效率确立为一等原则。与 MoE 的动态路由不同，Engram 采
78 用确定性 ID 来实现运行时预取，使通信与计算重叠。实证结果表明，将一个 1000 亿参数的表
79 卸载到主机内存所产生的开销可忽略不计（< 3%）。这证明 Engram 有效地绕过了 GPU 内存限
制，促进了激进的参数扩展。




Figure 1 | **The Engram Architecture.** 该模块通过检索静态的 N -gram 记忆，并通过上下文感知门控将其与动态隐藏状态融合，从而增强主干网络。此模块仅应用于特定层，以将记忆与计算解耦，同时保持标准输入嵌入和解嵌入模块不变。

80

81 2. Architecture

82 2.1. Overview

83 如 Figure 1 所示，Engram 是一个条件记忆模块，旨在通过结构上将静态模式存储与动态计算分
84 离来增强 Transformer 主干网络。形式上，给定输入序列 $X = (x_1, \dots, x_T)$ 和层 ℓ 处的隐藏状态
85 $\mathbf{H}^{(\ell)} \in \mathbb{R}^{T \times d}$ ，该模块分两个功能阶段处理每个位置 t : **retrieval and fusion**。首先，如 节 2.2
86 中详述，我们提取并压缩后缀 N -gram，通过哈希确定性检索静态嵌入向量。随后，在 节 2.3 中，
87 这些检索到的嵌入由当前隐藏状态动态调制，并通过轻量级卷积进行精炼。最后，我们在 节 2.4
88 中讨论与多分支架构的集成，并在 节 2.5 中讨论系统级设计。

2.2. Sparse Retrieval via Hashed N -grams

第一阶段将局部上下文映射到静态记忆条目，涉及分词器压缩和通过确定性哈希检索嵌入。

Tokenizer Compression 虽然 N -gram 模型通常直接对分词器输出进行操作，但标准子词分词器优先考虑 *lossless reconstruction*，通常为语义上等价的术语分配不相交的 ID（例如，`Apple` 与 `apple`）(Kudo and Richardson, 2018; Li et al., 2023b)。为了最大化语义密度，我们实现了一个词汇表投影层。具体来说，我们预先计算一个满射函数 $\mathcal{P} : V \rightarrow V'$ ，该函数根据规范化的文本等价性（使用 NFKC (Whistler, 2025)、小写转换等）将原始词元 ID 折叠为规范标识符。在实践中，此过程对于 128k 分词器，有效词汇量大小减少了 23%（参见 Appendix C）。形式上，对于位置 t 的词元，我们将其原始 ID x_t 映射到规范 ID $x'_t = \mathcal{P}(x_t)$ ，以形成后缀 N -gram $g_{t,n} = (x'_{t-n+1}, \dots, x'_t)$ 。

Multi-Head Hashing. 直接参数化所有可能的 N -gram 的组合空间是难以处理的。遵循 Tito Svenstrup et al. (2017)，我们采用基于哈希的方法。为了减轻冲突，我们为每个 N -gram 阶数 n 使用 K 个不同的哈希头。每个头 k 通过一个确定性函数 $\varphi_{n,k}$ 将压缩后的上下文映射到嵌入表 $\mathbf{E}_{n,k}$ （大小为质数 $M_{n,k}$ ）内的一个索引：

$$z_{t,n,k} \triangleq \varphi_{n,k}(g_{t,n}), \quad \mathbf{e}_{t,n,k} = \mathbf{E}_{n,k}[z_{t,n,k}]. \quad (1)$$

在实践中， $\varphi_{n,k}$ 被实现为一个轻量级的乘法-XOR 哈希。我们通过连接所有检索到的嵌入来构建最终的记忆向量 $\mathbf{e}_t \in \mathbb{R}^{d_{\text{mem}}}$ ：

$$\mathbf{e}_t \triangleq \parallel_{n=2}^N \parallel_{k=1}^K \mathbf{e}_{t,n,k}. \quad (2)$$

2.3. Context-aware Gating

检索到的嵌入 $\mathbf{e}_t$ 作为上下文无关的先验。然而，由于是静态的，它们本质上缺乏上下文适应性，并且可能因哈希冲突或多义性 (Haber and Poesio, 2024) 而受到噪声影响。为了增强表达能力并解决这种歧义，我们采用了受注意力机制 (Bahdanau et al., 2015; Vaswani et al., 2017) 启发的上下文感知门控机制。具体来说，我们利用当前隐藏状态 $\mathbf{h}_t$ ——它已通过先前的注意力层聚合了全局上下文——作为动态查询，而检索到的记忆 $\mathbf{e}_t$ 则作为键和值投影的来源：

$$\mathbf{k}_t = \mathbf{W}_K \mathbf{e}_t, \quad \mathbf{v}_t = \mathbf{W}_V \mathbf{e}_t \quad (3)$$

其中 $\mathbf{W}_K, \mathbf{W}_V$ 是可学习的投影矩阵。为了确保梯度稳定性 (Dehghani et al., 2023)，我们在计算标量门 $\alpha_t \in (0, 1)$ 之前对查询和键应用 RMSNorm (Zhang and Sennrich, 2019)：

$$\alpha_t = \sigma \left(\frac{\text{RMSNorm}(\mathbf{h}_t)^\top \text{RMSNorm}(\mathbf{k}_t)}{\sqrt{d}} \right). \quad (4)$$

门控输出定义为 $\tilde{\mathbf{v}}_t = \alpha_t \cdot \mathbf{v}_t$ 。这种设计强制了语义对齐：如果检索到的记忆 $\mathbf{e}_t$ 与当前上下文 $\mathbf{h}_t$ 相矛盾，门 α_t 倾向于趋近于零，从而有效地抑制噪声。




Figure 2 | **System implementation of Engram.** (a) 训练阶段：海量嵌入表被分片到可用的 GPU 上。采用 All-to-All 通信原语来跨设备检索活跃的嵌入行。(b) 推理阶段：Engram 表被卸载到主机内存。通过利用确定性检索逻辑，主机异步预取并传输嵌入，使通信与设备上前一个 Transformer 块的计算重叠。

最后，为了扩展感受野并增强模型的非线性，我们引入了一个短深度因果卷积 (Gu et al., 2022; Peng et al., 2023)。令 $\tilde{\mathbf{V}} \in \mathbb{R}^{T \times d}$ 表示门控值序列。使用核大小 w (设为 4)、膨胀率 δ (设为最大 N -gram 阶数) 和 SiLU 激活函数 (Elfwing et al., 2018)，最终输出 $\mathbf{Y}$ 计算如下：

$$\mathbf{Y} = \text{SiLU}(\text{Conv1D}(\text{RMSNorm}(\tilde{\mathbf{V}}))) + \tilde{\mathbf{V}}, \quad (5)$$

Engram 模块通过残差连接集成到主干网络中： $\mathbf{H}^{(\ell)} \leftarrow \mathbf{H}^{(\ell)} + \mathbf{Y}$ ，随后是标准的注意力层和 MoE。至关重要，Engram 并不应用于每一层；其具体放置由 节 2.5 中详述的系统级延迟约束所控制。

2.4. Integration with Multi-branch Architecture

在本工作中，我们并未采用标准的单流连接 (He et al., 2016)，而是选择了先进的多分支架构作为默认主干网络，因其卓越的建模能力 (Larsson et al., 2017; Szegedy et al., 2015; Xie et al., 2025; Zhu et al., 2025)。该架构的一个显著特征是将残差流扩展为 M 个并行分支，其中信息流由可学习的连接权重进行调制。

尽管 Engram 模块本质上是拓扑无关的，但将其适配到多分支框架中需要进行结构优化，以平衡效率与表达能力。具体而言，我们实施了一种参数共享策略：一个稀疏嵌入表和一个值投影矩阵 $\mathbf{W}_V$ 在所有 M 个分支间共享，而 M 个不同的键投影矩阵 $\{\mathbf{W}_K^{(m)}\}_{m=1}^M$ 被用来实现分支特定

129 的门控行为。对于第 m 个具有隐藏状态 $\mathbf{h}_t^{(m)}$ 的分支，其分支特定的门控信号计算如下：

$$\alpha_t^{(m)} = \sigma \left(\frac{\text{RMSNorm}(\mathbf{h}_t^{(m)})^\top \text{RMSNorm}(\mathbf{W}_K^{(m)} \mathbf{e}_t)}{\sqrt{d}} \right). \quad (6)$$

130 检索到的记忆随后由这些独立门控信号调制共享的值向量： $\mathbf{u}_t^{(m)} = \alpha_t^{(m)} \cdot (\mathbf{W}_V \mathbf{e}_t)$ 。该设计允许线
131 性投影（一个 $\mathbf{W}_V$ 和 M 个不同的 $\mathbf{W}_K^{(m)}$ ）融合为单个密集的 FP8 矩阵乘法，从而最大化现代
132 GPU 的计算利用率。除非另有说明，所有实验均采用这种与流形约束超连接 ($M = 4$) (Xie et al.,
133 2025) 的集成方式。

134 2.5. System Efficiency: Decoupling Compute and Memory

135 扩展记忆增强模型通常受到 GPU 高带宽内存 (HBM) 有限容量的制约。然而，Engram 的确定
136 性检索机制天然支持将参数存储与计算资源解耦。与依赖运行时隐藏状态进行动态路由的 MoE
137 不同，Engram 的检索索引仅依赖于输入词元序列。这种可预测性为训练和推理都提供了专门的
138 优化策略，如Figure 2所示。

139 在训练期间，为了容纳大规模的嵌入表，我们采用标准的模型并行方法，将表分片到可用的
140 GPU 上。使用 All-to-All 通信原语在前向传播中收集活跃行，并在反向传播中分发梯度，从而
141 使总内存容量能够随加速器数量线性扩展。

142 在推理期间，这种确定性特性使得预取与重叠策略成为可能。由于内存索引在前向传播之
143 前已知，系统可以通过 PCIe 异步地从充裕的主机内存中检索嵌入。为了有效掩盖通信延迟，
144 Engram 模块被放置在骨干网络中的特定层，利用前序层的计算作为缓冲区来防止 GPU 停顿。
145 这需要一种硬件-算法协同设计策略：虽然将 Engram 放置得更深可以延长用于隐藏延迟的计算
146 窗口，但我们在节 5.2 中的消融实验表明，建模性能倾向于早期介入以卸载局部模式重建。因此，
147 最优的放置必须同时满足建模和系统延迟的约束。

148 此外，自然语言的 N -元组天然遵循齐夫分布 (Chao and Zipf, 1950; Piantadosi, 2014)，其
149 中一小部分模式占据了绝大多数内存访问。这一统计特性催生了多级缓存层次结构：频繁访问
150 的嵌入可以缓存在更快的存储层级（例如 GPU HBM 或主机 DRAM）中，而长尾的罕见模式则
151 驻留在速度较慢、容量较大的介质（例如 NVMe SSD）中。这种分层使得 Engram 能够扩展到
152 海量内存容量，同时对有效延迟的影响最小。

153 3. Large Scale Pre-training

154 基于所提出的 Engram 架构和经验推导的分配定律，我们将 Engram 扩展到数十亿参数规模，以
155 验证其在现实世界语言模型预训练中的有效性。具体而言，我们训练了四个模型：(1) **Dense-4B**
156 (总计 41 亿参数)，(2) **MoE-27B** (总计 267 亿参数)，(3) **Engram-27B** (总计 267 亿参数)，以
157 及 (4) **Engram-40B** (总计 395 亿参数)。所有模型均使用相同的数据课程（相同的 token 预算
158 和顺序）进行训练，并且在激活参数数量上严格匹配。

Table 1 | **Pre-training performance comparison between dense, MoE, and Engram models.** 所有模型均训练了 262B 个词元，并在激活参数量（3.8B）上匹配。Engram-27B 通过将参数从路由专家（72 $\rightarrow$ 55）重新分配到 5.7B 参数的 Engram 记忆，实现了与 MoE-27B 的等参数量。Engram-40B 在保持激活参数量预算固定的同时，进一步增加了 Engram 记忆（18.5B 参数）。完整的训练时间基准轨迹见 [Appendix B](#)。

	Benchmark (Metric)	# Shots	Dense-4B	MoE-27B	Engram-27B	Engram-40B
	# Total Params		4.1B	26.7B	26.7B	39.5B
	# Activated (w/o token embed)		3.8B	3.8B	3.8B	3.8B
	# Trained Tokens		262B	262B	262B	262B
	# Experts (shared + routed, top- k)		-	2 + 72 (top-6)	2 + 55 (top-6)	2 + 55 (top-6)
	# Engram Params		-	-	5.7B	18.5B
Language Modeling	Pile (loss)	-	2.091	1.960	1.950	1.942
	Validation Set (loss)	-	1.768	1.634	1.622	1.610
Knowledge & Reasoning	MMLU (Acc.)	5-shot	48.6	57.4	60.4	60.6
	MMLU-Redux (Acc.)	5-shot	50.7	60.6	64.0	64.5
	MMLU-Pro (Acc.)	5-shot	21.1	28.3	30.1	31.3
	CMMLU (Acc.)	5-shot	47.9	57.9	61.9	63.4
	C-Eval (Acc.)	5-shot	46.9	58.0	62.7	63.3
	AGIEval (Acc.)	0-shot	29.1	38.6	41.8	45.9
	ARC-Easy (Acc.)	25-shot	76.8	86.5	89.0	90.1
	ARC-Challenge (Acc.)	25-shot	59.3	70.1	73.8	76.4
	TriviaQA (EM)	5-shot	33.0	48.8	50.7	51.8
	TriviaQA-ZH (EM)	5-shot	62.8	74.8	76.3	77.9
	PopQA (EM)	15-shot	15.1	19.2	19.4	21.2
	CCPM (Acc.)	0-shot	72.2	79.6	87.1	87.7
	BBH (EM)	3-shot	42.8	50.9	55.9	57.5
	HellaSwag (Acc.)	0-shot	64.3	71.8	72.7	73.1
	PIQA (Acc.)	0-shot	63.8	71.9	73.5	76.5
	WinoGrande (Acc.)	5-shot	64.0	67.6	67.8	68.1
Reading Comprehension	DROP (F1)	1-shot	41.6	55.7	59.0	60.7
	RACE-Middle (Acc.)	5-shot	72.4	80.9	82.8	83.3
	RACE-High (Acc.)	5-shot	66.0	75.4	78.2	79.2
	C3 (Acc.)	0-shot	57.7	60.1	63.6	61.8
Code & Math	HumanEval (Pass@1)	0-shot	26.8	37.8	40.8	38.4
	MBPP (Pass@1)	3-shot	35.4	46.6	48.2	46.2
	CruxEval-i (EM)	0-shot	27.6	30.7	32.2	36.2
	CruxEval-o (EM)	0-shot	28.7	34.1	35.0	35.3
	GSM8K (EM)	8-shot	35.5	58.4	60.6	62.6
	MGSM (EM)	8-shot	27.0	46.8	49.4	52.4
	MATH (EM)	4-shot	15.2	28.3	30.7	30.6

3.1. Experimental Setup

Training Data and Model Configurations 所有模型均在包含 2620 亿个标记的语料库上进行预训练，我们使用来自 DeepSeek-v3 (Liu et al., 2024a) 的分词器，其词汇表大小为 128k。在建模方面，为确保受控比较，除非另有明确说明，我们在所有模型中均遵循一致的默认设置。我们使用一个包含 30 个块的 Transformer，其隐藏层大小为 2560。每个块集成了一个具有 32 个头的多头潜在注意力 (MLA) (DeepSeek-AI et al., 2024)，并通过扩展率为 4 的 mHC (Xie et al., 2025) 连接到 FFN。所有模型均使用 Muon (Jordan et al., 2024; Team et al., 2025) 进行优化；详细的超参数列于 Appendix A 中。我们实例化了四个不同的模型：

- **Dense-4B** 作为基线模型。它采用上述骨干架构，在每个块中集成了一个标准密集 FFN。
- **MoE-27B** 将标准密集 FFN 替换为 DeepSeekMoE 模块 (Dai et al., 2024)。该模型配置了 72 个路由专家和 2 个共享专家（每个标记激活前 $k = 6$ 个路由专家），总参数量扩展至 26.7B，同时保持与 Dense-4B 相同的激活参数量。
- **Engram-27B** 严格源自 **MoE-27B** 架构以确保公平比较。我们将路由专家数量从 72 个减少到 55 个，并将释放出的参数重新分配到一个 5.7B 参数的嵌入模块 ($\rho = 74.3\%$)，使模型总大小保持在 26.7B 不变。关于 Engram 配置，我们在第 2 层和第 15 层实例化该模块，并将最大 N -gram 大小设置为 3，头数设置为 8，维度设置为 1280。在优化方面，嵌入参数使用 Adam (Kingma, 2014) 进行更新，学习率按 $5\times$ 缩放且无权重衰减，而卷积参数初始化为零，以在训练开始时严格保持恒等映射。
- **Engram-40B** 保持与 Engram-27B 相同的骨干架构和计算预算，但将稀疏嵌入模块扩展到 18.5B 参数（总计 39.5B 参数）。该模型旨在研究 Engram 的缩放特性。

Evaluation Protocol 我们在涵盖语言建模、知识、推理、阅读理解以及代码/数学的多样化基准测试套件上评估模型。对于每个基准测试，我们遵循标准的提示协议和评估指标。

- **Language Modeling:** 我们报告 The Pile (Gao et al., 2020) 测试集上的损失，以及一个从与训练数据相同分布中抽取的验证集上的损失。
- **Knowledge & Reasoning:** MMLU (Hendrycks et al., 2021a), MMLU-Redux (Gema et al., 2025), MMLU-Pro (Wang et al., 2024b), CMMLU (Li et al., 2024), C-Eval (Huang et al., 2023), AGIEval (Zhong et al., 2024), ARC-Easy/Challenge (Clark et al., 2018), TriviaQA (Joshi et al., 2017), TriviaQA-ZH (内部), PopQA (Mallen et al., 2023), CCPM (Li et al., 2021), BBH (Suzgun et al., 2023), HellaSwag (Zellers et al., 2019), PIQA (Bisk et al., 2020), 以及 WinoGrande (Sakaguchi et al., 2021)。
- **Reading Comprehension:** DROP (Dua et al., 2019), RACE (Middle/High) (Lai et al., 2017), 以及 C3 (Sun et al., 2020)。
- **Code & Math:** HumanEval (Chen et al., 2021), MBPP (Austin et al., 2021), CruxEval (Gu et al., 2024), GSM8K (Cobbe et al., 2021), MGSM (Shi et al., 2023), 以及 MATH (Hendrycks et al., 2021b)。

Table 2 | **Long-context performance comparison.** 括号内的数值（例如 *(50k, 1.62)*）表示长上下文扩展前的预训练步数及相应的损失。两个关键发现：(1) 仅使用基线预训练 FLOPs 的 82%（41k 对比 50k），Engram-27B 在 LongPPL (Fang et al.) 性能上与基线持平，同时在 RULER (Hsieh et al.) 上取得了显著更高的准确率；(2) 在等预训练损失（46k）和等预训练 FLOPs（50k）两种设置下，Engram-27B 在所有指标上都大幅优于基线。**Bold** 表示最佳，underline 表示次佳。

Model	LongPPL (32k)				RULER (32k)							
	Perplexity (↓)				NIAH Accuracy (↑)				Other Tasks (↑)			
	Book	Paper	Code	L-CoT	S	MK	MV	MQ	VT	CWE	FWE	QA
MoE-27B <i>(50k, 1.63)</i>	4.38	2.91	2.49	14.16	100.0	88.0	92.7	84.2	77.0	<u>4.5</u>	73.0	34.5
=== Ours (Engram Variants) === Engram-27B <i>(46k, 1.63)</i>	<u>4.19</u>	<u>2.84</u>	<u>2.45</u>	<u>13.59</u>	97.6	89.0	<u>95.5</u>	97.0	<u>87.2</u>	4.3	<u>98.6</u>	37.5
Engram-27B <i>(50k, 1.62)</i>	4.14	2.82	2.44	13.41	99.3	89.3	96.5	97.0	89.0	5.9	99.3	<u>40.5</u>

3.2. Experimental Results

表 1 总结了主要结果。首先，与先前文献 (Borgeaud et al., 2022; He, 2024; Shazeer et al., 2017) 一致，稀疏架构展现出比密集模型更优的缩放定律。在相同的训练计算预算下，所有三种稀疏变体（MoE-27B、Engram-27B/40B）在所有基准测试上都显著优于等 FLOPs 的 Dense-4B 基线。

更重要的是，Engram-27B 持续优于等参数量和等 FLOPs 的 MoE-27B 基线。有趣的是，这些收益并不局限于知识密集型任务（例如，MMLU: +3.0, MMLU-Pro: +1.8, CMMLU: +4.0），尽管在这些任务中，记忆容量直观上是有益的。我们在通用推理领域（例如，BBH: +5.0, ARC-Challenge: +3.7, DROP: +3.3）以及代码和数学推理领域（例如，HumanEval: +3.0, MBPP: +1.6, GSM8K: +2.2, MATH: +2.4）观察到了更显著的改进。为了减少基准测试噪声的影响并可视化训练动态，我们在 Appendix B 中提供了预训练期间完整的基准测试轨迹。这些结果支持了我们的假设：引入一个专用的知识查找原语，其表征效率的提升超越了将整个稀疏预算全部分配给条件计算所能达到的效果。

最后，扩展到 Engram-40B 进一步降低了预训练损失，并在大多数基准测试上提升了性能。尽管它尚未在所有任务上严格超越 Engram-27B，但这很可能是训练不足导致的。我们观察到，在训练接近尾声时，Engram-40B 与基线之间的训练损失差距持续扩大，这表明在当前 token 预算内，扩展的记忆容量尚未完全饱和。

4. Long Context Training

通过将局部依赖建模卸载给静态查找，Engram 架构保留了宝贵的注意力容量以管理全局上下文。在本节中，我们通过进行长上下文扩展训练 (Gao et al., 2025; Peng et al., 2024)，从经验上验证了这一结构优势。通过一个严格的评估协议，该协议将架构贡献与基础模型能力分离开来，我们证明了 Engram 在长程检索和推理任务中能带来显著增益。

4.1. Experimental Setup

Training Details. 为了启用长上下文能力，我们采用了 DeepSeek-V3 (Liu et al., 2024a) 中引入的上下文扩展策略。在预训练阶段之后，我们应用 YaRN (Peng et al., 2024) 进行上下文窗口扩展，在一个 32768 个标记的上下文训练阶段中进行 5000 步训练（使用 300 亿个标记的高质量长上下文数据）。超参数为缩放尺度 $s = 10$, $\alpha = 1$, $\beta = 32$ 和缩放因子 $f = 0.707$ 。

Model Configurations. 我们比较了四种不同模型配置下的上下文扩展效果。我们使用了 MoE-27B 和 Engram-27B 的最终预训练检查点（50k 步）。此外，为了严格评估架构效率，我们为 Engram-27B 选择了两个中间检查点，分别在 41k 步和 46k 步。尽管初始阶段不同，所有变体都遵循 *the exact same* 上下文扩展训练协议。关键的是，选择 Engram-27B（46k）是因为其预训练损失与完全训练的 MoE-27B（50k）相同。这创建了一个受控的“等损失”设置，确保在上下文扩展期间出现的任何性能差异都可归因于架构，而非模型的起始质量。

Evaluation Benchmarks. 我们使用 LongPPL (Fang et al.) 和 RULER (Hsieh et al.) 来评估长上下文性能。对于 LongPPL，我们构建了涵盖四个类别的评估集：长书籍、研究论文、代码仓库和长思维链轨迹。对于 RULER，我们在 14 个子集上进行评估，这些子集聚合为 8 个类别：单针（S）、多键（MK）、多值（MV）和多查询（MQ）大海捞针；多跳变量追踪（VT）、常见词提取（CWE）、高频词提取（FWE）和问答（QA）。

4.2. Experimental Results

评估结果总结于 表 3.2。为了准确评估印迹架构的贡献，我们的分析分两步进行：首先，将基础模型能力的影响与架构设计解耦；其次，进行受控分析。

1. Long-Context Capability Beyond Attention Mechanics. 虽然注意力机制和位置编码为上下文处理提供了结构基础 (Press et al., 2022; Su et al., 2024; Xiao et al., 2024; Yang et al., 2025)，但我们的结果表明，长上下文性能并非仅由架构先验决定。观察印迹模型的轨迹（41k $\rightarrow$ 50k），我们发现长上下文性能随着预训练的推进而单调提升，即使在控制模型架构相同且在上下文扩展阶段计算预算固定的情况下也是如此。这表明长上下文性能与基础模型的通用建模能力存在内在耦合。因此，严格的架构比较必须通过对齐基础模型损失而非仅仅对齐训练步数来控制这一混杂变量。

2. Architectural Superiority under Controlled Settings. 基于上述原则，我们将印迹模型与 MoE 基线进行基准测试。在控制基础能力的情况下，印迹模块的效率优势变得明显：

- **Iso-Loss Setting (46k vs. Baseline):** 此设置严格隔离了架构效率。当比较印迹-27B（46k）与完全训练的 MoE-27B（50k）——这些模型在预训练损失上对齐——时，印迹模型显示出显著优势。具体而言，它在复杂检索任务上优于基线（例如，多查询 NIAH: 97.0 对比 84.2; VT: 87.2 对比 77.0）。




Figure 3 | **Analysis of representational alignment and convergence speed.** (a) 通过 LogitLens (nostalgebraist, 2020) 计算的逐层 KL 散度。早期层持续较低的散度表明 Engram 加速了预测收敛。(b-c) 由 CKA (Kornblith et al., 2019) 计算的相似性热力图。高相似性对角线的明显上移表明, Engram 的浅层在功能上等同于 MoE 模型的深层, 从而有效地增加了模型的深度。

- **Iso-FLOPs Setting (50k vs. Baseline):** 在标准的等计算预算下, 印迹-27B (50k) 进一步扩大了这一差距, 在所有方面都确立了最高性能。
- **Extreme Setting ($\approx 82\%$ Compute):** 即使是提前停止训练的印迹-27B (41k), 与完全训练的 MoE-27B (50k) 相比也仍然极具竞争力。它在 LongPPL 上与基线持平, 并在 RULER 上超越基线, 突显了印迹架构的内在优越性。

5. Analysis

在本节中, 我们探究 Engram 的内部机制, 包括其有效深度 (节 5.1)、核心模块设计 (节 5.2) 和参数敏感性 (节 5.3)。此外, 我们评估了带卸载的推理吞吐量 (节 5.4), 并以一个案例研究 (节 5.5) 作为总结。

5.1. Is Engram functionally equivalent to increasing the model's depth?

当前的 LLM 缺乏专用的知识查找原语, 它们依赖计算来模拟记忆检索。如表 3 所示, 为了识别实体 "Diana, Princess of Wales", LLM 必须消耗多层注意力和前馈网络来逐步组合特征 (Ghandeharioun et al., 2024; Jin et al., 2025; Li and Subramani, 2025), 这一过程理论上可以通过知识查找操作来识别。

基于此, 我们提出, 通过为模型配备显式的知识查找能力, Engram 通过免除模型早期的特征组合阶段, 有效地模拟了模型深度的增加。为了验证这一假设, 我们使用了两种机制可解释性工具: LogitLens (Belrose et al., 2023; nostalgebraist, 2020) 和中心核对齐分析 (CKA) (Davari et al., 2023; Kornblith et al., 2019)。

Table 3 | **Entity resolution example reproduced from Ghandeharioun et al. (2024)**。本表格展示了 LLM 如何通过注意力层和前馈网络层逐步整合上下文标记，以构建实体 ``Diana, Princess of Wales'' 的内部表征。“潜在状态翻译”列显示了通过 PatchScope (Ghandeharioun et al., 2024) 为最后一个标记 ``Wales'' 自动生成的文本，而“解释”列则呈现了原作者提供的手动解释。

Layer	Latent State Translation	Explanation
1-2	: Country in the United Kingdom	Wales
3	: Country in Europe	Wales
4	: Title held by female sovereigns in their own right or by queens consort	Princess of Wales (unspecific)
5	: Title given to the wife of the Prince of Wales (and later King)	Princess of Wales (unspecific)
6	: Diana, Princess of Wales (1961-1997), the first wife of Prince Charles, Prince of Wales, who was famous for her beauty and humanitarian work	Diana, Princess of Wales

5.1.1. Accelerated Prediction Convergence

我们首先使用 LogitLens (nostalgebraist, 2020) 分析预测在不同层间的演变。通过将每个中间层的隐藏状态用最终的 LM Head 进行投影, 我们计算中间输出分布与模型最终输出分布之间的 Kullback-Leibler 散度 (Kullback and Leibler, 1951)。该指标量化了潜在表示距离”准备好进行预测” (Belrose et al., 2023; Csordás et al., 2025) 的程度。

Figure 3 (a) 报告了逐层的 KL 散度。与 MoE 基线相比, 两种 Engram 变体都表现出系统性的更小 KL 散度, 最显著的差距出现在早期块中。Engram 曲线更陡峭的下降表明模型完成特征组合的速度要快得多。这一观察结果与我们的假设一致: 通过显式访问外部知识, Engram 减少了所需的计算步骤, 从而在网络层级中更早地达到高置信度的有效预测。

5.1.2. Representational Alignment and Effective Depth

为了进一步研究记忆印迹层是否在语义上对应于基线的更深层, 我们采用了中心核对齐 (CKA), 这是一种广泛用于比较表示结构的度量标准 (Kornblith et al., 2019; Kriegeskorte et al., 2008)。给定两组表示 X 和 Y (例如, 来自不同模型或层的激活), CKA 定义为:

$$\text{CKA}(K, L) = \frac{\text{HSIC}(K, L)}{\sqrt{\text{HSIC}(K, K)\text{HSIC}(L, L)}} \quad (7)$$

其中 $K = XX^\top$ 和 $L = YY^\top$ 表示 Gram 矩阵 (使用线性核), HSIC 是希尔伯特-施密特独立性准则 (Gretton et al., 2005)。我们采用带有 HSIC 无偏估计器的小批量实现 (Davari et al., 2023), 并在 Few-NERD 数据集 (Ding et al., 2021) 上进行评估, 提取命名实体最后一个标记对应的隐藏状态。

为了严格量化层间对应关系, 我们首先计算成对 CKA 相似度矩阵 $S \in [0, 1]^{L \times L}$, 其中 L 是层数。然后我们引入一个软对齐指数 a_j , 定义为每个记忆印迹层 j 对应的前 k 个最相似的 MoE 层的加权质心:

$$a_j = \frac{\sum_{i \in \mathcal{I}_j} S_{i,j} \cdot i}{\sum_{i \in \mathcal{I}_j} S_{i,j}}, \quad \text{where } \mathcal{I}_j = \underset{i}{\text{argtopk}}(S_{i,j}). \quad (8)$$

这里, $S_{i,j}$ 表示 MoE 层 i 与记忆印迹层 j 之间的相似度分数。指数 a_j 作为记忆印迹层 j 对应的“有效 MoE 深度”的稳健代理, 利用前 k 过滤 (取 $k = 5$) 来减轻低相似度噪声。

Figure 3 (b)–(c) 可视化了叠加有软对齐曲线 (白色虚线) 的相似度热图。我们观察到一个明显的向上偏离对角线的偏移, 这意味着 $a_j > j$ 对于广泛的层范围成立。例如, Engram-27B 第 5 层形成的表示与 MoE 基线大约第 12 层的表示最为接近。

这种一致的偏离对角线偏移, 与 LogitLens 结果 (节 5.1.1) 相符, 证实了记忆印迹在更早的层实现了更深的表示。这验证了我们的核心假设: 通过显式查找绕过早期特征组合, 记忆印迹在功能上等同于增加了模型的有效深度。




Figure 4 | **Architecture ablation results.** 我们在两种设置下比较 3B MoE 基线与记忆印迹变体：(1) 层敏感性（深蓝色曲线）：扫描单个记忆印迹模块的插入深度证实，早期注入（第 2 层）是最优的，而在更深层注入效果会下降。(2) 组件消融（右侧标记）：从参考配置中移除子模块，证明了多分支集成、分词器压缩和上下文感知门控的重要性。

5.2. Structural Ablation and Layer Sensitivity

在本节中，我们在受控设置下对 Engram 进行消融研究，以探究每个关键模块设计的有效性。除非另有说明，主干网络是一个 12 层、30 亿参数的 MoE 模型（激活参数为 5.6 亿），训练了 1000 亿个词元。Figure 4 报告了验证损失。橙色虚线表示 30 亿参数 MoE 基线（验证损失 = 1.808）。

Reference configuration. 我们使用一个固定的 16 亿参数 Engram 记忆库来增强主干网络。我们的参考模型使用 {2,3}-grams 并在第 2 层和第 6 层插入 Engram，实现了验证损失 = 1.768，相较于 MoE 基线 ($\Delta = 0.04$) 有显著提升。以下所有结构消融均相对于此参考模型定义。

Where should memory be injected? 为了研究深度敏感性，我们保持 Engram 预算固定（16 亿），但将其合并为单个 Engram 模块，并将其插入层从 1 到 12 进行扫描（Figure 4 中的深蓝色“层扫描”曲线）。该实验揭示了 Engram 放置位置固有的权衡。

A placement trade-off. 早期注入 Engram 使其能够在主干网络消耗计算深度之前卸载局部模式重建，这与主干网络的自然分层处理方式一致 (Ghandeharioun et al., 2024; Jin et al., 2025; Li and Subramani, 2025; Tenney et al., 2019)。然而，这会带来门控精度的代价：早期的隐藏状态尚未通过注意力聚合足够的全局上下文，并且并行分支缺乏细粒度调制所需的表征差异 (Xie et al., 2025; Zhu et al., 2025)。因此，最优放置需要平衡 (i) 早期卸载静态局部模式和 (ii) 后期利用更强的上下文查询进行门控。

扫描结果显示，第 2 层实现了最佳的单层性能（验证损失 = 1.770），优于第 1 层，并且随




Figure 5 | **Retained performance under Engram ablation.** 事实性知识高度依赖于记忆印迹模块，而阅读理解能力则主要由骨干网络保留。

着插入点变深而性能下降。这表明，一轮注意力已经足以门控提供一个有意义的、上下文化的 $\mathbf{h}_t$ ，同时仍然足够早，可以替代主干网络底层的局部聚合。

虽然第 2 层在单次注入约束下是最优的，但我们发现，将相同的 16 亿记忆库分成两个较小的模块（通过减少嵌入维度 d_{mem} 实现）并将其放置在第 2 层和第 6 层，性能甚至更好（验证损失 = 1.768）。这种分层设计通过结合早期干预和丰富的后期上下文门控，调和了上述权衡。更重要的是，分层插入还提供了实际的系统优势，能够更好地利用内存层次结构，如节 2.5 中所述。

Which components matter? 从参考配置出发，我们消融了各个设计选择，同时保持 Engram 参数预算固定。结果由 Figure 4 中的标记点表示。我们发现三个组件带来了最显著的收益：(i) 多分支主干网络内的分支特定融合，(ii) 上下文感知门控，以及 (iii) 分词器压缩。移除其中任何一个都会导致验证损失出现最大的回归。具体来说，对于“无多分支”消融，我们保留了 mHC 主干结构，但将分支特定门控替换为应用于预映射 $\mathcal{H}^{\text{pre}}$ (Xie et al., 2025) 后隐藏状态的单一 Engram 融合。其他改动的影响较小：移除轻量级深度卷积只会轻微降低性能。在固定的 16 亿参数预算下，将容量分配给 4-gram 略有不足——可能是因为它稀释了来自更频繁的 2/3-gram 模式的容量——尽管我们不排除更高阶的 N -gram 在更大的内存规模下会变得有益。

5.3. Sensitivity Analysis

为了表征记忆印迹模块的功能贡献，我们在推理过程中完全抑制稀疏嵌入输出，同时保持骨干网络不变，以此来评估模型。至关重要的是，这种事后消融会引发 **training-inference inconsistency**，可能在复杂的混合能力任务中引入噪声。因此，我们优先分析 *Factual Knowledge* 和 *Reading Comprehension*——这两个位于敏感性谱两端的极端情况——在此压力测试下表现出最高的信噪比。

如Figure 5所示，结果揭示了一种鲜明的功能二分法。事实性知识基准测试遭受了灾难性的

崩溃，仅保留了原始性能的 29–44%（例如，TriviaQA 为 29%），这证实了记忆印迹模块是参数化知识的主要存储库。相反，阅读理解任务表现出显著的韧性，保留了 81–93%（例如，C3 为 93%），这表明基于上下文的任务主要依赖于骨干网络的注意力机制，而非记忆印迹。

5.4. System Efficiency

Engram 相对于基于路由的 MoE 的一个关键系统优势在于，其稀疏激活是通过显式、静态的哈希 ID 进行寻址的。这产生了一种严格确定性的内存访问模式：一旦已知令牌序列，下一次 Engram 查找的索引就是固定的，并且可以在相应层执行之前计算出来。

Experimental Setup. 我们基于 nano-vLLM¹——一个行业标准 vLLM 引擎的简化原型 (Kwon et al., 2023)——实现了一个推理测试框架。为了获得一个不受 MoE 中专家并行通信模式干扰的纯净延迟基线，我们在两个稠密骨干网络（Dense-4B 和 Dense-8B）上进行基准测试。我们在第二个 Transformer 块中插入了一个庞大的 100B 参数 Engram 层，整个嵌入表驻留在主机 DRAM 中。在推理过程中，系统异步预取 Engram 层的嵌入，使 PCIe 传输与第一个块的计算重叠。

Table 4 | **End-to-end Inference Throughput.** 我们测量了将一个 100B 参数的 Engram 层完全卸载到主机内存时的推理吞吐量。

Experimental Setup		
Hardware	NVIDIA H800	
Workload	512 Sequences	
Sequence Length	Uniform(100,1024)	
Throughput Results		
Base Model	Configuration	Throughput (tok/s)
4B-Dense	Baseline	9,031.62
	+ 100B Engram (CPU Offload)	8,858.28
8B-Dense	Baseline	6,315.52
	+ 100B Engram (CPU Offload)	6,140.02

343

Results. 如表 4 中详述，卸载一个 100B 参数的嵌入表带来的吞吐量惩罚可以忽略不计，在 8B 骨干网络上峰值仅为 2.8%。这证实了早期稠密块的计算强度提供了一个足够的时间窗口来掩盖检索延迟。至关重要的是，每一步的有效通信量随激活槽的数量缩放，而不是随整个嵌入表的大小缩放。

¹<https://github.com/GeeekExplorer/nano-vllm>




Figure 6 | **Visualization of the gating mechanism of Engram.** 热图强度对应于门控标量 $\alpha_t \in [0,1]$ 的大小，其中更深的红色表示更强的激活。因为 Engram 作用于后缀 N -gram（此处为 $N = 3$ ），在特定标记 x_t 上的高激活意味着，以该标记为结尾的前置标记（例如，在 t 处结束的短语）被识别为从记忆中有效检索到的静态模式。

至关重要的是，这个实验提供了一个保守的基线。虽然节 2.5 中的分层设计利用 Zipfian 局部性将频繁项缓存在 HBM 中，但我们的实验设置强制所有 *all* 检索都必须通过 PCIe 总线从主机内存获取。这种基线检索策略产生极小的开销这一事实，强烈表明一个完全优化的、具备局部性感知能力的实现将带来可忽略的吞吐量惩罚。

5.5. Case Study: Gating Visualization

在节 2.3 中，我们介绍了上下文感知的门控机制，旨在动态调节从主干网络检索到的静态记忆的整合。为了通过实证验证 Engram 是否按预期运行，我们可视化了 Engram-27B² 在不同样本中的门控标量 α_t （见 Figure 6）。

结果展示了一种明显的选择性模式。该门控机制在完成局部的、静态的模式时持续激活（以红色显示）。在英语中，我们观察到在多标记命名实体（例如，“Alexander the Great”、“the Milky Way”）和公式化短语（例如，“By the way”、“Princess of Wales”）上有强烈的激活。这种行为在不同语言中都能有效泛化。在中文示例中，Engram 识别并检索了独特的习语表达和历史实体，例如“四大发明”（四大发明）和“张仲景”（张仲景）。这些定性结果证实，Engram 成功地识别并处理了刻板化的语言依赖关系，有效地减轻了 Transformer 主干网络记忆这些静态关联的负担。

6. Related Work

N -gram Modeling and Embedding Scaling. 源于香农的框架 (Shannon, 1948)， N -元模型依赖局部历史来预测词元，传统上采用平滑技术 (Katz, 1987; Kneser and Ney, 1995) 来缓解数据稀疏性问题。尽管范式已转向神经架构 (Bengio et al., 2003) 以捕捉长程依赖关系，但 N -元查找的计算效率在现代表示学习中得以保留，例如 FastText (Bojanowski et al., 2017) 等开创性工

²正如我们的架构设置中所详述，该模型使用了一个 mHC ($M = 4$)，并在第 2 层和第 15 层插入了 Engram 模块。因此，对于任何给定的标记，模型会计算总共 8 个不同的门控标量。我们观察到并非每个分支都编码可解释的激活模式。为了本可视化的清晰性，我们选择并展示了与语义模式匹配最强烈相关的门控值。

作所示。

最近,这一范式以 *embedding scaling* 的形式重新兴起。虽然诸如 Per-Layer Embeddings (Team, 2025) 和 DeepEmbed (RWKV Team, 2025) 等架构通过庞大的表格扩展了容量,但另一条开创性的研究路线——与我们的方法最相关——将组合式的 N -元结构直接整合到表示空间中。SuperBPE (Liu et al., 2025) 和 SCONE (Yu et al., 2025) 明确针对高频模式:前者通过将多词表达式合并为“超词”词元,后者则通过辅助编码模型实现。与此同时,OverEncoding (Huang et al., 2025a) 和字节潜在变换器 (BLT) (Pagnoni et al., 2025) 分别采用哈希 N -元嵌入来捕捉词元级和字节级的局部依赖关系。这些研究共同证明了通过 N -元表示扩展参数的有效性,且计算开销极小。虽然这些方法在各自的情境下带来了显著收益,但我们的工作两个关键维度上存在根本性差异。

- 首先,关于建模和评估协议。先前的方法通常将 N -元嵌入视为外部增强,而未在严格公平的比较协议下验证其效率。例如,SCONE (Yu et al., 2025) 侧重于推理,并依赖会产生额外训练 FLOPs 的辅助模块。类似地,即使在非等参数设置下,OverEncoding (Huang et al., 2025a) 在稀疏 MoE 骨干网络上也无法产生有意义的改进。相比之下,我们将条件记忆视为通过精心设计的 Engram 模块实例化的一等建模原语。通过在 *Sparsity Allocation* 框架内严格评估此设计,我们证明了其相对于严格等参数和等 FLOPs 的 MoE 基线的明显优势。
- 其次,从系统视角出发,我们倡导算法-系统协同设计。现有方法将嵌入严格置于输入层(第 0 层),这本质上串行化了内存访问和计算 (Huang et al., 2025a; Yu et al., 2025)。相反,Engram 策略性地将内存注入到更深层,以实现通信与计算的重叠。此外,通过利用 N -元固有的齐夫分布特性,我们可以最大化硬件内存层次结构的效用。这种整体设计使得 Engram 能够扩展到海量参数,同时推理开销可忽略不计。

Mixture-of-Experts. MoE 架构通过为每个 token 有条件地激活一个稀疏的专家子集,将模型容量与计算成本解耦,这一范式由 Shazeer et al. (2017) 引入。后续的创新,如 GShard (Lepikhin et al., 2020)、BASE (Lewis et al., 2021)、Switch Transformer (Fedus et al., 2022) 和 GLaM (Du et al., 2022),实现了超线性的参数扩展,同时保持了恒定的推理成本。最近,DeepSeek-MoE (Dai et al., 2024) 展示了卓越的效率,通过细粒度的专家分割和共享专家隔离,在同等激活参数下显著优于稠密模型。采用这种架构,最先进的模型如 DeepSeek-V3 (Liu et al., 2024a) 和 Kimi-k2 (Team et al., 2025) 进一步将总参数量推至数千亿规模。

Memory Network. 关于记忆增强网络的研究旨在扩展模型容量而不成比例地增加计算成本,大致可分为参数化和非参数化方法。参数化记忆方法,如 PKM (Lample et al., 2019)、PEER (He, 2024)、Selfmem (Cheng et al., 2023b)、Memory+ (Berges et al., 2025) 和 UltraMem (Huang et al., 2025b,c),将大规模、稀疏的键值存储直接集成到模型层中,从而显著增加容量,而对 FLOPs 的影响微乎其微。相反,非参数化记忆方法如 REALM (Guu et al., 2020)、RETRO (Borgeaud et al., 2022; Wang et al., 2023) 和 PlugLM (Cheng et al., 2023a),将知识存储与模型处理解耦,

将外部存储器视为一个可编辑和可扩展的键值存储，使模型能够适应不断变化的信息而无需重新训练。

Mechanisms of Knowledge Storage. 与容量扩展并行，大量研究审视了 Transformer 编码和检索事实知识的内在机制。前馈网络被广泛假设为起到键值记忆的作用 (Geva et al., 2021)。在此框架下，第一层充当模式检测器 (“键”)，而第二层将特定信息投影到残差流中 (“值”)。这种模块化通过识别负责存储不同事实的特定“知识神经元”得到证明 (Dai et al., 2022)。因果追踪方法提供了进一步的验证，该方法将事实回忆的信息流映射到特定的 FFN 层 (Meng et al., 2022)。这些见解催生了精确的模型编辑算法，如 ROME (Meng et al., 2022) 和 MEMIT (Meng et al., 2023)，它们允许直接更新事实关联而无需重新训练。此外，对内部表示的研究，例如在 Othello-GPT (Li et al., 2023a) 中的研究，表明这些存储机制可能促进了结构化“世界模型”的出现，而不仅仅是统计记忆。

7. Conclusion

在这项工作中，我们引入 **conditional memory** 作为主流条件计算范式 (MoE) 的补充稀疏轴，旨在解决通过动态计算模拟知识检索的低效问题。我们通过 Engram 这一模块实例化了这一概念，该模块将经典的 N -gram 嵌入现代化，以实现针对静态模式的可扩展、恒定时间 $O(1)$ 查找。

通过形式化 *Sparsity Allocation* 问题，我们发现了一种 U 形缩放定律，表明在 MoE 专家和 Engram 记忆之间进行稀疏容量的混合分配，其性能严格优于纯 MoE 基线。在此定律的指导下，我们将 Engram 扩展到 270 亿参数，在多个领域实现了卓越的性能。值得注意的是，虽然记忆模块直观上有助于知识检索，但我们在通用推理、代码和数学方面观察到了更大的收益。

我们的机制分析表明，Engram 通过将早期层从静态重建任务中解放出来，有效地“加深”了网络，从而释放了注意力容量以专注于全局上下文和复杂推理。这种架构转变转化为长上下文能力的显著提升，这在 LongPPL 和 RULER 的性能增益中得到了证明。最后，Engram 倡导将基础设施感知的效率作为首要设计原则。其确定性寻址允许存储与计算的解耦，使得海量参数表可以卸载到主机内存中，而推理开销可忽略不计。我们设想条件记忆功能将成为下一代稀疏模型不可或缺的建模原语。

References

- J. Austin, A. Odena, M. Nye, M. Bosma, H. Michalewski, D. Dohan, E. Jiang, C. Cai, M. Terry, Q. Le, et al. Program synthesis with large language models. [arXiv preprint arXiv:2108.07732](https://arxiv.org/abs/2108.07732), 2021.
- D. Bahdanau, K. Cho, and Y. Bengio. Neural machine translation by jointly learning to align and translate. In Y. Bengio and Y. LeCun, editors, *3rd International Conference on*

Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings, 2015. URL <http://arxiv.org/abs/1409.0473>.

N. Belrose, Z. Furman, L. Smith, D. Halawi, I. Ostrovsky, L. McKinney, S. Biderman, and J. Steinhardt. Eliciting latent predictions from transformers with the tuned lens. arXiv preprint arXiv:2303.08112, 2023.

Y. Bengio, R. Ducharme, P. Vincent, and C. Janvin. A neural probabilistic language model. J. Mach. Learn. Res., 3:1137–1155, 2003. URL <https://jmlr.org/papers/v3/bengio03a.html>.

Y. Bengio, N. Léonard, and A. Courville. Estimating or propagating gradients through stochastic neurons for conditional computation, 2013. URL <https://arxiv.org/abs/1308.3432>.

V. Berges, B. Oguz, D. Haziza, W. Yih, L. Zettlemoyer, and G. Ghosh. Memory layers at scale. In Forty-second International Conference on Machine Learning, ICML 2025, Vancouver, BC, Canada, July 13-19, 2025. OpenReview.net, 2025. URL <https://openreview.net/forum?id=ATqGm1WyDj>.

X. Bi, D. Chen, G. Chen, S. Chen, D. Dai, C. Deng, H. Ding, K. Dong, Q. Du, Z. Fu, et al. Deepseek llm: Scaling open-source language models with longtermism. arXiv preprint arXiv:2401.02954, 2024.

Y. Bisk, R. Zellers, J. Gao, Y. Choi, et al. Piqa: Reasoning about physical commonsense in natural language. In Proceedings of the AAAI conference on artificial intelligence, volume 34, pages 7432–7439, 2020.

P. Bojanowski, E. Grave, A. Joulin, and T. Mikolov. Enriching word vectors with subword information. Transactions of the association for computational linguistics, 5:135–146, 2017.

S. Borgeaud, A. Mensch, J. Hoffmann, T. Cai, E. Rutherford, K. Millican, G. B. Van Den Driessche, J.-B. Lespiau, B. Damoc, A. Clark, et al. Improving language models by retrieving from trillions of tokens. In International conference on machine learning, pages 2206–2240. PMLR, 2022.

T. Brants, A. C. Popat, P. Xu, F. J. Och, and J. Dean. Large language models in machine translation. In J. Eisner, editor, Proceedings of the 2007 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning (EMNLP-CoNLL), pages 858–867, Prague, Czech Republic, June 2007. Association for Computational Linguistics. URL <https://aclanthology.org/D07-1090/>.

Y. R. Chao and G. K. Zipf. Human behavior and the principle of least effort: An introduction to human ecology. Language, 26:394, 1950. URL <https://api.semanticscholar.org/CorpusID:10182796>.

- M. Chen, J. Tworek, H. Jun, Q. Yuan, H. P. de Oliveira Pinto, J. Kaplan, H. Edwards, Y. Burda, N. Joseph, G. Brockman, A. Ray, R. Puri, G. Krueger, M. Petrov, H. Khlaaf, G. Sastry, P. Mishkin, B. Chan, S. Gray, N. Ryder, M. Pavlov, A. Power, L. Kaiser, M. Bavarian, C. Winter, P. Tillet, F. P. Such, D. Cummings, M. Plappert, F. Chantzis, E. Barnes, A. Herbert-Voss, W. H. Guss, A. Nichol, A. Paino, N. Tezak, J. Tang, I. Babuschkin, S. Balaji, S. Jain, W. Saunders, C. Hesse, A. N. Carr, J. Leike, J. Achiam, V. Misra, E. Morikawa, A. Radford, M. Knight, M. Brundage, M. Murati, K. Mayer, P. Welinder, B. McGrew, D. Amodei, S. McCandlish, I. Sutskever, and W. Zaremba. Evaluating large language models trained on code, 2021. URL <https://arxiv.org/abs/2107.03374>.
- X. Cheng, Y. Lin, X. Chen, D. Zhao, and R. Yan. Decouple knowledge from parameters for plug-and-play language modeling. In A. Rogers, J. Boyd-Graber, and N. Okazaki, editors, *Findings of the Association for Computational Linguistics: ACL 2023*, pages 14288–14308, Toronto, Canada, July 2023a. Association for Computational Linguistics. doi: 10.18653/v1/2023.findings-acl.901. URL <https://aclanthology.org/2023.findings-acl.901/>.
- X. Cheng, D. Luo, X. Chen, L. Liu, D. Zhao, and R. Yan. Lift yourself up: Retrieval-augmented text generation with self-memory. *Advances in Neural Information Processing Systems*, 36: 43780–43799, 2023b.
- P. Clark, I. Cowhey, O. Etzioni, T. Khot, A. Sabharwal, C. Schoenick, and O. Tafjord. Think you have solved question answering? try arc, the ai2 reasoning challenge. *arXiv preprint arXiv:1803.05457*, 2018.
- K. Cobbe, V. Kosaraju, M. Bavarian, M. Chen, H. Jun, L. Kaiser, M. Plappert, J. Tworek, J. Hilton, R. Nakano, et al. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*, 2021.
- G. Comanici, E. Bieber, M. Schaeckermann, I. Pasupat, N. Sachdeva, I. Dhillon, M. Blistein, O. Ram, D. Zhang, E. Rosen, et al. Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities. *arXiv preprint arXiv:2507.06261*, 2025.
- M. Constant, G. Eryigit, J. Monti, L. Van Der Plas, C. Ramisch, M. Rosner, and A. Todirascu. Survey: multiword expression processing: a survey. *Computational Linguistics*, 43(4):837–892, 2017.
- R. Csordás, C. D. Manning, and C. Potts. Do language models use their depth efficiently? *arXiv preprint arXiv:2505.13898*, 2025.
- D. Dai, L. Dong, Y. Hao, Z. Sui, B. Chang, and F. Wei. Knowledge neurons in pretrained transformers. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 8493–8502, 2022.

- 503 D. Dai, C. Deng, C. Zhao, R. Xu, H. Gao, D. Chen, J. Li, W. Zeng, X. Yu, Y. Wu, et al.
 504 Deepseekmoe: Towards ultimate expert specialization in mixture-of-experts language models.
 505 arXiv preprint arXiv:2401.06066, 2024.
- 506 M. Davari, S. Horoi, A. Natick, G. Lajoie, G. Wolf, and E. Belilovsky. Reliability of CKA as a
 507 similarity measure in deep learning. In The Eleventh International Conference on Learning
 508 Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023. OpenReview.net, 2023. URL
 509 <https://openreview.net/forum?id=8HRvyxc606>.
- 510 DeepSeek-AI, A. Liu, B. Feng, B. Wang, B. Wang, B. Liu, C. Zhao, C. Dengr, C. Ruan, D. Dai,
 511 D. Guo, D. Yang, D. Chen, D. Ji, E. Li, F. Lin, F. Luo, G. Hao, G. Chen, G. Li, H. Zhang,
 512 H. Xu, H. Yang, H. Zhang, H. Ding, H. Xin, H. Gao, H. Li, H. Qu, J. L. Cai, J. Liang,
 513 J. Guo, J. Ni, J. Li, J. Chen, J. Yuan, J. Qiu, J. Song, K. Dong, K. Gao, K. Guan, L. Wang,
 514 L. Zhang, L. Xu, L. Xia, L. Zhao, L. Zhang, M. Li, M. Wang, M. Zhang, M. Zhang, M. Tang,
 515 M. Li, N. Tian, P. Huang, P. Wang, P. Zhang, Q. Zhu, Q. Chen, Q. Du, R. J. Chen, R. L.
 516 Jin, R. Ge, R. Pan, R. Xu, R. Chen, S. S. Li, S. Lu, S. Zhou, S. Chen, S. Wu, S. Ye, S. Ma,
 517 S. Wang, S. Zhou, S. Yu, S. Zhou, S. Zheng, T. Wang, T. Pei, T. Yuan, T. Sun, W. L. Xiao,
 518 W. Zeng, W. An, W. Liu, W. Liang, W. Gao, W. Zhang, X. Q. Li, X. Jin, X. Wang, X. Bi,
 519 X. Liu, X. Wang, X. Shen, X. Chen, X. Chen, X. Nie, X. Sun, X. Wang, X. Liu, X. Xie, X. Yu,
 520 X. Song, X. Zhou, X. Yang, X. Lu, X. Su, Y. Wu, Y. K. Li, Y. X. Wei, Y. X. Zhu, Y. Xu,
 521 Y. Huang, Y. Li, Y. Zhao, Y. Sun, Y. Li, Y. Wang, Y. Zheng, Y. Zhang, Y. Xiong, Y. Zhao,
 522 Y. He, Y. Tang, Y. Piao, Y. Dong, Y. Tan, Y. Liu, Y. Wang, Y. Guo, Y. Zhu, Y. Wang,
 523 Y. Zou, Y. Zha, Y. Ma, Y. Yan, Y. You, Y. Liu, Z. Z. Ren, Z. Ren, Z. Sha, Z. Fu, Z. Huang,
 524 Z. Zhang, Z. Xie, Z. Hao, Z. Shao, Z. Wen, Z. Xu, Z. Zhang, Z. Li, Z. Wang, Z. Gu, Z. Li, and
 525 Z. Xie. Deepseek-v2: A strong, economical, and efficient mixture-of-experts language model,
 526 2024. URL <https://arxiv.org/abs/2405.04434>.
- 527 M. Dehghani, J. Djolonga, B. Mustafa, P. Padlewski, J. Heek, J. Gilmer, A. P. Steiner, M. Caron,
 528 R. Geirhos, I. Alabdulmohsin, R. Jenatton, L. Beyer, M. Tschannen, A. Arnab, X. Wang,
 529 C. Riquelme Ruiz, M. Minderer, J. Puigcerver, U. Evci, M. Kumar, S. V. Steenkiste, G. F.
 530 Elsayed, A. Mahendran, F. Yu, A. Oliver, F. Huot, J. Bastings, M. Collier, A. A. Gritsenko,
 531 V. Birodkar, C. N. Vasconcelos, Y. Tay, T. Mensink, A. Kolesnikov, F. Pavetic, D. Tran,
 532 T. Kipf, M. Lucic, X. Zhai, D. Keysers, J. J. Harmsen, and N. Houlsby. Scaling vision trans-
 533 formers to 22 billion parameters. In A. Krause, E. Brunskill, K. Cho, B. Engelhardt, S. Sabato,
 534 and J. Scarlett, editors, Proceedings of the 40th International Conference on Machine Learning,
 535 volume 202 of Proceedings of Machine Learning Research, pages 7480–7512. PMLR, 23–29
 536 Jul 2023. URL <https://proceedings.mlr.press/v202/dehghani23a.html>.
- 537 N. Ding, G. Xu, Y. Chen, X. Wang, X. Han, P. Xie, H. Zheng, and Z. Liu. Few-nerd: A
 538 few-shot named entity recognition dataset. In Proceedings of the 59th Annual Meeting of

the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers), pages 3198–3213, 2021.

N. Du, Y. Huang, A. M. Dai, S. Tong, D. Lepikhin, Y. Xu, M. Krikun, Y. Zhou, A. W. Yu, O. Firat, et al. Glam: Efficient scaling of language models with mixture-of-experts. In International conference on machine learning, pages 5547–5569. PMLR, 2022.

D. Dua, Y. Wang, P. Dasigi, G. Stanovsky, S. Singh, and M. Gardner. DROP: A reading comprehension benchmark requiring discrete reasoning over paragraphs. In J. Burstein, C. Doran, and T. Solorio, editors, Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2019, Minneapolis, MN, USA, June 2-7, 2019, Volume 1 (Long and Short Papers), pages 2368–2378. Association for Computational Linguistics, 2019. doi: 10.18653/V1/N19-1246. URL <https://doi.org/10.18653/v1/n19-1246>.

S. Elfving, E. Uchibe, and K. Doya. Sigmoid-weighted linear units for neural network function approximation in reinforcement learning. Neural networks, 107:3–11, 2018.

B. Erman. The idiom principle and the open choice principle. Text-Interdisciplinary Journal for the Study of Discourse, 2000.

L. Fang, Y. Wang, Z. Liu, C. Zhang, S. Jegelka, J. Gao, B. Ding, and Y. Wang. What is wrong with perplexity for long-context language modeling? In The Thirteenth International Conference on Learning Representations.

W. Fedus, B. Zoph, and N. Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. Journal of Machine Learning Research, 23(120):1–39, 2022.

L. Gao, S. Biderman, S. Black, L. Golding, T. Hoppe, C. Foster, J. Phang, H. He, A. Thite, N. Nabeshima, et al. The pile: An 800gb dataset of diverse text for language modeling. arXiv preprint arXiv:2101.00027, 2020.

T. Gao, A. Wettig, H. Yen, and D. Chen. How to train long-context language models (effectively). In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pages 7376–7399, 2025.

A. P. Gema, J. O. J. Leang, G. Hong, A. Devoto, A. C. M. Mancino, R. Saxena, X. He, Y. Zhao, X. Du, M. R. G. Madani, et al. Are we done with mmlu? In Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers), pages 5069–5096, 2025.

M. Geva, R. Schuster, J. Berant, and O. Levy. Transformer feed-forward layers are key-value memories. In Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, pages 5484–5495, 2021.

- A. Ghandeharioun, A. Caciularu, A. Pearce, L. Dixon, and M. Geva. Patchscopes: A unifying framework for inspecting hidden representations of language models. In International Conference on Machine Learning, pages 15466–15490. PMLR, 2024.
- A. Gretton, O. Bousquet, A. Smola, and B. Schölkopf. Measuring statistical dependence with hilbert-schmidt norms. In International conference on algorithmic learning theory, pages 63–77. Springer, 2005.
- A. Gu, K. Goel, and C. Ré. Efficiently modeling long sequences with structured state spaces. In The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25-29, 2022. OpenReview.net, 2022. URL <https://openreview.net/forum?id=uYLFoz1v1AC>.
- A. Gu, B. Rozière, H. J. Leather, A. Solar-Lezama, G. Synnaeve, and S. Wang. Cruxeval: A benchmark for code reasoning, understanding and execution. In Forty-first International Conference on Machine Learning, ICML 2024, Vienna, Austria, July 21-27, 2024. OpenReview.net, 2024. URL <https://openreview.net/forum?id=Ffpg52swvg>.
- D. Guo, D. Yang, H. Zhang, J. Song, R. Zhang, R. Xu, Q. Zhu, S. Ma, P. Wang, X. Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. arXiv preprint arXiv:2501.12948, 2025.
- K. Guu, K. Lee, Z. Tung, P. Pasupat, and M. Chang. Retrieval augmented language model pre-training. In International conference on machine learning, pages 3929–3938. PMLR, 2020.
- J. Haber and M. Poesio. Polysemy—Evidence from linguistics, behavioral science, and contextualized language models. Computational Linguistics, 50(1):351–417, Mar. 2024. doi: 10.1162/coli_a_00500. URL <https://aclanthology.org/2024.cl-1.10/>.
- K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 770–778, 2016.
- X. O. He. Mixture of a million experts. arXiv preprint arXiv:2407.04153, 2024.
- D. Hendrycks, C. Burns, S. Basart, A. Zou, M. Mazeika, D. Song, and J. Steinhardt. Measuring massive multitask language understanding. In 9th International Conference on Learning Representations, ICLR 2021, Virtual Event, Austria, May 3-7, 2021. OpenReview.net, 2021a. URL <https://openreview.net/forum?id=d7KBjmI3GmQ>.
- D. Hendrycks, C. Burns, S. Kadavath, A. Arora, S. Basart, E. Tang, D. Song, and J. Steinhardt. Measuring mathematical problem solving with the MATH dataset. In J. Vanschoren and S. Yeung, editors, Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks 1, NeurIPS Datasets and Benchmarks 2021, December 2021, virtual, 2021b.

URL <https://datasets-benchmarks-proceedings.neurips.cc/paper/2021/hash/be83ab3ecd0db773eb2dc1b0a17836a1-Abstract-round2.html>.

C.-P. Hsieh, S. Sun, S. Krman, S. Acharya, D. Rekesh, F. Jia, and B. Ginsburg. Ruler: What’s the real context size of your long-context language models? In First Conference on Language Modeling.

H. Huang, D. Zhu, B. Wu, Y. Zeng, Y. Wang, Q. Min, and X. Zhou. Over-tokenized transformer: Vocabulary is generally worth scaling. In Forty-second International Conference on Machine Learning, ICML 2025, Vancouver, BC, Canada, July 13-19, 2025. OpenReview.net, 2025a. URL <https://openreview.net/forum?id=gbeZKej40m>.

Y. Huang, Y. Bai, Z. Zhu, J. Zhang, J. Zhang, T. Su, J. Liu, C. Lv, Y. Zhang, Y. Fu, et al. C-eval: A multi-level multi-discipline chinese evaluation suite for foundation models. Advances in Neural Information Processing Systems, 36:62991–63010, 2023.

Z. Huang, Y. Bao, Q. Min, S. Chen, R. Guo, H. Huang, D. Zhu, Y. Zeng, B. Wu, X. Zhou, et al. Ultramemv2: Memory networks scaling to 120b parameters with superior long-context learning. arXiv preprint arXiv:2508.18756, 2025b.

Z. Huang, Q. Min, H. Huang, Y. Zeng, D. Zhu, R. Guo, and X. Zhou. Ultra-sparse memory network. In The Thirteenth International Conference on Learning Representations, ICLR 2025, Singapore, April 24-28, 2025. OpenReview.net, 2025c. URL <https://openreview.net/forum?id=zjeHLSiNv1>.

M. Jin, Q. Yu, J. Huang, Q. Zeng, Z. Wang, W. Hua, H. Zhao, K. Mei, Y. Meng, K. Ding, F. Yang, M. Du, and Y. Zhang. Exploring concept depth: How large language models acquire knowledge and concept at different layers? In O. Rambow, L. Wanner, M. Apidianaki, H. Al-Khalifa, B. D. Eugenio, and S. Schockaert, editors, Proceedings of the 31st International Conference on Computational Linguistics, COLING 2025, Abu Dhabi, UAE, January 19-24, 2025, pages 558–573. Association for Computational Linguistics, 2025. URL <https://aclanthology.org/2025.coling-main.37/>.

K. Jordan, Y. Jin, V. Boza, J. You, F. Cesista, L. Newhouse, and J. Bernstein. Muon: An optimizer for hidden layers in neural networks, 2024. URL <https://kellerjordan.github.io/posts/muon/>.

M. Joshi, E. Choi, D. S. Weld, and L. Zettlemoyer. Triviaqa: A large scale distantly supervised challenge dataset for reading comprehension. In R. Barzilay and M. Kan, editors, Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, ACL 2017, Vancouver, Canada, July 30 - August 4, Volume 1: Long Papers, pages 1601–1611. Association for Computational Linguistics, 2017. doi: 10.18653/V1/P17-1147. URL <https://doi.org/10.18653/v1/P17-1147>.

- S. M. Katz. Estimation of probabilities from sparse data for the language model component of a speech recognizer. *IEEE Trans. Acoust. Speech Signal Process.*, 35(3):400–401, 1987. doi: 10.1109/TASSP.1987.1165125. URL <https://doi.org/10.1109/TASSP.1987.1165125>.
- D. P. Kingma. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- R. Kneser and H. Ney. Improved backing-off for m-gram language modeling. In *1995 international conference on acoustics, speech, and signal processing*, volume 1, pages 181–184. IEEE, 1995.
- S. Kornblith, M. Norouzi, H. Lee, and G. Hinton. Similarity of neural network representations revisited. In *International conference on machine learning*, pages 3519–3529. PMIR, 2019.
- N. Kriegeskorte, M. Mur, and P. A. Bandettini. Representational similarity analysis-connecting the branches of systems neuroscience. *Frontiers in systems neuroscience*, 2:249, 2008.
- T. Kudo and J. Richardson. Sentencepiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. In E. Blanco and W. Lu, editors, *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, EMNLP 2018: System Demonstrations, Brussels, Belgium, October 31 - November 4, 2018*, pages 66–71. Association for Computational Linguistics, 2018. doi: 10.18653/V1/D18-2012. URL <https://doi.org/10.18653/v1/d18-2012>.
- S. Kullback and R. A. Leibler. On information and sufficiency. *The annals of mathematical statistics*, 22(1):79–86, 1951.
- W. Kwon, Z. Li, S. Zhuang, Y. Sheng, L. Zheng, C. H. Yu, J. Gonzalez, H. Zhang, and I. Stoica. Efficient memory management for large language model serving with pagedattention. In *Proceedings of the 29th symposium on operating systems principles*, pages 611–626, 2023.
- G. Lai, Q. Xie, H. Liu, Y. Yang, and E. H. Hovy. RACE: large-scale reading comprehension dataset from examinations. In M. Palmer, R. Hwa, and S. Riedel, editors, *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, EMNLP 2017, Copenhagen, Denmark, September 9-11, 2017*, pages 785–794. Association for Computational Linguistics, 2017. doi: 10.18653/V1/D17-1082. URL <https://doi.org/10.18653/v1/d17-1082>.
- G. Lample, A. Sablayrolles, M. Ranzato, L. Denoyer, and H. Jégou. Large memory layers with product keys. *Advances in Neural Information Processing Systems*, 32, 2019.
- G. Larsson, M. Maire, and G. Shakhnarovich. Fractalnet: Ultra-deep neural networks without residuals. In *5th International Conference on Learning Representations, ICLR 2017, Toulon*,

France, April 24-26, 2017, Conference Track Proceedings. OpenReview.net, 2017. URL <https://openreview.net/forum?id=S1VaB4cex>.

P. Lennie. The cost of cortical computation. *Current biology*, 13(6):493–497, 2003.

D. Lepikhin, H. Lee, Y. Xu, D. Chen, O. Firat, Y. Huang, M. Krikun, N. Shazeer, and Z. Chen. Gshard: Scaling giant models with conditional computation and automatic sharding. *arXiv preprint arXiv:2006.16668*, 2020.

M. Lewis, S. Bhosale, T. Dettmers, N. Goyal, and L. Zettlemoyer. Base layers: Simplifying training of large, sparse models. In M. Meila and T. Zhang, editors, *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *Proceedings of Machine Learning Research*, pages 6265–6274. PMLR, 18–24 Jul 2021. URL <https://proceedings.mlr.press/v139/lewis21a.html>.

H. Li, Y. Zhang, F. Koto, Y. Yang, H. Zhao, Y. Gong, N. Duan, and T. Baldwin. Cmmlu: Measuring massive multitask language understanding in chinese. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 11260–11285, 2024.

K. Li, A. K. Hopkins, D. Bau, F. B. Viégas, H. Pfister, and M. Wattenberg. Emergent world representations: Exploring a sequence model trained on a synthetic task. In *The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023*. OpenReview.net, 2023a. URL https://openreview.net/forum?id=DeG07_TcZvT.

M. Li and N. Subramani. Echoes of bert: Do modern language models rediscover the classical nlp pipeline?, 2025. URL <https://arxiv.org/abs/2506.02132>.

R. Li, L. B. Allal, Y. Zi, N. Muennighoff, D. Kocetkov, C. Mou, M. Marone, C. Akiki, J. Li, J. Chim, Q. Liu, E. Zheltonozhskii, T. Y. Zhuo, T. Wang, O. Dehaene, M. Davaadorj, J. Lamy-Poirier, J. Monteiro, O. Shliazhko, N. Gontier, N. Meade, A. Zebaze, M. Yee, L. K. Umaphathi, J. Zhu, B. Lipkin, M. Oblokulov, Z. Wang, R. M. V, J. T. Stillerman, S. S. Patel, D. Abulkhanov, M. Zocca, M. Dey, Z. Zhang, N. Fahmy, U. Bhattacharyya, W. Yu, S. Singh, S. Luccioni, P. Villegas, M. Kunakov, F. Zhdanov, M. Romero, T. Lee, N. Timor, J. Ding, C. Schlesinger, H. Schoelkopf, J. Ebert, T. Dao, M. Mishra, A. Gu, J. Robinson, C. J. Anderson, B. Dolan-Gavitt, D. Contractor, S. Reddy, D. Fried, D. Bahdanau, Y. Jernite, C. M. Ferrandis, S. Hughes, T. Wolf, A. Guha, L. von Werra, and H. de Vries. Starcoder: may the source be with you! *Trans. Mach. Learn. Res.*, 2023, 2023b. URL <https://openreview.net/forum?id=KoF0g41haE>.

W. Li, F. Qi, M. Sun, X. Yi, and J. Zhang. Ccpm: A chinese classical poetry matching dataset. *arXiv preprint arXiv:2106.01979*, 2021.

707 A. Liu, B. Feng, B. Xue, B. Wang, B. Wu, C. Lu, C. Zhao, C. Deng, C. Zhang, C. Ruan, et al.
708 Deepseek-v3 technical report. arXiv preprint arXiv:2412.19437, 2024a.

709 A. Liu, J. Hayase, V. Hofmann, S. Oh, N. A. Smith, and Y. Choi. SuperBPE: Space travel
710 for language models. In Second Conference on Language Modeling, 2025. URL <https://openreview.net/forum?id=lcDRvffeNP>.
711

712 J. Liu, S. Min, L. Zettlemoyer, Y. Choi, and H. Hajishirzi. Infini-gram: Scaling unbounded n-
713 gram language models to a trillion tokens. In First Conference on Language Modeling, 2024b.
714 URL <https://openreview.net/forum?id=u2vAyMeLMm>.

715 A. Mallen, A. Asai, V. Zhong, R. Das, D. Khashabi, and H. Hajishirzi. When not to trust
716 language models: Investigating effectiveness of parametric and non-parametric memories. In
717 Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics
718 (Volume 1: Long Papers), pages 9802–9822, 2023.

719 K. Meng, D. Bau, A. Andonian, and Y. Belinkov. Locating and editing factual associations in
720 gpt. Advances in neural information processing systems, 35:17359–17372, 2022.

721 K. Meng, A. S. Sharma, A. J. Andonian, Y. Belinkov, and D. Bau. Mass-editing memory in a
722 transformer. In The Eleventh International Conference on Learning Representations, ICLR
723 2023, Kigali, Rwanda, May 1-5, 2023. OpenReview.net, 2023. URL <https://openreview.net/forum?id=MkbcAHlYgyS>.
724

725 T. Nguyen. Understanding transformers via n-gram statistics. Advances in neural information
726 processing systems, 37:98049–98082, 2024.

727 nostalgebraist. interpreting gpt: the logit lens. LessWrong, 2020. URL <https://www.lesswrong.com/posts/AcKRB8wDpdaN6v6ru/interpreting-gpt-the-logit-lens>.
728

729 B. A. Olshausen and D. J. Field. Sparse coding with an overcomplete basis set: A strategy
730 employed by v1? Vision research, 37(23):3311–3325, 1997.

731 A. Pagnoni, R. Pasunuru, P. Rodriguez, J. Nguyen, B. Muller, M. Li, C. Zhou, L. Yu, J. E.
732 Weston, L. Zettlemoyer, et al. Byte latent transformer: Patches scale better than tokens. In
733 Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics
734 (Volume 1: Long Papers), pages 9238–9258, 2025.

735 B. Peng, E. Alcaide, Q. Anthony, A. Albalak, S. Arcadinho, S. Biderman, H. Cao, X. Cheng,
736 M. Chung, L. Derczynski, X. Du, M. Grella, K. K. GV, X. He, H. Hou, P. Kazienko, J. Kocon,
737 J. Kong, B. Koptyra, H. Lau, J. Lin, K. S. I. Mantri, F. Mom, A. Saito, G. Song, X. Tang,
738 J. S. Wind, S. Wozniak, Z. Zhang, Q. Zhou, J. Zhu, and R. Zhu. RWKV: reinventing rnns for
739 the transformer era. In H. Bouamor, J. Pino, and K. Bali, editors, Findings of the Association

for Computational Linguistics: EMNLP 2023, Singapore, December 6-10, 2023, pages 14048–14077. Association for Computational Linguistics, 2023. doi: 10.18653/V1/2023.FINDINGS-S-EMNLP.936. URL <https://doi.org/10.18653/v1/2023.findings-emnlp.936>.

B. Peng, J. Quesnelle, H. Fan, and E. Shippole. Yarn: Efficient context window extension of large language models. In The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024. OpenReview.net, 2024. URL <https://openreview.net/forum?id=wHBfxhZulu>.

S. T. Piantadosi. Zipf’s word frequency law in natural language: A critical review and future directions. Psychonomic bulletin & review, 21(5):1112–1130, 2014.

O. Press, N. A. Smith, and M. Lewis. Train short, test long: Attention with linear biases enables input length extrapolation. In The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25-29, 2022. OpenReview.net, 2022. URL <https://openreview.net/forum?id=R8sQPpGCv0>.

RWKV Team. Rwkv architecture history. <https://wiki.rwkv.com/basic/architecture.html>, 2025. Section “RWKV-V8’s DeepEmbed”, accessed 2025-12-09.

K. Sakaguchi, R. L. Bras, C. Bhagavatula, and Y. Choi. Winogrande: An adversarial winograd schema challenge at scale. Communications of the ACM, 64(9):99–106, 2021.

C. E. Shannon. A mathematical theory of communication. The Bell system technical journal, 27(3):379–423, 1948.

N. Shazeer, A. Mirhoseini, K. Maziarz, A. Davis, Q. Le, G. Hinton, and J. Dean. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. arXiv preprint arXiv:1701.06538, 2017.

F. Shi, M. Suzgun, M. Freitag, X. Wang, S. Srivats, S. Vosoughi, H. W. Chung, Y. Tay, S. Ruder, D. Zhou, D. Das, and J. Wei. Language models are multilingual chain-of-thought reasoners. In The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023. OpenReview.net, 2023. URL <https://openreview.net/forum?id=fR3wGCk-IXp>.

J. Su, M. H. M. Ahmed, Y. Lu, S. Pan, W. Bo, and Y. Liu. Roformer: Enhanced transformer with rotary position embedding. Neurocomputing, 568:127063, 2024. doi: 10.1016/J.NEUCOM.2023.127063. URL <https://doi.org/10.1016/j.neucom.2023.127063>.

K. Sun, D. Yu, D. Yu, and C. Cardie. Investigating prior knowledge for challenging chinese machine reading comprehension. Transactions of the Association for Computational Linguistics, 8:141–155, 2020.

- M. Suzgun, N. Scales, N. Schärli, S. Gehrmann, Y. Tay, H. W. Chung, A. Chowdhery, Q. Le, E. Chi, D. Zhou, et al. Challenging big-bench tasks and whether chain-of-thought can solve them. In Findings of the Association for Computational Linguistics: ACL 2023, pages 13003–13051, 2023.
- C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich. Going deeper with convolutions. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 1–9, 2015.
- G. Team. Gemma 3n. 2025. URL <https://ai.google.dev/gemma/docs/gemma-3n>.
- K. Team, Y. Zhang, Z. Lin, X. Yao, J. Hu, F. Meng, C. Liu, X. Men, S. Yang, Z. Li, et al. Kimi linear: An expressive, efficient attention architecture. arXiv preprint arXiv:2510.26692, 2025.
- I. Tenney, D. Das, and E. Pavlick. Bert rediscovers the classical nlp pipeline. In Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2019.
- D. Tito Svenstrup, J. Hansen, and O. Winther. Hash embeddings for efficient word representations. Advances in neural information processing systems, 30, 2017.
- A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. Advances in neural information processing systems, 30, 2017.
- B. Wang, W. Ping, P. Xu, L. McAfee, Z. Liu, M. Shoeybi, Y. Dong, O. Kuchaiev, B. Li, C. Xiao, et al. Shall we pretrain autoregressive language models with retrieval? a comprehensive study. In Proceedings of the 2023 conference on empirical methods in natural language processing, pages 7763–7786, 2023.
- L. Wang, H. Gao, C. Zhao, X. Sun, and D. Dai. Auxiliary-loss-free load balancing strategy for mixture-of-experts, 2024a. URL <https://arxiv.org/abs/2408.15664>.
- Y. Wang, X. Ma, G. Zhang, Y. Ni, A. Chandra, S. Guo, W. Ren, A. Arulraj, X. He, Z. Jiang, et al. Mmlu-pro: A more robust and challenging multi-task language understanding benchmark. Advances in Neural Information Processing Systems, 37:95266–95290, 2024b.
- K. Whistler. Unicode standard annex #15: Unicode normalization forms. Unicode Standard Annex 15, The Unicode Consortium, July 2025. URL <https://www.unicode.org/reports/tr15/tr15-57.html>. Version Unicode 17.0.0, Revision 57. Accessed 2026-01-04.
- G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis. Efficient streaming language models with attention sinks. In The Twelfth International Conference on Learning Representations, ICLR

2024, Vienna, Austria, May 7-11, 2024. OpenReview.net, 2024. URL <https://openreview.net/forum?id=NG7sS51zVF>.

Z. Xie, Y. Wei, H. Cao, C. Zhao, C. Deng, J. Li, D. Dai, H. Gao, J. Chang, L. Zhao, S. Zhou, Z. Xu, Z. Zhang, W. Zeng, S. Hu, Y. Wang, J. Yuan, L. Wang, and W. Liang. mhc: Manifold-constrained hyper-connections, 2025. URL <https://arxiv.org/abs/2512.24880>.

S. Yang, Y. Shen, K. Wen, S. Tan, M. Mishra, L. Ren, R. Panda, and Y. Kim. Path attention: Position encoding via accumulating householder transformations. arXiv preprint arXiv:2505.16381, 2025.

D. Yu, E. Cohen, B. Ghazi, Y. Huang, P. Kamath, R. Kumar, D. Liu, and C. Zhang. Scaling embedding layers in language models. arXiv preprint arXiv:2502.01637, 2025.

R. Zellers, A. Holtzman, Y. Bisk, A. Farhadi, and Y. Choi. Hellaswag: Can a machine really finish your sentence? In A. Korhonen, D. R. Traum, and L. Màrquez, editors, Proceedings of the 57th Conference of the Association for Computational Linguistics, ACL 2019, Florence, Italy, July 28- August 2, 2019, Volume 1: Long Papers, pages 4791–4800. Association for Computational Linguistics, 2019. doi: 10.18653/V1/P19-1472. URL <https://doi.org/10.18653/v1/p19-1472>.

B. Zhang and R. Sennrich. Root mean square layer normalization. Advances in neural information processing systems, 32, 2019.

W. Zhong, R. Cui, Y. Guo, Y. Liang, S. Lu, Y. Wang, A. Saied, W. Chen, and N. Duan. Agieval: A human-centric benchmark for evaluating foundation models. In Findings of the Association for Computational Linguistics: NAACL 2024, pages 2299–2314, 2024.

D. Zhu, H. Huang, Z. Huang, Y. Zeng, Y. Mao, B. Wu, Q. Min, and X. Zhou. Hyper-connections. In The Thirteenth International Conference on Learning Representations, ICLR 2025, Singapore, April 24-28, 2025. OpenReview.net, 2025. URL <https://openreview.net/forum?id=9FqARW7dwB>.

Appendices

A. Detailed Model Architecture and Hyper Parameters

B. Full Benchmark Curves




Figure 7 | 最后 10k 步预训练基准曲线。

	Dense-4B	MoE-27B	Engram-27B	Engram-40B
Total Params	4.1B	26.7B	26.7B	39.5B
Active Params			3.8B	
Total Tokens			262B	
Layers			30	
Dimension			2560	
Leading Dense Layers	-	1	1	1
Routed Experts	-	72	55	55
Active Experts	-	6	6	6
Shared Experts	-	2	2	2
Load Balancing Method	-	Loss Free (Wang et al., 2024a)		
Attention module		MLA (DeepSeek-AI et al., 2024)		
RoPE θ			10000	
mHC Expansion Rate			4	
Sequence Length			4096	
Vocab Size			129280	
Batch Size			1280	
Training Steps			50000	
Backbone Optimizer		Muon (Jordan et al., 2024)		
Embedding Optimizer		Adam (Kingma, 2014)		
Base Learning Rate			4e-4	
Lr Scheduler		Step Decay (Bi et al., 2024)		
Weight Decay			0.1	
Engram Dim d_{mem}	-	-	1280	1280
Engram Vocab Size	-	-	2262400	7239680
Engram Num Head	-	-	8	8
Engram Layer	-	-	[2,15]	[2,15]
Engram N -gram	-	-	[2,3]	[2,3]
Engram combine mHC	-	-	True	True
Engram tokenizer compression	-	-	True	True
Engram Conv Zero Init	-	-	True	True
Engram Lr Multiplier	-	-	x5	x5
Engram Weight Decay	-	-	0.0	0.0
Engram Optimizer (Embed. only)	-	-	Adam (Kingma, 2014)	

Table 5 | Detailed model architecture information and training hyper parameters.

C. Case Study of Tokenizer Compression

Rank	Merge Count	Normalized Token	Original Tokens
1	163	' <code>\t</code> '	' <code>\t</code> ', ' <code>\n</code> ', ' <code>\r</code> ', ' <code>\t</code> ', ' <code>\t\t</code> ', ' <code>\n\n</code> ', ' <code>\t\t\t</code> ', ' <code>\t\n</code> ', ...
2	54	' <code>a</code> '	' <code>A</code> ', ' <code>a</code> ', ' <code>\ta</code> ', ' <code>\tA</code> ', ' <code>á</code> ', ' <code>ä</code> ', ' <code>ã</code> ', ' <code>ą</code> ', ' <code>\tą</code> ', ' <code>\tă</code> ', ' <code>\tâ</code> ', ...
3	40	' <code>o</code> '	' <code>0</code> ', ' <code>o</code> ', ' <code>\to</code> ', ' <code>\t0</code> ', ' <code>ó</code> ', ' <code>ö</code> ', ' <code>ô</code> ', ' <code>õ</code> ', ' <code>ố</code> ', ' <code>ò</code> ', ...